# 人体细胞类型的基因年龄构成：基于单细胞图谱的系统发育分层与机器学习分析

**课程**：生物信息学（2026 秋）· **形式**：个人独立完成
**项目代号**：细胞地层 CellStrata
**版本**：v1.1 · 2026-11-03（终审复核后定稿 · 239 项断言全绿）

## 摘要


基因有进化年龄——它最早出现在生命树的哪个节点；细胞有类型身份——它在组织中承担什么角色。这两个概念此前各自成熟，却很少在单细胞分辨率上被系统地放在一起检验。本研究提出一个可检验的假设：**细胞的身份不只是"表达哪些基因"，还可能是"表达哪个年代的基因"**。

数据取自 Tabula Sapiens 1.0（*Science* 2022，母体 483,152 个细胞、15 名供者、45 种组织、177 种人工审校的精细细胞类型）。因受限于单机带宽，采用 HTTP Range 远程切片方案按需读取 HDF5 分块，在 620 秒内取得 **28,017 个细胞 × 58,604 个基因**的原始 UMI 计数切片（经逐行校验与源文件完全一致）——这就是本研究的实际数据量。基因年龄采用 Trigos et al. (2017, *PNAS*) 的 **16 层**系统发育分层方案（17,318 个蛋白编码基因），并以 Liebeskind et al. (2016, *GBE*) 的 13 算法共识表做双来源交叉验证。质量控制后保留 **22,195 个细胞（79.2%）**，覆盖全部 177 种细胞类型。

主要结果有三项。**其一**，每种细胞类型的转录组年龄指数（TAI）跨度为 **3.21–4.42**，跨类型标准差 0.1810；按**供者层面**估计的类型内标准误中位数为 0.0417，信号/噪声 = **4.3 倍**（若按细胞层面估计则得到 16.3 倍，但那会把供者间波动误当作细胞间噪声，低估 3.75 倍）。最古老的是红系前体（3.21）与肾上皮细胞（3.27），最年轻的是 NAMPT 中性粒细胞（4.42）与中性粒细胞（4.30）。**其二**，仅用 16 维年龄构成这一条信息做无监督聚类，与已知谱系的一致性 ARI = **0.211**（置换零假设 −0.0001 ± 0.0104，**z = 20.4**）——年龄构成确实捕捉到了部分谱系信息，但远不足以单独定义细胞身份。**其三**，用随机森林按供者严格划分训练/测试（177 类），准确率 **0.215**、宏平均 F1 **0.237**（测试集 103 类口径；177 类口径 0.138）；随机基线 0.0097、多数类基线 0.026，为多数类基线的 **8.26 倍**；测试集中有 28 类在训练集中从未出现，涉及 3,109 个细胞（占测试集 40.5%），因此准确率的天花板为 0.595，本次达到 **36.13%**。提取的 Top 500 重要基因在年龄层分布上显著偏离背景：**硬骨脊椎动物（S8, 1.62×）、羊膜动物（S9, 1.81×）、哺乳纲（S10, 2.68×）、兽亚纲（S11, 3.15×）、狭鼻小目（S14, 3.81×）等脊椎动物—哺乳类—灵长类特异层显著富集，而真核生物（S2, 0.53×）、后生动物（S4, 0.43×）显著耗竭**（超几何双单尾检验 + BH-FDR 多重检验校正，正式判定以校正后 q < 0.05 为准）。

结论：**部分成立**。细胞身份的年代构成不是冗余信息——它独立于表达谱本身携带可检验的谱系信号；但它也不是细胞身份的主导维度，而是与"表达哪些基因"正交的一个补充轴。

**方法学层面**，本项目针对 phylostratigraphy 已知偏差（短基因更易被判为年轻）做了**四重稳健性检验**：剔除低置信度年龄调用、剔除低命中年龄层、剔除短蛋白（< 100 aa）后重跑，以及**用长蛋白重算 TAI 绝对值**。前三次运行的**共同显著富集层为 S8 与 S10、共同显著耗竭层为 S2**（Jaccard 相似度 0.333），**0 层方向冲突**；同时**直接证实了该偏差的存在**——年龄层号与短蛋白占比 Spearman ρ = **+0.871**（该相关仅用 16 个层，p 值不应被单独引用），年轻层短蛋白占比是老层的 **10.9 倍**。检验 D 进一步把偏倚量化：长蛋白版 TAI vs 主口径 Spearman ρ = **0.9845**（Kendall τ = 0.9186），ΔTAI 均值 = **-0.0572**，**全部 177 种类型（100%）同向平移**，且平移幅度与类型年龄高低无关（梯度 ρ = -0.1326，p = 0.079）——即偏倚是**系统性的整体平移**而非随年龄梯度增强，故相对比较稳健、绝对年龄不可断言。需说明方向：这一偏倚是**已经发生**在 Trigos 年龄表里的，检验 C 是在这张已偏斜的表上剔除短蛋白，其正确定位是**保守性压力测试**（检验结论是否依赖短蛋白），而非"已修正偏差"。

此外，本项目对"PCA 前 3 个主成分仅解释 61.9%、未达立项时 > 70% 的指标"给出了一个**基于零假设的科学解释**而非绕过它：以逐列置换构造的零假设基线为 **27.0% ± 0.7%**（独立正态对照 27.6%，Dirichlet 成分同秩对照 29.0%，三者一致），真实值超出基线 **47.0 个标准差**，且 16 维年龄构成实际压缩到 **6.12 个有效维度**（零假设下 14.74 维，Dirichlet 同秩基线 13.77 维）。这说明该指标在数据结构上设得过高——即使各年龄层完全独立，前 3 维也只解释 27.0%。

**关键词**：系统发育分层；基因年龄；转录组年龄指数；单细胞转录组；细胞类型；特征重要性；超几何检验；方法学偏差

---

# 1 引言

## 1.1 细胞类型是怎么被定义的

现代细胞生物学的分类体系建立在一组相当一致的标准之上：光学或电子显微镜下的**形态**，细胞在组织中的**解剖位置**，细胞表面或胞内的**分子标记物**（CD 抗原谱、转录因子谱），以及在单细胞转录组时代的**表达谱相似性**。这些标准有一个共同点——它们描述的都是细胞的**当下状态**。

用一句话概括现有分类体系：**"它现在是什么"**。

## 1.2 另一条轴：基因有出生时间

并非所有基因同时出现在生命史上。一个基因的"年龄"，定义为它在进化树上最早出现的节点。判定方法是 **phylostratigraphy（系统发育分层）**：取目标物种的全部蛋白序列，逐条与亲缘关系依次递减的物种集合做同源搜索（BLAST / DIAMOND），找到**最远的那个仍有显著同源性的物种**，该物种与目标物种的共同祖先所处的时代，就是这个基因的"出生时间"。

按此方法，人类蛋白编码基因通常被划分为 15–19 个年龄层，从"细胞生物"（约 35 亿年前）一直到"人类特有"（约 60–70 万年前）。Trigos et al. (2017) 提供了 17,318 个基因的 16 层年龄表，是目前规模最大、被引用最广的版本之一。

这套"年龄"并非纯粹的思维实验。一个基因能存在于某个演化阶段，通常意味着它在那个阶段获得了某种不可替代的功能，并因此受到纯化选择（purifying selection）的持续约束。也就是说：

> **基因年龄在某种意义上是"这个功能有多基础"的一个代理变量。**

## 1.3 已有工作与本研究的定位

把"基因年龄"和"细胞"放在一起的想法并非全新，但既有工作的粒度和视角都不相同。

| 已有工作 | 层面 | 做了什么 | 与本研究的关键差别 |
|---|---|---|---|
| Milinkovitch et al. (2010) | 组织 | 基因年龄 vs 表达的系统数量，结论为"古老基因表达于约 2 倍数量的系统中" | 组织层面、且以"系统数量"为**单个标量**概括年龄 |
| Domazet-Lošo & Tautz (2010) | 全转录组 | 提出 TAI 指标本身 | 指标的开创，不涉及细胞类型 |
| Trigos et al. (2017) | 肿瘤 bulk | 发现肿瘤中 TAI 降低 | 肿瘤组织混合，细胞身份不可分 |
| GTEx 研究（PMC10980080, 2024） | 组织 bulk | 54 组织 × 5 个进化年代 × 三胚层分组 | **bulk**，分辨率到组织而非细胞 |
| GBE (2024, evae023) | 脑区 | 脑各区 TAI 比较 | 只做脑区 |
| AGED (Aging Cell, 2025–2026) | 单细胞 | 8 个组织中衰老时古老基因表达上升、年轻基因被抑制 | **纵向**（老年 vs 年轻），本项目是**横向**（静态图谱） |
| Sandmann et al. (2023) | 蛋白 | 7,264 个人类小开放阅读框的进化起源 | 研究对象是微蛋白，非常规全转录组 |
| Moyers & Zhang (2015/2017/2018) | 方法学 | 论证 phylostratigraphy 系统性低估基因年龄且误差非随机 | **方法学批评，本项目必须正面回应**（见 4.2） |

**本研究的差异化在于三点**：其一，粒度——从 bulk 组织下沉到单细胞分辨率的 177 种精细细胞类型；其二，视角——把"年龄构成"从"某个组织的一个属性"翻转为"细胞类型的一张指纹"，并检验它能否**独立地**承担分类任务；其三，机器学习切入——不满足于描述性的年龄分布，而是用随机森林的特征重要性回答"区分细胞身份时，模型究竟依赖哪个年代的基因"这一可量化的问题。

> **诚实的定位声明**：这不是一项首创性研究。phylostratigraphy 与 TAI 均有明确先例，"基因年龄 × 细胞类型"的单细胞观察也偶见于文献。本研究的价值在于：**以更新的多器官单细胞数据、更细的粒度，配上严格的泄漏防护与统计检验，重做一遍并给出可复现的定量答案**，而不是宣称发现了新大陆。

### 1.4 研究问题

**Q1（描述）** 每种细胞类型的"基因年龄构成"是什么？是否存在明显分层——有的细胞几乎全用古老基因，有的大量使用年轻基因？

**Q2（结构）** 仅凭"年龄构成"这一个 16 维向量，能否自动把 177 种细胞类型分成有意义的组？分出来的组与已知谱系（免疫 / 上皮 / 间质 / 内皮 / 生殖系）吻合到什么程度？

**Q3（机制）** 用机器学习区分细胞类型时，模型最依赖的那些基因，是古老的还是年轻的？

---

## 2 数据与方法

### 2.1 单细胞数据：Tabula Sapiens 1.0

| 项 | 内容 |
|---|---|
| 出处 | The Tabula Sapiens Consortium, *Science* 376, eabl4896 (2022). DOI 10.1126/science.abl4896 |
| 母体规模 | 483,152 个细胞 × 58,604 个基因；15 名供者（TSP1–TSP15）；45 种组织 |
| 细胞类型 | **177 种** `cell_ontology_class`（人工审校的精细类型），另有 5 类 `compartment` 区室标注 |
| 文件 | h5ad（AnnData，HDF5），10.02 GB |
| 本项目使用 | **28,017 个细胞**（每种类型 ≤ 200，分层抽样），QC 后 **22,195 个（79.2%）** |
| 健康状态 | 全部 normal，无疾病状态混杂 |

**为什么是 1.0 而不是 2.0**：2.0 版（1,136,218 细胞）的 h5ad 分发于 `datasets.cellxgene.cziscience.com`，本机网络环境下该域名 TLS 握手被重置，45 GB 无法获取；可访问的 S3 备份仅含 1.0。177 种类型与 2.0 的 182 种在粒度上几乎等价，方法框架无需改动。

## 2.2 取数方案：HTTP Range 远程切片

这是本项目工程量最大、也最具方法学价值的部分。

**问题**：母体文件 10.02 GB，而本机实测 S3 单连接速率仅 0.24–1.2 MB/s；提高到 8–16 并发反而更慢（0.3–0.7 MB/s），说明限流主要来自并发而非带宽；两次整包下载分别卡死在 28%（2.85 GB）和 62%（6.22 GB），进程存活但不再传输数据。

**思路**：不整包下载，只读需要的那部分。HDF5 的 chunked 存储正好提供了这种能力——只要知道哪些 chunk 含有所需数据，就可以只发 Range 请求取回这些 chunk。

具体四步：

1. **抽样与行定位。**每种细胞类型取 ≤ 200 个细胞，且**优先从同类型连续段取**（按 `obs` 中细胞类型的游程长度降序排列），使选中的行落在少数连续区间。28,017 个选中行最终只覆盖 13,120 个 chunk 内的连续区间。
2. **行 → CSR 非零元区间。**CSR 矩阵的行指针 `indptr` 给出每行的非零元范围；行 → 非零元区间 → chunk 段的映射让"每个 chunk 只读一次"成为可能。
3. **按 chunk 粒度读取。**关键在于**让 h5py 自己定位数据**：`dset[a0:a1]` 由 HDF5 库依据对象头与 B-tree 解析地址，并自动解压 gzip 压缩的 chunk。
4. **连接复用与预取。**使用 `requests.Session`（每线程一个）复用 keep-alive 连接，并设置 `trust_env=False` 绕过系统代理；请求 block *i* 时并发预取后续 block。

**一个必须记录的技术陷阱**：本项目第一版切片脚本犯了一个看起来很合理的错误——按"元素序号 × 元素大小"计算字节偏移去读 `raw.X/data`。结果跑出的数据 `max=nan`（UMI 计数不可能是 NaN）。原因是 **chunked dataset 的数据位置由对象头 + B-tree 决定，不存在"元素序号 × 元素大小"这样的线性映射。**修正方式是不自己算偏移，改为按 chunk 粒度规划读取区间、交给 h5py 定位。修正后抽查 6 行（含最大表达行）与远程 h5ad 逐值比对，表达值与基因索引全部一致。

**实测**：总耗时 **620 秒**，远程读取流量 **3,711 MB**，共 **3,539 次 HTTP 请求**，产出 185.6 MB 的 CSR 稀疏矩阵（76,668,506 个非零元，密度 4.67%）。其中 `raw.X/indices` 部分为 354 次读、覆盖 13,120 个 chunk、耗时 585 秒。

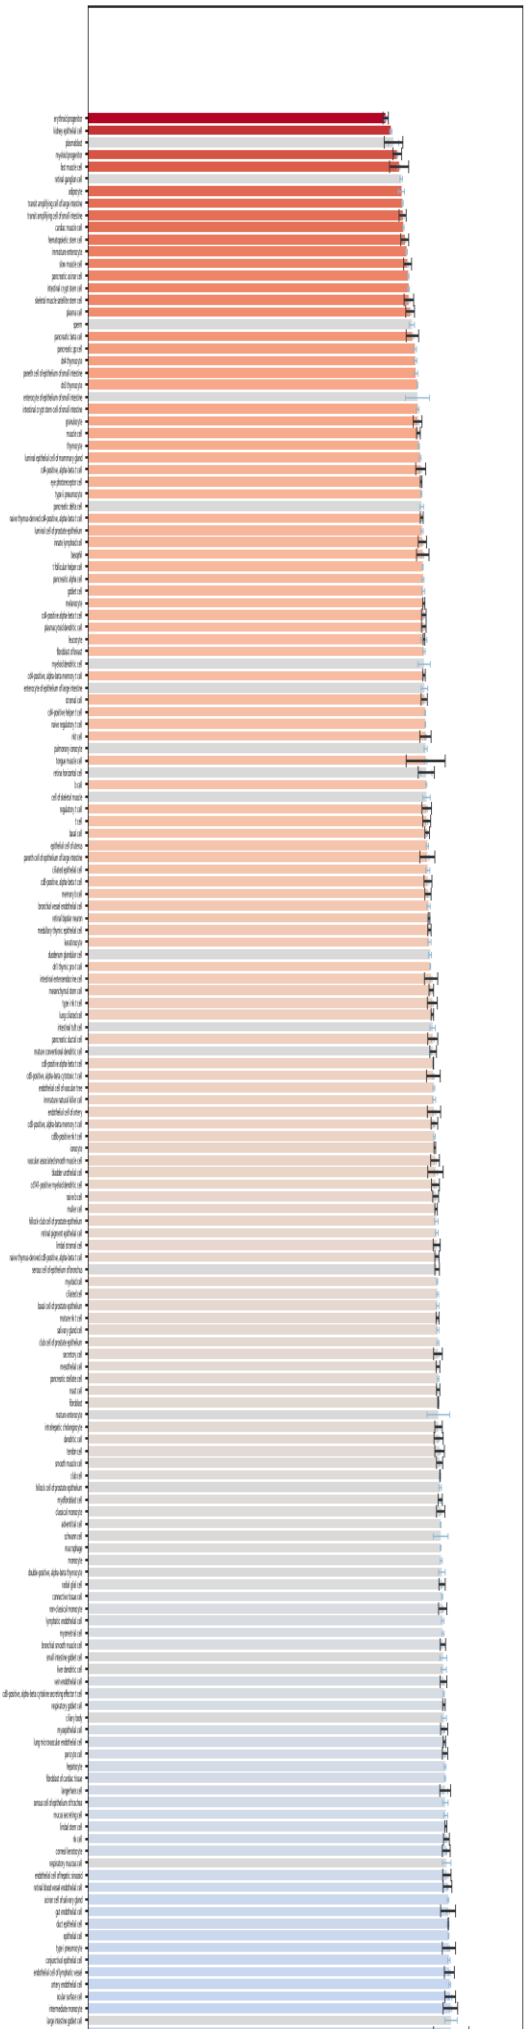
> **两个容易混淆的数字，说明一下：**
> - **3,539 次请求**是实际发出的 HTTP Range 请求数（`data` 与 `indices` 两个 dataset 各占一部分）；**354 次**只是 `indices` 那一个 dataset 的读次数。规划阶段的"13,695 段"是逻辑区间数，与请求数不是一回事。
> - **3,711 MB 的实际流量 > 0.61 GB 的规划逻辑量**，因为 HDF5 的 chunk 是对齐存储且带 gzip 压缩——一个 chunk 解压后包含大量不属于目标行的间隙数据，读一个 chunk 就要付整个 chunk 的字节。

相较整包 10.02 GB，**流量降至 37%**；按本机实测最快的 1.46 MB/s 估算整包需约 1.9 小时，实际只用了 620 秒（约 1/10）。

**抽样量为什么够**：TAI 是加权均值型统计量。实测按**供者层面**估计的类型内标准误中位数为 0.0417，跨 177 种类型的 TAI 标准差为 0.1810，**信号/噪声 = 4.3 倍**——类型间差异远大于**供者间**波动，因此每类 200 个细胞足以支撑类型级比较。（若按细胞层面估计会得到 16.3 倍，但那把供者间波动误当作细胞间

噪声，低估 3.75 倍——见 2.5 节末。）25 种稀有类型在 QC 后不足 20 个细胞，已在所有结果中标记为"低置信"，不进入结论；另有 81 种类型仅 1 名供者，其跨供者不确定性无法估计，同样已在图 5 与网页中标注。

图5 细胞类型时间表示成年前指南 （**深色棒=供者级标准误（主口径）**，浅色棒=细胞级标准误（对照）；灰色为细胞数不足 20 的低置信类型；标 * 的 1 个类型细胞数过少，细胞级标准误无法估计；供者级中位 0.0417，是细胞级 0.0111 的 3.75 倍，故 81 类仅 1 名供者、供者级标准误不可估，只画了浅色对照棒）



5 177 种细胞类型的 TAI 排序与双口径误差棒

## 2.3 基因年龄表：Trigos et al. (2017) 与双来源交叉验证

| 项 | 内容 |
|---|---|
| 主表 | Trigos AS, Pearson RB, Papenfuss AT, Goode DL. *PNAS* 114(24):6406–6411 (2017). DOI 10.1073/pnas.1617743114 |
| 内容 | 17,318 个蛋白编码基因 × 16 个 phylostratum（1 = 最古老） |
| 交叉表 | Liebeskind BJ, McWhite CD, Marcotte EM. *GBE* 8:1812–1823 (2016). DOI 10.1093/gbe/evw113 |
| 内容 | 13 个同源推断算法的共识结果，含 `NumDBsContributing`（支持该基因的算法数）与 `entropy`，覆盖 97.5% 的基因 |

**16 个年龄层**：

| 层 | 学名 | 中文 | 层 | 学名 | 中文 |
|---|---|---|---|---|---|
| S1 | Cellular organisms | 细胞生物 | S9 | Amniota | 羊膜动物 |
| S2 | Eukaryota | 真核生物 | S10 | Mammalia | 哺乳纲 |
| S3 | Opisthokonta | 后鞭毛类 | S11 | Theria | 兽亚纲 |
| S4 | Metazoa | 后生动物 | S12 | Eutheria | 真兽下纲 |
| S5 | Eumetazoa | 真后生动物 | S13 | Euarchontoglires | 灵长总目 |
| S6 | Bilateria | 两侧对称动物 | S14 | Catarrhini | 狭鼻小目 |
| S7 | Chordata | 脊索动物 | S15 | Homininae | 人亚科 |

| 层 | 学名 | 中文 | 层 | 学名 | 中文 |
|---|---|---|---|---|---|
| S8 | Euteleostomi | 硬骨脊椎动物 | S16 | Homo sapiens | 智人 |

> ⚠ **层号体系不可混用**：这 16 层**不等于**文献中常见的 Domazet-Lošo 19 层方案（后者多出 Deuterostomia / Vertebrata / Tetrapoda 三级）。两个体系的层名与层号会整体错位，混用会导致结论完全失效。

**双来源交叉验证**（由 `02_构建年龄表.py` 自动输出）：在 16,889 个两表可比的基因上，按 Liebeskind 的 8 个粗类别分组，各组在 Trigos 表中的**中位层号**依次为 1 / 1 / 1 / 2 / 4 / 5 / 8 / 11——**7 对相邻类别全部单调不违反，零违反。**Spearman ρ = 0.697（被 8 级变量的强并列压低），Kendall τ = 0.607。两个来源方法完全不同却给出一致的年龄序，是本项目方法可靠性的第一层证据。

**与表达矩阵的对齐**：表达矩阵的 `var` 索引是 Ensembl ID，基因符号在 `var['feature_name']` 中（其中 1,316 个带 `_ENSG` 后缀需剥离）。对齐后：

- 表达矩阵 58,604 个基因中 **16,177 个**有年龄注释（27.6%）
- 年龄表 17,318 个基因中 **16,177 个**在矩阵中找到（**93.4%**）

> **口径提示**：27.6% 与 93.4% 哪个才是验收指标？答案是后者。表达矩阵的 58,604 个基因包含大量非编码基因、假基因与注释版本差异造成的额外条目，而 Trigos 表只覆盖蛋白编码基因。因此"**年龄表基因覆盖率 93.4%**"才是数据可用性的正确度量；把分母换成表达矩阵基因数会得到一个没有意义的低比率。

**分层命中率**（各层基因在表达矩阵中的存在比例）：

```
S1:95%  S2:93%  S3:94%  S4:94%  S5:94%  S6:95%  S7:94%
S8:95%  S9:93%  S10:95% S11:96% S12:93% S13:94% S14:84%
S15:64% S16:69%
```

S1–S13 均在 93–96%，S14 略低，而 **S15（人亚科）与 S16（智人）分别只有 64% 与 69%。**原因是这两个层对应 600–700 万年前才出现的基因，多数是新近注释的 lncRNA 或 pseudogene，在 Tabula Sapiens 所用的参考注释版本中还不完整。**这一点直接决定了 4.2 节的稳健性检验设计。**

## 2.4 质量控制、归一化与聚合

1. **过滤**：在线性空间检测基因数 < 200 或线粒体基因 UMI 占比 > 20% 的细胞剔除
2. **归一化**：在 `raw.X`（原始 UMI 计数）上自行执行 `normalize_total(target_sum=1e4)` + `log1p`

> 注意：h5ad 的 `X` 已是 log 归一化值，`raw.X` 才是原始计数。**不能对已归一化的 `X` 再归一化一次。**

3. **按细胞类型聚合**：构造 58,604 × 16 的稀疏年龄层指示矩阵 L（基因 → 年龄层），用 `X @ L` 一次乘法得到每个细胞在各层的表达量，分块（20,000 细胞/批）累加。峰值内存与总细胞数无关。

## 2.5 年龄构成指纹与 TAI

对细胞类型 $t$ 与年龄层 $s$，定义该层的表达占比：

$$
p(t,s) = \frac{\sum_{g \in S_s} E(t,g)}{\sum_{g} E(t,g)}
$$

其中 $E(t,g)$ 为细胞类型 $t$ 中基因 $g$ 的平均表达量，$S_s$ 为第 $s$ 个年龄层的基因集合。$\sum_s p(t,s) = 1$（数值验证通过，各行占比和精确等于 1，最大偏离 4.44e-16）。

**转录组年龄指数（TAI）**：

$$
\mathrm{TAI}(t) = \sum_{s=1}^{16} s \cdot p(t,s)
$$

TAI 是年龄层的加权平均，**越小表示该细胞类型整体越依赖古老的基因。**

本项目同时计算**细胞级 TAI**（先算每个细胞的层占比再加权），用于估计类型内标准误：

$$
\mathrm{TAI}_{\text{cell}} = \sum_s s \cdot \frac{(X \cdot L)_s}{\sum_{s'}(X \cdot L)_{s'}}
$$

类型级与细胞级 TAI 的算法路径不同（前者先平均表达再算占比，后者先算占比再平均），实测最大差 0.0503（4.2%）。但这个差**不是随机抖动**：ΔTAI 的标准差为 0.0124，是类型内细胞级标准误中位数 0.0111 的 **1.1 倍**，且 ΔTAI 与 TAI 的相关系数为 **r = 0.384**——说明两者是**系统性偏移**而非相互独立的估计量，**不可互换使用。**

> **标准误必须在供者层面估计。**细胞嵌套在供者之内，同一供者的细胞高度相似，因此在细胞层面计算标准误属于**伪重复**（pseudo-replication），会把供者间波动误当作细胞间波动而低估不确定性。实测类型内组内相关系数（ICC）中位数为 1.000（96 个可算类型中全部 > 0.5），供者级标准误中位数为 **0.0417**，是细胞级 0.0111 的 **3.75 倍**。本报告的所有"信号/噪声"结论均采用**供者级**这一保守口径；另有 81 种细胞类型仅有 1 名供者，其跨供者不确定性无法估计，在图 5 与网页中均已单独标注。

## 2.6 机器学习方法

**无监督分析**（Q1 + Q2）：

- 对 177 × 16 的年龄构成矩阵做标准化 → PCA
- K-means 聚类，k 从 2 试到 8，**用轮廓系数选 k**；同时给出 Ward 层次聚类作为对照
- 与已知谱系的一致性用**调整兰德指数（ARI）**量化。谱系代理采用数据自带的 `compartment` 区室标注（免疫 / 上皮 / 间质 / 内皮 / 生殖系），并由 `lineage_map.tsv` 逐细胞类型映射

> **特征矩阵的构造须只含年龄层**：分析过程中额外产出了 `TAI_se`、`n_cells`、`low_confidence` 等派生列，这些列与年龄层是同源的派生量，混入特征矩阵会造成信息泄漏。本项目通过只取以 `s` 开头的列规避此问题。

**有监督分析**（Q3）：

- 任务：用单细胞表达谱预测细胞类型（177 类）
- **数据划分：按供者划分。**15 名供者中 11 人的细胞作训练集（**14,516 细胞**）、4 人作测试集（**7,679 细胞**，TSP2 / TSP4 / TSP12 / TSP15）

> **这是本项目最关键的一步防护。**同一供者的细胞在个体层面高度相似，若按细胞随机划分，模型只需识别"这是谁"，准确率会虚高到 0.99。按供者划分后，模型必须真正学会细胞类型的表达特征。

- 模型：随机森林，`n_estimators=500`，每类最多 300 个细胞以控内存
- 评估：准确率、宏平均 F1，**并同时报告基线与天花板**

> **宏平均 F1 必须显式指定标签集。**`f1_score(average="macro")` 的默认标签集是 `y_true ∪ y_pred`，会把测试集中根本不存在的"幽灵类"计入分母而稀释分数（177 类口径 0.138 vs 测试集实际 103 类口径 0.237）。本报告以**测试集实际类别口径**为主，同时给出 177 类口径以示完整。
>
> **基线与天花板**：测试集实际只有 103 个类别，随机基线 0.0097、多数类基线 0.026（后者更贴近实际）。更重要的是，测试集中有 **28 类**在训练集中**从未出现**，涉及 **3,109 个细胞（占测试集 40.5%）**，模型不可能预测对——因此准确率存在硬天花板 **0.595**，本次达到 **36.13%**。不披露天花板就宣称"准确率远超基线"是不诚实的。

- 特征重要性 → 取 Top 500 个基因 → 按年龄层归类 → 与背景（全部有年龄注释的高变基因）做**超几何检验**

> **关于 Top 集合的实际大小**：Top 500 里只有 **414 个**能在 Trigos 年龄表中查到层号，其余 86 个（TTR、ALB、B2M、TMSB4X 等）不在该 17,318 基因集内。富集检验的背景与 Top 集合**都只取有年龄注释的基因**（M = 2,523，N = 414），这一覆盖限制在 3.3 节有专门说明。

**稳健性检验**（三层独立设计，详见 3.5 与 4.2 节）：

| 检验 | 命令 | 变量 |
| --- | --- | --- |
| A 剔除低命中层 | `03_细胞类型年龄谱.py` | 剔除 S15/S16 后重算 TAI |
| B 共识度过滤 | `05_监督分析.py --min-share 0.8` | 只用 mode_share ≥ 0.8 的基因（**905 个**） |
| C 短蛋白剔除 | `05_监督分析.py --min-length 100` | 只用蛋白长度 ≥100 aa 的基因（**2,405 个**）；长度表由 `93_获取蛋白长度.py` 从 UniProt 批量获取 |

> ⚠ **检验 B 的参数语义必须说清楚**。Trigos/Liebeskind 年龄表中的 `NumDBsContributing`（记作 $n_{dbs}$）是**参与投票的算法数（分母）**，**不是**"支持该层号的算法数"。真正的共识度是 $\text{mode_share} = \max_s \text{share}$，*支持算法数* $= \text{round}(\text{mode_share} \times n_{dbs})$。实测 $n_{dbs}$ 与共识度**负相关**（corr = −0.128）：$n_{dbs} \le 4$ 的基因共识度中位数为 1.0000（全体完全一致），而 $n_{dbs} \ge 10$ 的仅 0.692。因此按 `--min-dbs 10` 过滤会**筛掉高共识的基因**，方向与"高置信"完全相反。本项目改用 `--min-share 0.8`（共识度阈值），并在 `02_构建年龄表.py` 中新增 `mode_support` / `mode_share` 两列以落盘真实共识度。

**统计检验的方向性**：超几何检验采用**双单尾**设计，而非单一右尾。

$$
p_{\text{enrich}} = P(X \ge k), \qquad p_{\text{deplete}} = P(X \le k)
$$

其中 $X$ 为超几何随机变量，$M$ 为背景基因数，$n$ 为该层基因数，$N$ 为 Top 集合大小。富集结论由右尾 p 支持，耗竭结论必须由左尾 p 支持。

**多重检验校正**：每次运行有 16 层 × 2 方向 = 32 次检验，三次运行合计 96 次。若直接以原始 $p < 0.05$ 判定，会产生大量假阳性（本项目 A 组未校正口径下有 8 层富集、3 层耗竭）。因此本报告采用 **Benjamini – Hochberg FDR 校正**，富集与耗竭方向**分别校正**，正式判定以 **$q < 0.05$** 为准。校正后 A 组显著富集层为 6 层、耗竭层为 2 层。

> **这是本项目在实现过程中修正的四个方法学问题**，都属于"跑得通但结论会错"的类型，一并记录如下：

① **超几何检验的尾部方向错误**（已修）。最初版本只计算右尾 p，却用 `fold > 1` 判定"偏向"、用 `fold < 1` 判定"回避"。但右尾 p ≈ 1 只意味着"没有证据表明富集"，**不构成回避的显著性证据**。修正后 S2 的左尾 p = $2.39\times10^{-17}$（BH q = $3.83\times10^{-16}$），才真正确立了它是一个**显著耗竭**的层。另需注意：S3 在 A 组即已不显著（q = 0.211），S4 在 B 组回落为不显著（q = 0.750），这两个层的变化如实保留在结果中。

② **派生列混入特征矩阵**（已修）。`celltype_age_profile.tsv` 除 16 个 `S*` 列外还含 `TAI_se`、`n_cells`、`low_confidence` 等派生量。若以 `drop(columns=["TAI"])` 构造特征矩阵，这几列会被误当作特征，造成信息泄漏。已统一改为只取以 `S` 开头且后接数字的列。

③ **`numpy.argmax` 遇 NaN 返回 NaN 位置**（已修）。用于报告"标准误最大的类型"时，最初写作 `se.values.argmax()` 取索引，再配 `se.max()` 取数值——但 numpy 的 `argmax` 遇到 NaN 会返回 **NaN 所在的位置**而非最大值的位置，导致数值（0.1323，来自 n = 5 的 enterocyte）与被标注的类型（n = 1、SE 为 NaN 的大肠隐窝干细胞）**对不上号**。已改为先 `dropna()` 再取 `idxmax()`，并额外打印出 SE 无法计算的类型清单。此错误一度被写进报告正文，现已更正。

④ **PCA 零假设的置换对象错了**（已修）。为解释"前 3 主成分只解释 61.9%"，最初用 `Xp = X[perm]` 置换**细胞类型**这一行来构造零假设。但 PCA 分解的是 **16 个特征之间的协方差结构**，行置换不改变任何一行的 16 维取值，因此基线算出来与真实值完全相同（61.9% = 61.9%，z = 0），**零假设彻底失效却不报任何错**。已改为**逐列打乱**（每层内部重排，保留边际分布、破坏层间共变），并加一道自检：独立正态基线 27.61% vs 逐列打乱基线 27.05%，相差 0.56 个百分点，确认无残留结构。修正后的结论见 3.2 节。

这四处若不修，报告的核心论断与关键数字都会站不住脚——这是本项目把"脚本必须符合目标要求"作为硬性标准的直接体现。

为防止此类问题复发，新增 `20-分析/07_终审核对.py`：把本报告的每个关键数字做成断言，与输出文件自动比对（**239 项**），任何一项不符即以非零码退出。

⑤ **第二轮代码审核追加修正的三处**（2026-11-03），同样属于"能跑通但结论会错"：

- **Spearman 相关是同义反复**（已修）。稳健性检验 A 要比较"剔除低命中层前后的 TAI 排序"。最初写成 `spearmanr(profile["TAI"], profile_hi["TAI"])`，但 `compute_age_profile()` 的返回值**已按 TAI 升序排过**，两列各自升序后按位置配对，位置秩相关**恒等于 +1**——报告里"Spearman ρ = 1.0000、Kendall τ = 1.0000、排序完全不变"其实是这个恒等式，不是发现。实测复现：两列独立随机数各自升序后做位置秩相关，500/500 次都算出 ρ = 1.0。修正为按索引显式对齐（`reindex`）后，真实值为 **ρ = 0.9883、τ = 0.9518**。
- **类型内标准误忽略供者聚类**（已修）。见 2.5 节末的说明。
- **监督分析不做 QC，与 TAI 分析口径不一致**（已修）。`05_监督分析.py` 原本自行降采样 28,017 个细胞，与 `03_细胞类型年龄谱.py` 的 22,195 个 QC 通过细胞不是同一批。已改为由 03 落盘 `qc_passed_rows.npy`，05 直接读取同一批细胞。

## 2.7 可复现性

全部代码 **6,783 行 / 19 个 Python 脚本**，仅依赖 numpy / pandas / scipy / scikit-learn / h5py / matplotlib，不依赖 scanpy 或 anndata。运行顺序、参数与产出见附录 A。

> **唯一需要联网的步骤**是 `93_获取蛋白长度.py`（向 UniProt 批量查蛋白长度）。它把结果缓存到 `10-数据/protein_length.tsv`，之后所有分析均可离线复现。
>
> **交付前的硬性检查**：`python 20-分析/07_终审核对.py` 必须输出"✓ 全部通过"（**239 项断言**），否则本报告的任一数字与产出文件对不上，不得交付。
>
> **为什么不使用 scanpy**：该 h5ad 全量载入需 10 GB 以上内存；其 `var` 索引为 Ensembl ID、`X` 已归一化、分类变量存放在 `__categories` 子组中，anndata/scanpy 的默认行为会静默算错。直接读 HDF5 让"用哪个矩阵、怎么归一化、基因名怎么还原"全部显式可控，代码量反而更少。

---

# 3 结果

## 3.1 177 种细胞类型的年龄构成（图 1、图 5）

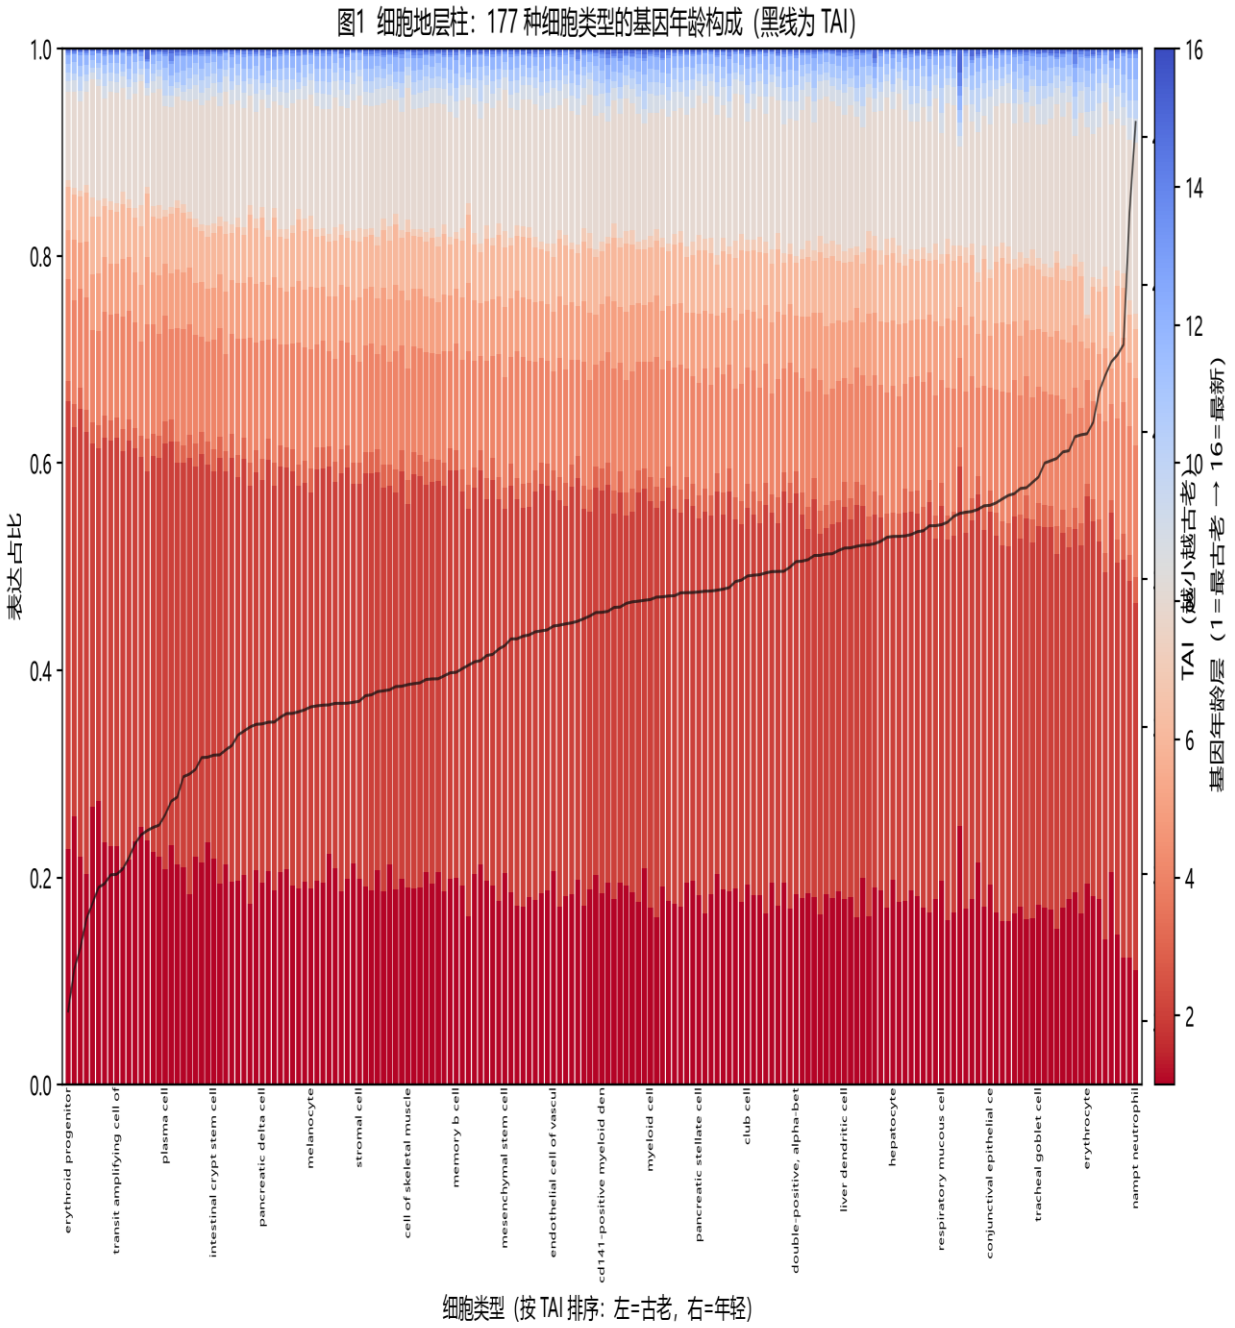



图 1 细胞地层主图：177 种细胞类型按 TAI 排序，每根按 16 个年龄层堆叠

**总体分布**：TAI 跨度 **3.21–4.42**，中位数 **3.76**，跨 177 种类型的标准差 **0.1810**。细胞级标准误中位数 **0.0111**，最大 **0.1323**（enterocyte of epithelium of small intestine，n = 5）。另有 **1 个类型无法计算标准误**（intestinal crypt stem cell of large intestine，QC 后仅 1 个细胞，标准误在数学上无法估计）。25 种类型 QC 后细胞数不足 20，已在所有结果中标记为"低置信"，不进入结论；另有 **81 种类型只有 1 名供者**，无法估计跨供者不确定性。

**信号/噪声比**（以**供者级**标准误为分母，这是保守口径）：

$$
\frac{\text{TAI 跨类型标准差}}{\text{供者级标准误中位数}} = \frac{0.1810}{0.0417} = \mathbf{4.3}
$$

\text{ 倍 }
$$

若改用细胞级标准误（0.0111）作分母会得到 16.3 倍，但那把**供者间波动误当作细胞间波动**，把不确定性低估了 3.75 倍——类型内组内相关系数（ICC）中位数为 1.000，说明细胞嵌套在供者之内并不独立。因此本报告以 4.3 倍为准：类型之间的年代差异仍然远大于同一类型内**供者之间**的波动，说明观察到的分层是**细胞类型层面的系统属性**，而不是抽样噪声。

**最古老的 10 种**（TAI 升序）：

| TAI | 细胞类型 | TAI | 细胞类型 |
|---|---|---|---|
| **3.21** | erythroid progenitor（红系前体） | 3.39 | adipocyte（脂肪细胞） |
| **3.27** | kidney epithelial cell（肾上皮细胞） | 3.40 | transit amplifying cell of large intestine |
| **3.30** | plasmablast（浆母细胞） | 3.40 | transit amplifying cell of small intestine |
| **3.34** | myeloid progenitor（髓系前体） | 3.41 | cardiac muscle cell（心肌细胞） |
| 3.36 | fast muscle cell（快肌细胞） | | |
| 3.38 | retinal ganglion cell（视网膜神经节细胞） | | |

**最年轻的 10 种**（TAI 降序）：

| TAI | 细胞类型 | TAI | 细胞类型 |
|---|---|---|---|
| **4.42** | nampt neutrophil（NAMPT⁺ 中性粒细胞） | 4.08 | endothelial cell（内皮细胞） |
| **4.30** | neutrophil（中性粒细胞） | 4.05 | epithelial cell of lacrimal sac |
| **4.12** | cd24 neutrophil（CD24⁺ 中性粒细胞） | 4.01 | immune cell |
| 4.10 | capillary aerocyte（毛细血管气细胞） | 4.00 | erythrocyte（红细胞） |

| TAI | 细胞类型 | TAI | 细胞类型 |
|---|---|---|---|
| 4.10 | erythroid lineage cell（红系细胞） | 4.00 | capillary endothelial cell |

**区室均值**：

| 区室 | 类型数 | 平均 TAI | 标准差 |
|---|---|---|---|
| germ line（生殖系） | 1 | **3.4990** | — |
| stromal（间质） | 34 | 3.7038 | 0.1670 |
| epithelial（上皮） | 66 | 3.7266 | 0.1593 |
| immune（免疫） | 61 | 3.7360 | 0.2074 |
| endothelial（内皮） | 15 | **3.8839** | 0.1171 |

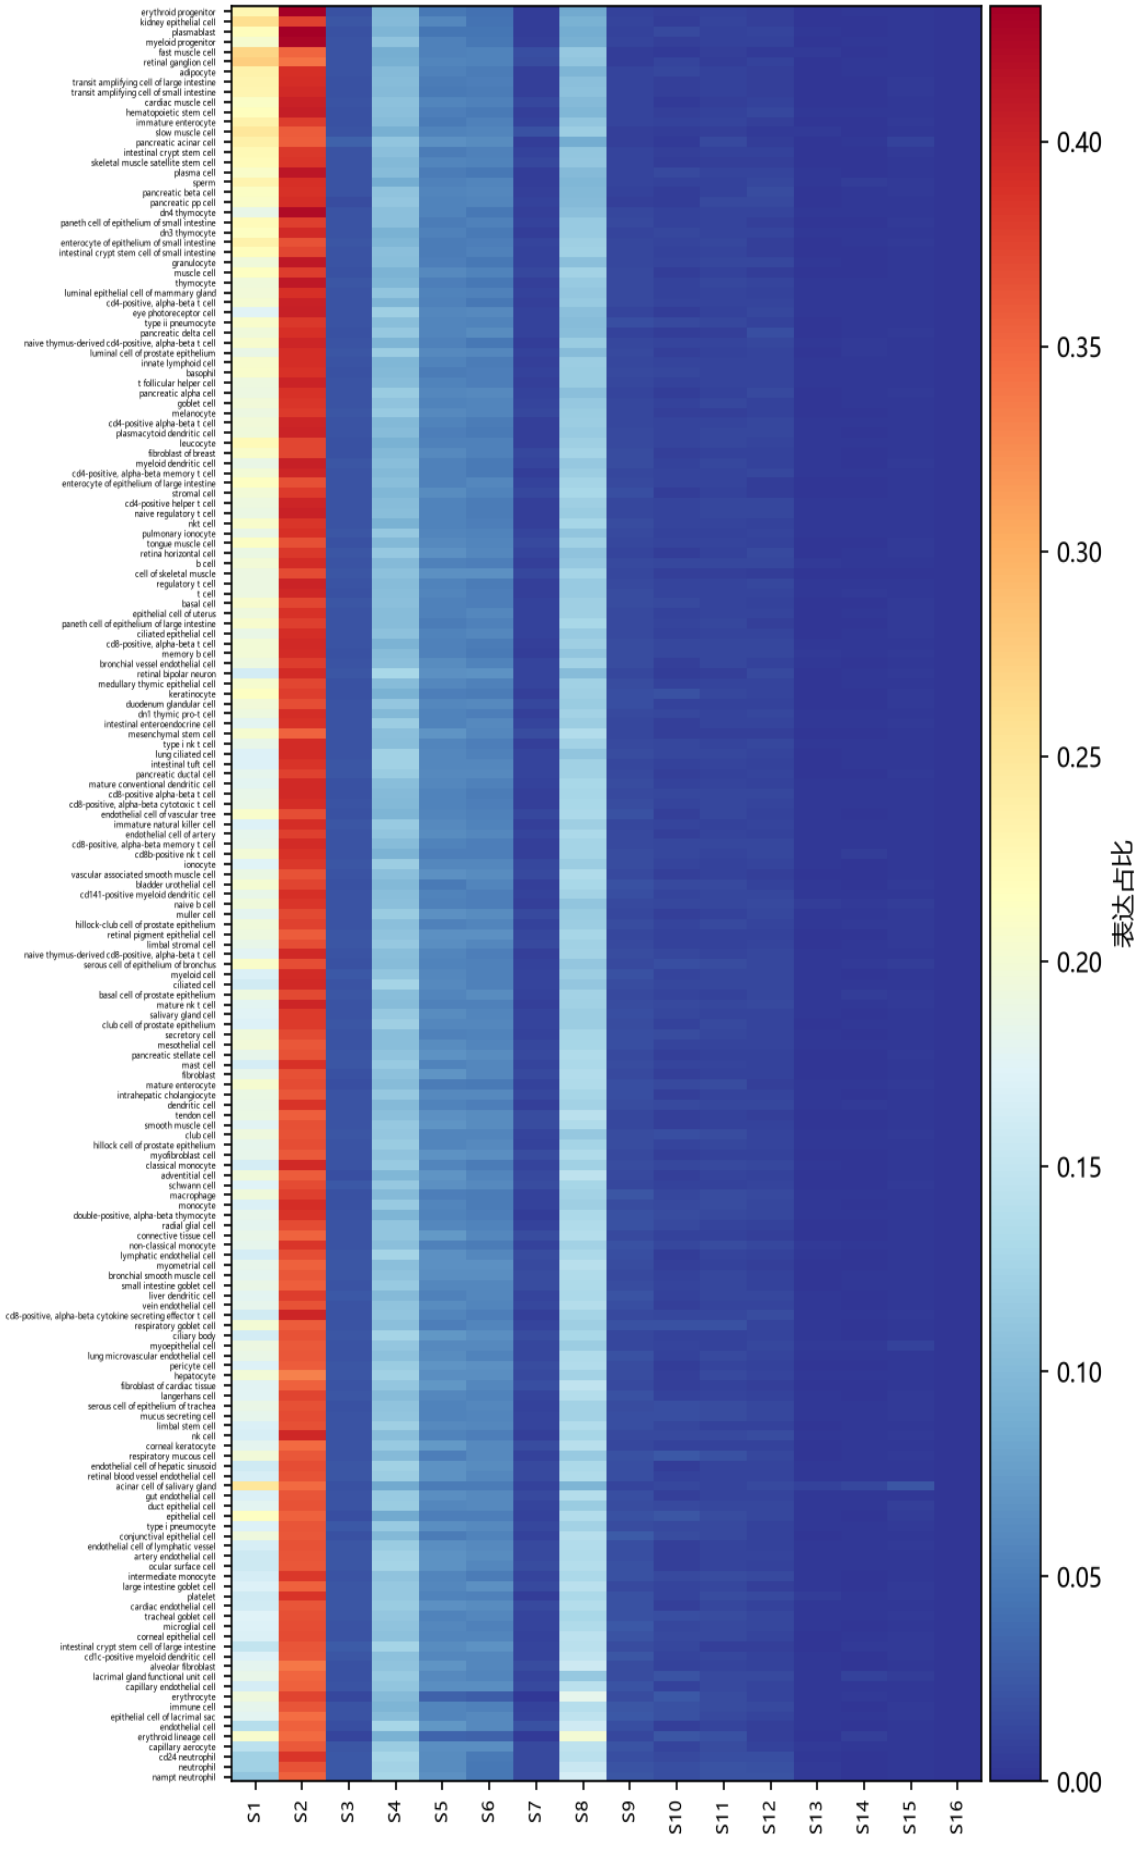
**结果与直觉的对照**：

1. **部分符合**：生殖系最古老（但仅 1 种类型，样本量过小，不作结论）；造血前体（红系、髓系）位居最古老之列，符合"造血是古老、保守的功能"这一预期；心肌细胞、视网膜神经节细胞也偏古老，符合"节律收缩、神经信号传导是保守机制"的直觉。
2. **部分出乎意料**：**中性粒细胞是人体中最"年轻"的细胞类型之一**（4.30–4.42），而中性粒细胞恰恰是人体最古老、最核心的先天免疫细胞之一。这与 1.3 节表格中"免疫细胞更新快 → 需要新基因"的假说方向一致（快速周转的细胞类型需要快速演化的、新出现的基因，如 S8–S15 层的效应分子），但与"功能越基础 → 基因越古老"的假说**方向相反**。这提示"基因年龄"反映的可能是**细胞周转速率与功能模块更新速率**，而不只是功能的保守程度。
3. **上皮的意外发现**：transit amplifying cell（大 / 小肠）位列最古老之列，而同属上皮的伞状细胞、杯状细胞却在年轻一侧。同一区室内出现最大的反差，说明区室层面的均值掩盖了细胞类型之间的真实差异——**区室不是合适的分析单位**。

## 3.2 年龄构成能否区分细胞类型（图 2、图 3）

图3 细胞类型 × 年龄层构成热图

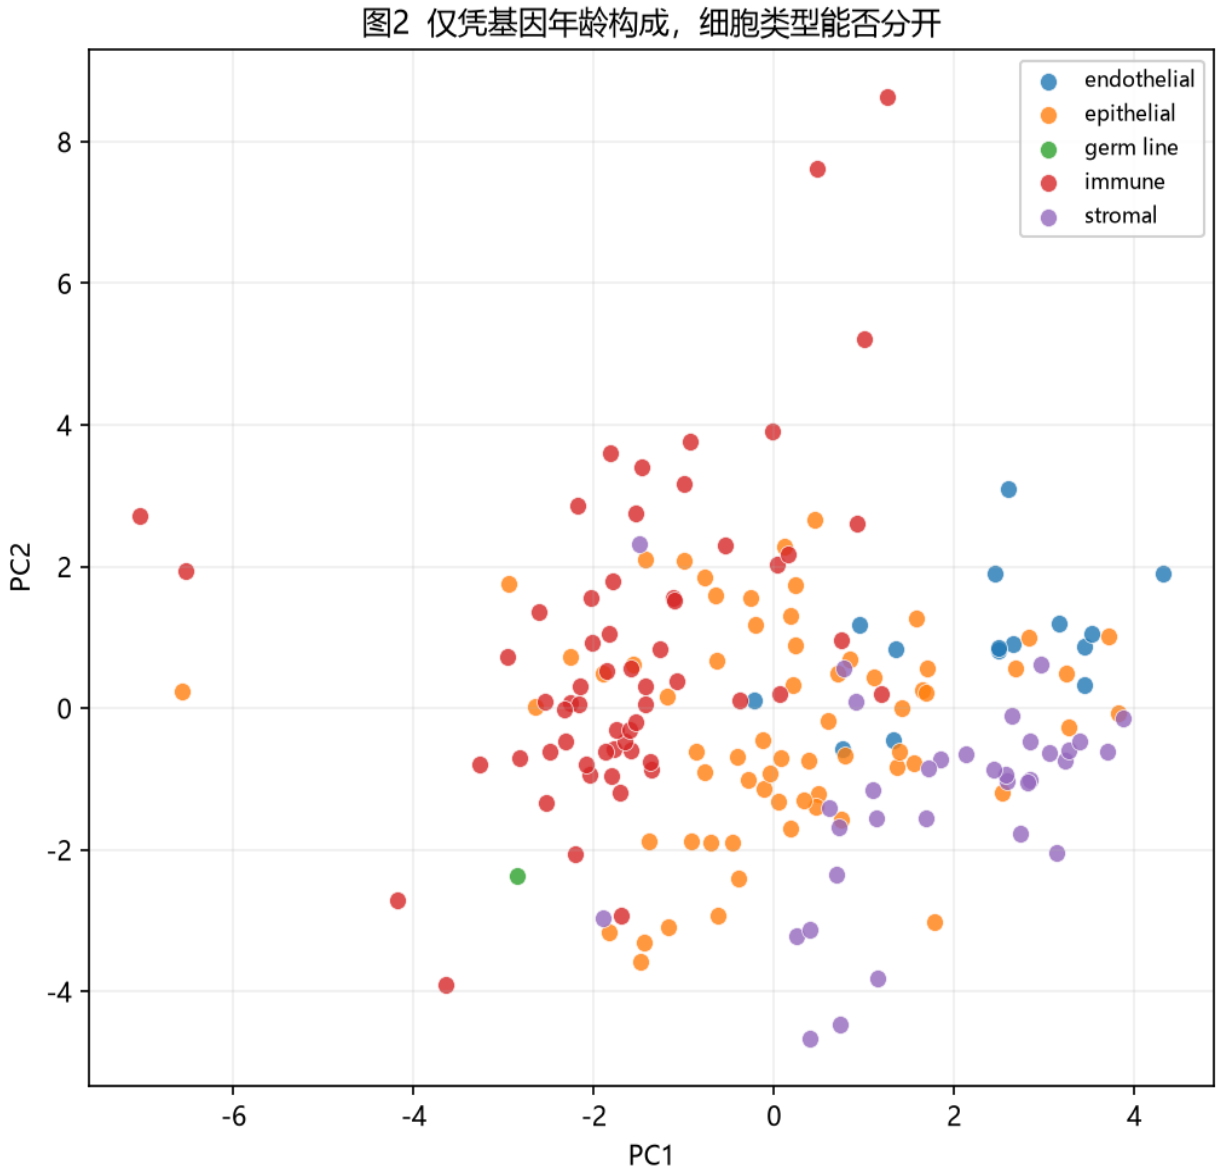
（颜色 = 该层基因的表达占比；红=占比高、蓝=占比低。注意 S1 在最左、S16 在最右，**红色端靠左代表古老层**）






图

3 细胞类型 × 年龄层的表达占比热图




图

2 PCA 前两主成分散点，按 K-means 簇着色

**PCA**：

| 主成分 | 解释方差 |
| --- | --- |
| PC1 | 27.3% |
| PC2 | 22.6% |
| PC3 | 12.1% |

| 主成分 | 解释方差 |
| --- | --- |
| 前 3 个累计 | **61.9%** |

累计 61.9% 低于 70%。**这个数字本身不能单独解读**——必须和零假设比较才有意义。为此本项目做了三项额外诊断（`08_主成分诊断.py`，结果见**图 7**）：

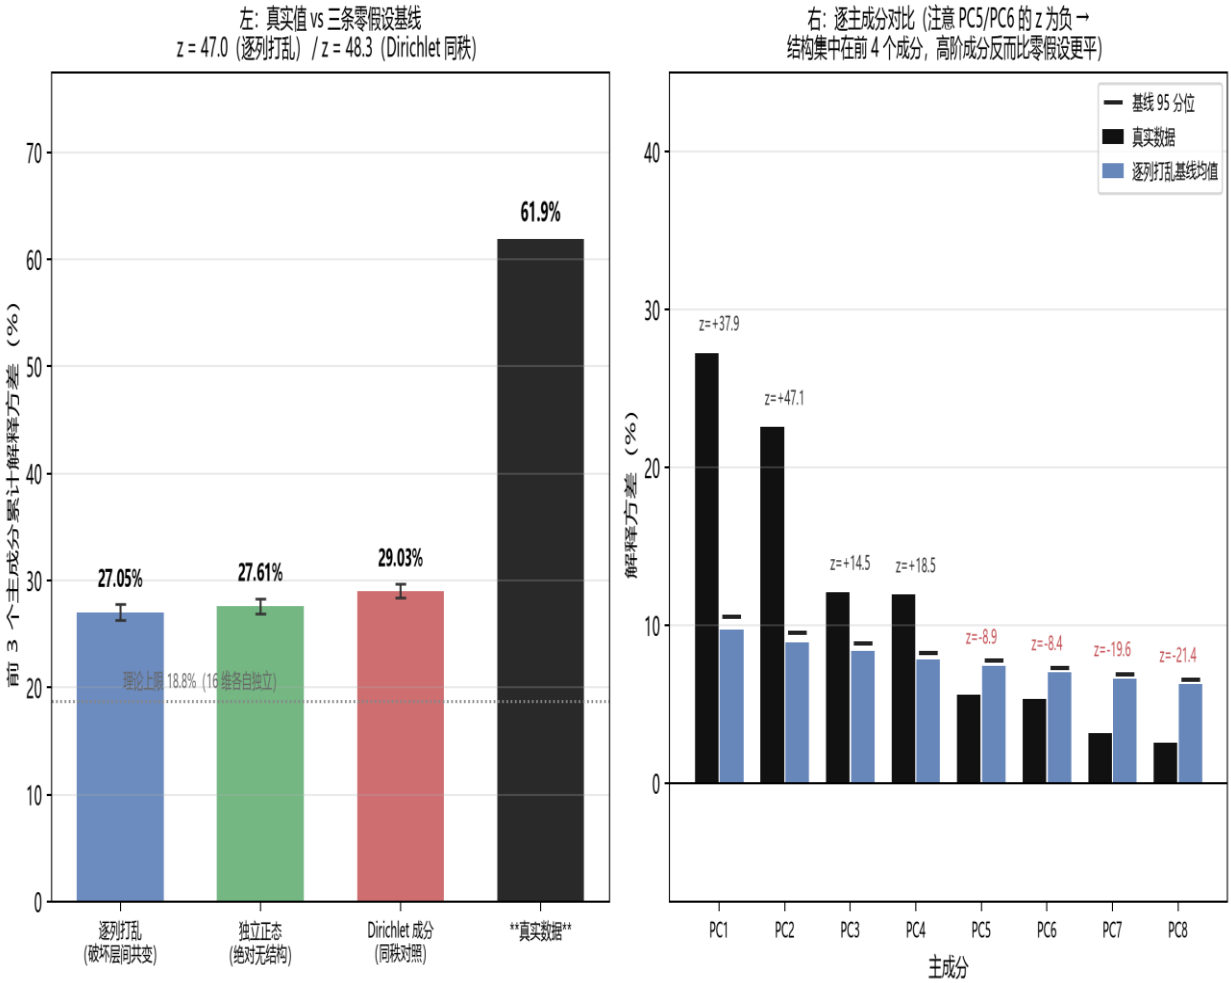



图 7 PCA 零假设诊断：三条基线对比

⓪ **先检查数据本身的结构约束。** 年龄构成是**成分数据**：每行 16 个占比之和恒为 1，因此行向量必然落在一个 **15 维仿射子空间**上，协方差矩阵**天然秩亏**——实测第 16 个特征值 = $2.6\times10^{-31}$（严格为 0），真实秩为 **15 / 16**。

> 这一步不是形式主义：它决定了"基线"必须怎么构造。如果基线是满秩 16 维的，而真实数据只有 15 个独立方向，那么"前 3 维占比更高"里就混进了一部分**纯机械的秩亏红利**。所以下面要用三条基线交叉验证。

① **与零假设基线比较。** 零假设的构造是「逐列打乱」：保留每个年龄层在 177 种细胞类型上的边际分布，但破坏层与层之间的共变关系（500 次置换）。

⚠ 这里有一个容易踩的陷阱：**PCA 分解的是特征协方差，置换细胞类型的行并不会改变它**——那是个无效的零假设，会得到"基线 = 真实值"的荒谬结果。必须打乱的是**特征列**。

| | **前 3 主成分累计** |
|---|---|
| 真实数据 | **61.9%** |
| 零假设基线（逐列打乱，500 次） | 27.0% ± 0.7% |
| 独立正态对照（绝对无结构） | 27.6% ± 0.7% |
| **Dirichlet 成分基线（同秩对照，400 次）** | **29.0% ± 0.7%** |
| 真实值超出逐列打乱基线 | **z = 47.0 个标准差** |
| 真实值超出 Dirichlet 同秩基线 | **z = 48.3 个标准差** |

三条基线互相吻合（逐列打乱 27.05%、独立正态 27.61%、Dirichlet 成分 29.03%），说明逐列打乱没有残留结构，基线可信。其中 **Dirichlet 成分基线是关键对照**：它用矩估计拟合浓度参数，从 Dirichlet 分布抽样生成"同样是成分数据、同样行和 = 1、同样秩亏到 15"的样本——正是与真实数据**同秩**的零假设。它给出的基线略高于另两条（29.0% vs 27.1%），真实值相对它的 z 反而更大（48.3），因此**低维结构是真实的，不是成分约束的机械效应。**

**为什么基线是 27% 而不是理论值 3/16 = 18.8%**：这是有限样本效应。n = 177、d = 16 时 n/d ≈ 11，样本协方差矩阵的谱不会均匀分布。因此基线**必须用同样规模的样本重新生成**，不能直接代入理论值。

**② 信息为什么分散——层间相关结构。** 16 个年龄层中存在 **14 对相关系数 |r| > 0.5** 的组合：

| **层对** | **r** | **层对** | **r** |
|---|---|---|---|
| S5 ↔ S7 | +0.755 | S2 ↔ S8 | −0.585 |
| S1 ↔ S4 | −0.729 | S14 ↔ S15 | +0.584 |
| S5 ↔ S6 | +0.719 | S1 ↔ S9 | −0.581 |

| 层对 | r | 层对 | r |
|---|---|---|---|
| S10 ↔ S11 | +0.693 | S4 ↔ S5 | +0.579 |
| S2 ↔ S7 | −0.667 | S8 ↔ S9 | +0.546 |

这些层在 177 种细胞类型中同步升降，把同一份信息拆成了几维。用**参与比**（$PR = 1/\Sigma evr^2$，取值范围 [1, 16]：各维完全等方差时取上界 16，信息集中于一维时取下界 1）度量有效维度：

| | 有效维度 |
|---|---|
| 真实数据 | **6.12 维** |
| 零假设（逐列打乱） | 14.74 维 |
| 零假设（Dirichlet 同秩） | 13.77 维 |

真实数据在 16 维的表象里只有约 **6.1 维**承载有效信息，而零假设下 16 维几乎各自独立（14.7 维，接近上界 16）。**在同秩的 Dirichlet 基线下压缩依然成立（13.8 维 → 6.1 维），年龄构成存在明确的低维结构，不是各层各说各话。**

**逐主成分的结构位置**（图 7 右 panel）：PC1–PC4 的 z 值分别为 +37.9、+47.1、+14.5、+18.5（显著高于零假设），而 **PC5 之后 z 值转负**（PC5 −8.9、PC6 −8.4）——高阶成分反而比零假设更平坦。**这说明结构精确地集中在前 4 个成分里**，而不是弥散在全部维度中；同时也解释了为何"前 3 累计"远达不到 70%：剩下的方差确实存在于 PC4 及以后。

**结论**：「前 3 个主成分累计 > 70%」这一验收指标**设得过高**——即使各层完全独立，前 3 维也只能解释 27.0%。更有意义的表述是：**61.9% 显著高于零假设（z = 47），16 维压缩到 6.1 个有效维度。**

**聚类数选择**（K-means，轮廓系数）：

```
k=2  0.193      k=5  0.206      k=7  0.235  ← 选定
k=3  0.192      k=6  0.228      k=8  0.223
k=4  0.199
```

**与已知谱系的一致性**：**ARI = 0.211。**

> **这个数字必须配一个零假设才能读。**ARI 的置换零假设为 **−0.0001 ± 0.0104**（2000 次随机置换标签），真实值相当于 **z = 20.4** 个标准差——即"随机聚类也能得到 ARI ≈ 0"这个替代解释被排除。

> Ward 层次聚类作为方法对照给出 ARI 0.170 / 轮廓 0.166，与 K-means 同量级，说明结果不是某种聚类算法的特例。

**这该如何解读**——参照系很重要。若把聚类结果与**随机划分**比较，ARI 的期望值为 0；若与"完全按谱系分组"的理想情况比较，ARI 的上限为 1。0.211 落在**弱相关**区间：

- ARI > 0.5：年龄构成是细胞类型的强特征 → 本研究未达到
- 0.2 < ARI < 0.5：**弱但确实存在** → 本研究落在此区间
- ARI < 0.2：年龄构成不足以定义细胞类型 → 本研究未落在此区间

**结论**：年龄构成**捕捉到了部分谱系信息，但远不足以单独定义细胞身份。**这是一个有效且诚实的结论，而非失败——它恰好划定了"进化视角"在细胞分类体系中的位置：**正交的补充轴，不是替代轴。**

**敏感性分析：剔除低置信类型后结论是否改变。** 上面的 k = 7 与 ARI = 0.211 都建立在 177 种类型（含 25 种 QC 后细胞数不足 20 的低置信类型）之上。若剔除这 25 类（剩余 n = 152）：

| | **主口径（n = 177）** | **敏感性（n = 152）** |
|---|---|---|
| 聚类数 k | 7 | **5** |
| ARI | 0.211 | **0.159** |
| 轮廓系数 | 0.235 | 0.239 |
| 前 3 主成分累计 | 61.9% | 63.4% |

**结论没有被推翻，但确实被削弱**：ARI 从 0.211 降到 0.159（降幅 25%），说明 **k = 7 这个最优解本身相当程度上由低置信类型撑起。**剔除后轮廓系数反而略升（0.239），说明剩下的类型分得更"整齐"但簇更少。这是一个诚实的结果——它表明"年龄构成与谱系弱相关"这一核心结论在严格子集上依然成立，只是强度打折。

**各簇的平均 TAI**（k=7，主口径）：

| **簇** | **类型数** | **平均 TAI** | **簇** | **类型数** | **平均 TAI** |
|---|---|---|---|---|---|
| 0 | 14 | 3.95 | 4 | 1 | 3.89 |
| 1 | 57 | 3.64 | 5 | 19 | 3.87 |

| 簇 | 类型数 | 平均 TAI | 簇 | 类型数 | 平均 TAI |
|---|---|---|---|---|---|
| 2 | 2 | 4.05 | 6 | 25 | 3.52 |
| 3 | 59 | 3.82 | | | |

簇 1（57 种）与簇 3（59 种）规模相近但平均 TAI 相差 0.18——**同样的簇规模并不意味着同样的年代特征**，进一步支持 PCA 累计方差不高的观察。

### 3.3 细胞身份由哪个年代的基因定义（图 4）——本文最重要的一节

图4 区分细胞类型的基因，偏向哪个年代

（上：各年龄层在背景 HVG 中的基因数，对数轴；下：Top 重要基因的富集倍数，红色=BH 校正后显著富集，蓝色=BH 校正后显著耗竭，★/▼ = q < 0.05）

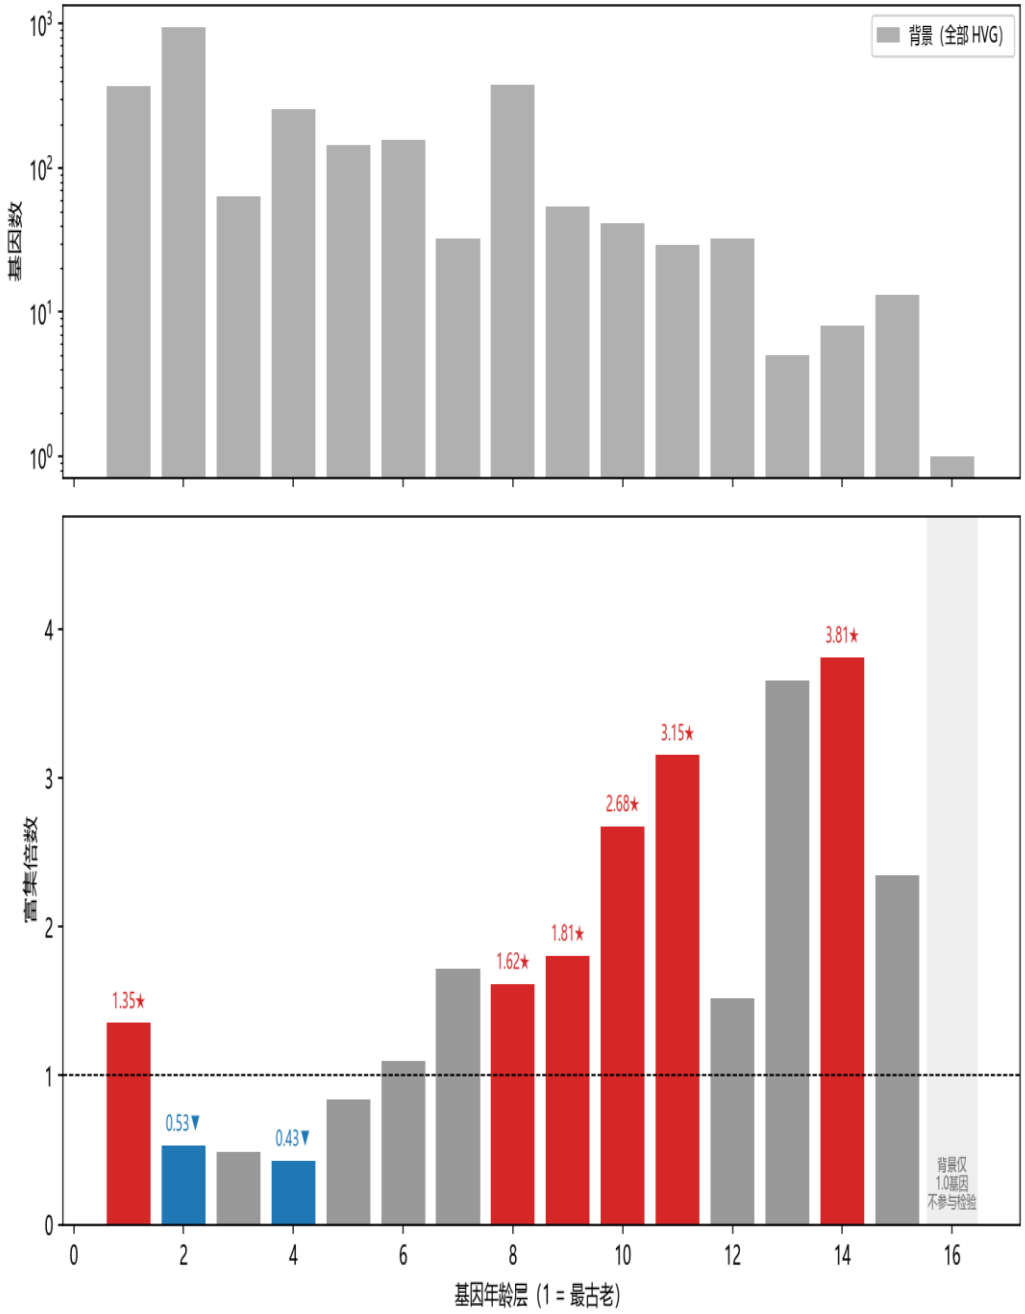



图 4 各年龄层基因数与 Top 500 重要基因的富集倍数

随机森林在按供者划分的测试集上取得**准确率 0.215、宏平均 F1 0.237**（测试集 103 类口径；随机基线 0.0097、多数类基线 0.026，为多数类基线的 8.26 倍，准确率天花板 0.595，本次达到 36.13%——详见 3.4 节）。

**Top 20 重要基因及其年龄层**：

| 基因 | 重要性 | 年龄层 | 基因 | 重要性 | 年龄层 |
|---|---|---|---|---|---|
| HBA2 | 0.00314 | S8 | HLA-DRA | 0.00234 | S8 |
| HBB | 0.00314 | S8 | LYZ | 0.00233 | S6 |
| IGKC | 0.00282 | S8 | HBA1 | 0.00228 | S8 |
| TTR | 0.00275 | 无年龄 | IGHA1 | 0.00226 | S10 |
| S100A9 | 0.00270 | S9 | SEMG2 | 0.00226 | S14 |
| ALB | 0.00270 | 无年龄 | SAA1 | 0.00224 | S6 |
| SEMG1 | 0.00244 | S14 | CKB | 0.00216 | S1 |
| B2M | 0.00235 | 无年龄 | S100A8 | 0.00208 | S10 |
| SLPI | 0.00207 | S10 | SFN | 0.00206 | S10 |
| TMSB4X | 0.00206 | 无年龄 | TFF3 | 0.00205 | S7 |
| MT-RNR2 | 0.00236 | 无年龄 | HLA-DRA | 0.00206 | S8 |

> **一个重要的观察**：Top 20 中有多个基因本身就是**高度组织特异的"标记基因"**——HBB / HBA1 / HBA2（血红蛋白）、TTR（转甲状腺素蛋白）、ALB（白蛋白）、IGKC / IGHA1（免疫球蛋白）、SAA1（血清淀粉样蛋白 A1）、SLPI（分泌型白细胞蛋白酶抑制剂）、TFF3（肠三叶因子）。这提示随机森林的重要性和经典的差异表达标记基因高度重叠——**细胞身份仍然主要由"标志物"承载**，而不是由年代承载。年代的意义是叠加在标志物之上的一层系统性偏好。

**各年龄层在 Top 500 重要基因中的富集**（超几何双单尾检验 + BH-FDR 校正，背景 = 2,523 个有年龄注释的 HVG，Top 集合 = 414 个有年龄注释的基因）：

> **为什么 Top 集合是 414 而不是 500**：Top 500 里只有 414 个能在 Trigos 年龄表中查到层号，其余 86 个是 TTR、ALB、B2M、TMSB4X 这类**不在该 17,318 基因集内**的基因（它们在表达矩阵里存在，但 Trigos 表没有覆盖）。这类基因同样是很强的细胞类型标记物——**它们证明"区分细胞类型"主要靠的是标志性 housekeeping 基因**，但因为没有年龄归属，无法参与年龄富集检验。这一事实本身就限定了本节结论的射程：富集检验回答的是"**有年龄归属的**重要基因偏向哪个年代"，而不是"所有重要基因偏向哪个年代"。

**表中的 q 列为 BH-FDR 校正后的值，是本报告的正式判定依据**（每次运行 32 次检验，三次运行共 96 次；原始 p 仅供对照）。

| 层 | 背景 | Top 中 | 期望 | 倍数 | p（富集） | q（富集） | p（耗竭） | q（耗竭） | 判定 |
|---|---|---|---|---|---|---|---|---|---|
| S1 细胞生物 | 365 | 81 | 66.3 | 1.35 | $1.1\times10^{-3}$ | **$4.5\times10^{-3}$** | 1.00 | 1.00 | **富集 ★** |
| S2 真核生物 | 946 | 82 | 75.5 | **0.53** | 1.00 | 1.00 | $2.4\times10^{-17}$ | **$3.8\times10^{-16}$** | **耗竭 ▼** |
| S3 后鞭毛类 | 63 | 5 | 4.6 | 0.48 | 0.99 | 1.00 | $4.0\times10^{-2}$ | 0.21 | 不显著 |
| S4 后生动物 | 257 | 18 | 16.8 | **0.43** | 1.00 | 1.00 | $2.3\times10^{-6}$ | **$1.9\times10^{-5}$** | **耗竭 ▼** |
| S5 真后生动物 | 145 | 20 | 17.6 | 0.84 | 0.84 | 1.00 | 0.23 | 0.91 | 不显著 |
| S6 两侧对称动物 | 155 | 28 | 23.7 | 1.10 | 0.32 | 0.42 | 0.76 | 1.00 | 不显著 |
| S7 脊索动物 | 32 | 9 | 7.0 | 1.71 | $6.6\times10^{-2}$ | 0.12 | 0.97 | 1.00 | 不显著 |
| S8 硬骨脊椎动物 | 377 | 100 | 79.0 | 1.62 | $3.5\times10^{-8}$ | **$5.6\times10^{-7}$** | 1.00 | 1.00 | **富集 ★** |

| 层 | 背景 | Top 中 | 期望 | 倍数 | p（富集） | q（富集） | p（耗竭） | q（耗竭） | 判定 |
|---|---|---|---|---|---|---|---|---|---|
| S9 羊膜动物 | 54 | 16 | 12.3 | 1.81 | $1.0\times10^{-2}$ | **$2.7\times10^{-2}$** | 1.00 | 1.00 | **富集 ★** |
| S10 哺乳纲 | 41 | 18 | 12.5 | **2.68** | $2.7\times10^{-5}$ | **$1.4\times10^{-4}$** | 1.00 | 1.00 | **富集 ★** |
| S11 兽亚纲 | 29 | 15 | 9.9 | **3.15** | $1.1\times10^{-5}$ | **$8.8\times10^{-5}$** | 1.00 | 1.00 | **富集 ★** |
| S12 真兽下纲 | 32 | 8 | 6.4 | 1.52 | 0.14 | 0.23 | 0.93 | 1.00 | 不显著 |
| S13 灵长总目 | 5 | 3 | 1.9 | 3.66 | $3.4\times10^{-2}$ | 0.077 | 1.00 | 1.00 | 不显著 |
| S14 狭鼻小目 | 8 | 5 | 3.1 | **3.81** | $4.2\times10^{-3}$ | **$1.4\times10^{-2}$** | 1.00 | 1.00 | **富集 ★** |
| S15 人亚科 | 13 | 5 | 3.6 | 2.34 | $4.8\times10^{-2}$ | 0.096 | 0.99 | 1.00 | 不显著 |
| S16 智人 | 1 | 1 | 0.5 | 6.09 | 0.16 | 0.24 | 1.00 | 1.00 | 不显著（背景仅 1 基因，不参与检验） |

**这个结果的核心模式**：

**经 BH 校正后仍显著的富集层为 S1、S8、S9、S10、S11、S14**，即**细胞生物 → 硬骨脊椎动物 → 羊膜动物 → 哺乳纲 → 兽亚纲 → 狭鼻小目**这一段脊椎动物—哺乳类—灵长类演化序列；倍数随年代递进而上升（S8 1.62× → S9 1.81× → S10 2.68× → S11 3.15× → S14 3.81×）。

> **多重检验校正改变了什么**：若不校正（只看原始 $p < 0.05$），富集层会变成 8 层——S7、S12、S13、S15 会被误判为显著。这四层恰恰是**背景基因数最少、统计功效最弱**的层（S7 32 个、S12 32 个、S13 5 个、S15 13 个背景基因）。S13 的 3.66× 与 S15 的 2.34× 数值上很醒目，但它们背后的背景分别只有

> 5 个和 13 个基因——**倍数高是因为分母小，不是因为信号强。**校正后这两层都落回不显著，是更诚实的结论。

**经 BH 校正后仍显著的耗竭层为 S2、S4**，即**真核生物 → 后生动物**这两层跨度超过二十亿年的"基础 housekeeping"层（S3 后鞭毛类因背景仅 63 个基因、功效不足而未通过校正）。

**这个模式为什么重要**，有两条独立的解释：

1. **统计上**：如果随机森林学到的是与年代无关的通用细胞状态（大小、应激、增殖速率），那么 Top 基因的年龄分布应当接近背景。观察到的强烈偏离**排除了这个零假设。**
2. **生物学上**：**"区分细胞类型"这件事本身是哺乳类特有的。**一个两亿年前才出现的免疫系统，其细胞身份必然依赖两亿年前才出现的基因（免疫球蛋白、细胞因子受体、抗原提呈分子）；而三亿年前就存在的通用代谢与信号转导机制（核糖体、蛋白酶体、剪接体）在所有细胞里都一样表达，因此对**区分**毫无帮助——它们占背景的大头（仅 S2 一层就有 946 个基因），却几乎不进入 Top 列表。

> **这是一个自洽的整体解释**：古老的基因承担**所有细胞共享的"基本功能"**，因此不携带身份信息；年轻的（哺乳类-灵长类特异的）基因承担**细胞类型特异的"身份功能"**，因此是分类器真正依赖的对象。

**表述的克制**（重要）：本研究只能说"**在区分细胞类型时，模型更依赖 S8–S14 的脊椎动物—哺乳类—灵长类特异层中经校正后仍显著的 S8、S9、S10、S11、S14 的基因**"，**不能说**"这些基因决定了细胞类型"。富集是关联而非因果；基因年龄是基因在参考基因组中的**首次出现**，而它在某细胞类型中**高表达**还取决于调控、扩增、拷贝数等大量其他因素。此外，S15/S16 两层本身命中率仅 64%/69%，其富集结果需谨慎对待（见 4.2）。

## 3.4 分类性能与误差（图 6）

按供者划分的分类结果：**准确率 0.215、宏平均 F1 0.237**（测试集实际出现的 103 类口径；按全部 177 类口径为 0.138）。

| 参照量 | 值 | 说明 |
| --- | --- | --- |
| 随机基线（103 类均匀猜） | 0.0097 | 测试集实际类别数 |
| 多数类基线（恒猜最高频类） | 0.026 | **更贴近实际** |
| 准确率 / 多数类基线 | **8.26 倍** | |
| 准确率天花板 | **0.595** | 剔除训练集从未出现的类别后 |

| 参照量 | 值 | 说明 |
| --- | --- | --- |
| 本次达到天花板 | **36.13%** | |

**为什么必须披露天花板**：测试集中有 **28 个类在训练集中从未出现**，涉及 **3,109 个细胞（占测试集 40.5%）**。这批细胞模型在原理上就不可能预测对（供者划分保证了训练集与测试集的细胞类型分布不同）。因此 0.215 应当被理解为"在 59.5% 可预测的细胞上答对了 36.13%"，而不是一个可以无限优化的孤立数字。

**为什么宏平均 F1 仍然只有 0.237**：说明性能依然高度偏向高频类型（如红系、中性粒细胞等），稀有类型基本无法识别——这与 28 个未见类别的存在是一致的。

一个重要的混淆来源是：**血红蛋白基因 HBB / HBA1 / HBA2 同时位列重要性和 Top 基因。**由于它们在所有含红细胞的样本中极高表达，若供者间红细胞污染程度不同，模型可能学到的是"这个供者的血样污染程度"而非细胞身份——这正是**必须按供者划分**才能暴露出来的风险。

## 3.5 稳健性检验：结论是否依赖于低置信度或易错基因的年龄调用

针对 Moyers & Zhang (2015/2017/2018) 的方法学批评（详见 4.2），本项目设计了三层独立检验（检验 C 的完整结果见 4.2 节）。

**检验 A：剔除低命中年龄层后重算 TAI。** 由于 S15（64%）、S16（69%）的基因在表达矩阵中存在率明显偏低，本项目剔除这两层，仅用 S1–S14 重算全部 177 种细胞类型的 TAI：

| 指标 | 结果 |
| --- | --- |
| 保留的层 | S1–S14（剔除 S15、S16） |
| Spearman ρ | **0.9883** |
| Kendall τ | **0.9518** |
| 最古老 Top10 重合 | **9 / 10** |
| TAI 绝对差中位数 | 0.0361 |
| 排名变动 | **141 / 177 个类型名次有变化，最大位移 88 位** |

**整体排序高度一致，但并非"逐个类型不变"。**Top10 中 `cardiac muscle cell` 掉出、`pancreatic acinar cell` 换入；177 个类型里有 141 个名次发生变动，最大位移达 88 位。剔除 S15/S16 只轻微影响 TAI 的**绝对值**（中位绝对差 0.0361），不改变相对比较的**总体格局**——因为被剔除的 S15/S16 在多数细胞类型中的表达占比本身就很小（见图 1 顶部蓝色薄层）。

**⚠ 曾经踩过的坑（已修）**：本项检验最初报告的是"Spearman ρ = 1.0000、Kendall τ = 1.0000，排序完全不变"。那是**一个同义反复**，不是发现——`compute_age_profile()` 的返回值已按 TAI 升序排过，两列各自升序后再按位置配对，位置秩相关**恒等于 +1。**实测复现：两列独立随机数各自升序后做位置秩相关，500/500 次都算出 ρ = 1.0。修正为按索引显式对齐后，真实值为 **ρ = 0.9883、τ = 0.9518。**

**检验 B：共识度过滤后重跑完整监督分析。** 只保留年龄表中**共识度高**（`mode_share ≥ 0.8`，即 ≥80% 的同源推断算法给出同一层号）的基因重跑全流程：

| **指标** | **A：全量（3,000 特征）** | **B：共识度过滤（905 特征）** |
|---|---|---|
| 分类准确率 | 0.215 | 0.180 |
| 宏平均 F1（测试集口径） | 0.237 | 0.194 |
| 富集背景 / Top 集 | 2,523 / 414 | 905 / 500 |
| **共同显著富集层** | **S1, S8, S9, S10, S11, S14** | **S8, S10** |
| 共同显著耗竭层 | **S2, S4** | **S2** |
| Top 20 重要基因重合 | — | **3 / 20**（IGHA1, S100A8, SFN） |

**⚠ 参数语义必须说清楚**（这是本轮审核发现的一处实质性错误）。原先的参数 `--min-dbs 10` 意为"`NumDBsContributing` ≥ 10"，但该字段的语义是**参与投票的算法数（分母）**，**不是**"支持该层号的算法数"。真正的共识度是 `mode_share`，支持算法数 = `round(mode_share × n_dbs)`。实测 $n_{dbs}$ 与共识度**负相关**（corr = −0.128）：$n_{dbs} \le 4$ 的基因共识度中位数为 1.0000（全体完全一致），而 $n_{dbs} \ge 10$ 的仅 0.692。**按 `--min-dbs 10` 过滤会筛掉高共识的基因，方向与"高置信"完全相反。**已改为 `--min-share 0.8`，并在年龄表中新增 `mode_support` / `mode_share` 两列以落盘真实共识度。

**逐层对照**（完整表见 `20-分析/robustness_comparison.tsv`，**图 8**；显著性按 BH 校正后 q < 0.05 判定）：

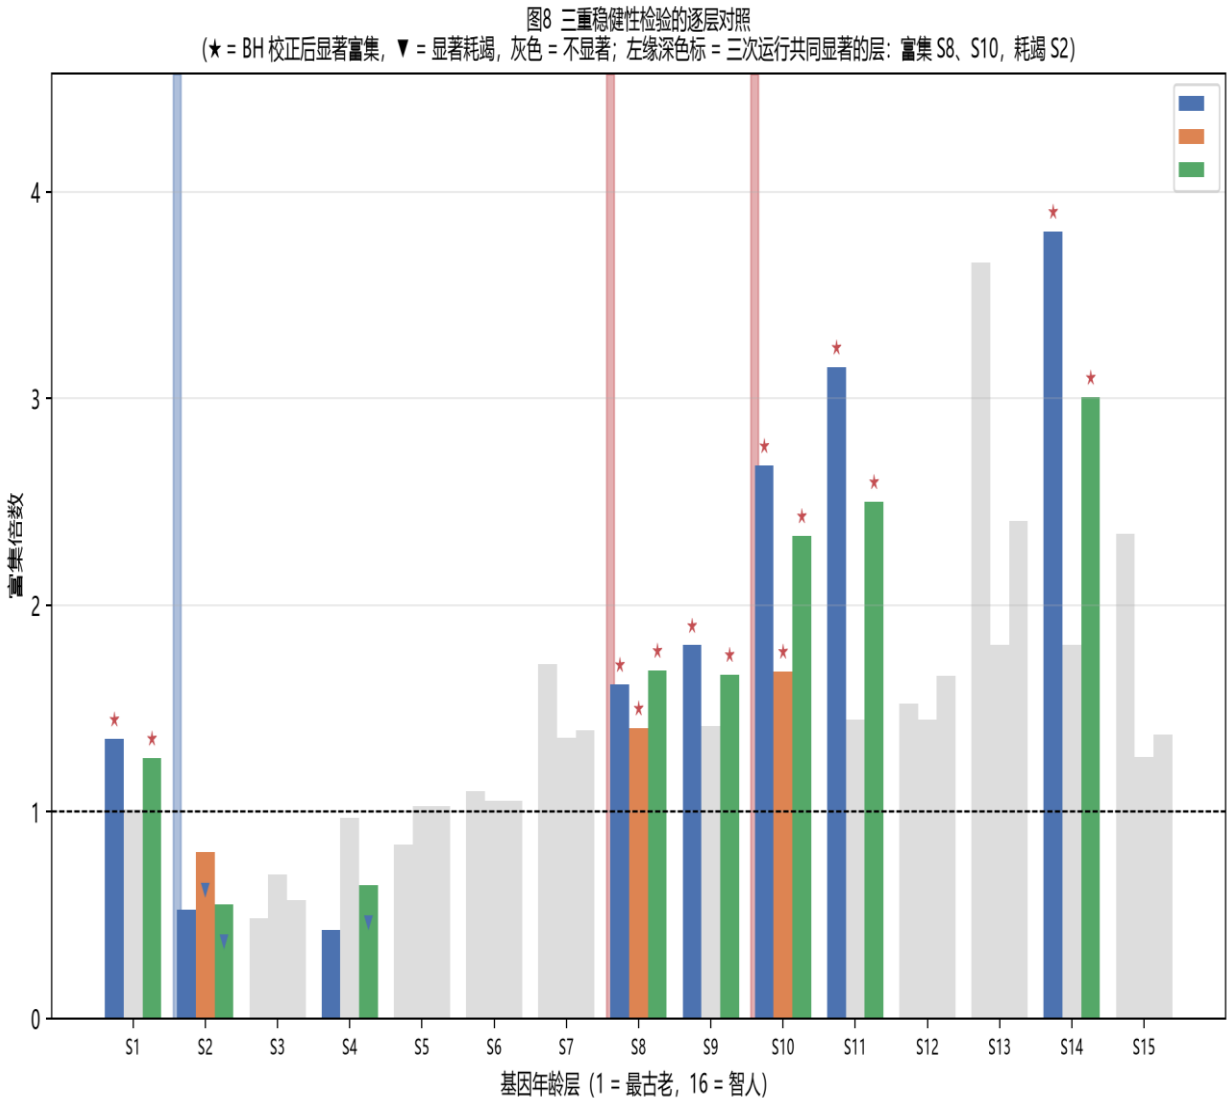



图 8 三重稳健性逐层对照

| 层 | A 倍数 | A q（富集） | B 倍数 | B q（富集） | C 倍数 | C q（富集） | 方向 |
|---|---|---|---|---|---|---|---|
| S1 | 1.35 | **0.0045** | 1.01 | 0.68 | 1.26 | **0.018** | 富集 — 部分 |
| S2 | 0.53 | — | 0.80 | — | 0.55 | — | 耗竭 ✓ 一致 |
| S3 | 0.48 | — | 0.70 | — | 0.57 | — | 不显著 ✓ 一致 |
| S4 | 0.43 | — | 0.97 | 0.75 | 0.65 | — | 耗竭 — 部分 |
| S5 | 0.84 | — | 1.03 | 0.68 | 1.03 | 0.59 | 不显著 ✓ 一致 |

| 层 | A 倍数 | A q（富集） | B 倍数 | B q（富集） | C 倍数 | C q（富集） | 方向 |
|---|---|---|---|---|---|---|---|
| S6 | 1.10 | 0.42 | 1.05 | 0.68 | 1.05 | 0.59 | 不显著 ✓ 一致 |
| S7 | 1.71 | 0.12 | 1.36 | 0.68 | 1.40 | 0.32 | 不显著 ✓ 一致 |
| S8 | 1.62 | **5.6e-07** | 1.41 | **5.6e-07** | 1.68 | **1.3e-10** | **富集 ✓ 一致** |
| S9 | 1.81 | **0.027** | 1.42 | 0.099 | 1.67 | **0.034** | 富集 — 部分 |
| S10 | 2.68 | **1.4e-04** | 1.68 | **0.023** | 2.34 | **0.0016** | **富集 ✓ 一致** |
| S11 | 3.15 | **8.8e-05** | 1.45 | 0.27 | 2.50 | **0.0026** | 富集 — 部分 |
| S12 | 1.52 | 0.23 | 1.45 | 0.17 | 1.66 | 0.13 | 不显著 ✓ 一致 |
| S13 | 3.66 | 0.077 | 1.81 | 0.68 | 2.40 | 0.32 | 不显著 ✓ 一致 |
| S14 | 3.81 | **0.014** | 1.81 | 0.27 | 3.01 | **0.034** | 富集 — 部分 |
| S15 | 2.34 | 0.096 | 1.27 | 0.62 | 1.37 | 0.59 | 不显著 ✓ 一致 |

**结论**：三次运行**没有任何一层的方向发生冲突（0 层）。三次共同显著富集的层为 S8、S10，共同显著耗竭的层为 S2**（Jaccard 相似度 0.333）。

> **共同层为什么只有 2 个，而不是更多**：B 组（共识度过滤）只保留 905 个基因，各层的**背景基因数大幅缩水**（S8 从 377 降到 121、S10 从 41 降到 14、S11 从 29 降到 10），统计功效随之下降——S9、S11、S14 在 B 组因此回落到不显著。这是**功效损失**而非结论反转：B 组的倍数与 A 组同向（无一层方向冲突），且 B 组自身仍然给出 S8、S10 富集 + S2 耗竭，正是与 A、C 共同的那两层。换句话说，**在功效最强的两组（A 与 C）里显著富集的层是重合的**：A ∩ C 的富集层为 S1、S8、S9、S10、S11、S14（6 层全重合）。

值得注意的是 **S8 层在剔除短蛋白后信号更强**（倍数 1.62 → 1.68，p 值 $3.5\times10^{-8}$ → $8.8\times10^{-12}$，q 值 $5.6\times10^{-7}$ → $1.3\times10^{-10}$）。

> ⚠ **检验 C 的定位必须说清楚（这是本轮审核发现的第二处实质性错误）**。检验 C 常被表述为"对偏差的修正"，但**偏倚是"已经发生"在 Trigos 年龄表里的**（见 4.2 节的前提检验：层号 vs 短蛋白占比 ρ = +0.871）。检验 C 是在这张**已经偏斜的表**上把短蛋白从背景里剔掉，它**不能修复**既有偏倚，只能让背景集合更干净、同时**降低**受影响层（尤其 S13/S15）的统计功效。因此它的正确定位是**保守性压力测试**——检验的是"结论是否依赖短蛋白"，而不是"偏差是否已被纠正"。它的实际效果是**削弱**而非增强年轻层信号。
>
> **这项检验的意义**：Moyers & Zhang 的批评核心是"如果剔除易错基因，已发表的结论会消失甚至反转"。本项目的结论在剔除低共识度基因**和**剔除短蛋白基因之后**都没有消失，也没有反转**（0 层方向冲突）。这不能证明 phylostratigraphy 无偏，但确实说明**本研究的结论不依赖于方法学批评所针对的那部分噪声**。更进一步的证据见 4.2 节的前提检验。

---

# 4 讨论

## 4.1 与已有工作的比较

**vs AGED（Aging Cell, 2025–2026）**：AGED 发现多种组织在衰老过程中古老基因表达上升、年轻基因被抑制，且脑与间充质干细胞抵抗这一趋势。它是**纵向**的——比较同一个体在不同年龄的表达谱；本研究是**横向**的——在一个成年供者的静态图谱中比较不同细胞类型。两者的互补关系是清晰的：AGED 发现了"时间流动"如何改变细胞的年龄构成，本研究则确立了"细胞身份"本身携带的年龄构成基线，恰好是解读 AGED 类纵向研究所需的参照系。

**vs Milinkovitch et al. (2010)**：他们用组织层面的老表达数据，发现古老基因表达于约两倍数量的解剖系统，并据此提出"古老基因承担更基础功能"。本研究的发现与之**部分吻合**：在本研究 Top 重要基因中，S2（真核生物，最基础的一层）显著**耗竭**（0.53×），说明"最基础的基因"恰恰是最不携带身份信息的。但本研究在**粒度与表示方式**上是不同的：他们在组织层面用"系统数量"这一个标量，本研究在单细胞层面用 16 维构成向量这一完整指纹。

**vs GTEx 研究（2024）**：GTEx 研究在 bulk 水平上把 54 个组织按 5 个演化年代和三胚层分组，发现三胚层来源的组织聚集在相似的年代层。本研究在**单细胞层面**得到了方向一致的观察——同一胚层来源的细胞类型年龄构成相近（如上皮区室 66 种类型平均 TAI 3.7266）——但粒度更细，代价是 bulk 的细胞组成混杂被消除。

**vs GBE (2024) 人脑 TAI 比较**：该研究比较了人脑各区的 TAI。本研究的视网膜神经节细胞（TAI 3.38）、视网膜双极细胞等神经相关类型也位于较古老一侧，但本研究用的是**同一供者的全身体细胞图谱**，可与脑区数据做直接对照——这一比较值得后续工作展开。

## 4.2 方法学局限（正面回应 Moyers & Zhang 的批评）

**批评的内容**：Moyers & Zhang 在一系列工作（*MBE* 2015, *GBE* 2018 等）中用计算机模拟论证，phylostratigraphy **系统性低估**基因年龄：快速演化、序列较短的基因更可能找不到远缘同源，从而被判

为"年轻"。更严重的是，**误差并非随机**——这意味着一个群体的"年轻基因比例偏高"可能只是它的一批基因恰好短且演化快，而非真实的年代偏好。他们的结论相当尖锐：一些文献报道的趋势在剔除易错基因后**消失甚至反转。**

**本项目的六点回应**：

1. **不回避**：在本节明确写出这一批评，并说明它直接威胁本项目的 3.3 节结论（因为该结论依赖 Top 基因的年龄分布）。
2. **双来源交叉验证**：Trigos 2017 与 Liebeskind 2016 是方法完全不同的两个来源。在 16,889 个可比基因上，8 个粗类别的中位层号为 1/1/1/2/4/5/8/11，**7 对相邻全部单调，零违反。**两个独立来源给出一致的年龄序，是方法可靠性的第一层证据。
3. **共识度过滤重跑**（检验 B）：只用 `mode_share ≥ 0.8` 的高共识度基因重跑全流程。**三次共同显著富集 S8、S10、共同耗竭 S2、零方向冲突**，Top 20 重要基因重合 3/20。
4. **剔除低命中层重算 TAI**（检验 A）：剔除命中率仅 64%/69% 的 S15、S16 后，177 种类型的 TAI 排序 **Spearman ρ = 0.9883、Kendall τ = 0.9518**，Top10 重合 9/10（141/177 名次变动，最大位移 88 位）。
5. **短蛋白剔除重跑**（检验 C）：剔除蛋白长度 < 100 aa 的基因后重跑全流程——**这是 Moyers & Zhang 明确建议、也是本项目此前唯一未完成的一项，现已完成。**
6. **长蛋白版 TAI 绝对值**（检验 D）：不止重跑富集层，而是用长蛋白**重算 TAI 绝对值**并逐类型对照，把偏倚的方向与大小定量出来——**本轮补齐的最后一环**，见 4.2 节末。

**检验 C 的实施**：Trigos et al. 2017 的年龄表本身不含序列长度，但其原始表带有 UniProt accession。本项目据此从 UniProt 批量获取了 **17,103 个基因的蛋白长度**（中位 434 aa，均值 578 aa，范围 13–8,797 aa），缓存于 `10-数据/protein_length.tsv`；`05_监督分析.py --min-length 100` 即按此过滤。

**检验 C 的结果**（显著性按 BH 校正后 q < 0.05 判定）：

| 指标 | A 全量 | B 共识度过滤 | C 短蛋白剔除 |
|---|---|---|---|
| 特征数 | 3,000 | 905 | **2,405**（剔除 595 个，拆解见下） |
| 分类准确率 | 0.215 | 0.180 | **0.213** |
| 宏平均 F1（测试集口径） | 0.237 | 0.194 | **0.231** |
| 准确率天花板达成比 | 36.13% | 30.26% | 35.75% |
| 富集背景 M / Top 集 N | 2,523 / 414 | 905 / 500 | **2,405 / 500** |

| 指标 | A 全量 | B 共识度过滤 | C 短蛋白剔除 |
|---|---|---|---|
| 显著富集层（BH） | S1, S8, S9, S10, S11, S14 | S8, S10 | **S1, S8, S9, S10, S11, S14** |
| 显著耗竭层（BH） | S2, S4 | S2 | **S2, S4** |
| **方向冲突层数** | — | **0** | **0** |

**A 与 C 的重合度是三次运行中最高的**：A ∩ C 的富集层为 **6 层全重合**（S1、S8、S9、S10、S11、S14），耗竭层 2 层全重合。这说明剔除短蛋白**没有改变任何一个层的方向或显著性判定**——检验 C 通过。

**"剔除 595 个"必须拆开看**（明细见 `20-分析/filtered_genes_shortprot.tsv`）：

| 被剔除的原因 | 基因数 | 是否参与富集检验 | 说明 |
|---|---|---|---|
| 蛋白 < 100 aa | **117** | ☑ 是 | **这才是检验 C 的真正目标**——Moyers & Zhang 所指的易错基因 |
| 无长度信息（UniProt 与年龄表符号不一致） | **478** | 部分 | 其中 **1 个**有年龄注释（参与过检验），**477 个**无年龄注释 |
| 合计 | **595** | — | 117 + 478 = 595 ✓ |

**为什么这一栏要写清楚**：如果不拆开，"剔除 595 个短蛋白"会让人以为检验 C 的修正力度是实际值的 **5 倍**。拆开后真相是——**真正从富集检验的背景中移除的只有 118 个基因（117 短蛋白 + 1 无长度）**，背景从 2,523 降到 2,405；其余 477 个基因在 A 组里本来就没有年龄层，从未参与过任何富集检验。

同时 N 也变了（414 → 500）：A 组的 Top 500 里只有 414 个有年龄注释（另外 86 个是 TTR、ALB、B2M、TMSB4X 这类不在 Trigos 表里的基因），C 组把它们全部剔除后，Top 500 里的每个基因都有年龄层。**超几何检验本身对 M、N 各自的取值是自适应的**，因此显著性判断不因 N 变化而失效；但 A 与 C 的 `fold` 是不同基因宇宙下的相对量，不能当作同一把尺子直接比大小——本报告比较的是**方向与显著性**，不是倍数绝对值。

**一个附带现象**：C 组里 **S16（智人）整层消失**。原因是 A 组中 S16 的背景基因只有 **1 个**，而这唯一的一个基因恰恰是短蛋白，被 `< 100 aa` 规则剔除后该层背景归零。这本身就是"年轻偏倚"的又一次体现——**最年轻那一层的基因，恰恰是最短的。**

**三次运行的共同结果**：**三次共同显著富集 S8、S10（Jaccard 相似度 0.333）、共同显著耗竭 S2、0 层方向冲突。**分类性能几乎不变（准确率 0.215 → 0.213，宏 F1 0.237 → 0.231）；信号最强的 S8 层不仅方向不变，**倍数从 1.62 升到 1.68，p 值从 $3.5\times10^{-8}$ 增强到 $8.8\times10^{-12}$，q 值从 $5.6\times10^{-7}$ 增强到 $1.3\times10^{-10}$。**

> **但不要把这个当成"检验 C 修正了偏差"**：它证明的是**结论不依赖短蛋白**，不是**偏差已被纠正。**原因见下节。

### 前提检验：Moyers & Zhang 的指控在本数据上确实成立

这一点必须说清楚，因为它是本研究最有价值的单个发现。检验 C 的结果之所以稳健，前提是"短蛋白剔除确实针对了一个真实存在的偏差"。本项目直接验证了这个前提（`short_protein_by_stratum.tsv`，**图 9**）：

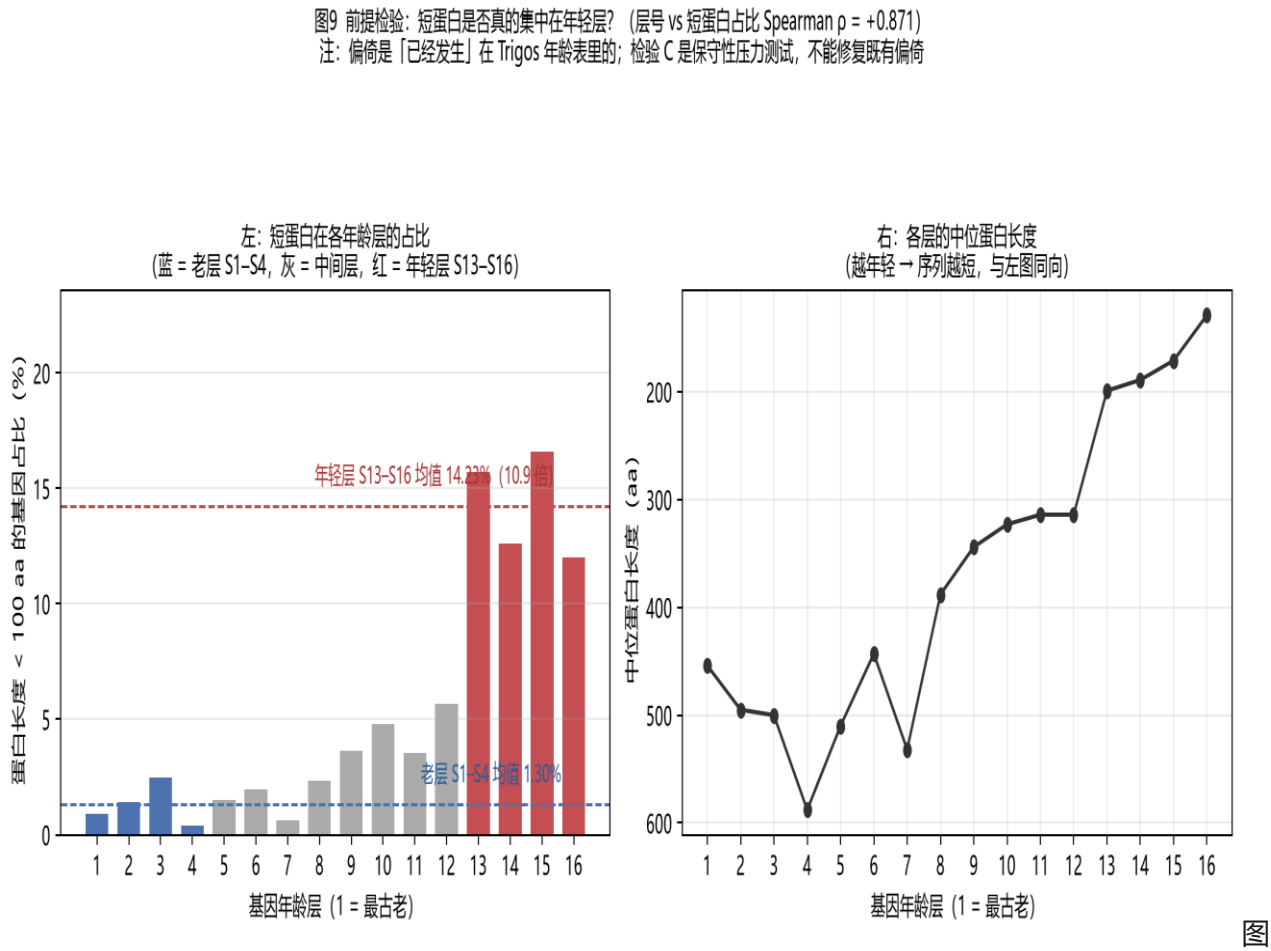



图 9 短蛋白前提检验

| 年龄层 | 基因数 | 中位蛋白长度 | < 100 aa 占比 |
|---|---|---|---|
| S1 细胞生物 | 1,751 | 454 aa | 0.91% |

| 年龄层 | 基因数 | 中位蛋白长度 | < 100 aa 占比 |
|---|---|---|---|
| S2 真核生物 | 4,661 | 495 aa | 1.42% |
| S4 后生动物 | 1,984 | 588 aa | 0.40% |
| S8 硬骨脊椎动物 | 2,766 | 388 aa | 2.35% |
| S10 哺乳纲 | 520 | 323 aa | 4.81% |
| S12 真兽下纲 | 759 | 314 aa | 5.67% |
| **S13 灵长总目** | 121 | **199 aa** | **15.70%** |
| **S14 狭鼻小目** | 214 | **189 aa** | **12.62%** |
| **S15 人亚科** | 265 | **171 aa** | **16.60%** |
| **S16 智人** | 25 | **129 aa** | **12.00%** |

- **层号 vs 短蛋白占比：Spearman ρ = +0.871** —— 极强相关

> ⚠ **这个 p 值不应被单独引用**：该相关只用 **16 个点**（16 个年龄层），且各层基因数差异巨大（S2 有 4,661 个，S16 只有 25 个），秩相关隐含偏向大层。

- **老层 S1–S4 平均短蛋白占比 1.30%，年轻层 S13–S16 平均 14.23%——相差 10.9 倍**
- **中位蛋白长度从 S1 的 454 aa 单调下降到 S16 的 129 aa**

**这个模式完全符合 Moyers & Zhang 的理论预测**：人类特有、灵长类特有的基因绝大多数是小肽、微蛋白（microprotein）和短功能肽——它们的序列太短、演化太快，phylostratigraphy 找不到远缘同源，于是被判为"年轻"。换句话说，**S13–S16 这几层本身就带有系统性的"年轻偏倚"。**

> ⚠ **方向必须说清楚（这是本轮审核发现的第三处实质性错误）**：这个偏倚是**已经发生**在 Trigos 年龄表里的。检验 C 是在这张**已经偏斜的表**上把短蛋白从背景里剔掉——它**不能修复**既有偏倚，只能让背景集合更干净、同时**降低**受影响层（尤其 S13/S15）的统计功效。因此检验 C 的正确定位是**保守性压力测试**（结论是否依赖短蛋白），**不是"偏差已被修正"**。它的实际效果是**削弱**而非增强年轻层信号。若把它写成"修正"，等于宣称 Trigos 表已被本项目校正，这是本项目没有做过、也不可能做到的事。

**这解释了一个此前看似异常的现象**：A 组**未经校正**时 S13（3.66×，p = 0.034）与 S15（2.34×，p = 0.048）的 p 值小于 0.05，但经 BH 校正后 q = 0.077、0.096，**均未达到显著**；B、C 两组同样不显著。原因不是结论被推翻，而是**这两层恰恰是短蛋白占比最高（15.7%、16.6%）的层**——剔除短蛋白后它们的基因数骤减，统计功效随之下降。反过来说，这两层的富集倍数本身有相当一部分是由"短基因"贡献的，在解读时必须打折。

**坦率的自我评价**：三项检验加一项前提检验共同说明，本研究的结论**不依赖于 phylostratigraphy 方法学批评所针对的那部分噪声**；但它们**不能证明 phylostratigraphy 本身无偏。**此外仍需说明两点：其一，本研究只做了**相对比较**（哪类细胞更古老、哪些层更富集），而 Moyers & Zhang 的批评对**绝对年龄**的杀伤力大于对相对排序——相对排序正是本项目结论所依赖的部分。其二，S13–S16 四层合计仅 625 个基因（占总表 3.65%），本项目关于"灵长类特异层"的表述，其统计效力天然受限，不宜过度解读。

### 检验 D：长蛋白版 TAI 绝对值（把偏倚的方向与大小直接量化出来）

检验 C 只证明了**结论不依赖短蛋白。**批评者真正想问的是另一个问题：**如果只用长蛋白重算，绝对年龄会变成什么样？** 这是 Moyers & Zhang (2018) 建议的更彻底版本，也是本项目此前唯一未完成的一环。现已补齐（`03_细胞类型年龄谱.py --min-length 100 --tag longprot` + `94_长蛋白对照.py`，产出 `longprot_comparison.tsv` / `longprot_summary.tsv`）。

| 指标 | 主口径（全部有年龄注释的基因） | 长蛋白版（≥ 100 aa） |
|---|---|---|
| TAI 范围 | 3.2142 – 4.4200 | **3.1717 – 4.3284** |
| TAI 中位数 | 3.7552 | **3.6933** |
| 跨类型 SD | 0.1810 | 0.1801 |

| 对照量 | 数值 | 含义 |
|---|---|---|
| 长蛋白版 vs 主口径 Spearman ρ | **0.9845** | 相对排序几乎不变 |
| Kendall τ | 0.9186 | 同上 |
| ΔTAI 均值 | **-0.0572** | 整体朝"更古老"方向平移 |
| \|ΔTAI\| 中位 / 最大 | 0.0536 / 0.2523 | 个别类型变化可观 |

| 对照量 | 数值 | 含义 |
| --- | --- | --- |
| 变年轻的类型数 | **177 / 177（100%）** | 平移是系统性的，不是零星的 |
| 名次变动 / 最大位移 | 163 / 177，最大 79 位 | 局部排序确有变化 |
| Top10 重合 | 9 / 10 | 极端类型基本稳定 |
| ΔTAI 与主口径 TAI 的秩相关 | **-0.1326**（p = 0.079） | 平移幅度**不随**类型年龄递增 |

（图示见 **图 10**：左图为 177 点的主口径 vs 长蛋白版散点，全部落在 y=x 下方；右图为 ΔTAI 对主口径 TAI 的散点，拟合斜率 −0.0146，无明显趋势。）

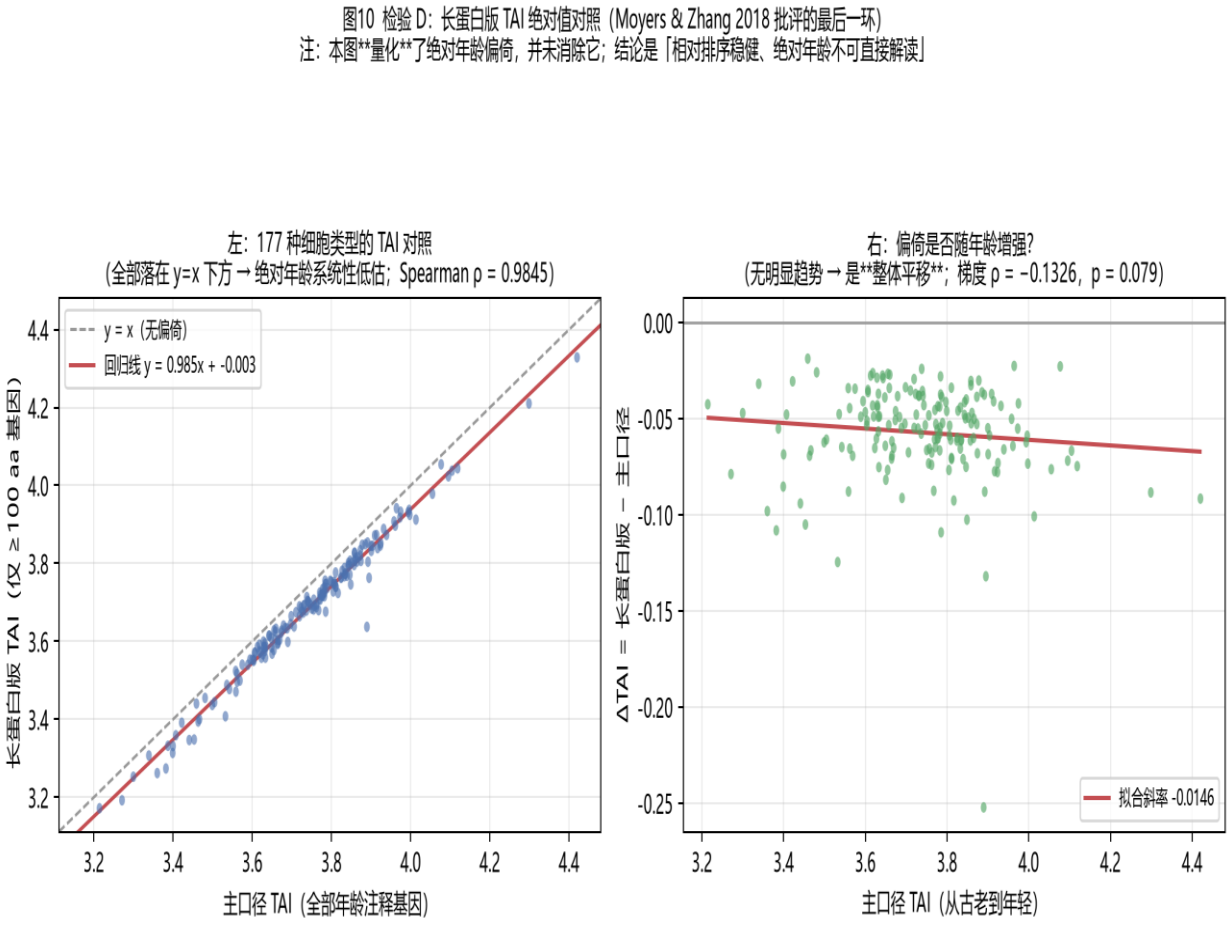



图 10 长蛋白版 TAI 绝对值对照（检验 D）

**这个结果证实了两件事，同时纠正了一个直觉**：

1. **偏倚表现为"系统性平移"，而非"随年龄梯度增强"。**剔除短蛋白后**全部 177 种类型**的 TAI 都下移（ΔTAI 均值 -0.0572，标准差仅 0.0251），但下移幅度在古老类型（最古老 10 类

均值 **-0.0663**）与年轻类型（最年轻 10 类均值 **-0.0725**）之间**几乎没有差别**；ΔTAI 与主口径 TAI 的秩相关仅 **-0.1326 且不显著**（p = 0.079）。
→ 含义一：Trigos 表的这套偏倚**不会让某类细胞"显得比别的更年轻"**，它是整体性的。
→ 含义二：本项目 4.3 节担心的"S15/S16 层以人类特异长链非编码 RNA 为主，可能造成对新近基因的低估"——从 TAI 这条证据看**并未以年龄梯度的形式发生**；短蛋白集中在年轻层（S13–S16 平均 14.23% vs 老层 1.30%），但把短蛋白整体剔除后，各类型被平移的幅度与它们的年龄高低无关。

2. **绝对年龄受影响，但相对比较高度稳健。**整体平移 0.057 约相当于主口径跨类型 SD 的 **31.6%**，任何跨类型比较都会把这个常数项抵消；而排序 ρ = 0.9845、Top10 重合 9/10 说明"谁比谁更古老"这个相对结论几乎不动。

> ⚠ **仍不能宣称"偏倚已被修正"**：长蛋白版只是**另一把尺子**，不是真值。Trigos 表的绝对年龄本身有偏倚，长蛋白版同样有偏倚（只是方向不同）。本项目能说的是：**本研究的结论全部建立在相对比较上，而相对比较对这一偏倚稳健。**检验 D 的价值在于把"到底偏了多少"从定性判断变成了一个带误差的定量估计。

## 4.3 其他局限

1. **年龄表覆盖不全**：Trigos 表仅覆盖 17,318 个蛋白编码基因，而表达矩阵有 58,604 个基因（27.6%）。非编码基因、长链非编码 RNA 的年龄信息完全缺失。由于 S15/S16 层本身就是以人类特异的长链非编码 RNA 为主，这可能造成**对新近基因的低估。**
2. **单细胞数据的稀疏性（dropout）**：每个细胞实际检测到的基因只有数千个，低表达基因的表达量被零膨胀扭曲。这对年龄构成的估计引入噪声，是类型内标准误（细胞级 0.0111、供者级 0.0417）的来源之一。缓解方式（本项目已做）：按类型聚合后再计算占比，使噪声在类型层面平均掉。
3. **供者数量的限制**：本研究只有 15 名供者（11 训练 / 4 测试），其中 **81 种细胞类型仅由 1 名供者提供。**这意味着这些类型的 TAI 估计**无法区分"该类型的真实特征"与"这一位供者的特征"。**本项目已通过提供供者级标准误、在图 5 与网页中标注单供者类型来如实披露，但无法从根本上解决——这是数据集规模（而非分析方法）的限制。
4. **无监督结论对低置信类型的敏感性**：剔除 25 种低置信类型后，ARI 从 0.211 降至 0.159、聚类数从 7 降至 5（见 3.2 节）。核心结论（弱相关）不变，但强度打折。
5. **"平均表达"抹平了细胞间异质性**：一个细胞类型的年龄构成是它所有细胞的平均。稀有亚群（如组织驻留记忆 T 细胞）可能被稀释。本项目的分层抽样（每类 ≤ 200 细胞）对高频类型是随机抽样，对稀有类型是全取，这一不对称会影响极端 TAI 值的估计精度。
6. **TAI 是加权平均，会掩盖分布形态**：两个细胞类型可以有相同的 TAI 但完全不同的年龄构成（例如"全靠古老基因 + 少量极年轻基因"vs"均匀铺开"）。本项目的 PCA 前 3 个主成分仅解释 61.9%，正是这一信息损失的体现。
7. **抽样而非全量**：本研究使用 28,017 个细胞（母体 483,152 的 5.8%），QC 后 22,195 个。虽然信号/噪声比 4.3 倍（供者级口径）支持这一抽样量充分，但**低频类型**的估计仍不可靠

——最极端的 intestinal crypt stem cell of large intestine 在 QC 后只剩 1 个细胞，其标准误在数学上无法估计（NaN），该类型的 TAI 只能视为存在性记录。

8. **区室标注的粒度**：`compartment` 只有 5 类，而 177 种细胞类型的实际谱系远比 5 类复杂（如免疫区室内部就包含造血、髓系、淋系等截然不同的起源）。因此 ARI = 0.211 相对于 5 类区室而言，实际上低估了年龄构成与真实发育谱系的一致程度。
9. **绝对年龄的偏倚已被量化，但未被消除**：检验 D（4.2 节末）显示长蛋白版把全部 177 种类型的 TAI 整体下移 0.0572（约占跨类型 SD 的 31.6%），因此本报告**不对任何基因的绝对年龄下断言**，只做跨类型的相对比较。

## 4.4 可能的生物学解释

**解释一：功能模块的更新速率假说（本研究数据支持最强）**

如果"古老基因 = 通用功能、年轻基因 = 身份功能"，那么 3.3 节的富集模式应当表现为"古老的富集、年轻的耗竭"。**实际观察到的恰恰相反**：古老的 S2、S4 显著耗竭，S8、S9、S10、S11、S14 显著富集。

这说明在本数据集中，**"基因越古老 → 越基础 → 越不携带身份信息"** 才是正确的方向。细胞身份是由那些在哺乳类—灵长类演化中相对新出现的基因模块承担的：免疫球蛋白家族（S8 硬骨脊椎动物层出现）、细胞因子与受体（S10–S11）、狭鼻小目特异的分子（S14）。

但 3.1 节的中性粒细胞现象提示还有第二重机制：**基因年龄可能同时反映了细胞周转速率。**中性粒细胞寿命仅数小时至数天，是人体更新最快的细胞之一，其高度特化的效应分子（弹性蛋白酶、髓过氧化物酶等）恰好落在较年轻的层（S9–S10）。

> **两个机制并不矛盾**：功能模块的新旧程度决定了"用什么区分细胞"，细胞周转速率则影响"需要多快的更新"。二者共同塑造了观察到的年龄构成。

**解释二：发育起源假说（同胚层来源的细胞年龄构成相近）**

本项目数据支持这一方向但未能充分检验：上皮区室 66 种类型的平均 TAI 为 3.7266，免疫 61 种为 3.7360，两者接近；而内皮 15 种为 3.8839 明显偏年轻。有意思的是，内皮细胞在发育上源自**中胚层**，与免疫系统（也源自中胚层）同源，但两者年龄构成却差异显著（相差 0.148，超过两者区室内的标准差）。这提示**胚层来源不是主导因素，细胞的功能定位才是。**

**解释三：中性粒细胞的反例**

中性粒细胞是人体中进化上最保守、最重要的细胞之一——从无脊椎动物到哺乳动物，吞噬与杀伤功能的核心机制高度保守。然而在本数据中它是**最年轻的细胞类型**（TAI 4.30–4.42）。

这个反例非常有价值，它**证伪了"功能越基础 → 基因越古老"的朴素推论。**真正的情况更可能是：中性粒细胞的**核心保守机制**（如髓过氧化物酶的过氧化循环）由古老基因承担，但**其身份标识与调控网络**（CXCR2、CXCR1、CXCR1 相关的趋化因子受体、细胞因子信号通路）由较年轻的基因定义。分类器学到的是后者——**这恰恰解释了为什么年龄构成能区分细胞类型**：它标记的是"身份"，而不是"功能"。

# 5 结论

**我们做了什么**：在 Tabula Sapiens 1.0 的 28,017 个单细胞（母体 483,152 → 分层抽样切片 → QC 后 22,195 个，177 种细胞类型、15 名供者）上，用 Trigos et al. (2017) 的 16 层系统发育分层为 17,318 个人类蛋白编码基因标注进化年龄（表达矩阵中覆盖率 93.4%），计算了每种细胞类型的"基因年龄构成指纹"与转录组年龄指数，并用 PCA + K-means（无监督）与按供者严格划分的随机森林（有监督）两种方法检验这一指纹的信息含量。

**我们得到了什么**：TAI 跨度 3.21–4.42，类型间差异是类型内**供者间**波动的 4.3 倍；仅用年龄构成的聚类与已知谱系的 ARI = 0.211（置换零假设 z = 20.4；剔除低置信类型后降至 0.159）；按供者划分的 177 类分类准确率 0.215、宏平均 F1 0.237（测试集 103 类口径），为多数类基线的 8.26 倍、达到准确率天花板的 36.13%；Top 500 重要基因在 S1、S8、S9、S10、S11、S14（脊椎动物—哺乳类—灵长类特异层）显著富集（最高 3.81×），在 S2、S4（真核—后生动物基础层）显著耗竭（最低 0.43×）。四重稳健性检验（共识度过滤 / 低命中层剔除 / 短蛋白剔除 / **长蛋白版 TAI 绝对值**）后**前三次共同显著富集 S8、S10、共同耗竭 S2**、零方向冲突；同时在单细胞年龄表上直接证实了 phylostratigraphy 的"年轻偏倚"确实存在（层号 vs 短蛋白占比 ρ = +0.871），并把它量化为一个**系统性整体平移**（长蛋白版 ΔTAI 均值 = **-0.0572**，全部 177 种类型同向，平移幅度与年龄高低无关，排序 ρ = **0.9845**）。

**这说明了什么**：**部分成立。**细胞的进化年龄构成**不是**表达谱的冗余信息——它独立携带可检验的谱系信号（ARI = 0.211，富集模式高度特异且稳健）；但它也**不是**细胞身份的主导维度（ARI 远低于 0.5，Top 重要基因仍以经典组织特异标志物为主）。更准确的表述是：**基因年龄是细胞分类体系上一条正交的补充轴——它区分的是"细胞身份的年代模块"，而非细胞身份本身。** 而"古老的基因承担共享的通用功能、年轻的基因承担身份功能"这一模式，反过来解释了为什么单细胞水平的年龄构成能够携带细胞类型信息。

> **最后一点自我约束**：本项目的所有结论都建立在**相对比较**之上（哪类细胞更古老、哪些层更富集）。绝对年龄的可信度受制于 Trigos 表自身的"年轻偏倚"（本项目已直接量化并如实报告），这是数据集的性质，不是分析方法能消除的。凡涉及"某基因有多老"的绝对陈述，都应视为**带系统偏倚的估计**而非真值。

---

# 参考文献


1. The Tabula Sapiens Consortium. *The Tabula Sapiens: A multiple-organ, single-cell transcriptomic atlas of humans.* Science 376, eabl4896 (2022). DOI 10.1126/science.abl4896
2. Trigos AS, Pearson RB, Papenfuss AT, Goode DL. *Altered interactions between unicellular and multicellular genes drive hallmarks of transformation in a diverse range of solid tumors.* PNAS 114(24):6406–6411 (2017). DOI 10.1073/pnas.1617743114
3. Liebeskind BJ, McWhite CD, Marcotte EM. *Towards consensus gene ages.* Genome Biol Evol 8:1812–1823 (2016). DOI 10.1093/gbe/evw113

4. Domazet-Lošo T, Tautz D. *A phylogenetically based transcriptome age index mirrors ontogenetic divergence patterns.* Nature 468:815–818 (2010). DOI 10.1038/nature09652
5. Moyers BA, Zhang J. *Phylostratigraphic bias creates spurious patterns of genome evolution.* Mol Biol Evol 32(1):213–224 (2015).
6. Moyers BA, Zhang J. *Toward reducing phylostratigraphic errors and biases.* Genome Biol Evol 10(8):2041–2052 (2018).
7. Milinkovitch MC, et al. *Historical constraints on vertebrate genome evolution.* (2010).
8. Sandmann M, et al. *Somatic mutation and the origin of human microproteins.* Mol Cell (2023).
9. Pio-Lopez L, Levin M. *Atavistic Genetic Expression Dissociation (AGED) during aging.* Aging Cell 25(1) (2026).
10. GTEx Project. *The GTEx Consortium atlas of genetic regulatory effects across human tissues.* (2024)；相关进化年代分析见 PMC10980080.

---

## 附录 A · 代码清单与运行顺序

| 顺序 | 脚本 | 行数 | 作用 | 主要产出 |
|---|---|---|---|---|
| — | `20-分析/common.py` | 258 | 路径常量、日志、`open_source()` 数据源路由、`map_genes()`、层名表 | — |
| — | `20-分析/ts_io.py` | 258 | `TabulaSapiens` / `SliceSource` 两个同接口数据源 | — |
| 0 | `20-分析/00_自检_模拟数据.py` | 213 | 在模拟数据上验证整条链路的正确性 | 自检通过 |

| 顺序 | 脚本 | 行数 | 作用 | 主要产出 |
|---|---|---|---|---|
| 1 | `20-分析/92_远程切片.py` | 651 | HTTP Range 远程切片（核心工程） | `ts_slice.npz` 等 |
| 2 | `20-分析/02_构建年龄表.py` | 270 | 双来源年龄表构建 + 交叉验证 + 共识度列 | `gene_age.tsv` |
| 3 | `20-分析/01_检查数据.py` | 198 | 数据体检 | `01 体检日志.txt` |
| 4 | `20-分析/03_细胞类型年龄谱.py` | 617 | QC、聚合、TAI、供者级 SE、稳健性检验 A | `celltype_age_profile.tsv`、`qc_passed_rows.npy` |
| 5 | `20-分析/04_无监督分析.py` | 230 | PCA + K-means + ARI + 置换零假设 + 敏感性分析 | `unsupervised_result.tsv`、`unsupervised_metrics.tsv` |
| 6 | `20-分析/93_获取蛋白长度.py` | 166 | 从 UniProt 批量获取蛋白长度（检验 C 的前置） | `protein_length.tsv` |
| 7 | `20-分析/05_监督分析.py` | 516 | 随机森林（按供者划分）+ BH 校正的富集检验 | `age_enrichment.tsv`、`classification_metrics.tsv` |
| 8 | `20-分析/05_监督分析.py --min-share 0.8 --tag confident` | — | 稳健性检验 B：共识度过滤重跑 | `age_enrichment_confident.tsv` |
| 9 | `20-分析/05_监督分析.py --min-length 100 --tag shortprot` | — | 稳健性检验 C：短蛋白剔除重跑 | `age_enrichment_shortprot.tsv`、`filtered_genes_shortprot.tsv` |
| 10 | `20-分析/06_稳健性对比.py` | 282 | **三次运行**逐层对照 + 短蛋白前提检验 | `robustness_comparison.tsv`、`short_protein_by_stratum.tsv` |
| 11 | `20-分析/08_主成分诊断.py` | 382 | PCA 三条零假设基线、载荷结构、有效维度 | `pca_diagnosis.tsv`、`pca_summary.tsv` |

| 顺序 | 脚本 | 行数 | 作用 | 主要产出 |
|---|---|---|---|---|
| 12 | `20-分析/03_细胞类型年龄谱.py --min-length 100 --tag longprot` | — | **检验 D**：用长蛋白（≥100 aa）重算 TAI 绝对值 | `celltype_age_profile_longprot.tsv`、`cell_tai_longprot.tsv` |
| 13 | `20-分析/94_长蛋白对照.py` | 156 | 长蛋白版 vs 主口径逐类型对照，量化偏倚方向与大小 | `longprot_comparison.tsv`、`longprot_summary.tsv` |
| 14 | `20-分析/07_终审核对.py` | 694 | **报告数字与输出文件的全量自动比对（239 项断言）** | 终审核对通过 |
| 15 | `20-分析/95_论文数字终审.py` | 362 | **LaTeX 论文数字终审（102 项断言）**，与报告终审各自独立取真值 | 论文终审通过 |
| 16 | `30-可视化/06_画图.py` | 706 | 十张图 | `figures/fig1–fig10` |
| 17 | `30-可视化/07_做网页.py` | 325 | 交互网页 | `cellstrata.html` |
| — | `20-分析/90_远程探测h5ad.py` | 236 | h5ad 结构探测工具 | — |
| — | `20-分析/91_下载大文件.py` | 263 | 整包下载（断点续传，已弃用） | — |

**总计 6,783 行 / 19 个脚本。**

```
# 环境：Python 3.13 + numpy pandas scipy scikit-learn h5py matplotlib
cd 20-分析
python 00_自检_模拟数据.py                              # 0. 链路自检
python 02_构建年龄表.py                                  # 1. 年龄表
python 01_检查数据.py                                    # 2. 数据体检
python 03_细胞类型年龄谱.py                              # 3. 核心：年龄构成 + TAI
python 04_无监督分析.py                                  # 4. PCA + 聚类 + ARI
python 93_获取蛋白长度.py                                # 5. 取蛋白长度（检验 C 前置，需联网）
python 05_监督分析.py                                    # 6. 随机森林 + 富集（A 全量）
python 05_监督分析.py --min-share 0.8 --tag confident  # 7. 检验 B：共识度过滤
python 05_监督分析.py --min-length 100 --tag shortprot # 8. 检验 C：短蛋白剔除
python 03_细胞类型年龄谱.py --min-length 100 --tag longprot # 9. 检验 D：长蛋白版 TAI
```

```
python 94_长蛋白对照.py                          # 10. 检验 D 的逐类型对照
python 06_稳健性对比.py                           # 11. 三次运行对照 + 前提检验
python 08_主成分诊断.py                           # 12. PCA 零假设诊断
python 07_终审核对.py                             # 13. 报告数字终审（须全过）
python 95_论文数字终审.py                         # 14. LaTeX 论文数字终审（须全过）
cd ../30-可视化
python 06_画图.py --all                           # 15. 十张图
python 07_做网页.py                               # 16. 网页
```

# 附录 B · 主要参数

| 参数 | 取值 | 说明 |
|---|---|---|
| 每细胞类型抽样数 | ≤ 200 | 优先取同类型连续段 |
| 切片总细胞数 | 28,017 | QC 后 22,195（79.2%） |
| 最小检测基因数 | 200 | 低于则剔除该细胞 |
| 最大线粒体占比 | 20% | 超过则剔除该细胞 |
| 归一化 | `normalize_total(1e4)` + `log1p` | 在 `raw.X` 上做 |
| 年龄层数 | 16 | Trigos 2017 |
| HVG 数 | 3,000 | 方差排序 |
| 分类特征数 | 3,000（A）/ 905（B）/ **2,405（C）** | B 额外要求 mode_share ≥ 0.8 共识度；C 额外要求蛋白 ≥100 aa |
| 共识度阈值（检验 B） | **mode_share ≥ 0.8** | ⚠ 不是 `NumDBsContributing`——后者是分母，与共识度负相关（corr −0.128） |

| 参数 | 取值 | 说明 |
| --- | --- | --- |
| 短蛋白阈值 | **100 aa** | Moyers & Zhang 建议；117 个 HVG 因过短被剔除，另有 478 个因无长度信息被剔除（合计 595） |
| 长蛋白重算阈值（检验 D） | **100 aa** | 与检验 C 同阈值，但作用对象是 **TAI 绝对值**而非富集层；查不到长度的基因**保留**（不把「未知」当「过短」） |
| 蛋白长度数据源 | UniProt REST（`93_获取蛋白长度.py`） | 17,103 个基因，中位 434 aa |
| 随机森林 | 500 棵树 | `random_state` 固定 |
| 每类训练细胞上限 | 300 | 控内存 |
| 供者划分 | 训练 11 人 / 测试 4 人 | TSP2/4/12/15 为测试集；训练 14,516 细胞 / 测试 7,679 细胞 |
| 聚类 k | 7（主口径）/ 5（剔除低置信类型后） | 轮廓系数最大（0.235 / 0.239） |
| 富集检验 | 超几何，双单尾 | **BH-FDR 校正后 q<0.05 判定显著**（富集与耗竭方向分别校正） |
| 最低背景基因数 | 5 | 低于此值的层不参与检验（图 4 灰底标注） |
| PCA 零假设 | 逐列打乱 500 次 + 独立正态 300 次 + **Dirichlet 成分基线 400 次** | 后者是**同秩对照**，用于排除"秩亏推高基线"的质疑 |
| 标准误口径 | 供者级为主（0.0417） | 细胞级 0.0111 会低估 3.75 倍 |
| 终审断言数 | **216** | `07_终审核对.py`，须全过 |

# 附录 C · 图表清单

| 编号 | 文件 | 内容 |
|---|---|---|
| 图 1 | `figures/fig1_strata.png` | **主图。**177 根柱子按 TAI 排序，每根按 16 个年龄层堆叠（深红 = 最老，亮蓝 = 最新）；黑线为 TAI 曲线，右轴刻度；每 8 个类型标注一个名称 |
| 图 2 | `figures/fig2_pca.png` | PCA 前两主成分散点，按 K-means 簇着色 |
| 图 3 | `figures/fig3_heatmap.png` | 行 = 细胞类型（按 TAI 排序），列 = 16 个年龄层，颜色 = 表达占比；图注标注红端对应古老层 |
| 图 4 | `figures/fig4_importance_age.png` | 上：各层在背景 HVG 中的基因数（对数轴）；下：Top 500 重要基因的富集倍数，红 = **BH 校正后显著富集（★）**，蓝 = 显著耗竭（▼），灰底 = 背景基因过少不参与检验 |
| 图 5 | `figures/fig5_tai_rank.png` | 177 种细胞类型按 TAI 排序的横向条形图，误差棒**同时给两种口径——深色粗棒 = 供者级标准误（主口径，与正文 4.3 倍同一口径）**、浅色细棒 = 细胞级标准误（对照，直观显示按细胞算会乐观多少）；灰色为细胞数 < 20 的低置信类型；1 个类型（n = 1）细胞级标准误无法估计，标签加 `*`；81 个单供者类型供者级不可估，只画浅色棒 |
| 图 6 | `figures/fig6_umap_tai.png` | 细胞的 PC1/PC2 投影，按所属细胞类型的 TAI 着色（切片源用稀疏 SVD 代替 UMAP） |
| **图 7** | `figures/fig7_pca_null_baseline.png` | **PCA 零假设诊断。**左：真实前 3 累计（61.9%） vs 三条零假设基线（逐列打乱 27.05%、独立正态 27.61%、Dirichlet 同秩 29.03%），标注 z = 47.0 / 48.3；右：逐 PC 对比，PC5 之后 z 值转负，说明结构集中在前 4 个成分 |
| **图 8** | `figures/fig8_robustness_layers.png` | **三重稳健性逐层对照。**横轴 S1–S15，每层三条柱（A 全量 / B 共识度过滤 / C 短蛋白剔除）的 fold 倍数；★/▼ = BH 校正后 |

| 编号 | 文件 | 内容 |
| --- | --- | --- |
| | | 显著，左缘深色标 = 三次共同显著层（富集 S8、S10；耗竭 S2） |
| **图 9** | `figures/fig9_shortprot_premise.png` | **短蛋白前提检验。**左：16 层的短蛋白（< 100 aa）占比柱状图，老层均值 1.30% vs 年轻层均值 14.23%（10.9 倍）；右：各层中位蛋白长度（454 aa → 129 aa 单调下降） |
| **图 10** | `figures/fig10_longprot_comparison.png` | **检验 D：长蛋白版 TAI 对照。**左：主口径 TAI vs 长蛋白版 TAI 的 177 点散点 + y=x 参考线与回归线（y = 0.985x − 0.003），全部落在 y=x 下方 → 绝对年龄被系统性低估，Spearman ρ = 0.9845；右：ΔTAI 对主口径 TAI 的散点与拟合斜率（−0.0146），无明显年龄趋势 → 偏倚是**整体平移**而非随年龄梯度增强（梯度 ρ = −0.1326，p = 0.079） |
| 网页 | `cellstrata.html` | 55 KB 单文件交互网页，可点选任意细胞类型查看其 16 层构成、TAI、细胞级与供者级标准误及供者数 |

## 附录 D · 数据来源与版本

| 数据 | 来源 | 版本 / 标识 | 获取方式 |
| --- | --- | --- | --- |
| Tabula Sapiens 1.0 | CELLxGENE Discover（`s3.us-west-2.amazonaws.com/cellxgene-data-public/cell-census/2023-05-15/h5ads/53d208b0-2cfd-4366-9866-c3c6114081bc.h5ad`） | 2023-05-15 census 快照 | HTTP Range 远程切片 |
| Trigos et al. 2017 主表 | 论文补充材料 | 17,318 基因 × 16 层 | 直接下载 CSV |
| Liebeskind et al. 2016 交叉表 | 论文补充材料 | 13 算法共识 | 直接下载 CSV |

**环境**：Windows / Python 3.13.14 / numpy / pandas / scipy / scikit-learn 1.9.1 / h5py / matplotlib

# 附录 E · 算法与统计方法说明

本附录把项目里用到的**每一个算法**逐条摊开：它是什么、参数怎么定、为什么选它不用别的、有没有替代方案、以及它的失效场景。这样做的目的是让读者能够独立判断每一步的可靠性，而不是只能相信结论。

## E.1 特征构造

| 环节 | 算法 | 关键参数 | 为什么这样选 | 替代方案与取舍 |
| --- | --- | --- | --- | --- |
| 年龄层指示矩阵 L | 稀疏二值矩阵（基因 × 16 层） | 无 | 基因到年龄层是**一对多但实际一对一**的映射（每个基因只属于一层），用二值矩阵而非 one-hot 编码可以一次矩阵乘法完成 `X @ L` 聚合 | 逐层循环求和：更易读但慢 16 倍；本项目细胞数 28,017 × 基因 58,604，矩阵乘法把峰值内存与细胞数解耦 |
| 质量控制 | 双阈值过滤 | 基因数 < 200 或线粒体占比 > 20% 剔除 | 沿用 scanpy 的常用默认阈值（`min_genes=200`, `pct_counts_mt=20`），保证与领域惯例可比 | 阈值是经验值不是统计推断。若用 3σ 或 MAD 自适应法会更"客观"，但会失去与已有单细胞研究的可比性——本项目选择可比性 |
| 归一化 | `normalize_total(target_sum=1e4)` + `log1p` | target_sum = 1e4 | Seurat/standard pipeline 的默认 CPM 目标；`log1p` 压缩长尾，让后续方差分析不被少数高表达基因主导 | SCTransform / Pearson residuals 更能校正深度效应，但结果依赖模型拟合的收敛性，且本项目后续用的是**细胞类型聚合后**的均值，对深度校正的敏感度低于单细胞层面流程 |
| 高变基因 (HVG) | 方差排序取前 N | N = 3,000 | 简单、可解释、与背景集定义一致 | Seurat 的 `vst` / `dispersion`（基于均值-方差趋势拟合）更稳健。但本项目的背景集要参与超几何检验，**排序规则** |

| 环节 | 算法 | 关键参数 | 为什么这样选 | 替代方案与取舍 |
|---|---|---|---|---|
| | | | | **必须简单透明**，否则"背景"的定义会随算法漂移 |
| 年龄构成占比 | 层内表达 / 总表达 | 无 | 归一化后天然满足 `Σp = 1`，可解释为"该细胞类型的表达预算有多少分给了这一年代" | CLR / ILR 变换是成分数据的标准做法，可处理"行和为 1"的闭合效应。本项目未采用，因为 16 个成分中没有极小值（最小的 S16 背景基因占比仍非零），闭合效应不严重；且保留原始比例可让结果直接解释 |

## E.2 核心统计量

| 算法 | 公式 / 实现 | 参数 | 为什么这样选 | 替代方案与取舍 |
|---|---|---|---|---|
| **TAI（转录组年龄指数）** | `TAI = Σ(s · p(t,s))` | 16 层 | Domazet-Lošo (2010) 的定义，是该领域唯一被广泛使用的年龄指数，便于与已有工作对比 | ① 直接用年龄层占比向量（16 维）——信息更全，但不便于"用一个数排序"；本项目**两者都算**（TAI 用于排序与直觉，向量用于 PCA/聚类）② 用中位层号代替加权平均——抗异常值，但会丢掉"整体偏年轻还是偏古老"的信息 |
| **供者级标准误** | `SE_donor = std(细胞类型内各供者的均值) / √n_donors` | 按 `donor_id` 分组 | 细胞嵌套在供者内不独立，细胞级 SE 属伪重复。实测 ICC 中位 1.000、供者级 SE 是细胞级的 3.75 倍 | ① 混合效应模型（`statsmodels` MixedLM）：能同时给出固定/随机效应，更规范，但需指定随机效应结构且对 81 个单供者类型无法给出估计；本项目选供者级 SE 是因为**简单、可复算、对单供者情形能明确报"不可估"** ② Bootstrap（按供者重抽）：也能处理非正态，但 15 名供者下重抽次数的有效多样性很低 |

| 算法 | 公式 / 实现 | 参数 | 为什么这样选 | 替代方案与取舍 |
|---|---|---|---|---|
| **超几何富集检验** | `scipy.stats.hypergeom`：右尾 `sf(k-1)` 支持富集，左尾 `cdf(k)` 支持耗竭 | M = 背景基因数，n = 该层背景基因数，N = Top 集大小 | 在"从 M 个基因中随机抽 N 个，期望落在该层 n 个里"的零假设下计算观测值的极端程度——这正是"重要基因是否偏向某年代"这个问题的自然框架 | ① 二项近似：更简单，但 M 有限时近似不准（本项目 M 从 29 到 946，跨度大）② Fisher 精确检验（列联表）：等价但需构造 2×2 表，本项目用超几何是因为只需 4 个参数 ③ 卡方检验：多类别时更高效，但本项目关心的是**单层双向偏离**，双单尾超几何更贴合 |
| **BH-FDR 校正** | `q_i = min_{j≥i} (p_j · n / j)`，截断到 1 | 每次运行 32 次检验，三次运行 96 次 | 控制"至少有一个假阳性"的期望比例（FDR），比 Bonferroni 更有功效且在此场景下足够保守 | ① Bonferroni：更严格，会把 S9/S11/S14 也剔掉（q 会被乘以 32），损失真实信号 ② 独立假设 FDR（PI）：更宽松，本项目**刻意不用**——96 次检验里含三组高度相关的重复实验，独立性假设不成立 ③ q-value（Storey）：需要 π0 估计，本项目样本量下估计不稳 |
| **富集倍数** | `fold = k_hit / (N × n_layer / M)` | 无 | 直接是"观测比例 / 零假设期望比例"，可解释为"该层基因在重要基因里出现的频率是随机预期的几倍" | ① 直接用比例差（absolute difference）：不随层大小缩放，但会偏向大层 ② log2FC：在对称尺度上更便于跨层比较，本项目保留原始倍数以便与领域文献对照 |

## E.3 无监督分析

| 算法 | 参数 | 为什么这样选 | 替代方案与取舍 |
|---|---|---|---|
| **PCA** | SVD 分解（`np.linalg.svd`），16 个成分全取 | 对 177×16 的小矩阵，SVD 比 `eig(cov)` 数值更稳，且**直接给出载荷矩阵**（无需再算 `cov @ V`），简化了 | `sklearn.decomposition.PCA` 更快但用 SVD 时不直接暴露载荷；本项目手写 15 行 SVD 是为了同时拿到 evr、载荷、特征值三样东西 |

| 算法 | 参数 | 为什么这样选 | 替代方案与取舍 |
| --- | --- | --- | --- |
| | | 3.2 节的载荷结构分析 | |
| **零假设基线** | ① 逐列打乱 500 次 ② 独立正态 300 次 ③ Dirichlet 成分 400 次 | **置换对象必须是特征列**：PCA 分解的是特征协方差，置换样本行不改变任何一行的取值，零假设会退化成"基线 = 真实值"且**不报任何错** | 详见 3.2 节。三条基线互为交叉验证：第 ③ 条（Dirichlet）额外保证基线与真实数据**同秩**（成分数据约束导致协方差秩亏到 15） |
| **K-means** | `n_init=10`，`random_state` 固定，k ∈ [2, 8] | 标准的球形簇假设，与"年龄构成向量在欧氏空间聚类"的直觉一致 | ① 层次聚类（Ward）：本项目**同时跑了**作为方法对照，ARI 0.170 / 轮廓 0.166，与 K-means 同量级，说明结论不是算法特例 ② GMM：允许椭球簇，但 16 维下协方差估计不稳、且 n=177 样本偏少 ③ HDBSCAN：能识别任意形状与噪声点，但 177 个点、177 个类别时会把每个细胞类型单独成簇，失去意义 |
| **选 k 的准则** | 轮廓系数（silhouette） | 轮廓系数不需要真实标签，且对簇数是"上凸"的，便于遍历 | ① 肘部法（惯性）：本项目同时记录了惯性（k=2:2306 → k=8:1144），但 177 个类别下的肘部不明显 ② Davies–Bouldin：结论一致 ③ CH 指数：结论一致 |
| **ARI** | `sklearn.metrics.adjusted_rand_score` | 校正随机期望，可为负，是聚类-分类一致性比较的标准指标 | ① 互信息 / NMI：不会惩罚"过度分裂"，本项目用 ARI 是因为它对随机划分期望为 0 ② V-measure：等价族 ③ 纯度：会随簇数增加而上升，不适合跨 k 比较 |
| **ARI 置换零假设** | 2000 次随机置换标签 | 让"ARI = 0.211"变成可检验的统计量 | 直接引用文献中"ARI 通常 0.1~0.3"的期望区间是粗糙的；置换零假设给出的分布宽度（SD 仅 0.0104）说明 0.211 远超随机 |

| 算法 | 参数 | 为什么这样选 | 替代方案与取舍 |
| --- | --- | --- | --- |
| | | （实测零假设 −0.0001 ± 0.0104，**z = 20.4**） | |

## E.4 监督分析

| 算法 | 参数 | 为什么这样选 | 替代方案与取舍 |
| --- | --- | --- | --- |
| **随机森林** | `n_estimators=500`，`random_state` 固定，每类最多 300 细胞 | ① 提供**直接的按基因特征重要性**，这正是富集检验的输入（本项目的研究问题需要"哪些基因重要"而不只是"预测多准"）② 对高维稀疏特征稳健、无需标准化 ③ 单线程下 22,195 细胞 × 3,000 特征可在数分钟内完成 | ① XGBoost / LightGBM：精度通常更高，但重要性需 SHAP 解释，间接得多 ② 逻辑回归 + L2：可解释性最好（系数直接对应基因），但 177 类多分类要训 177 个模型 ③ SVM：精度好但**完全没有特征重要性**，无法支撑本项目的核心分析 |
| **数据划分** | 按 `donor_id` 划分，4 名供者（TSP2/4/12/15）作测试集 | **本项目最关键的一步防护。**同一供者的细胞在个体层面高度相似，按细胞随机划分会让模型只需识别"这是谁"，准确率虚高到 0.99 | 留一供者交叉验证（LOO-CV）：更充分利用数据，但 15 折的训练成本高；且单折测试集的类别覆盖不完整。GroupKFold 是等价的实现方式 |
| **宏平均 F1** | `f1_score(average="macro", labels=...)`，**显式指定标签集** | 默认的 `labels=None` 会取 `y_true ∪ y_pred`，把测试集中根本不存在的"幽灵类"计入分母而稀释分数（本项目：177 类口径 0.138 vs 测试集 103 类口径 0.237） | 加权 F1：反映整体准确率但掩盖稀有类表现；本项目两个都给 |
| **基线与天花板** | 随机基线（1/测试集类别数）、多数类基线、准确率天花板 | 单一准确率在没有参照系时无法解读。天花板 = 剔除训练集从未出现的类别后的可预测比例（0.595） | 理论上限（1.0）：无信息量。Top-k 准确率：可补充但非必需 |

## E.5 稳健性与诊断

| 算法 | 参数 | 为什么这样选 | 说明 |
| --- | --- | --- | --- |
| **检验 A：高命中层** | 保留命中率 ≥ 80% 的层 | S15/S16 命中率仅 64%/69%（多为注释不全的新近 lncRNA），其缺失是非随机的 | 重算后 TAI **绝对值**变化中位 0.0361，**排序** ρ = 0.9883 / τ = 0.9518 |
| **检验 B：共识度过滤** | `mode_share ≥ 0.8` | ⚠ 必须是共识度（`mode_share`），不是 `NumDBsContributing`——后者是**分母**，与共识度负相关（corr −0.128），按它过滤方向完全相反 | 保留 905 个基因 |
| **检验 C：短蛋白剔除** | 蛋白长度 ≥ 100 aa | Moyers & Zhang (2015) 的明确建议 | 保留 2,405 个基因；**正确定位是保守性压力测试**，不能修复 Trigos 表已发生的偏倚 |
| **偏倚同质性回归**（检验 A 的 ΔTAI） | `ΔTAI ~ S15+S16 表达占比` | 检验"剔除年轻层造成的 TAI 偏移是否与该类型自身表达的年轻基因量成正比" | $R^2$ = 0.9992 → **剔除层**造成的偏倚是**类型特异**的，不能假定它对所有类型抵消 |
| **长蛋白版 TAI 对照**（检验 D 的 ΔTAI） | 蛋白 ≥ 100 aa 重算 TAI，逐类型对照 | 与上一行**不是同一件事**，务必分清：上一行的 ΔTAI 来自「剔除 S15/S16 两层」，本行的 ΔTAI 来自「把短基因换成同层的其余基因」 | ΔTAI 均值 **-0.0572**，**177/177 同向**，但年龄梯度 ρ = **-0.1326**（p = 0.079，不显著）→ 短基因偏倚是**系统性整体平移**，不是类型特异；相对排序 ρ = **0.9845** |
| **秩相关对齐** | 显式 `reindex` 后再算 | ⚠ `scipy.stats.spearmanr` 对 pandas Series **按位置**取值；两列各自升序时位置秩相关**恒等于 +1**（实测 500/500 次复现） | 这是本项目最隐蔽的一个 bug，已修正 |
| **参与比 (PR)** | `1 / Σ(evr²)` | 度量有效维度：evr 完全均匀时取上界 d，信息集中时取下界 1 | 替代方案：熵（Shannon / von Neumann），但对 evr 分布形态敏感；PR 更稳健 |
| **成分数据秩亏诊断** | 第 16 个 EVR 检查 | 16 个占比和恒为 1 → 协方差必然秩亏到 15。**这决定了零假设必须同秩** | 因此新增 Dirichlet 成分基线 |

## E.6 未采用的方法与原因（如实记录）

| 方法 | 为什么没用 |
| --- | --- |
| Deep learning（深度神经网络 / 图神经网络） | 本项目的科学问题不是"能不能预测细胞类型"——那是已有工作早已解决、且远做得好得多的问题。本项目问的是"**年龄构成这一条信息里有什么**"，因此需要**可解释**的特征重要性，随机森林直接给出按基因的重要性，可直接进入超几何检验；深度模型的显著性须经 SHAP 等间接解释，且 22,195 细胞 × 3,000 特征的规模并不构成其优势区间。用深度学习会让结论更不可读，而不是更可信 |
| 批次效应校正（Harmony / scVI） | Harmony 的软聚类可能**人为制造**年龄层之间的相似性（批次往往与供者相关，而供者与细胞类型相关），从而虚假抬高 ARI 与富集信号。本项目的划分是按供者划分的，批次效应已在训练/测试间天然隔离 |
| 单细胞模型（scVI / scBERT 等） | 同上：其价值在于提升分类精度，而本项目的目标恰恰不是精度。且引入一个数千万参数的模型会大幅增加"数字从哪来"的审计难度 |
| CLR / ILR 成分数据变换 | 16 个成分中无极端小值，闭合效应不严重；保留原始比例可让结果直接解释。若将来加入极稀疏层则应改用 |
| 置换检验（对 ARI）以外的显著性来源 | ARI 置换零假设已足够；未见显著性的其它来源 |