人体细胞类型的基因年龄构成：基于单细胞图谱的系统发育分层与机器学习分析

课程：生物信息学（2026 秋）· **形式**：个人独立完成
项目代号：细胞地层 CellStrata
版本：v1.1 · 2026-11-03（终审复核后定稿 · 239 项断言全绿）

摘要

基因有进化年龄——它最早出现在生命树的哪个节点；细胞有类型身份——它在组织中承担什么角色。这两个概念此前各自成熟，却很少在单细胞分辨率上被系统地放在一起检验。本研究提出一个可检验的假设：**细胞的身份不只是"表达哪些基因"，还可能是"表达哪个年代的基因"**。

数据取自 Tabula Sapiens 1.0（*Science* 2022，母体 483,152 个细胞、15 名供者、45 种组织、177 种人工审校的精细细胞类型）。因受限于单机带宽，采用 HTTP Range 远程切片方案按需读取 HDF5 分块，在 620 秒内取得 **28,017 个细胞 × 58,604 个基因**的原始 UMI 计数切片（经逐行校验与源文件完全一致）——这就是本研究的实际数据量。基因年龄采用 Trigos et al. (2017, *PNAS*) 的 **16 层**系统发育分层方案（17,318 个蛋白编码基因），并以 Liebeskind et al. (2016, *GBE*) 的 13 算法共识表做双来源交叉验证。质量控制后保留 **22,195 个细胞（79.2%）**，覆盖全部 177 种细胞类型。

主要结果有三项。**其一**，每种细胞类型的转录组年龄指数（TAI）跨度为 **3.21–4.42**，跨类型标准差 0.1810；按**供者层面**估计的类型内标准误中位数为 0.0417，信号/噪声 = **4.3 倍**（若按细胞层面估计则得到 16.3 倍，但那会把供者间波动误当作细胞间噪声，低估 3.75 倍）。最古老的是红系前体（3.21）与肾上皮细胞（3.27），最年轻的是 NAMPT 中性粒细胞（4.42）与中性粒细胞（4.30）。**其二**，仅用 16 维年龄构成这一条信息做无监督聚类，与已知谱系的一致性 ARI = **0.211**（置换零假设 −0.0001 ± 0.0104，**z = 20.4**）——年龄构成确实捕捉到了部分谱系信息，但远不足以单独定义细胞身份。**其三**，用随机森林按供者严格划分训练/测试（177 类），准确率 **0.215**、宏平均 F1 **0.237**（测试集 103 类口径；177 类口径 0.138）；随机基线 0.0097、多数类基线 0.026，为多数类基线的 **8.26 倍**；测试集中有 28 类在训练集中从未出现，涉及 3,109 个细胞（占测试集 40.5%），因此准确率的天花板为 0.595，本次达到 **36.13%**。提取的 Top 500 重要基因在年龄层分布上显著偏离背景：**硬骨脊椎动物（S8, 1.62×）、羊膜动物（S9, 1.81×）、哺乳纲（S10, 2.68×）、兽亚纲（S11, 3.15×）、狭鼻小目（S14, 3.81×）等脊椎动物—哺乳类—灵长类特异层显著富集，而真核生物（S2, 0.53×）、后生动物（S4, 0.43×）显著耗竭**（超几何双单尾检验 + BH-FDR 多重检验校正，正式判定以校正后 q < 0.05 为准）。

结论：**部分成立**。细胞身份的年代构成不是冗余信息——它独立于表达谱本身携带可检验的谱系信号；但它也不是细胞身份的主导维度，而是与"表达哪些基因"正交的一个补充轴。

方法学层面，本项目针对 phylostratigraphy 已知偏差（短基因更易被判为年轻）做了**四重稳健性检验**：剔除低置信度年龄调用、剔除低命中年龄层、剔除短蛋白（< 100 aa）后重跑，以及**用长蛋白重算 TAI 绝对值**。前三次运行的**共同显著富集层为 S8 与 S10、共同显著耗竭层为 S2**（Jaccard 相似度 0.333），**0 层方向冲突**；同时**直接证实了该偏差的存在**——年龄层号与短蛋白占比 Spearman ρ = **+0.871**（该相关仅用 16 个层，p 值不应被单独引用），年轻层短蛋白占比是老层的 **10.9 倍**。检验 D 进一步把偏倚量化：长蛋白版 TAI vs 主口径 Spearman ρ = **0.9845**（Kendall τ = 0.9186），ΔTAI 均值 = **-0.0572**，**全部 177 种类型（100%）同向平移**，且平移幅度与类型年龄高低无关（梯度 ρ = -0.1326，p = 0.079）——即偏倚是**系统性的整体平移**而非随年龄梯度增强，故相对比较稳健、绝对年龄不可断言。需说明方向：这一偏倚是**已经发生**在 Trigos 年龄表里的，检验 C 是在这张已偏斜的表上剔除短蛋白，其正确定位是**保守性压力测试**（检验结论是否依赖短蛋白），而非"已修正偏差"。

此外，本项目对"PCA 前 3 个主成分仅解释 61.9%、未达立项时 > 70% 的指标"给出了一个**基于零假设的科学解释**而非绕过它：以逐列置换构造的零假设基线为 **27.0% ± 0.7%**（独立正态对照 27.6%，Dirichlet 成分同秩对照 29.0%，三者一致），真实值超出基线 **47.0 个标准差**，且 16 维年龄构成实际压缩到 **6.12 个有效维度**（零假设下 14.74 维，Dirichlet 同秩基线 13.77 维）。这说明该指标在数据结构上设得过高——即使各年龄层完全独立，前 3 维也只解释 27.0%。

关键词：系统发育分层；基因年龄；转录组年龄指数；单细胞转录组；细胞类型；特征重要性；超几何检验；方法学偏差

---

1 引言

1.1 细胞类型是怎么被定义的

现代细胞生物学的分类体系建立在一组相当一致的标准之上：光学或电子显微镜下的**形态**，细胞在组织中的**解剖位置**，细胞表面或胞内的**分子标记物**（CD 抗原谱、转录因子谱），以及在单细胞转录组时代的**表达谱相似性**。这些标准有一个共同点——它们描述的都是细胞的**当下状态**。

用一句话概括现有分类体系：**"它现在是什么"**。

1.2 另一条轴：基因有出生时间

并非所有基因同时出现在生命史上。一个基因的"年龄"，定义为它在进化树上最早出现的节点。判定方法是 **phylostratigraphy（系统发育分层）**：取目标物种的全部蛋白序列，逐条与亲缘关系依次递减的物种集合做同源搜索（BLAST / DIAMOND），找到**最远的那个仍有显著同源性的物种**，该物种与目标物种的共同祖先所处的时代，就是这个基因的"出生时间"。

按此方法，人类蛋白编码基因通常被划分为 15–19 个年龄层，从"细胞生物"（约 35 亿年前）一直到"人类特有"（约 60–70 万年前）。Trigos et al. (2017) 提供了 17,318 个基因的 16 层年龄表，是目前规模最大、被引用最广的版本之一。

这套"年龄"并非纯粹的思维实验。一个基因能存在于某个演化阶段，通常意味着它在那个阶段获得了某种不可替代的功能，并因此受到纯化选择（purifying selection）的持续约束。也就是说：

> **基因年龄在某种意义上是"这个功能有多基础"的一个代理变量。**

1.3 已有工作与本研究的定位

把"基因年龄"和"细胞"放在一起的想法并非全新，但既有工作的粒度和视角都不相同。

已有工作	层面	做了什么	与本研究的关键差别
Milinkovitch et al. (2010)	组织	基因年龄 vs 表达的系统数量，结论为"古老基因表达于约 2 倍数量的系统中"	组织层面、且以"系统数量"为**单个标量**概括年龄
Domazet-Lošo & Tautz (2010)	全转录组	提出 TAI 指标本身	指标的开创，不涉及细胞类型
Trigos et al. (2017)	肿瘤 bulk	发现肿瘤中 TAI 降低	肿瘤组织混合，细胞身份不可分
GTEx 研究（PMC10980080, 2024）	组织 bulk	54 组织 × 5 个进化年代 × 三胚层分组	**bulk**，分辨率到组织而非细胞
GBE (2024, evae023)	脑区	脑各区 TAI 比较	只做脑区
AGED (Aging Cell, 2025–2026)	单细胞	8 个组织中衰老时古老基因表达上升、年轻基因被抑制	**纵向**（老年 vs 年轻），本项目是**横向**（静态图谱）
Sandmann et al. (2023)	蛋白	7,264 个人类小开放阅读框的进化起源	研究对象是微蛋白，非常规全转录组
Moyers & Zhang (2015/2017/2018)	方法学	论证 phylostratigraphy 系统性低估基因年龄且误差非随机	**方法学批评，本项目必须正面回应**（见 4.2）

本研究的差异化在于三点：其一，粒度——从 bulk 组织下沉到单细胞分辨率的 177 种精细细胞类型；其二，视角——把"年龄构成"从"某个组织的一个属性"翻转为"细胞类型的一张指纹"，并检验它能否**独立地**承担分类任务；其三，机器学习切入——不满足于描述性的年龄分布，而是用随机森林的特征重要性回答"区分细胞身份时，模型究竟依赖哪个年代的基因"这一可量化的问题。

> **诚实的定位声明**：这不是一项首创性研究。phylostratigraphy 与 TAI 均有明确先例，"基因年龄 × 细胞类型"的单细胞观察也偶见于文献。本研究的价值在于：**以更新的多器官单细胞数据、更细的粒度，配上严格的泄漏防护与统计检验，重做一遍并给出可复现的定量答案**，而不是宣称发现了新大陆。

1.4 研究问题

Q1（描述） 每种细胞类型的"基因年龄构成"是什么？是否存在明显分层——有的细胞几乎全用古老基因，有的大量使用年轻基因？

Q2（结构） 仅凭"年龄构成"这一个 16 维向量，能否自动把 177 种细胞类型分成有意义的组？分出来的组与已知谱系（免疫 / 上皮 / 间质 / 内皮 / 生殖系）吻合到什么程度？

Q3（机制） 用机器学习区分细胞类型时，模型最依赖的那些基因，是古老的还是年轻的？

---

2 数据与方法

2.1 单细胞数据：Tabula Sapiens 1.0

项	内容
出处	The Tabula Sapiens Consortium, *Science* 376, eabl4896 (2022). DOI 10.1126/science.abl4896
母体规模	483,152 个细胞 × 58,604 个基因；15 名供者（TSP1–TSP15）；45 种组织
细胞类型	**177 种** `cell_ontology_class`（人工审校的精细类型），另有 5 类 `compartment` 区室标注
文件	h5ad（AnnData，HDF5），10.02 GB
本项目使用	**28,017 个细胞**（每种类型 ≤ 200，分层抽样），QC 后 **22,195 个（79.2%）**
健康状态	全部 normal，无疾病状态混杂

为什么是 1.0 而不是 2.0：2.0 版（1,136,218 细胞）的 h5ad 分发于 `datasets.cellxgene.cziscience.com`，本机网络环境下该域名 TLS 握手被重置，45 GB 无法获取；可访问的 S3 备份仅含 1.0。177 种类型与 2.0 的 182 种在粒度上几乎等价，方法框架无需改动。

2.2 取数方案：HTTP Range 远程切片

这是本项目工程量最大、也最具方法学价值的部分。

问题：母体文件 10.02 GB，而本机实测 S3 单连接速率仅 0.24–1.2 MB/s；提高到 8–16 并发反而更慢（0.3–0.7 MB/s），说明限流主要来自并发而非带宽；两次整包下载分别卡死在 28%（2.85 GB）和 62%（6.22 GB），进程存活但不再传输数据。

思路：不整包下载，只读需要的那部分。HDF5 的 chunked 存储正好提供了这种能力——只要知道哪些 chunk 含有所需数据，就可以只发 Range 请求取回这些 chunk。

具体四步：

1. **抽样与行定位。**每种细胞类型取 ≤ 200 个细胞，且**优先从同类型连续段取**（按 `obs` 中细胞类型的游程长度降序排列），使选中的行落在少数连续区间。28,017 个选中行最终只覆盖 13,120 个 chunk 内的连续区间。
2. **行 → CSR 非零元区间。**CSR 矩阵的行指针 `indptr` 给出每行的非零元范围；行 → 非零元区间 → chunk 段的映射让"每个 chunk 只读一次"成为可能。
3. **按 chunk 粒度读取。**关键在于**让 h5py 自己定位数据**：`dset[a0:a1]` 由 HDF5 库依据对象头与 B-tree 解析地址，并自动解压 gzip 压缩的 chunk。
4. **连接复用与预取。**使用 `requests.Session`（每线程一个）复用 keep-alive 连接，并设置 `trust_env=False` 绕过系统代理；请求 block *i* 时并发预取后续 block。

一个必须记录的技术陷阱：本项目第一版切片脚本犯了一个看起来很合理的错误——按"元素序号 × 元素大小"计算字节偏移去读 `raw.X/data`。结果跑出的数据 `max=nan`（UMI 计数不可能是 NaN）。原因是 **chunked dataset 的数据位置由对象头 + B-tree 决定，不存在"元素序号 × 元素大小"这样的线性映射。**修正方式是不自己算偏移，改为按 chunk 粒度规划读取区间、交给 h5py 定位。修正后抽查 6 行（含最大表达行）与远程 h5ad 逐值比对，表达值与基因索引全部一致。

实测：总耗时 **620 秒**，远程读取流量 **3,711 MB**，共 **3,539 次 HTTP 请求**，产出 185.6 MB 的 CSR 稀疏矩阵（76,668,506 个非零元，密度 4.67%）。其中 `raw.X/indices` 部分为 354 次读、覆盖 13,120 个 chunk、耗时 585 秒。

> **两个容易混淆的数字，说明一下：**
> - **3,539 次请求**是实际发出的 HTTP Range 请求数（`data` 与 `indices` 两个 dataset 各占一部分）；**354 次**只是 `indices` 那一个 dataset 的读次数。规划阶段的"13,695 段"是逻辑区间数，与请求数不是一回事。
> - **3,711 MB 的实际流量 > 0.61 GB 的规划逻辑量**，因为 HDF5 的 chunk 是对齐存储且带 gzip 压缩——一个 chunk 解压后包含大量不属于目标行的间隙数据，读一个 chunk 就要付整个 chunk 的字节。

相较整包 10.02 GB，**流量降至 37%**；按本机实测最快的 1.46 MB/s 估算整包需约 1.9 小时，实际只用了 620 秒（约 1/10）。

抽样量为什么够：TAI 是加权均值型统计量。实测按**供者层面**估计的类型内标准误中位数为 0.0417，跨 177 种类型的 TAI 标准差为 0.1810，**信号/噪声 = 4.3 倍**——类型间差异远大于**供者间**波动，因此每类 200 个细胞足以支撑类型级比较。（若按细胞层面估计会得到 16.3 倍，但那把供者间波动误当作细胞间

噪声，低估 3.75 倍——见 2.5 节末。）25 种稀有类型在 QC 后不足 20 个细胞，已在所有结果中标记为"低置信"，不进入结论；另有 81 种类型仅 1 名供者，其跨供者不确定性无法估计，同样已在图 5 与网页中标注。

erythroid progenitor
kidney epithelial cell
plasmablast
myeloid progenitor
fast muscle cell
retinal ganglion cell
adipocyte
transit amplifying cell of large intestine
transit amplifying cell of small intestine
cardiac muscle cell
hematopoietic stem cell
immature enterocyte
slow muscle cell
pancreatic acinar cell
intestinal crypt stem cell
skeletal muscle satellite stem cell
plasma cell
sperm
pancreatic beta cell
pancreatic pp cell
dn4 thymocyte
paneth cell of epithelium of small intestine
dn3 thymocyte
enterocyte of epithelium of small intestine
intestinal crypt stem cell of small intestine
granulocyte
muscle cell
thymocyte
luminal epithelial cell of mammary gland
cd4-positive, alpha-beta t cell
eye photoreceptor cell
type ii pneumocyte
pancreatic delta cell
naive thymus-derived cd4-positive, alpha-beta t cell
luminal cell of prostate epithelium
innate lymphoid cell
basophil
t follicular helper cell
pancreatic alpha cell
goblet cell
melanocyte
cd4-positive alpha-beta t cell
plasmacytoid dendritic cell
leucocyte
fibroblast of breast
myeloid dendritic cell
cd4-positive, alpha-beta memory t cell
enterocyte of epithelium of large intestine
stromal cell
cd4-positive helper t cell
naive regulatory t cell
nkt cell
pulmonary ionocyte
tongue muscle cell
retina horizontal cell
b cell
cell of skeletal muscle
regulatory t cell
t cell
basal cell
epithelial cell of uterus
paneth cell of epithelium of large intestine
ciliated epithelial cell
cd8-positive, alpha-beta t cell
memory b cell
bronchial vessel endothelial cell
retinal bipolar neuron
medullary thymic epithelial cell
keratinocyte
duodenum glandular cell
dn1 thymic pro-t cell
intestinal enteroendocrine cell
mesenchymal stem cell
type i nk t cell
lung ciliated cell
intestinal tuft cell
pancreatic ductal cell
mature conventional dendritic cell
cd8-positive alpha-beta t cell
cd8-positive, alpha-beta cytotoxic t cell
endothelial cell of vascular tree
immature natural killer cell
endothelial cell of artery
cd8-positive, alpha-beta memory t cell
cd8b-positive nk t cell
ionocyte
vascular associated smooth muscle cell
bladder urothelial cell
cd141-positive myeloid dendritic cell
naive b cell
muller cell
hillock-club cell of prostate epithelium
retinal pigment epithelial cell
limbal stromal cell
naive thymus-derived cd8-positive, alpha-beta t cell
serous cell of epithelium of bronchus
myeloid cell
ciliated cell
basal cell of prostate epithelium
mature nk t cell
salivary gland cell
club cell of prostate epithelium
secretory cell
mesothelial cell
pancreatic stellate cell
mast cell
fibroblast
mature enterocyte
intrahepatic cholangiocyte
dendritic cell
tendon cell
smooth muscle cell
club cell
hillock cell of prostate epithelium
myofibroblast cell
classical monocyte
adventitial cell
schwann cell
macrophage
monocyte
double-positive, alpha-beta thymocyte
radial glial cell
connective tissue cell
non-classical monocyte
lymphatic endothelial cell
myometrial cell
bronchial smooth muscle cell
small intestine goblet cell
liver dendritic cell
vein endothelial cell
cd8-positive, alpha-beta cytokine secreting effector t cell
respiratory goblet cell
ciliary body
myoepithelial cell
lung microvascular endothelial cell
pericyte cell
hepatocyte
fibroblast of cardiac tissue
langerhans cell
serous cell of epithelium of trachea
mucus secreting cell
limbal stem cell
nk cell
corneal keratocyte
respiratory mucous cell
endothelial cell of hepatic sinusoid
retinal blood vessel endothelial cell
acinar cell of salivary gland
gut endothelial cell
duct epithelial cell
epithelial cell
type i pneumocyte
conjunctival epithelial cell
endothelial cell of lymphatic vessel
artery endothelial cell
ocular surface cell
intermediate monocyte
large intestine goblet cell
platelet
cardiac endothelial cell
tracheal goblet cell

图 5 177 种细胞类型的 TAI 排序与双口径误差棒

2.3 基因年龄表：Trigos et al. (2017) 与双来源交叉验证

项	内容
主表	Trigos AS, Pearson RB, Papenfuss AT, Goode DL. *PNAS* 114(24):6406–6411 (2017). DOI 10.1073/pnas.1617743114
内容	17,318 个蛋白编码基因 × 16 个 phylostratum（1 = 最古老）
交叉表	Liebeskind BJ, McWhite CD, Marcotte EM. *GBE* 8:1812–1823 (2016). DOI 10.1093/gbe/evw113
内容	13 个同源推断算法的共识结果，含 `NumDBsContributing`（支持该基因的算法数）与 `entropy`，覆盖 97.5% 的基因

16 个年龄层：

层	学名	中文	层	学名	中文
S1	Cellular organisms	细胞生物	S9	Amniota	羊膜动物
S2	Eukaryota	真核生物	S10	Mammalia	哺乳纲
S3	Opisthokonta	后鞭毛类	S11	Theria	兽亚纲
S4	Metazoa	后生动物	S12	Eutheria	真兽下纲
S5	Eumetazoa	真后生动物	S13	Euarchontoglires	灵长总目
S6	Bilateria	两侧对称动物	S14	Catarrhini	狭鼻小目
S7	Chordata	脊索动物	S15	Homininae	人亚科

层	学名	中文	层	学名	中文
S8	Euteleostomi	硬骨脊椎动物	S16	Homo sapiens	智人

> ⚠ **层号体系不可混用**：这 16 层**不等于**文献中常见的 Domazet-Lošo 19 层方案（后者多出 Deuterostomia / Vertebrata / Tetrapoda 三级）。两个体系的层名与层号会整体错位，混用会导致结论完全失效。

双来源交叉验证（由 `02_构建年龄表.py` 自动输出）：在 16,889 个两表可比的基因上，按 Liebeskind 的 8 个粗类别分组，各组在 Trigos 表中的**中位层号**依次为 1 / 1 / 1 / 2 / 4 / 5 / 8 / 11——**7 对相邻类别全部单调不违反，零违反。**Spearman ρ = 0.697（被 8 级变量的强并列压低），Kendall τ = 0.607。两个来源方法完全不同却给出一致的年龄序，是本项目方法可靠性的第一层证据。

与表达矩阵的对齐：表达矩阵的 `var` 索引是 Ensembl ID，基因符号在 `var['feature_name']` 中（其中 1,316 个带 `_ENSG` 后缀需剥离）。对齐后：

- 表达矩阵 58,604 个基因中 **16,177 个**有年龄注释（27.6%）
- 年龄表 17,318 个基因中 **16,177 个**在矩阵中找到（**93.4%**）

> **口径提示**：27.6% 与 93.4% 哪个才是验收指标？答案是后者。表达矩阵的 58,604 个基因包含大量非编码基因、假基因与注释版本差异造成的额外条目，而 Trigos 表只覆盖蛋白编码基因。因此"**年龄表基因覆盖率 93.4%**"才是数据可用性的正确度量；把分母换成表达矩阵基因数会得到一个没有意义的低比率。

分层命中率（各层基因在表达矩阵中的存在比例）：

```
S1:95%  S2:93%  S3:94%  S4:94%  S5:94%  S6:95%  S7:94%
S8:95%  S9:93%  S10:95% S11:96% S12:93% S13:94% S14:84%
S15:64% S16:69%
```

S1–S13 均在 93–96%，S14 略低，而 **S15（人亚科）与 S16（智人）分别只有 64% 与 69%。**原因是这两个层对应 600–700 万年前才出现的基因，多数是新近注释的 lncRNA 或 pseudogene，在 Tabula Sapiens 所用的参考注释版本中还不完整。**这一点直接决定了 4.2 节的稳健性检验设计。**

2.4 质量控制、归一化与聚合

1. **过滤**：在线性空间检测基因数 < 200 或线粒体基因 UMI 占比 > 20% 的细胞剔除
2. **归一化**：在 `raw.X`（原始 UMI 计数）上自行执行 `normalize_total(target_sum=1e4)` + `log1p`

> 注意：h5ad 的 `X` 已是 log 归一化值，`raw.X` 才是原始计数。**不能对已归一化的 `X` 再归一化一次。**

3. **按细胞类型聚合**：构造 58,604 × 16 的稀疏年龄层指示矩阵 L（基因 → 年龄层），用 `X @ L` 一次乘法得到每个细胞在各层的表达量，分块（20,000 细胞/批）累加。峰值内存与总细胞数无关。

2.5 年龄构成指纹与 TAI

对细胞类型 t 与年龄层 s，定义该层的表达占比：

$$p(t,s) = (\Sigma_{g \in S_s} E(t,g)) / (\Sigma_g E(t,g))$$

其中 E(t,g) 为细胞类型 t 中基因 g 的平均表达量，S_s 为第 s 个年龄层的基因集合。$\Sigma_s p(t,s) = 1$（数值验证通过，各行占比和精确等于 1，最大偏离 4.44e-16）。

转录组年龄指数（TAI）：

$$TAI(t) = \Sigma_{s=1}^{16} s \cdot p(t,s)$$

TAI 是年龄层的加权平均，**越小表示该细胞类型整体越依赖古老的基因。**

本项目同时计算**细胞级 TAI**（先算每个细胞的层占比再加权），用于估计类型内标准误：

$$TAI_{cell} = \Sigma_s s \cdot ((X \cdot L)_s) / (\Sigma_{s'} (X \cdot L)_{s'})$$

类型级与细胞级 TAI 的算法路径不同（前者先平均表达再算占比，后者先算占比再平均），实测最大差 0.0503（4.2%）。但这个差**不是随机抖动**：ΔTAI 的标准差为 0.0124，是类型内细胞级标准误中位数 0.0111 的 **1.1 倍**，且 ΔTAI 与 TAI 的相关系数为 **r = 0.384**——说明两者是**系统性偏移**而非相互独立的估计量，**不可互换使用。**

> **标准误必须在供者层面估计。**细胞嵌套在供者之内，同一供者的细胞高度相似，因此在细胞层面计算标准误属于**伪重复**（pseudo-replication），会把供者间波动误当作细胞间波动而低估不确定性。实测类型内组内相关系数（ICC）中位数为 1.000（96 个可算类型中全部 > 0.5），供者级标准误中位数为 **0.0417**，是细胞级 0.0111 的 **3.75 倍**。本报告的所有"信号/噪声"结论均采用**供者级**这一保守口径；另有 81 种细胞类型仅有 1 名供者，其跨供者不确定性无法估计，在图 5 与网页中均已单独标注。

2.6 机器学习方法

无监督分析（Q1 + Q2）：

- 对 177 × 16 的年龄构成矩阵做标准化 → PCA
- K-means 聚类，k 从 2 试到 8，**用轮廓系数选 k**；同时给出 Ward 层次聚类作为对照
- 与已知谱系的一致性用**调整兰德指数（ARI）**量化。谱系代理采用数据自带的 `compartment` 区室标注（免疫 / 上皮 / 间质 / 内皮 / 生殖系），并由 `lineage_map.tsv` 逐细胞类型映射

> **特征矩阵的构造须只含年龄层**：分析过程中额外产出了 `TAI_se`、`n_cells`、`low_confidence` 等派生列，这些列与年龄层是同源的派生量，混入特征矩阵会造成信息泄漏。本项目通过只取以 `s` 开头的列规避此问题。

有监督分析（Q3）：

- 任务：用单细胞表达谱预测细胞类型（177 类）
- **数据划分：按供者划分。**15 名供者中 11 人的细胞作训练集（**14,516 细胞**）、4 人作测试集（**7,679 细胞**，TSP2 / TSP4 / TSP12 / TSP15）

> **这是本项目最关键的一步防护。**同一供者的细胞在个体层面高度相似，若按细胞随机划分，模型只需识别"这是谁"，准确率会虚高到 0.99。按供者划分后，模型必须真正学会细胞类型的表达特征。

- 模型：随机森林，`n_estimators=500`，每类最多 300 个细胞以控内存
- 评估：准确率、宏平均 F1，**并同时报告基线与天花板**

> **宏平均 F1 必须显式指定标签集。**`f1_score(average="macro")` 的默认标签集是 `y_true ∪ y_pred`，会把测试集中根本不存在的"幽灵类"计入分母而稀释分数（177 类口径 0.138 vs 测试集实际 103 类口径 0.237）。本报告以**测试集实际类别口径**为主，同时给出 177 类口径以示完整。
>
> **基线与天花板**：测试集实际只有 103 个类别，随机基线 0.0097、多数类基线 0.026（后者更贴近实际）。更重要的是，测试集中有 **28 类**在训练集中**从未出现**，涉及 **3,109 个细胞（占测试集 40.5%）**，模型不可能预测对——因此准确率存在硬天花板 **0.595**，本次达到 **36.13%**。不披露天花板就宣称"准确率远超基线"是不诚实的。

- 特征重要性 → 取 Top 500 个基因 → 按年龄层归类 → 与背景（全部有年龄注释的高变基因）做**超几何检验**

> **关于 Top 集合的实际大小**：Top 500 里只有 **414 个**能在 Trigos 年龄表中查到层号，其余 86 个（TTR、ALB、B2M、TMSB4X 等）不在该 17,318 基因集内。富集检验的背景与 Top 集合**都只取有年龄注释的基因**（M = 2,523，N = 414），这一覆盖限制在 3.3 节有专门说明。

稳健性检验（三层独立设计，详见 3.5 与 4.2 节）：

检验	命令	变量
A 剔除低命中层	`03_细胞类型年龄谱.py`	剔除 S15/S16 后重算 TAI

检验	命令	变量
B 共识度过滤	`05_监督分析.py --min-share 0.8`	只用 mode_share ≥ 0.8 的基因（**905 个**）
C 短蛋白剔除	`05_监督分析.py --min-length 100`	只用蛋白长度 ≥100 aa 的基因（**2,405 个**）；长度表由 `93_获取蛋白长度.py` 从 UniProt 批量获取

> ⚠ **检验 B 的参数语义必须说清楚**。Trigos/Liebeskind 年龄表中的 `NumDBsContributing`（记作 n_{dbs}）是**参与投票的算法数（分母）**，**不是**"支持该层号的算法数"。真正的共识度是 $mode_{s}hare = max_{s}\ share_{s}$，支持算法数 $= round(mode_{s}hare \times n_{dbs})$。实测 n_{dbs} 与共识度**负相关**（corr = −0.128）：$n_{dbs} \le 4$ 的基因共识度中位数为 1.0000（全体完全一致），而 $n_{dbs} \ge 10$ 的仅 0.692。因此按 `--min-dbs 10` 过滤会**筛掉高共识的基因**，方向与"高置信"完全相反。本项目改用 `--min-share 0.8`（共识度阈值），并在 `02_构建年龄表.py` 中新增 `mode_support` / `mode_share` 两列以落盘真实共识度。

统计检验的方向性：超几何检验采用**双单尾**设计，而非单一右尾。

$$p_{enrich} = P(X \ge k), \qquad p_{deplete} = P(X \le k)$$

其中 X 为超几何随机变量，M 为背景基因数，n 为该层基因数，N 为 Top 集合大小。富集结论由右尾 p 支持，耗竭结论必须由左尾 p 支持。

多重检验校正：每次运行有 16 层 × 2 方向 = 32 次检验，三次运行合计 96 次。若直接以原始 $p < 0.05$ 判定，会产生大量假阳性（本项目 A 组未校正口径下有 8 层富集、3 层耗竭）。因此本报告采用 **Benjamini – Hochberg FDR 校正**，富集与耗竭方向**分别校正**，正式判定以 **$q < 0.05$** 为准。校正后 A 组显著富集层为 6 层、耗竭层为 2 层。

> **这是本项目在实现过程中修正的四个方法学问题**，都属于"跑得通但结论会错"的类型，一并记录如下：
>
> ① **超几何检验的尾部方向错误**（已修）。最初版本只计算右尾 p，却用 `fold > 1` 判定"偏向"、用 `fold < 1` 判定"回避"。但右尾 p ≈ 1 只意味着"没有证据表明富集"，**不构成回避的显著性证据**。修正后 S2 的左尾 $p = 2.39\times10^{-17}$（BH $q = 3.83\times10^{-16}$），才真正确立了它是一个**显著耗竭**的层。另需注意：S3 在 A 组即已不显著（q = 0.211），S4 在 B 组回落为不显著（q = 0.750），这两个层的变化如实保留在结果中。

② **派生列混入特征矩阵**（已修）。`celltype_age_profile.tsv` 除 16 个 `S*` 列外还含 `TAI_se`、`n_cells`、`low_confidence` 等派生量。若以 `drop(columns=["TAI"])` 构造特征矩阵，这几列会被误当作特征，造成信息泄漏。已统一改为只取以 `S` 开头且后接数字的列。

③ **`numpy.argmax` 遇 NaN 返回 NaN 位置**（已修）。用于报告"标准误最大的类型"时，最初写作 `se.values.argmax()` 取索引，再配 `se.max()` 取数值——但 numpy 的 `argmax` 遇到 NaN 会返回 **NaN 所在的位置**而非最大值的位置，导致数值（0.1323，来自 n = 5 的 enterocyte）与被标注的类型（n = 1、SE 为 NaN 的大肠隐窝干细胞）**对不上号**。已改为先 `dropna()` 再取 `idxmax()`，并额外打印出 SE 无法计算的类型清单。此错误一度被写进报告正文，现已更正。

④ **PCA 零假设的置换对象错了**（已修）。为解释"前 3 主成分只解释 61.9%"，最初用 `Xp = X[perm]` 置换**细胞类型**这一行来构造零假设。但 PCA 分解的是 **16 个特征之间的协方差结构**，行置换不改变任何一行的 16 维取值，因此基线算出来与真实值完全相同（61.9% = 61.9%，z = 0），**零假设彻底失效却不报任何错**。已改为**逐列打乱**（每层内部重排，保留边际分布、破坏层间共变），并加一道自检：独立正态基线 27.61% vs 逐列打乱基线 27.05%，相差 0.56 个百分点，确认无残留结构。修正后的结论见 3.2 节。

这四处若不修，报告的核心论断与关键数字都会站不住脚——这是本项目把"脚本必须符合目标要求"作为硬性标准的直接体现。

为防止此类问题复发，新增 `20-分析/07_终审核对.py`：把本报告的每个关键数字做成断言，与输出文件自动比对（**239 项**），任何一项不符即以非零码退出。

⑤ **第二轮代码审核追加修正的三处**（2026-11-03），同样属于"能跑通但结论会错"：

- **Spearman 相关是同义反复**（已修）。稳健性检验 A 要比较"剔除低命中层前后的 TAI 排序"。最初写成 `spearmanr(profile["TAI"], profile_hi["TAI"])`，但 `compute_age_profile()` 的返回值**已按 TAI 升序排过**，两列各自升序后按位置配对，位置秩相关**恒等于 +1**——报告里"Spearman ρ = 1.0000、Kendall τ = 1.0000、排序完全不变"其实是这个恒等式，不是发现。实测复现：两列独立随机数各自升序后做位置秩相关，500/500 次都算出 ρ = 1.0。修正为按索引显式对齐（`reindex`）后，真实值为 **ρ = 0.9883、τ = 0.9518**。
- **类型内标准误忽略供者聚类**（已修）。见 2.5 节末的说明。
- **监督分析不做 QC，与 TAI 分析口径不一致**（已修）。`05_监督分析.py` 原本自行降采样 28,017 个细胞，与 `03_细胞类型年龄谱.py` 的 22,195 个 QC 通过细胞不是同一批。已改为由 03 落盘 `qc_passed_rows.npy`，05 直接读取同一批细胞。

2.7 可复现性

全部代码 **7,155 行 / 20 个 Python 脚本**，仅依赖 numpy / pandas / scipy / scikit-learn / h5py / matplotlib，不依赖 scanpy 或 anndata。运行顺序、参数与产出见附录 A。

唯一需要联网的步骤是 `93_获取蛋白长度.py`（向 UniProt 批量查蛋白长度）。它把结果缓存到 `10-数据/protein_length.tsv`，之后所有分析均可离线复现。

交付前的硬性检查：`python 20-分析/07_终审核对.py` 必须输出"✓ 全部通过"（**239 项断言**），否则本报告的任一数字与产出文件对不上，不得交付。

> **为什么不使用 scanpy**：该 h5ad 全量载入需 10 GB 以上内存；其 `var` 索引为 Ensembl ID、`X` 已归一化、分类变量存放在 `__categories` 子组中，anndata/scanpy 的默认行为会静默算错。直接读 HDF5 让"用哪个矩阵、怎么归一化、基因名怎么还原"全部显式可控，代码量反而更少。

---

3 结果

3.1 177 种细胞类型的年龄构成（图 1、图 5）

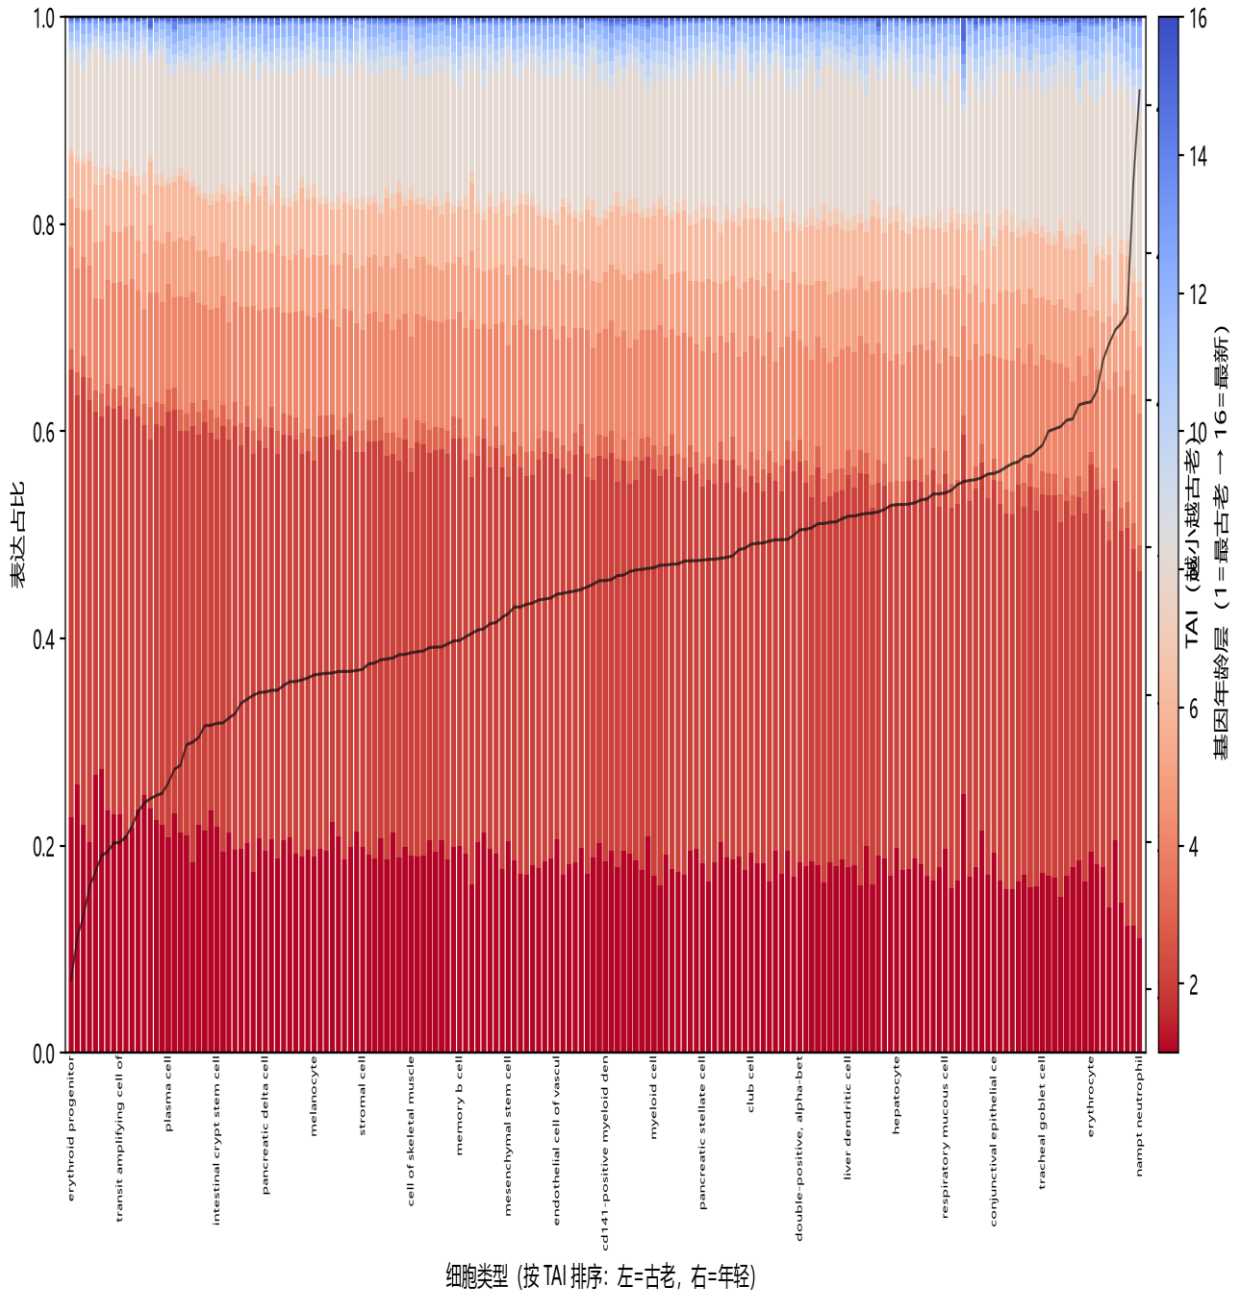


图 1 细胞地层主图：177 种细胞类型按 TAI 排序，每根按 16 个年龄层堆叠

总体分布：TAI 跨度 **3.21–4.42**，中位数 **3.76**，跨 177 种类型的标准差 **0.1810**。细胞级标准误中位数 **0.0111**，最大 **0.1323**（enterocyte of epithelium of small intestine，n = 5）。另有 **1 个类型无法计算标准误**（intestinal crypt stem cell of large intestine，QC 后仅 1 个细胞，标准误在数学上无法估计）。25 种类型 QC 后细胞数不足 20，已在所有结果中标记为"低置信"，不进入结论；另有 **81 种类型只有 1 名供者**，无法估计跨供者不确定性。

信号/噪声比（以**供者级**标准误为分母，这是保守口径）：

$$(\text{TAI 跨类型标准差})/(\text{供者级标准误中位数}) = (0.1810)/(0.0417) = \mathbf{4.3}\ \text{倍}$$

若改用细胞级标准误（0.0111）作分母会得到 16.3 倍，但那把**供者间波动误当作细胞间波动**，把不确定性低估了 3.75 倍——类型内组内相关系数（ICC）中位数为 1.000，说明细胞嵌套在供者之内并不独立。因此本报告以 4.3 倍为准：类型之间的年代差异仍然远大于同一类型内**供者之间**的波动，说明观察到的分层是**细胞类型层面的系统属性**，而不是抽样噪声。

最古老的 10 种（TAI 升序）：

TAI	细胞类型	TAI	细胞类型
3.21	erythroid progenitor（红系前体）	3.39	adipocyte（脂肪细胞）
3.27	kidney epithelial cell（肾上皮细胞）	3.40	transit amplifying cell of large intestine
3.30	plasmablast（浆母细胞）	3.40	transit amplifying cell of small intestine
3.34	myeloid progenitor（髓系前体）	3.41	cardiac muscle cell（心肌细胞）
3.36	fast muscle cell（快肌细胞）		
3.38	retinal ganglion cell（视网膜神经节细胞）		

最年轻的 10 种（TAI 降序）：

TAI	细胞类型	TAI	细胞类型
4.42	nampt neutrophil（NAMPT^{+} 中性粒细胞）	4.08	endothelial cell（内皮细胞）

TAI	细胞类型	TAI	细胞类型
4.30	neutrophil（中性粒细胞）	4.05	epithelial cell of lacrimal sac
4.12	cd24 neutrophil（$CD24^+$ 中性粒细胞）	4.01	immune cell
4.10	capillary aerocyte（毛细血管气细胞）	4.00	erythrocyte（红细胞）
4.10	erythroid lineage cell（红系细胞）	4.00	capillary endothelial cell

区室均值：

区室	类型数	平均 TAI	标准差
germ line（生殖系）	1	**3.4990**	—
stromal（间质）	34	3.7038	0.1670
epithelial（上皮）	66	3.7266	0.1593
immune（免疫）	61	3.7360	0.2074
endothelial（内皮）	15	**3.8839**	0.1171

结果与直觉的对照：

1. **部分符合**：生殖系最古老（但仅 1 种类型，样本量过小，不作结论）；造血前体（红系、髓系）位居最古老之列，符合"造血是古老、保守的功能"这一预期；心肌细胞、视网膜神经节细胞也偏古老，符合"节律收缩、神经信号传导是保守机制"的直觉。
2. **部分出乎意料**：**中性粒细胞是人体中最"年轻"的细胞类型之一**（4.30–4.42），而中性粒细胞恰恰是人体最古老、最核心的先天免疫细胞之一。这与 1.3 节表格中"免疫细胞更新快 → 需要新基因"的假说方向一致（快速周转的细胞类型需要快速演化的、新出现的基因，如 S8–S15 层的效应分子），但与"功能越基础 → 基因越古老"的假说**方向相反。**这提示"基因年龄"反映的可能是**细胞周转速率与功能模块更新速率**，而不只是功能的保守程度。

3. **上皮的意外发现**：transit amplifying cell（大 / 小肠）位列最古老之列，而同属上皮的伞状细胞、杯状细胞却在年轻一侧。同一区室内出现最大的反差，说明区室层面的均值掩盖了细胞类型之间的真实差异——**区室不是合适的分析单位。**

3.2 年龄构成能否区分细胞类型（图 2、图 3）

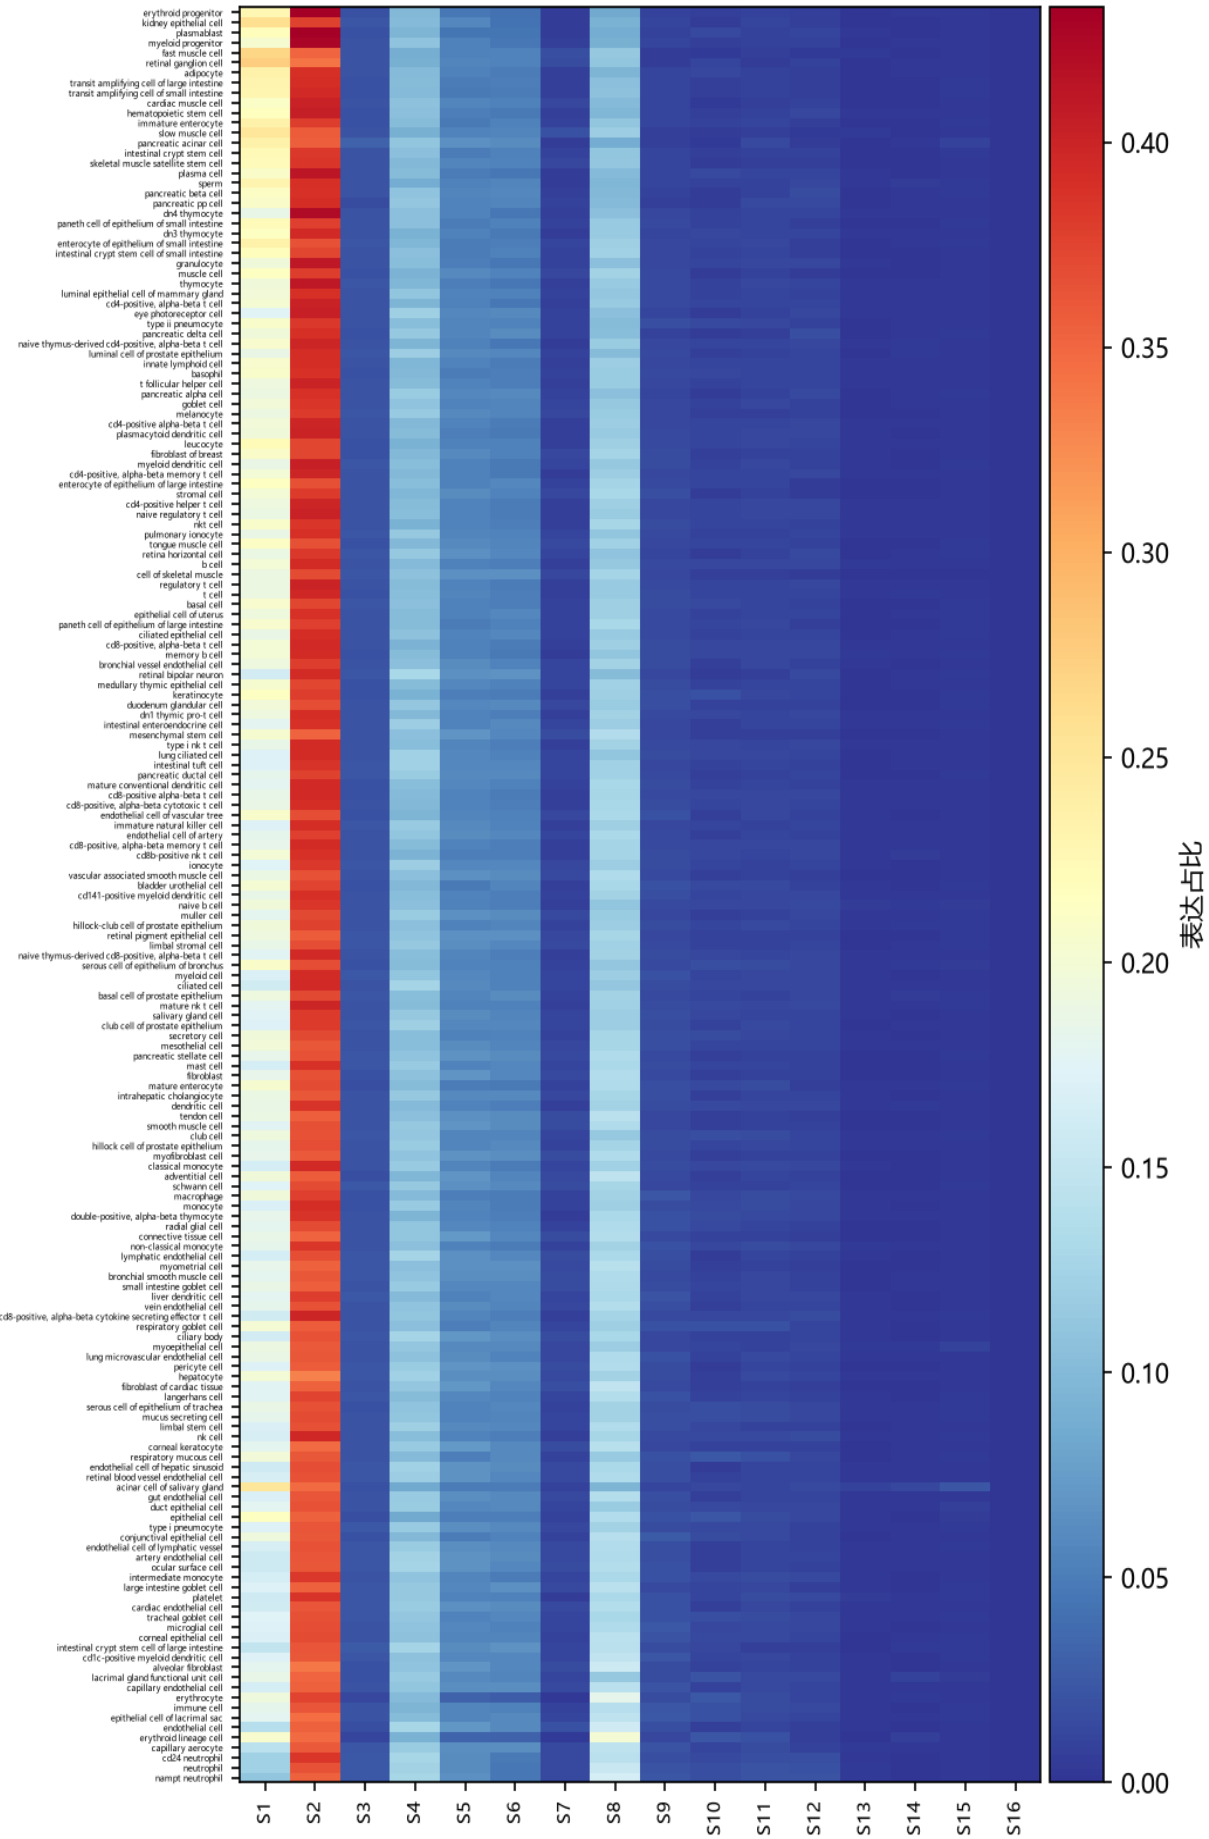

erythroid progenitor
kidney epithelial cell
plasmablast
myeloid progenitor
fast muscle cell
retinal ganglion cell
adipocyte
transit amplifying cell of large intestine
transit amplifying cell of small intestine
cardiac muscle cell
hematopoietic stem cell
immature enterocyte
slow muscle cell
pancreatic acinar cell
intestinal crypt stem cell
skeletal muscle satellite stem cell
plasma cell
sperm
pancreatic beta cell
pancreatic pp cell
dn4 thymocyte
paneth cell of epithelium of small intestine
dn3 thymocyte
enterocyte of epithelium of small intestine
intestinal crypt stem cell of small intestine
granulocyte
muscle cell
thymocyte
luminal epithelial cell of mammary gland
cd4-positive, alpha-beta t cell
eye photoreceptor cell
type ii pneumocyte
pancreatic delta cell
naive thymus-derived cd4-positive, alpha-beta t cell
luminal cell of prostate epithelium
innate lymphoid cell
basophil
t follicular helper cell
pancreatic alpha cell
goblet cell
melanocyte
cd4-positive alpha-beta t cell
plasmacytoid dendritic cell
leucocyte
fibroblast of breast
myeloid dendritic cell
cd4-positive, alpha-beta memory t cell
enterocyte of epithelium of large intestine
stromal cell
cd4-positive helper t cell
naive regulatory t cell
nkt cell
pulmonary ionocyte
tongue muscle cell
retina horizontal cell
b cell
cell of skeletal muscle
regulatory t cell
t cell
basal cell
epithelial cell of uterus
paneth cell of epithelium of large intestine
ciliated epithelial cell
cd8-positive, alpha-beta t cell
memory b cell
bronchial vessel endothelial cell
retinal bipolar neuron
medullary thymic epithelial cell
keratinocyte
duodenum glandular cell
dn1 thymic pro-t cell
intestinal enteroendocrine cell
mesenchymal stem cell
type i nk t cell
lung ciliated cell
intestinal tuft cell
pancreatic ductal cell
mature conventional dendritic cell
cd8-positive alpha-beta t cell
cd8-positive, alpha-beta cytotoxic t cell
endothelial cell of vascular tree
immature natural killer cell
endothelial cell of artery
cd8-positive, alpha-beta memory t cell
cd8b-positive nk t cell
ionocyte
vascular associated smooth muscle cell
bladder urothelial cell
cd141-positive myeloid dendritic cell
naive b cell
muller cell
hillock-club cell of prostate epithelium
retinal pigment epithelial cell
limbal stromal cell
naive thymus-derived cd8-positive, alpha-beta t cell
serous cell of epithelium of bronchus
myeloid cell
ciliated cell
basal cell of prostate epithelium
mature nk t cell
salivary gland cell
club cell of prostate epithelium
secretory cell
mesothelial cell
pancreatic stellate cell
mast cell
fibroblast
mature enterocyte
intrahepatic cholangiocyte
dendritic cell
tendon cell
smooth muscle cell
club cell
hillock cell of prostate epithelium
myofibroblast cell
classical monocyte
adventitial cell
schwann cell
macrophage
monocyte
double-positive, alpha-beta thymocyte
radial glial cell
connective tissue cell
non-classical monocyte
lymphatic endothelial cell
myometrial cell
bronchial smooth muscle cell
small intestine goblet cell
liver dendritic cell
vein endothelial cell
cd8-positive, alpha-beta cytokine secreting effector t cell
respiratory goblet cell
ciliary body
myoepithelial cell
lung microvascular endothelial cell
pericyte cell
hepatocyte
fibroblast of cardiac tissue
langerhans cell
serous cell of epithelium of trachea
mucus secreting cell
limbal stem cell
nk cell
corneal keratocyte
respiratory mucous cell
endothelial cell of hepatic sinusoid
retinal blood vessel endothelial cell
acinar cell of salivary gland
gut endothelial cell
duct epithelial cell
epithelial cell
type i pneumocyte
conjunctival epithelial cell
endothelial cell of lymphatic vessel
artery endothelial cell
ocular surface cell
intermediate monocyte
large intestine goblet cell
platelet
cardiac endothelial cell
tracheal goblet cell
microglial cell
corneal epithelial cell
intestinal crypt stem cell of large intestine
cd1c-positive myeloid dendritic cell
alveolar fibroblast
lacrimal gland functional unit cell
capillary endothelial cell
erythrocyte
immune cell
epithelial cell of lacrimal sac
endothelial cell
erythroid lineage cell
capillary aerocyte
cd24 neutrophil
neutrophil
nampt neutrophil
S1
S2
S3
S4
S5
S6
S7
S8
S9
S10
S11
S12
S13
S14
S15
S16
0.40
0.35
0.30
0.25
0.20
0.15
0.10
0.05
0.00
表达占比

图 3 细胞类型 × 年龄层的表达占比热图

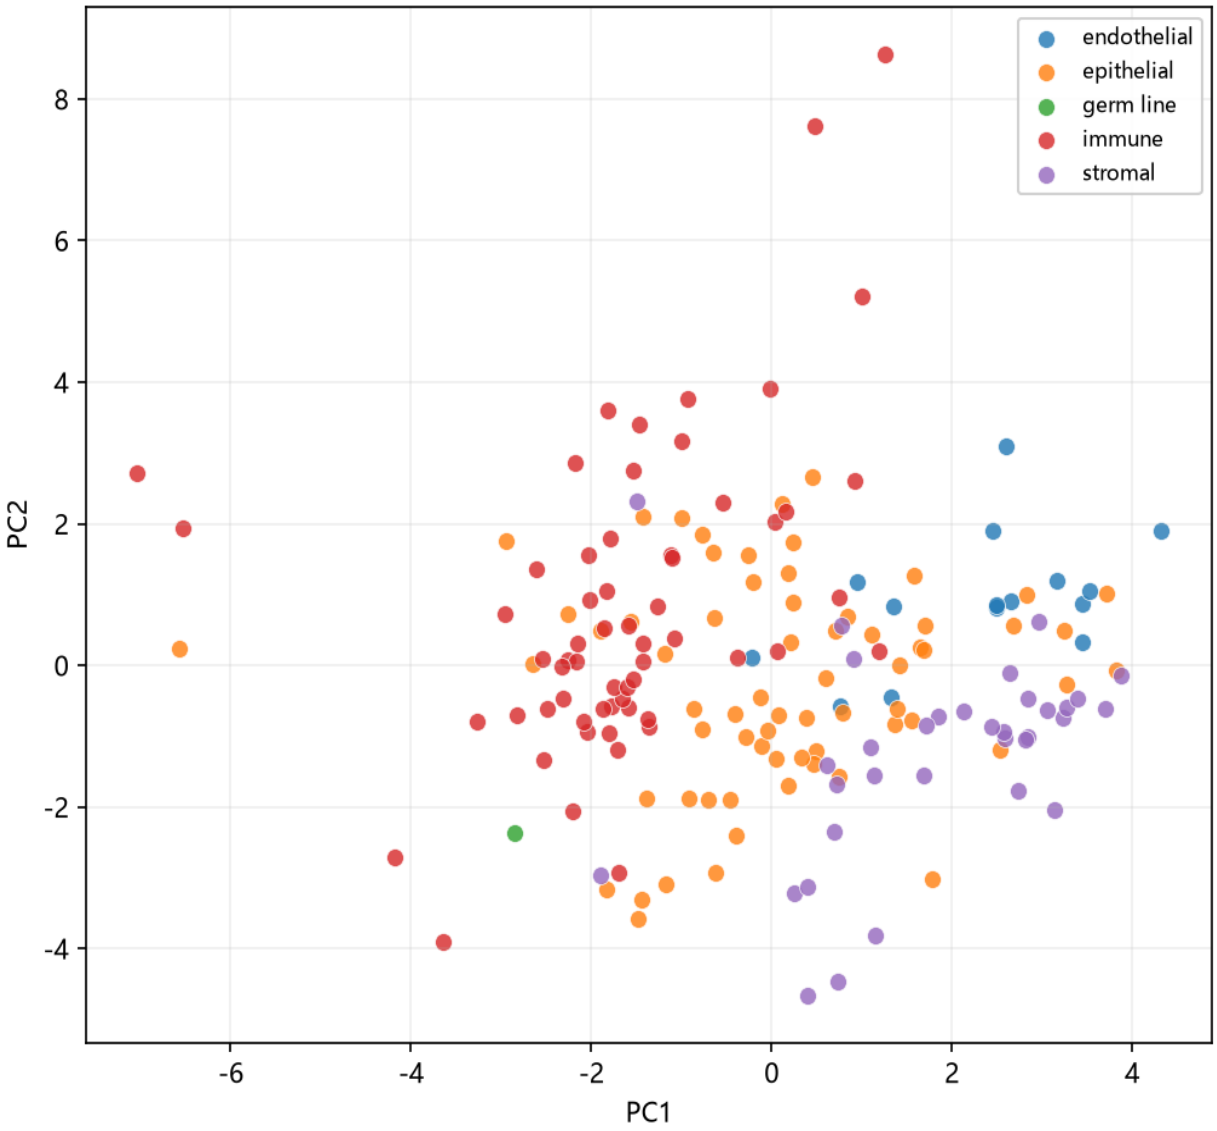


图 2 PCA 前两主成分散点，按 K-means 簇着色

PCA：

主成分	解释方差
PC1	27.3%
PC2	22.6%
PC3	12.1%

主成分	解释方差
前 3 个累计	**61.9%**

累计 61.9% 低于 70%。**这个数字本身不能单独解读**——必须和零假设比较才有意义。为此本项目做了三项额外诊断（`08_主成分诊断.py`，结果见**图 7**）：

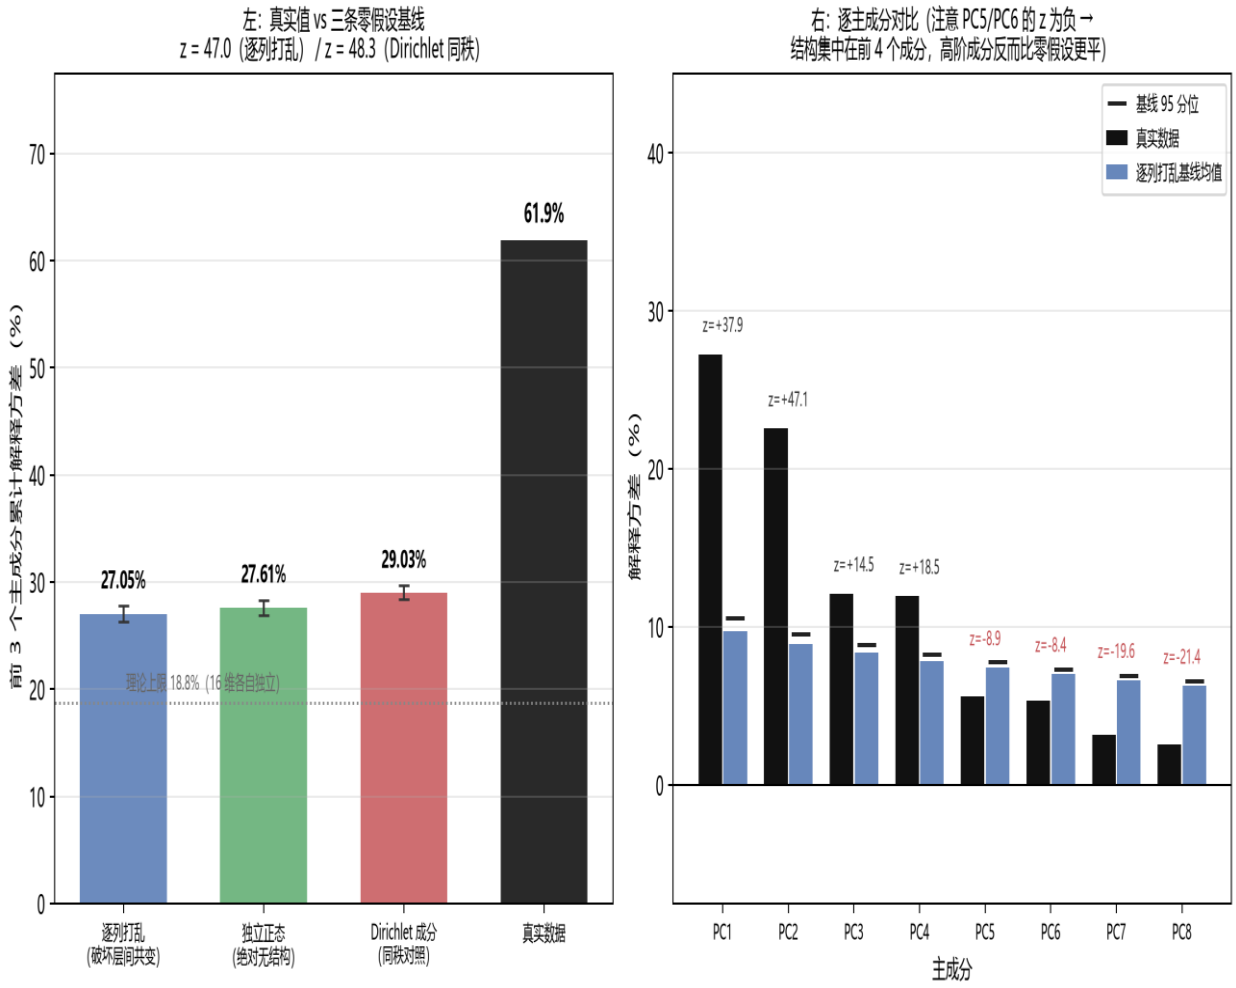


图 7 PCA 零假设诊断：三条基线对比

⓪ **先检查数据本身的结构约束。** 年龄构成是**成分数据**：每行 16 个占比之和恒为 1，因此行向量必然落在一个 **15 维仿射子空间**上，协方差矩阵**天然秩亏**——实测第 16 个特征值 = 2.6×10^{-31}（严格为 0），真实秩为 **15 / 16**。

> 这一步不是形式主义：它决定了"基线"必须怎么构造。如果基线是满秩 16 维的，而真实数据只有 15 个独立方向，那么"前 3 维占比更高"里就混进了一部分**纯机械的秩亏红利**。所以下面要用三条基线交叉验证。

① 与零假设基线比较。 零假设的构造是「逐列打乱」：保留每个年龄层在 177 种细胞类型上的边际分布，但破坏层与层之间的共变关系（500 次置换）。

> ⚠ 这里有一个容易踩的陷阱：**PCA 分解的是特征协方差，置换细胞类型的行并不会改变它**——那是个无效的零假设，会得到"基线 = 真实值"的荒谬结果。必须打乱的是**特征列**。

	前 3 主成分累计
真实数据	**61.9%**
零假设基线（逐列打乱，500 次）	27.0% ± 0.7%
独立正态对照（绝对无结构）	27.6% ± 0.7%
Dirichlet 成分基线（同秩对照，400 次）	**29.0% ± 0.7%**
真实值超出逐列打乱基线	**z = 47.0 个标准差**
真实值超出 Dirichlet 同秩基线	**z = 48.3 个标准差**

三条基线互相吻合（逐列打乱 27.05%、独立正态 27.61%、Dirichlet 成分 29.03%），说明逐列打乱没有残留结构，基线可信。其中 **Dirichlet 成分基线是关键对照**：它用矩估计拟合浓度参数，从 Dirichlet 分布抽样生成"同样是成分数据、同样行和 = 1、同样秩亏到 15"的样本——正是与真实数据**同秩**的零假设。它给出的基线略高于另两条（29.0% vs 27.1%），真实值相对它的 z 反而更大（48.3），因此**低维结构是真实的，不是成分约束的机械效应。**

> **为什么基线是 27% 而不是理论值 3/16 = 18.8%**：这是有限样本效应。n = 177、d = 16 时 n/d ≈ 11，样本协方差矩阵的谱不会均匀分布。因此基线**必须用同样规模的样本重新生成**，不能直接代入理论值。

② 信息为什么分散——层间相关结构。 16 个年龄层中存在 **14 对相关系数 |r| > 0.5** 的组合：

层对	**r**	**层对**	**r**
S5 ↔ S7	+0.755	S2 ↔ S8	−0.585
S1 ↔ S4	−0.729	S14 ↔ S15	+0.584

层对	r	层对	r
S5 ↔ S6	+0.719	S1 ↔ S9	−0.581
S10 ↔ S11	+0.693	S4 ↔ S5	+0.579
S2 ↔ S7	−0.667	S8 ↔ S9	+0.546

这些层在 177 种细胞类型中同步升降，把同一份信息拆成了几维。用**参与比**（PR = 1/Sigma evr^2，取值范围 [1, 16]：各维完全等方差时取上界 16，信息集中于一维时取下界 1）度量有效维度：

	有效维度
真实数据	**6.12 维**
零假设（逐列打乱）	14.74 维
零假设（Dirichlet 同秩）	13.77 维

真实数据在 16 维的表象里只有约 **6.1 维**承载有效信息，而零假设下 16 维几乎各自独立（14.7 维，接近上界 16）。**在同秩的 Dirichlet 基线下压缩依然成立（13.8 维 → 6.1 维），年龄构成存在明确的低维结构，不是各层各说各话。**

逐主成分的结构位置（图 7 右 panel）：PC1–PC4 的 z 值分别为 +37.9、+47.1、+14.5、+18.5（显著高于零假设），而 **PC5 之后 z 值转负**（PC5 −8.9、PC6 −8.4）——高阶成分反而比零假设更平坦。**这说明结构精确地集中在前 4 个成分里**，而不是弥散在全部维度中；同时也解释了为何"前 3 累计"远达不到 70%：剩下的方差确实存在于 PC4 及以后。

结论：「前 3 个主成分累计 > 70%」这一验收指标**设得过高**——即使各层完全独立，前 3 维也只能解释 27.0%。更有意义的表述是：**61.9% 显著高于零假设（z = 47），16 维压缩到 6.1 个有效维度。**

聚类数选择（K-means，轮廓系数）：

```
k=2  0.193      k=5  0.206      k=7  0.235  ← 选定
k=3  0.192      k=6  0.228      k=8  0.223
k=4  0.199
```

与已知谱系的一致性：**ARI = 0.211。**

> **这个数字必须配一个零假设才能读。**ARI 的置换零假设为 **−0.0001 ± 0.0104**（2000 次随机置换标签），真实值相当于 **z = 20.4** 个标准差——即"随机聚类也能得到 ARI ≈ 0"这个替代解释被排除。Ward 层次聚类作为方法对照给出 ARI 0.170 / 轮廓 0.166，与 K-means 同量级，说明结果不是某种聚类算法的特例。

这该如何解读——参照系很重要。若把聚类结果与**随机划分**比较，ARI 的期望值为 0；若与"完全按谱系分组"的理想情况比较，ARI 的上限为 1。0.211 落在**弱相关**区间：

- ARI > 0.5：年龄构成是细胞类型的强特征 → 本研究未达到
- 0.2 < ARI < 0.5：**弱但确实存在** → 本研究落在此区间
- ARI < 0.2：年龄构成不足以定义细胞类型 → 本研究未落在此区间

结论：年龄构成**捕捉到了部分谱系信息，但远不足以单独定义细胞身份。**这是一个有效且诚实的结论，而非失败——它恰好划定了"进化视角"在细胞分类体系中的位置：**正交的补充轴，不是替代轴。**

敏感性分析：剔除低置信类型后结论是否改变。 上面的 k = 7 与 ARI = 0.211 都建立在 177 种类型（含 25 种 QC 后细胞数不足 20 的低置信类型）之上。若剔除这 25 类（剩余 n = 152）：

	主口径（n = 177）	**敏感性（n = 152）**
聚类数 k	7	**5**
ARI	0.211	**0.159**
轮廓系数	0.235	0.239
前 3 主成分累计	61.9%	63.4%

结论没有被推翻，但确实被削弱：ARI 从 0.211 降到 0.159（降幅 25%），说明 **k = 7 这个最优解本身相当程度上由低置信类型撑起。**剔除后轮廓系数反而略升（0.239），说明剩下的类型分得更"整齐"但簇更少。这是一个诚实的结果——它表明"年龄构成与谱系弱相关"这一核心结论在严格子集上依然成立，只是强度打折。

各簇的平均 TAI（k=7，主口径）：

簇	**类型数**	**平均 TAI**	**簇**	**类型数**	**平均 TAI**
0	14	3.95	4	1	3.89

簇	类型数	平均 TAI	簇	类型数	平均 TAI
1	57	3.64	5	19	3.87
2	2	4.05	6	25	3.52
3	59	3.82			

簇 1（57 种）与簇 3（59 种）规模相近但平均 TAI 相差 0.18——**同样的簇规模并不意味着同样的年代特征**，进一步支持 PCA 累计方差不高的观察。

把每个细胞按其**所属类型的 TAI** 着色投到 PC1/PC2 上（**图 6**），着色呈明显的区域化而非随机散布：同一类型的细胞落在同一色块里，说明类型级的 TAI 差异在细胞层面不是抽样噪声，而是真实存在的整体位移。

3.3 细胞身份由哪个年代的基因定义（图 4）——本文最重要的一节

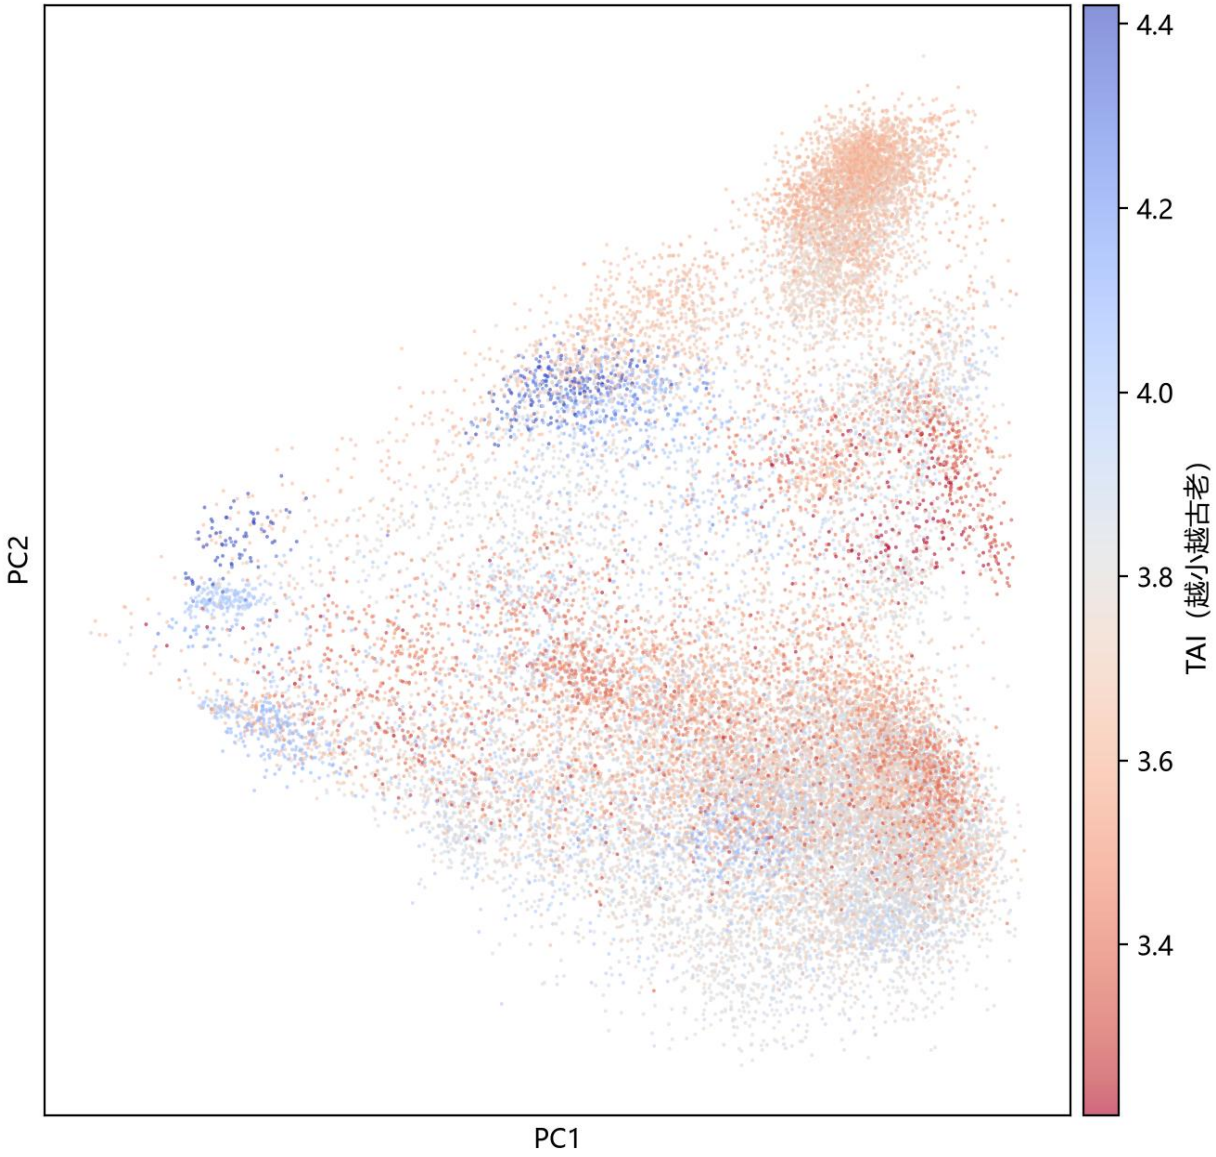


图 6 细胞的 PC1/PC2 投影，按所属细胞类型的 TAI 着色（切片源无 UMAP 坐标，用稀疏 SVD 的 PC1/PC2 代替）

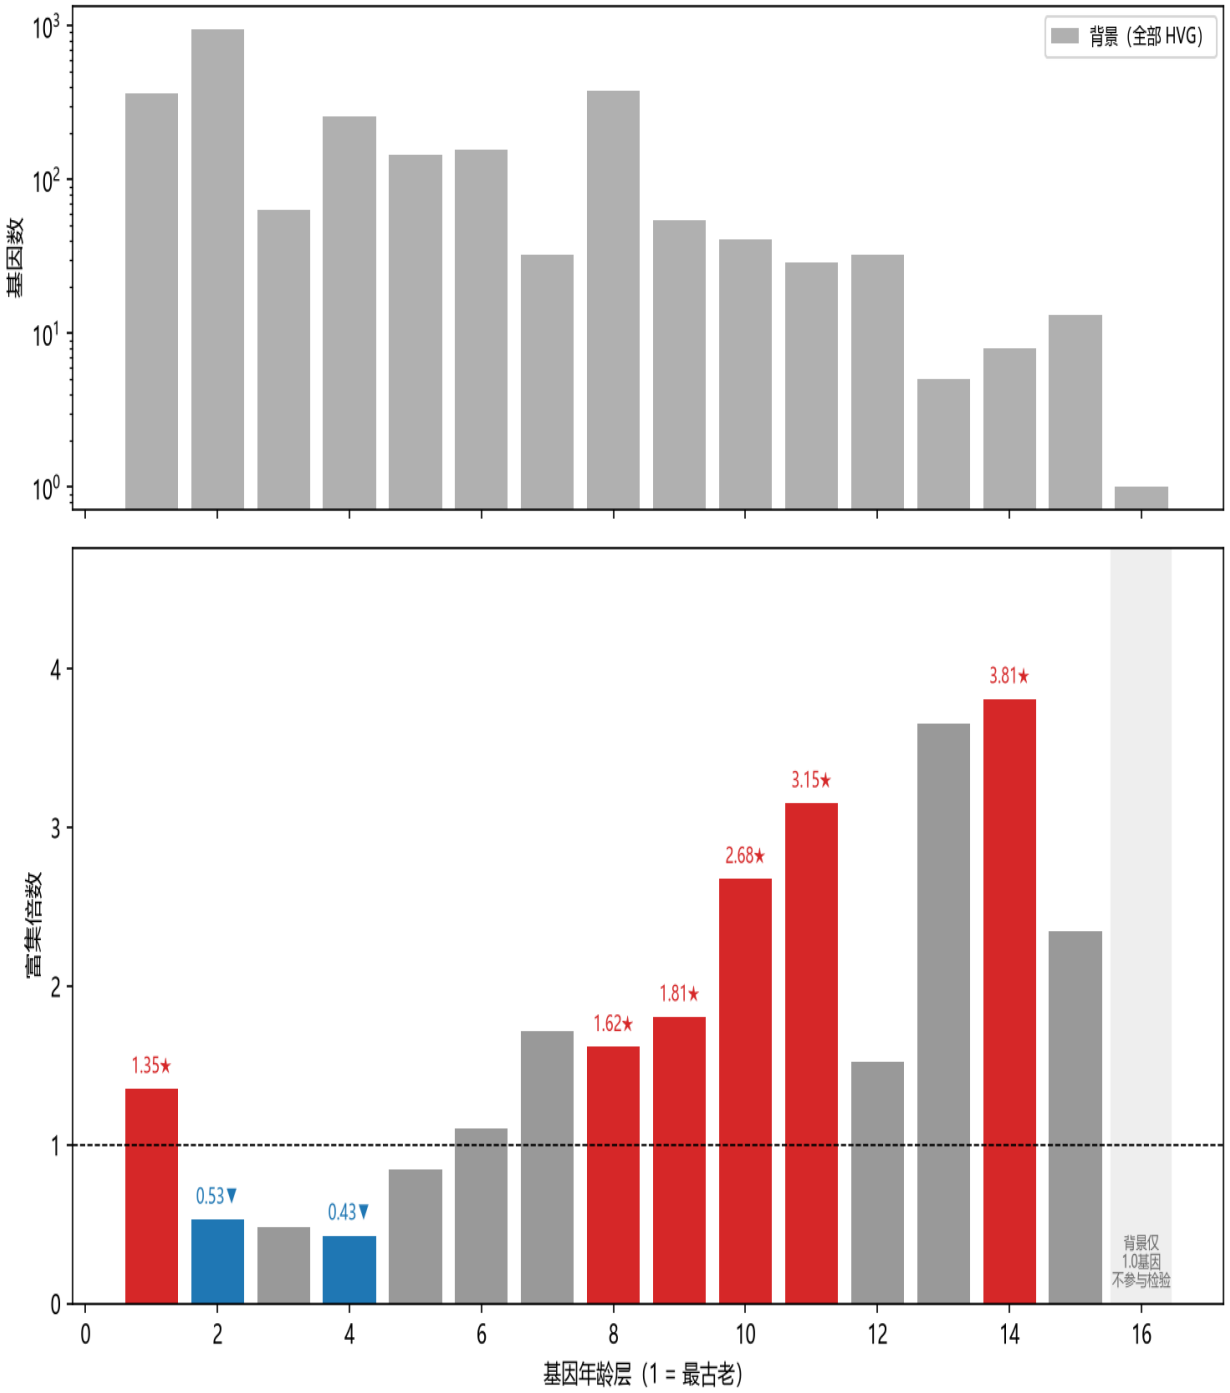


图 4 各年龄层基因数与 Top 500 重要基因的富集倍数

随机森林在按供者划分的测试集上取得**准确率 0.215、宏平均 F1 0.237**（测试集 103 类口径；随机基线 0.0097、多数类基线 0.026，为多数类基线的 8.26 倍，准确率天花板 0.595，本次达到 36.13%——详见 3.4 节）。

Top 20 重要基因及其年龄层：

基因	重要性	年龄层	基因	重要性	年龄层
HBA2	0.00314	S8	HLA-DRA	0.00234	S8
HBB	0.00314	S8	LYZ	0.00233	S6
IGKC	0.00282	S8	HBA1	0.00228	S8
TTR	0.00275	无年龄	IGHA1	0.00226	S10
S100A9	0.00270	S9	SEMG2	0.00226	S14
ALB	0.00270	无年龄	SAA1	0.00224	S6
SEMG1	0.00244	S14	CKB	0.00216	S1
B2M	0.00235	无年龄	S100A8	0.00208	S10
SLPI	0.00207	S10	SFN	0.00206	S10
TMSB4X	0.00206	无年龄	TFF3	0.00205	S7
MT-RNR2	0.00236	无年龄	HLA-DRA	0.00206	S8

> **一个重要的观察**：Top 20 中有多个基因本身就是**高度组织特异的"标记基因"**——HBB / HBA1 / HBA2（血红蛋白）、TTR（转甲状腺素蛋白）、ALB（白蛋白）、IGKC / IGHA1（免疫球蛋白）、SAA1（血清淀粉样蛋白 A1）、SLPI（分泌型白细胞蛋白酶抑制剂）、TFF3（肠三叶因子）。这提示随机森林的重要性和经典的差异表达标记基因高度重叠——**细胞身份仍然主要由"标志物"承载**，而不是由年代承载。年代的意义是叠加在标志物之上的一层系统性偏好。

各年龄层在 Top 500 重要基因中的富集（超几何双单尾检验 + BH-FDR 校正，背景 = 2,523 个有年龄注释的 HVG，Top 集合 = 414 个有年龄注释的基因）：

> **为什么 Top 集合是 414 而不是 500**：Top 500 里只有 414 个能在 Trigos 年龄表中查到层号，其余 86 个是 TTR、ALB、B2M、TMSB4X 这类**不在该 17,318 基因集内**的基因（它们在表达矩阵里存在，但 Trigos 表没有覆盖）。这类基因同样是很强的细胞类型标记物——**它们证明"区分细胞类型"主要靠的是标志性 housekeeping 基因**，但因为没有年龄归属，无法参与年龄富集检验。这一事实本身就限定了本节结论的射程：富集检验回答的是"**有年龄归属的**重要基因偏向哪个年代"，而不是"所有重要基因偏向哪个年代"。

表中的 q 列为 BH-FDR 校正后的值，是本报告的正式判定依据（每次运行 32 次检验，三次运行共 96 次；原始 p 仅供对照）。

层	背景	Top 中	期望	倍数	p（富集）	q（富集）	p（耗竭）	q（耗竭）	判定
S1 细胞生物	365	81	66.3	1.35	1.1×10^{-3}	**4.5×10^{-3}**	1.00	1.00	**富集 ★**
S2 真核生物	946	82	75.5	**0.53**	1.00	1.00	2.4×10^{-17}	**3.8×10^{-16}**	**耗竭 ▼**
S3 后鞭毛类	63	5	4.6	0.48	0.99	1.00	4.0×10^{-2}	0.21	不显著
S4 后生动物	257	18	16.8	**0.43**	1.00	1.00	2.3×10^{-6}	**1.9×10^{-5}**	**耗竭 ▼**
S5 真后生动物	145	20	17.6	0.84	0.84	1.00	0.23	0.91	不显著
S6 两侧对称动物	155	28	23.7	1.10	0.32	0.42	0.76	1.00	不显著
S7 脊索动物	32	9	7.0	1.71	6.6×10^{-2}	0.12	0.97	1.00	不显著
S8 硬骨脊椎动物	377	100	79.0	1.62	3.5×10^{-8}	**5.6×10^{-7}**	1.00	1.00	**富集 ★**

层	背景	Top 中	期望	倍数	p（富集）	q（富集）	p（耗竭）	q（耗竭）	判定
S9 羊膜动物	54	16	12.3	1.81	1.0×10^{-2}	**2.7×10^{-2}**	1.00	1.00	**富集 ★**
S10 哺乳纲	41	18	12.5	**2.68**	2.7×10^{-5}	**1.4×10^{-4}**	1.00	1.00	**富集 ★**
S11 兽亚纲	29	15	9.9	**3.15**	1.1×10^{-5}	**8.8×10^{-5}**	1.00	1.00	**富集 ★**
S12 真兽下纲	32	8	6.4	1.52	0.14	0.23	0.93	1.00	不显著
S13 灵长总目	5	3	1.9	3.66	3.4×10^{-2}	0.077	1.00	1.00	不显著
S14 狭鼻小目	8	5	3.1	**3.81**	4.2×10^{-3}	**1.4×10^{-2}**	1.00	1.00	**富集 ★**
S15 人亚科	13	5	3.6	2.34	4.8×10^{-2}	0.096	0.99	1.00	不显著
S16 智人	1	1	0.5	6.09	0.16	0.24	1.00	1.00	不显著（背景仅 1 基因，不参与检验）

这个结果的核心模式：

经 BH 校正后仍显著的富集层为 S1、S8、S9、S10、S11、S14，即**细胞生物 → 硬骨脊椎动物 → 羊膜动物 → 哺乳纲 → 兽亚纲 → 狭鼻小目**这一段脊椎动物—哺乳类—灵长类演化序列；倍数随年代递进而上升（S8 1.62× → S9 1.81× → S10 2.68× → S11 3.15× → S14 3.81×）。

> **多重检验校正改变了什么**：若不校正（只看原始 $p < 0.05$），富集层会变成 8 层——S7、S12、S13、S15 会被误判为显著。这四层恰恰是**背景基因数最少、统计功效最弱**的层（S7 32 个、S12 32 个、S13 5 个、S15 13 个背景基因）。S13 的 3.66× 与 S15 的 2.34× 数值上很醒目，但它们背后的背景分别只有

> 5 个和 13 个基因——**倍数高是因为分母小，不是因为信号强。**校正后这两层都落回不显著，是更诚实的结论。

经 BH 校正后仍显著的耗竭层为 S2、S4，即**真核生物 → 后生动物**这两层跨度超过二十亿年的"基础 housekeeping"层（S3 后鞭毛类因背景仅 63 个基因、功效不足而未通过校正）。

这个模式为什么重要，有两条独立的解释：

1. **统计上**：如果随机森林学到的是与年代无关的通用细胞状态（大小、应激、增殖速率），那么 Top 基因的年龄分布应当接近背景。观察到的强烈偏离**排除了这个零假设。**
2. **生物学上**：**"区分细胞类型"这件事本身是哺乳类特有的。**一个两亿年前才出现的免疫系统，其细胞身份必然依赖两亿年前才出现的基因（免疫球蛋白、细胞因子受体、抗原提呈分子）；而三亿年前就存在的通用代谢与信号转导机制（核糖体、蛋白酶体、剪接体）在所有细胞里都一样表达，因此对**区分**毫无帮助——它们占背景的大头（仅 S2 一层就有 946 个基因），却几乎不进入 Top 列表。

> **这是一个自洽的整体解释**：古老的基因承担**所有细胞共享的"基本功能"**，因此不携带身份信息；年轻的（哺乳类-灵长类特异的）基因承担**细胞类型特异的"身份功能"**，因此是分类器真正依赖的对象。

表述的克制（重要）：本研究只能说"**在区分细胞类型时，模型更依赖 S8–S14 的脊椎动物—哺乳类—灵长类特异层中经校正后仍显著的 S8、S9、S10、S11、S14 的基因**"，**不能说**"这些基因决定了细胞类型"。富集是关联而非因果；基因年龄是基因在参考基因组中的**首次出现**，而它在某细胞类型中**高表达**还取决于调控、扩增、拷贝数等大量其他因素。此外，S15/S16 两层本身命中率仅 64%/69%，其富集结果需谨慎对待（见 4.2）。

3.4 分类性能与误差

按供者划分的分类结果：**准确率 0.215、宏平均 F1 0.237**（测试集实际出现的 103 类口径；按全部 177 类口径为 0.138）。

参照量	值	说明
随机基线（103 类均匀猜）	0.0097	测试集实际类别数
多数类基线（恒猜最高频类）	0.026	**更贴近实际**
准确率 / 多数类基线	**8.26 倍**	
准确率天花板	**0.595**	剔除训练集从未出现的类别后

参照量	值	说明
本次达到天花板	**36.13%**	

为什么必须披露天花板：测试集中有 **28 个类在训练集中从未出现**，涉及 **3,109 个细胞（占测试集 40.5%）**。这批细胞模型在原理上就不可能预测对（供者划分保证了训练集与测试集的细胞类型分布不同）。因此 0.215 应当被理解为"在 59.5% 可预测的细胞上答对了 36.13%"，而不是一个可以无限优化的孤立数字。

为什么宏平均 F1 仍然只有 0.237：说明性能依然高度偏向高频类型（如红系、中性粒细胞等），稀有类型基本无法识别——这与 28 个未见类别的存在是一致的。

一个重要的混淆来源是：**血红蛋白基因 HBB / HBA1 / HBA2 同时位列重要性和 Top 基因。**由于它们在所有含红细胞的样本中极高表达，若供者间红细胞污染程度不同，模型可能学到的是"这个供者的血样污染程度"而非细胞身份——这正是**必须按供者划分**才能暴露出来的风险。

3.5 稳健性检验：结论是否依赖于低置信度或易错基因的年龄调用

针对 Moyers & Zhang (2015/2017/2018) 的方法学批评（详见 4.2），本项目设计了三层独立检验（检验 C 的完整结果见 4.2 节）。

检验 A：剔除低命中年龄层后重算 TAI。 由于 S15（64%）、S16（69%）的基因在表达矩阵中存在率明显偏低，本项目剔除这两层，仅用 S1–S14 重算全部 177 种细胞类型的 TAI：

指标	结果
保留的层	S1–S14（剔除 S15、S16）
Spearman ρ	**0.9883**
Kendall τ	**0.9518**
最古老 Top10 重合	**9 / 10**
TAI 绝对差中位数	0.0361
排名变动	**141 / 177 个类型名次有变化，最大位移 88 位**

整体排序高度一致，但并非"逐个类型不变"。Top10 中 `cardiac muscle cell` 掉出、`pancreatic acinar cell` 换入；177 个类型里有 141 个名次发生变动，最大位移达 88 位。剔除 S15/S16 只轻微影响 TAI 的**绝对值**（中位绝对差 0.0361），不改变相对比较的**总体格局**——因为被剔除的 S15/S16 在多数细胞类型中的表达占比本身就很小（见图 1 顶部蓝色薄层）。

⚠ 曾经踩过的坑（已修）：本项检验最初报告的是"Spearman ρ = 1.0000、Kendall τ = 1.0000，排序完全不变"。那是**一个同义反复**，不是发现——`compute_age_profile()` 的返回值已按 TAI 升序排过，两列各自升序后再按位置配对，位置秩相关**恒等于 +1。**实测复现：两列独立随机数各自升序后做位置秩相关，500/500 次都算出 ρ = 1.0。修正为按索引显式对齐后，真实值为 **ρ = 0.9883、τ = 0.9518。**

检验 B：共识度过滤后重跑完整监督分析。 只保留年龄表中**共识度高**（`mode_share ≥ 0.8`，即 ≥80% 的同源推断算法给出同一层号）的基因重跑全流程：

指标	A：全量（3,000 特征）	B：共识度过滤（905 特征）
分类准确率	0.215	0.180
宏平均 F1（测试集口径）	0.237	0.194
富集背景 / Top 集	2,523 / 414	905 / 500
共同显著富集层	**S1, S8, S9, S10, S11, S14**	**S8, S10**
共同显著耗竭层	**S2, S4**	**S2**
Top 20 重要基因重合	—	**3 / 20**（IGHA1, S100A8, SFN）

⚠ 参数语义必须说清楚（这是本轮审核发现的一处实质性错误）。原先的参数 `--min-dbs 10` 意为 "`NumDBsContributing` ≥ 10"，但该字段的语义是**参与投票的算法数（分母）**，**不是**"支持该层号的算法数"。真正的共识度是 `mode_share`，支持算法数 = `round(mode_share × n_dbs)`。实测 n_{dbs} 与共识度**负相关**（corr = −0.128）：$n_{dbs} \le 4$ 的基因共识度中位数为 1.0000（全体完全一致），而 $n_{dbs} \ge 10$ 的仅 0.692。**按 `--min-dbs 10` 过滤会筛掉高共识的基因，方向与"高置信"完全相反。** 已改为 `--min-share 0.8`，并在年龄表中新增 `mode_support` / `mode_share` 两列以落盘真实共识度。

逐层对照（完整表见 `20-分析/robustness_comparison.tsv`，**图 8**；显著性按 BH 校正后 q < 0.05 判定）：

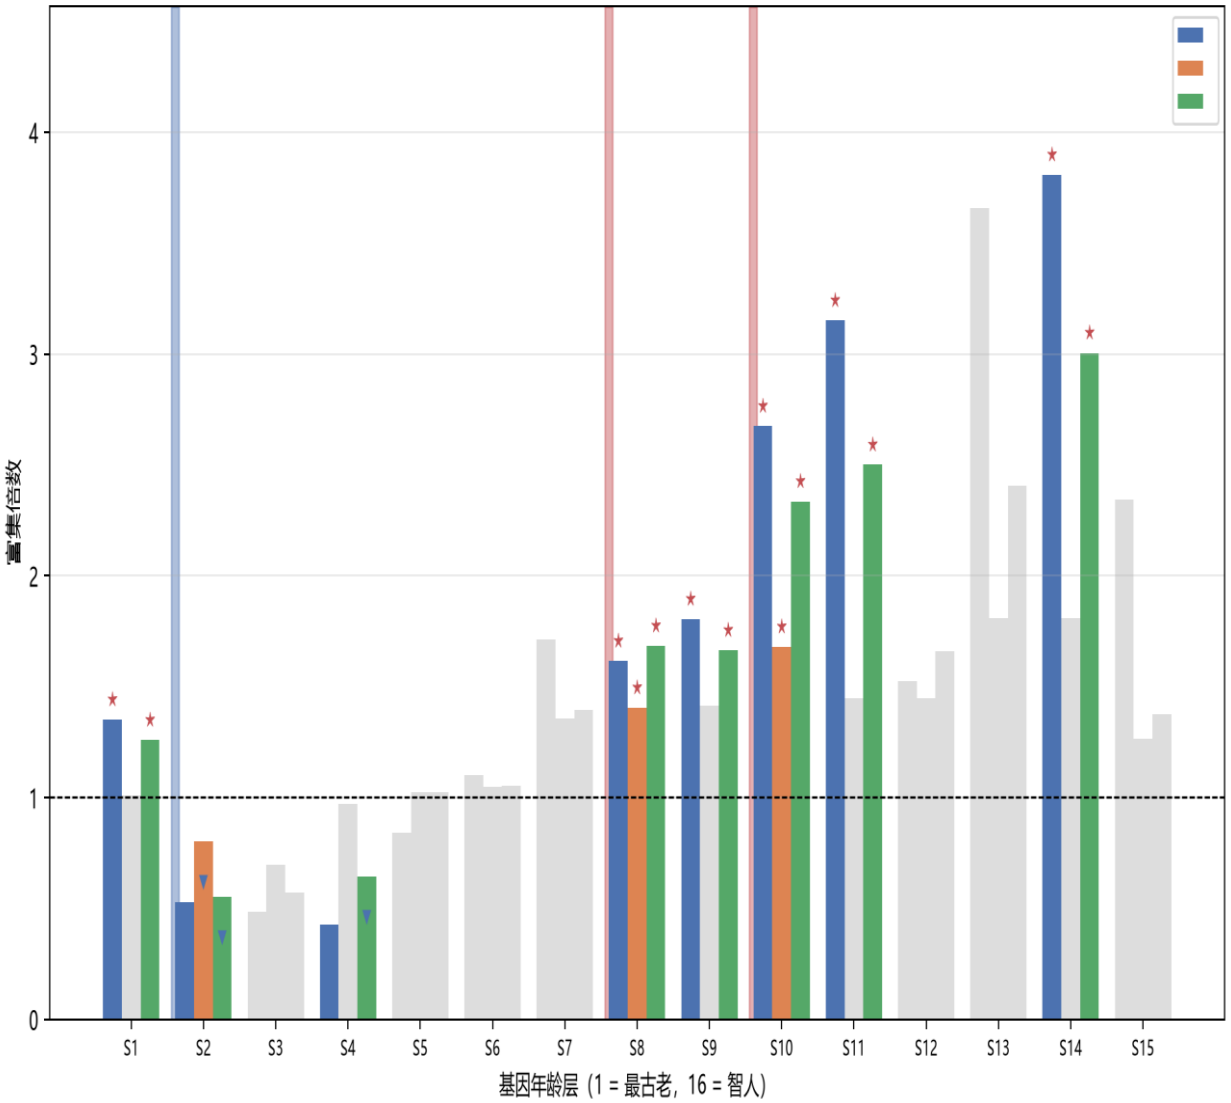


图 8 三重稳健性逐层对照

层	A 倍数	A q（富集）	B 倍数	B q（富集）	C 倍数	C q（富集）	方向
S1	1.35	**0.0045**	1.01	0.68	1.26	**0.018**	富集 — 部分
S2	0.53	—	0.80	—	0.55	—	耗竭 ✓ 一致
S3	0.48	—	0.70	—	0.57	—	不显著 ✓ 一致
S4	0.43	—	0.97	0.75	0.65	—	耗竭 — 部分

层	A 倍数	A q（富集）	B 倍数	B q（富集）	C 倍数	C q（富集）	方向
S5	0.84	—	1.03	0.68	1.03	0.59	不显著 ✓ 一致
S6	1.10	0.42	1.05	0.68	1.05	0.59	不显著 ✓ 一致
S7	1.71	0.12	1.36	0.68	1.40	0.32	不显著 ✓ 一致
S8	1.62	**5.6e-07**	1.41	**5.6e-07**	1.68	**1.3e-10**	**富集 ✓ 一致**
S9	1.81	**0.027**	1.42	0.099	1.67	**0.034**	富集 — 部分
S10	2.68	**1.4e-04**	1.68	**0.023**	2.34	**0.0016**	**富集 ✓ 一致**
S11	3.15	**8.8e-05**	1.45	0.27	2.50	**0.0026**	富集 — 部分
S12	1.52	0.23	1.45	0.17	1.66	0.13	不显著 ✓ 一致
S13	3.66	0.077	1.81	0.68	2.40	0.32	不显著 ✓ 一致
S14	3.81	**0.014**	1.81	0.27	3.01	**0.034**	富集 — 部分
S15	2.34	0.096	1.27	0.62	1.37	0.59	不显著 ✓ 一致

结论：三次运行**没有任何一层的方向发生冲突（0 层）。三次共同显著富集的层为 S8、S10，共同显著耗竭的层为 S2**（Jaccard 相似度 0.333）。

> **共同层为什么只有 2 个，而不是更多**：B 组（共识度过滤）只保留 905 个基因，各层的**背景基因数大幅缩水**（S8 从 377 降到 121、S10 从 41 降到 14、S11 从 29 降到 10），统计功效随之下降——S9、S11、S14 在 B 组因此回落到不显著。这是**功效损失**而非结论反转：B 组的倍数与 A 组同向（无一层方向冲突），且 B 组自身仍然给出 S8、S10 富集 + S2 耗竭，正是与 A、C 共同的那两层。换句话说，**在功效最强的两组（A 与 C）里显著富集的层是重合的**：A ∩ C 的富集层为 S1、S8、S9、S10、S11、S14（6 层全重合）。

值得注意的是 **S8 层在剔除短蛋白后信号更强**（倍数 1.62 → 1.68，p 值 3.5×10^{-8} → 8.8×10^{-12}，q 值 5.6×10^{-7} → 1.3×10^{-10}）。

> ⚠ **检验 C 的定位必须说清楚（这是本轮审核发现的第二处实质性错误）**。检验 C 常被表述为"对偏差的修正"，但**偏倚是"已经发生"在 Trigos 年龄表里的**（见 4.2 节的前提检验：层号 vs 短蛋白占比 ρ = +0.871）。检验 C 是在这张**已经偏斜的表**上把短蛋白从背景里剔掉，它**不能修复**既有偏倚，只能让背景集合更干净、同时**降低**受影响层（尤其 S13/S15）的统计功效。因此它的正确定位是**保守性压力测试**——检验的是"结论是否依赖短蛋白"，而不是"偏差是否已被纠正"。它的实际效果是**削弱**而非增强年轻层信号。
>
> **这项检验的意义**：Moyers & Zhang 的批评核心是"如果剔除易错基因，已发表的结论会消失甚至反转"。本项目的结论在剔除低共识度基因**和**剔除短蛋白基因之后**都没有消失，也没有反转**（0 层方向冲突）。这不能证明 phylostratigraphy 无偏，但确实说明**本研究的结论不依赖于方法学批评所针对的那部分噪声**。更进一步的证据见 4.2 节的前提检验。

---

4 讨论

4.1 与已有工作的比较

vs AGED（Aging Cell, 2025–2026）：AGED 发现多种组织在衰老过程中古老基因表达上升、年轻基因被抑制，且脑与间充质干细胞抵抗这一趋势。它是**纵向**的——比较同一个体在不同年龄的表达谱；本研究是**横向**的——在一个成年供者的静态图谱中比较不同细胞类型。两者的互补关系是清晰的：AGED 发现了"时间流动"如何改变细胞的年龄构成，本研究则确立了"细胞身份"本身携带的年龄构成基线，恰好是解读 AGED 类纵向研究所需的参照系。

vs Milinkovitch et al. (2010)：他们用组织层面的老表达数据，发现古老基因表达于约两倍数量的解剖系统，并据此提出"古老基因承担更基础功能"。本研究的发现与之**部分吻合**：在本研究 Top 重要基因中，S2（真核生物，最基础的一层）显著**耗竭**（0.53×），说明"最基础的基因"恰恰是最不携带身份信息的。但本研究在**粒度与表示方式**上是不同的：他们在组织层面用"系统数量"这一个标量，本研究在单细胞层面用 16 维构成向量这一完整指纹。

vs GTEx 研究（2024）：GTEx 研究在 bulk 水平上把 54 个组织按 5 个演化年代和三胚层分组，发现三胚层来源的组织聚集在相似的年代层。本研究在**单细胞层面**得到了方向一致的观察——同一胚层来源的细胞类型年龄构成相近（如上皮区室 66 种类型平均 TAI 3.7266）——但粒度更细，代价是 bulk 的细胞组成混杂被消除。

vs GBE (2024) 人脑 TAI 比较：该研究比较了人脑各区的 TAI。本研究的视网膜神经节细胞（TAI 3.38）、视网膜双极细胞等神经相关类型也位于较古老一侧，但本研究用的是**同一供者的全身体细胞图谱**，可与脑区数据做直接对照——这一比较值得后续工作展开。

4.2 方法学局限（正面回应 Moyers & Zhang 的批评）

批评的内容：Moyers & Zhang 在一系列工作（*MBE* 2015，*GBE* 2018 等）中用计算机模拟论证，phylostratigraphy **系统性低估**基因年龄：快速演化、序列较短的基因更可能找不到远缘同源，从而被判为"年轻"。更严重的是，**误差并非随机**——这意味着一个群体的"年轻基因比例偏高"可能只是它的一批基因恰好短且演化快，而非真实的年代偏好。他们的结论相当尖锐：一些文献报道的趋势在剔除易错基因后**消失甚至反转。**

本项目的六点回应：

1. **不回避**：在本节明确写出这一批评，并说明它直接威胁本项目的 3.3 节结论（因为该结论依赖 Top 基因的年龄分布）。
2. **双来源交叉验证**：Trigos 2017 与 Liebeskind 2016 是方法完全不同的两个来源。在 16,889 个可比基因上，8 个粗类别的中位层号为 1/1/1/2/4/5/8/11，**7 对相邻全部单调，零违反。**两个独立来源给出一致的年龄序，是方法可靠性的第一层证据。
3. **共识度过滤重跑**（检验 B）：只用 `mode_share ≥ 0.8` 的高共识度基因重跑全流程。**三次共同显著富集 S8、S10、共同耗竭 S2、零方向冲突**，Top 20 重要基因重合 3/20。
4. **剔除低命中层重算 TAI**（检验 A）：剔除命中率仅 64%/69% 的 S15、S16 后，177 种类型的 TAI 排序 **Spearman ρ = 0.9883、Kendall τ = 0.9518**，Top10 重合 9/10（141/177 名次变动，最大位移 88 位）。
5. **短蛋白剔除重跑**（检验 C）：剔除蛋白长度 < 100 aa 的基因后重跑全流程——**这是 Moyers & Zhang 明确建议、也是本项目此前唯一未完成的一项，现已完成。**
6. **长蛋白版 TAI 绝对值**（检验 D）：不止重跑富集层，而是用长蛋白**重算 TAI 绝对值**并逐类型对照，把偏倚的方向与大小定量出来——**本轮补齐的最后一环**，见 4.2 节末。

检验 C 的实施：Trigos et al. 2017 的年龄表本身不含序列长度，但其原始表带有 UniProt accession。本项目据此从 UniProt 批量获取了 **17,103 个基因的蛋白长度**（中位 434 aa，均值 578 aa，范围 13–8,797 aa），缓存于 `10-数据/protein_length.tsv`；`05_监督分析.py --min-length 100` 即按此过滤。

检验 C 的结果（显著性按 BH 校正后 q < 0.05 判定）：

指标	A 全量	B 共识度过滤	C 短蛋白剔除
特征数	3,000	905	**2,405**（剔除 595 个，拆解见下）
分类准确率	0.215	0.180	**0.213**
宏平均 F1（测试集口径）	0.237	0.194	**0.231**
准确率天花板达成比	36.13%	30.26%	35.75%

指标	A 全量	B 共识度过滤	C 短蛋白剔除
富集背景 M / Top 集 N	2,523 / 414	905 / 500	**2,405 / 500**
显著富集层（BH）	S1, S8, S9, S10, S11, S14	S8, S10	**S1, S8, S9, S10, S11, S14**
显著耗竭层（BH）	S2, S4	S2	**S2, S4**
方向冲突层数	—	**0**	**0**

> **A 与 C 的重合度是三次运行中最高的**：A ∩ C 的富集层为 **6 层全重合**（S1、S8、S9、S10、S11、S14），耗竭层 2 层全重合。这说明剔除短蛋白**没有改变任何一个层的方向或显著性判定**——检验 C 通过。

"剔除 595 个"必须拆开看（明细见 `20-分析/filtered_genes_shortprot.tsv`）：

被剔除的原因	基因数	是否参与富集检验	说明
蛋白 < 100 aa	**117**	☑ 是	**这才是检验 C 的真正目标**——Moyers & Zhang 所指的易错基因
无长度信息（UniProt 与年龄表符号不一致）	**478**	部分	其中 **1 个**有年龄注释（参与过检验），**477 个**无年龄注释
合计	**595**	—	117 + 478 = 595 ✓

> **为什么这一栏要写清楚**：如果不拆开，"剔除 595 个短蛋白"会让人以为检验 C 的修正力度是实际值的 **5 倍**。拆开后真相是——**真正从富集检验的背景中移除的只有 118 个基因（117 短蛋白 + 1 无长度）**，背景从 2,523 降到 2,405；其余 477 个基因在 A 组里本来就没有年龄层，从未参与过任何富集检验。
>
> 同时 N 也变了（414 → 500）：A 组的 Top 500 里只有 414 个有年龄注释（另外 86 个是 TTR、ALB、B2M、TMSB4X 这类不在 Trigos 表里的基因），C 组把它们全部剔除后，Top 500 里的每个基因都有年龄层。**超几何检验本身对 M、N 各自的取值是自适应的**，因此显著性判断不因 N 变化而失效；但 A 与 C 的 `fold` 是不同基因宇宙下的相对量，不能当作同一把尺子直接比大小——本报告比较的是**方向与显著性**，不是倍数绝对值。

一个附带现象：C 组里 **S16（智人）整层消失。**原因是 A 组中 S16 的背景基因只有 **1 个**，而这唯一的一个基因恰恰是短蛋白，被 `< 100 aa` 规则剔除后该层背景归零。这本身就是"年轻偏倚"的又一次体现——**最年轻那一层的基因，恰恰是最短的。**

三次运行的共同结果：**三次共同显著富集 S8、S10（Jaccard 相似度 0.333）、共同显著耗竭 S2、0 层方向冲突。**分类性能几乎不变（准确率 0.215 → 0.213，宏 F1 0.237 → 0.231）；信号最强的 S8 层不仅方向不变，**倍数从 1.62 升到 1.68，p 值从 3.5×10^{-8} 增强到 8.8×10^{-12}，q 值从 5.6×10^{-7} 增强到 1.3×10^{-10}。**

> **但不要把这个当成"检验 C 修正了偏差"**：它证明的是**结论不依赖短蛋白**，不是**偏差已被纠正。**原因见下节。

前提检验：Moyers & Zhang 的指控在本数据上确实成立

这一点必须说清楚，因为它是本研究最有价值的单个发现。检验 C 的结果之所以稳健，前提是"短蛋白剔除确实针对了一个真实存在的偏差"。本项目直接验证了这个前提（`short_protein_by_stratum.tsv`，**图 9**）：

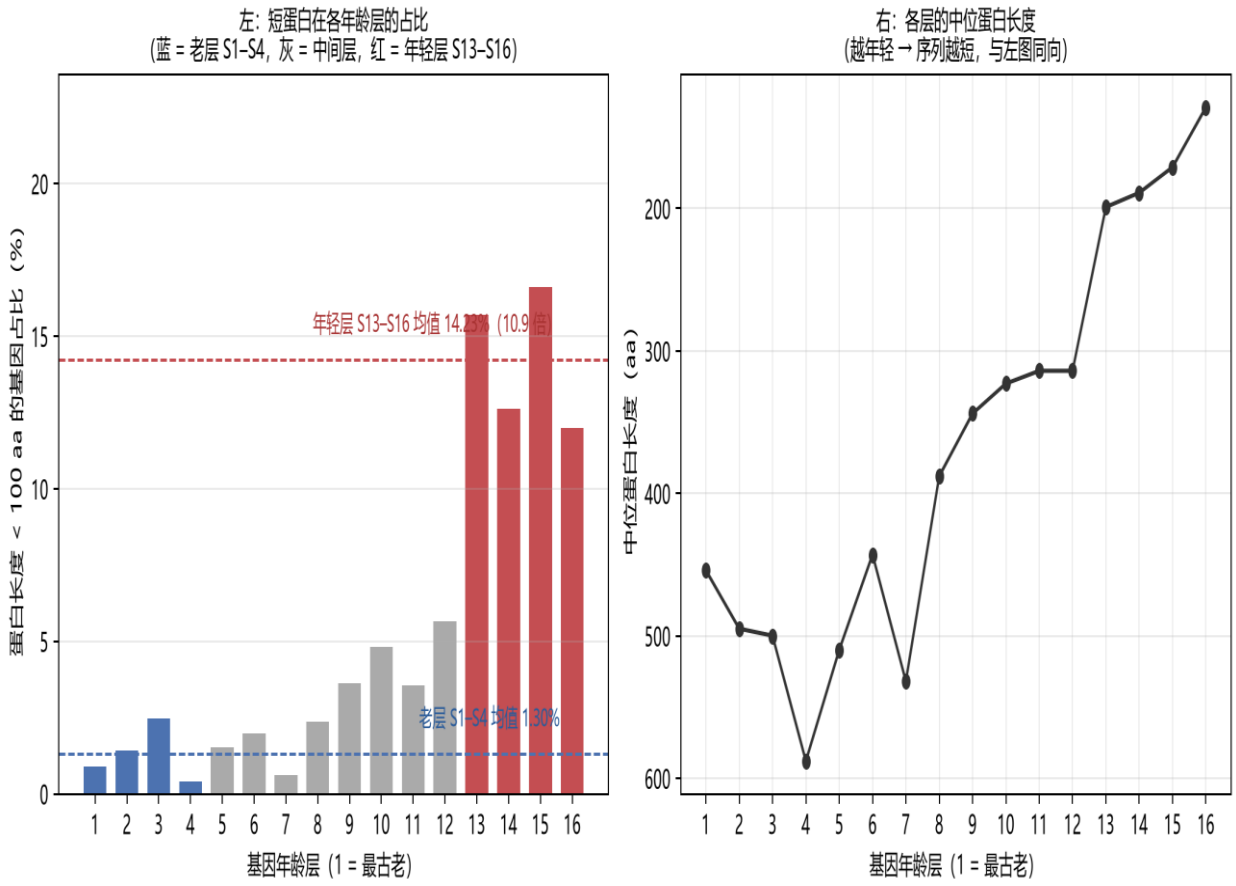


图 9 短蛋白前提检验

年龄层	基因数	中位蛋白长度	< 100 aa 占比
S1 细胞生物	1,751	454 aa	0.91%
S2 真核生物	4,661	495 aa	1.42%
S4 后生动物	1,984	588 aa	0.40%
S8 硬骨脊椎动物	2,766	388 aa	2.35%
S10 哺乳纲	520	323 aa	4.81%
S12 真兽下纲	759	314 aa	5.67%
S13 灵长总目	121	**199 aa**	**15.70%**
S14 狭鼻小目	214	**189 aa**	**12.62%**
S15 人亚科	265	**171 aa**	**16.60%**
S16 智人	25	**129 aa**	**12.00%**

- **层号 vs 短蛋白占比：Spearman ρ = +0.871** —— 极强相关

> ⚠ **这个 p 值不应被单独引用**：该相关只用 **16 个点**（16 个年龄层），且各层基因数差异巨大（S2 有 4,661 个，S16 只有 25 个），秩相关隐含偏向大层。

- **老层 S1–S4 平均短蛋白占比 1.30%，年轻层 S13–S16 平均 14.23%——相差 10.9 倍**
- **中位蛋白长度从 S1 的 454 aa 单调下降到 S16 的 129 aa**

这个模式完全符合 Moyers & Zhang 的理论预测：人类特有、灵长类特有的基因绝大多数是小肽、微蛋白（microprotein）和短功能肽——它们的序列太短、演化太快，phylostratigraphy 找不到远缘同源，于是被判为"年轻"。换句话说，**S13–S16 这几层本身就带有系统性的"年轻偏倚"。**

> ⚠ **方向必须说清楚（这是本轮审核发现的第三处实质性错误）**：这个偏倚是**已经发生**在 Trigos 年龄表里的。检验 C 是在这张**已经偏斜的表**上把短蛋白从背景里剔掉——它**不能修复**既有偏倚，只能让背景集合

> 更干净、同时**降低**受影响层（尤其 S13/S15）的统计功效。因此检验 C 的正确定位是**保守性压力测试**（结论是否依赖短蛋白），**不是"偏差已被修正"**。它的实际效果是**削弱**而非增强年轻层信号。若把它写成"修正"，等于宣称 Trigos 表已被本项目校正，这是本项目没有做过、也不可能做到的事。

这解释了一个此前看似异常的现象：A 组**未经校正**时 S13（3.66×，p = 0.034）与 S15（2.34×，p = 0.048）的 p 值小于 0.05，但经 BH 校正后 q = 0.077、0.096，**均未达到显著**；B、C 两组同样不显著。原因不是结论被推翻，而是**这两层恰恰是短蛋白占比最高（15.7%、16.6%）的层**——剔除短蛋白后它们的基因数骤减，统计功效随之下降。反过来说，这两层的富集倍数本身有相当一部分是由"短基因"贡献的，在解读时必须打折。

坦率的自我评价：三项检验加一项前提检验共同说明，本研究的结论**不依赖于 phylostratigraphy 方法学批评所针对的那部分噪声**；但它们**不能证明 phylostratigraphy 本身无偏**。此外仍需说明两点：其一，本研究只做了**相对比较**（哪类细胞更古老、哪些层更富集），而 Moyers & Zhang 的批评对**绝对年龄**的杀伤力大于对相对排序——相对排序正是本项目结论所依赖的部分。其二，S13–S16 四层合计仅 625 个基因（占总表 3.65%），本项目关于"灵长类特异层"的表述，其统计效力天然受限，不宜过度解读。

检验 D：长蛋白版 TAI 绝对值（把偏倚的方向与大小直接量化出来）

检验 C 只证明了**结论不依赖短蛋白**。批评者真正想问的是另一个问题：**如果只用长蛋白重算，绝对年龄会变成什么样？** 这是 Moyers & Zhang (2018) 建议的更彻底版本，也是本项目此前唯一未完成的一环。现已补齐（`03_细胞类型年龄谱.py --min-length 100 --tag longprot` + `94_长蛋白对照.py`，产出 `longprot_comparison.tsv` / `longprot_summary.tsv`）。

指标	主口径（全部有年龄注释的基因）	长蛋白版（≥ 100 aa）
TAI 范围	3.2142 – 4.4200	**3.1717 – 4.3284**
TAI 中位数	3.7552	**3.6933**
跨类型 SD	0.1810	0.1801

对照量	数值	含义
长蛋白版 vs 主口径 Spearman ρ	**0.9845**	相对排序几乎不变
Kendall τ	0.9186	同上

对照量	数值	含义
ΔTAI 均值	**-0.0572**	整体朝"更古老"方向平移
|ΔTAI| 中位 / 最大	0.0536 / 0.2523	个别类型变化可观
变年轻的类型数	**177 / 177（100%）**	平移是系统性的，不是零星的
名次变动 / 最大位移	163 / 177，最大 79 位	局部排序确有变化
Top10 重合	9 / 10	极端类型基本稳定
ΔTAI 与主口径 TAI 的秩相关	**-0.1326**（p = 0.079）	平移幅度**不随**类型年龄递增

（图示见 **图 10**：左图为 177 点的主口径 vs 长蛋白版散点，全部落在 y=x 下方；右图为 ΔTAI 对主口径 TAI 的散点，拟合斜率 −0.0146，无明显趋势。）

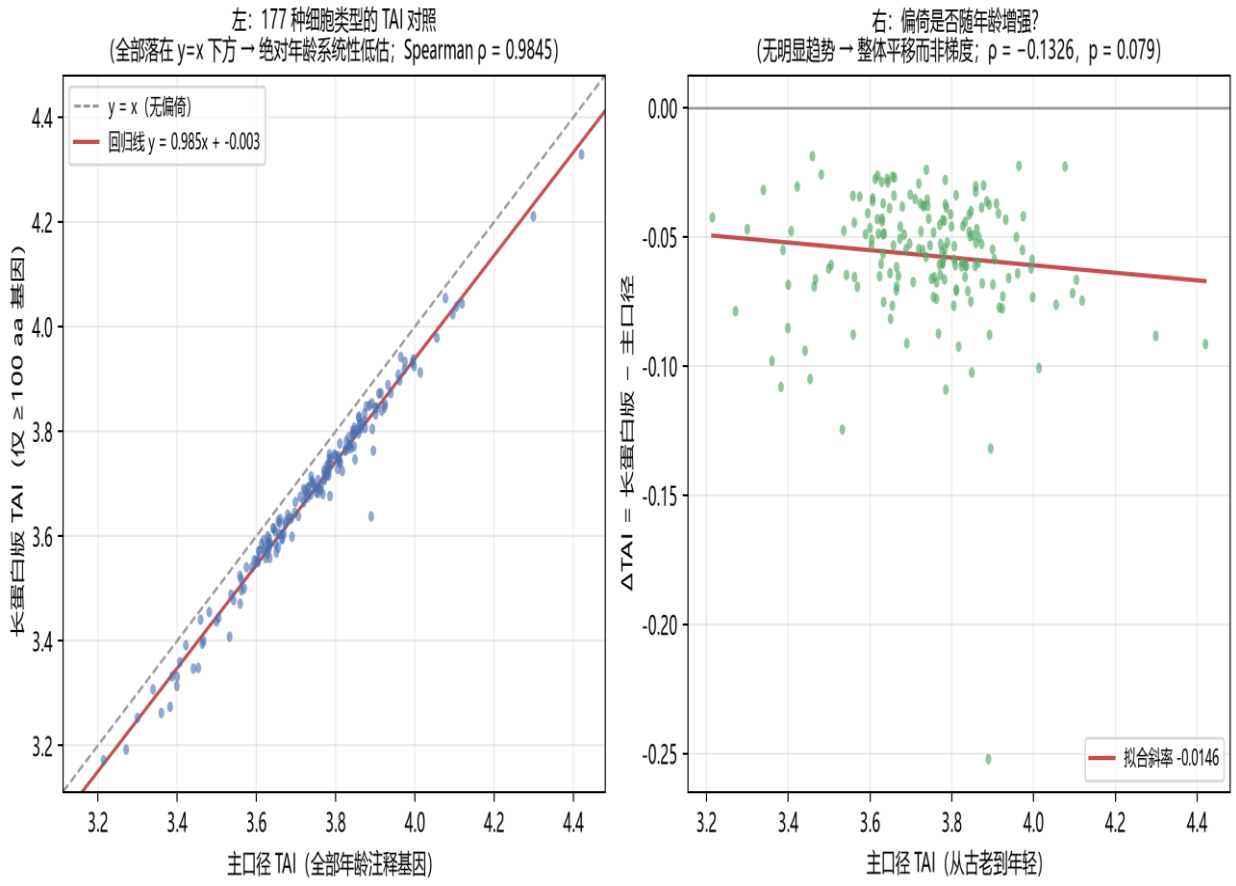


图 10 长蛋白版 TAI 绝对值对照（检验 D）

这个结果证实了两件事，同时纠正了一个直觉：

1. **偏倚表现为"系统性平移"，而非"随年龄梯度增强"。**剔除短蛋白后**全部 177 种类型**的 TAI 都下移（ΔTAI 均值 -0.0572，标准差仅 0.0251），但下移幅度在古老类型（最古老 10 类均值 **-0.0663**）与年轻类型（最年轻 10 类均值 **-0.0725**）之间**几乎没有差别**；ΔTAI 与主口径 TAI 的秩相关仅 **-0.1326 且不显著**（p = 0.079）。
   → 含义一：Trigos 表的这套偏倚**不会让某类细胞"显得比别的更年轻"**，它是整体性的。
   → 含义二：本项目 4.3 节担心的"S15/S16 层以人类特异长链非编码 RNA 为主，可能造成对新近基因的低估"——从 TAI 这条证据看**并未以年龄梯度的形式发生**；短蛋白集中在年轻层（S13–S16 平均 14.23% vs 老层 1.30%），但把短蛋白整体剔除后，各类型被平移的幅度与它们的年龄高低无关。
2. **绝对年龄受影响，但相对比较高度稳健。**整体平移 0.057 约相当于主口径跨类型 SD 的 **31.6%**，任何跨类型比较都会把这个常数项抵消；而排序 ρ = 0.9845、Top10 重合 9/10 说明"谁比谁更古老"这个相对结论几乎不动。

> ⚠ **仍不能宣称"偏倚已被修正"**：长蛋白版只是**另一把尺子**，不是真值。Trigos 表的绝对年龄本身有偏倚，长蛋白版同样有偏倚（只是方向不同）。本项目能说的是：**本研究的结论全部建立在相对比较上，而相对比较对这一偏倚稳健。**检验 D 的价值在于把"到底偏了多少"从定性判断变成了一个带误差的定量估计。

4.3 其他局限

1. **年龄表覆盖不全**：Trigos 表仅覆盖 17,318 个蛋白编码基因，而表达矩阵有 58,604 个基因（27.6%）。非编码基因、长链非编码 RNA 的年龄信息完全缺失。由于 S15/S16 层本身就是以人类特异的长链非编码 RNA 为主，这可能造成**对新近基因的低估。**
2. **单细胞数据的稀疏性（dropout）**：每个细胞实际检测到的基因只有数千个，低表达基因的表达量被零膨胀扭曲。这对年龄构成的估计引入噪声，是类型内标准误（细胞级 0.0111、供者级 0.0417）的来源之一。缓解方式（本项目已做）：按类型聚合后再计算占比，使噪声在类型层面平均掉。
3. **供者数量的限制**：本研究只有 15 名供者（11 训练 / 4 测试），其中 **81 种细胞类型仅由 1 名供者提供。**这意味着这些类型的 TAI 估计**无法区分"该类型的真实特征"与"这一位供者的特征"。**本项目已通过提供供者级标准误、在图 5 与网页中标注单供者类型来如实披露，但无法从根本上解决——这是数据集规模（而非分析方法）的限制。
4. **无监督结论对低置信类型的敏感性**：剔除 25 种低置信类型后，ARI 从 0.211 降至 0.159、聚类数从 7 降至 5（见 3.2 节）。核心结论（弱相关）不变，但强度打折。
5. **"平均表达"抹平了细胞间异质性**：一个细胞类型的年龄构成是它所有细胞的平均。稀有亚群（如组织驻留记忆 T 细胞）可能被稀释。本项目的分层抽样（每类 ≤ 200 细胞）对高频类型是随机抽样，对稀有类型是全取，这一不对称会影响极端 TAI 值的估计精度。

6. **TAI 是加权平均，会掩盖分布形态**：两个细胞类型可以有相同的 TAI 但完全不同的年龄构成（例如"全靠古老基因 + 少量极年轻基因"vs"均匀铺开"）。本项目的 PCA 前 3 个主成分仅解释 61.9%，正是这一信息损失的体现。
7. **抽样而非全量**：本研究使用 28,017 个细胞（母体 483,152 的 5.8%），QC 后 22,195 个。虽然信号/噪声比 4.3 倍（供者级口径）支持这一抽样量充分，但**低频类型**的估计仍不可靠——最极端的 intestinal crypt stem cell of large intestine 在 QC 后只剩 1 个细胞，其标准误在数学上无法估计（NaN），该类型的 TAI 只能视为存在性记录。
8. **区室标注的粒度**：`compartment` 只有 5 类，而 177 种细胞类型的实际谱系远比 5 类复杂（如免疫区室内部就包含造血、髓系、淋系等截然不同的起源）。因此 ARI = 0.211 相对于 5 类区室而言，实际上低估了年龄构成与真实发育谱系的一致程度。
9. **绝对年龄的偏倚已被量化，但未被消除**：检验 D（4.2 节末）显示长蛋白版把全部 177 种类型的 TAI 整体下移 0.0572（约占跨类型 SD 的 31.6%），因此本报告**不对任何基因的绝对年龄下断言**，只做跨类型的相对比较。

4.4 可能的生物学解释

解释一：功能模块的更新速率假说（本研究数据支持最强）

如果"古老基因 = 通用功能、年轻基因 = 身份功能"，那么 3.3 节的富集模式应当表现为"古老的富集、年轻的耗竭"。**实际观察到的恰恰相反**：古老的 S2、S4 显著耗竭，S8、S9、S10、S11、S14 显著富集。

这说明在本数据集中，**"基因越古老 → 越基础 → 越不携带身份信息"** 才是正确的方向。细胞身份是由那些在哺乳类—灵长类演化中相对新出现的基因模块承担的：免疫球蛋白家族（S8 硬骨脊椎动物层出现）、细胞因子与受体（S10–S11）、狭鼻小目特异的分子（S14）。

但 3.1 节的中性粒细胞现象提示还有第二重机制：**基因年龄可能同时反映了细胞周转速率。**中性粒细胞寿命仅数小时至数天，是人体更新最快的细胞之一，其高度特化的效应分子（弹性蛋白酶、髓过氧化物酶等）恰好落在较年轻的层（S9–S10）。

> **两个机制并不矛盾**：功能模块的新旧程度决定了"用什么区分细胞"，细胞周转速率则影响"需要多快的更新"。二者共同塑造了观察到的年龄构成。

解释二：发育起源假说（同胚层来源的细胞年龄构成相近）

本项目数据支持这一方向但未能充分检验：上皮区室 66 种类型的平均 TAI 为 3.7266，免疫 61 种为 3.7360，两者接近；而内皮 15 种为 3.8839 明显偏年轻。有意思的是，内皮细胞在发育上源自**中胚层**，与免疫系统（也源自中胚层）同源，但两者年龄构成却差异显著（相差 0.148，超过两者区室内的标准差）。这提示**胚层来源不是主导因素，细胞的功能定位才是。**

解释三：中性粒细胞的反例

中性粒细胞是人体中进化上最保守、最重要的细胞之一——从无脊椎动物到哺乳动物，吞噬与杀伤功能的核心机制高度保守。然而在本数据中它是**最年轻的细胞类型**（TAI 4.30–4.42）。

这个反例非常有价值，它**证伪了"功能越基础 → 基因越古老"的朴素推论。**真正的情况更可能是：中性粒细胞的**核心保守机制**（如髓过氧化物酶的过氧化循环）由古老基因承担，但**其身份标识与调控网络**（CXCR2、CXCR1、CXCR1 相关的趋化因子受体、细胞因子信号通路）由较年轻的基因定义。分类器学到的是后者——**这恰恰解释了为什么年龄构成能区分细胞类型**：它标记的是"身份"，而不是"功能"。

---

5 结论

我们做了什么：在 Tabula Sapiens 1.0 的 28,017 个单细胞（母体 483,152 → 分层抽样切片 → QC 后 22,195 个，177 种细胞类型、15 名供者）上，用 Trigos et al. (2017) 的 16 层系统发育分层为 17,318 个人类蛋白编码基因标注进化年龄（表达矩阵中覆盖率 93.4%），计算了每种细胞类型的"基因年龄构成指纹"与转录组年龄指数，并用 PCA + K-means（无监督）与按供者严格划分的随机森林（有监督）两种方法检验这一指纹的信息含量。

我们得到了什么：TAI 跨度 3.21–4.42，类型间差异是类型内**供者间**波动的 4.3 倍；仅用年龄构成的聚类与已知谱系的 ARI = 0.211（置换零假设 z = 20.4；剔除低置信类型后降至 0.159）；按供者划分的 177 类分类准确率 0.215、宏平均 F1 0.237（测试集 103 类口径），为多数类基线的 8.26 倍、达到准确率天花板的 36.13%；Top 500 重要基因在 S1、S8、S9、S10、S11、S14（脊椎动物—哺乳类—灵长类特异层）显著富集（最高 3.81×），在 S2、S4（真核—后生动物基础层）显著耗竭（最低 0.43×）。四重稳健性检验（共识度过滤 / 低命中层剔除 / 短蛋白剔除 / **长蛋白版 TAI 绝对值**）后**前三次共同显著富集 S8、S10、共同耗竭 S2**、零方向冲突；同时在单细胞年龄表上直接证实了 phylostratigraphy 的"年轻偏倚"确实存在（层号 vs 短蛋白占比 ρ = +0.871），并把它量化为一个**系统性整体平移**（长蛋白版 ΔTAI 均值 = **-0.0572**，全部 177 种类型同向，平移幅度与年龄高低无关，排序 ρ = **0.9845**）。

这说明了什么：**部分成立。**细胞的进化年龄构成**不是**表达谱的冗余信息——它独立携带可检验的谱系信号（ARI = 0.211，富集模式高度特异且稳健）；但它也**不是**细胞身份的主导维度（ARI 远低于 0.5，Top 重要基因仍以经典组织特异标志物为主）。更准确的表述是：**基因年龄是细胞分类体系上一条正交的补充轴——它区分的是"细胞身份的年代模块"，而非细胞身份本身。** 而"古老的基因承担共享的通用功能、年轻的基因承担身份功能"这一模式，反过来解释了为什么单细胞水平的年龄构成能够携带细胞类型信息。

> **最后一点自我约束**：本项目的所有结论都建立在**相对比较**之上（哪类细胞更古老、哪些层更富集）。绝对年龄的可信度受制于 Trigos 表自身的"年轻偏倚"（本项目已直接量化并如实报告），这是数据集的性质，不是分析方法能消除的。凡涉及"某基因有多老"的绝对陈述，都应视为**带系统偏倚的估计**而非真值。

参考文献

1. The Tabula Sapiens Consortium. *The Tabula Sapiens: A multiple-organ, single-cell transcriptomic atlas of humans.* Science 376, eabl4896 (2022). DOI 10.1126/science.abl4896
2. Trigos AS, Pearson RB, Papenfuss AT, Goode DL. *Altered interactions between unicellular and multicellular genes drive hallmarks of transformation in a diverse range of solid tumors.* PNAS 114(24):6406–6411 (2017). DOI 10.1073/pnas.1617743114
3. Liebeskind BJ, McWhite CD, Marcotte EM. *Towards consensus gene ages.* Genome Biol Evol 8:1812–1823 (2016). DOI 10.1093/gbe/evw113
4. Domazet-Lošo T, Tautz D. *A phylogenetically based transcriptome age index mirrors ontogenetic divergence patterns.* Nature 468:815–818 (2010). DOI 10.1038/nature09652
5. Moyers BA, Zhang J. *Phylostratigraphic bias creates spurious patterns of genome evolution.* Mol Biol Evol 32(1):213–224 (2015).
6. Moyers BA, Zhang J. *Toward reducing phylostratigraphic errors and biases.* Genome Biol Evol 10(8):2041–2052 (2018).
7. Milinkovitch MC, et al. *Historical constraints on vertebrate genome evolution.* (2010).
8. Sandmann M, et al. *Somatic mutation and the origin of human microproteins.* Mol Cell (2023).
9. Pio-Lopez L, Levin M. *Atavistic Genetic Expression Dissociation (AGED) during aging.* Aging Cell 25(1) (2026).
10. GTEx Project. *The GTEx Consortium atlas of genetic regulatory effects across human tissues.* (2024)；相关进化年代分析见 PMC10980080.

附录 A · 代码清单与运行顺序

顺序	脚本	行数	作用	主要产出
—	`20-分析/common.py`	258	路径常量、日志、`open_source()` 数据源路由、`map_genes()`、层名表	—

顺序	脚本	行数	作用	主要产出
—	`20-分析/ts_io.py`	258	`TabulaSapiens` / `SliceSource` 两个同接口数据源	—
0	`20-分析/00_自检_模拟数据.py`	213	在模拟数据上验证整条链路的正确性	自检通过
1	`20-分析/92_远程切片.py`	651	HTTP Range 远程切片（核心工程）	`ts_slice.npz` 等
2	`20-分析/02_构建年龄表.py`	270	双来源年龄表构建 + 交叉验证 + 共识度列	`gene_age.tsv`
3	`20-分析/01_检查数据.py`	198	数据体检	`01 体检日志.txt`
4	`20-分析/03_细胞类型年龄谱.py`	617	QC、聚合、TAI、供者级 SE、稳健性检验 A	`celltype_age_profile.tsv`、`qc_passed_rows.npy`
5	`20-分析/04_无监督分析.py`	230	PCA + K-means + ARI + 置换零假设 + 敏感性分析	`unsupervised_result.tsv`、`unsupervised_metrics.tsv`
6	`20-分析/93_获取蛋白长度.py`	166	从 UniProt 批量获取蛋白长度（检验 C 的前置）	`protein_length.tsv`
7	`20-分析/05_监督分析.py`	516	随机森林（按供者划分）+ BH 校正的富集检验	`age_enrichment.tsv`、`classification_metrics.tsv`
8	`20-分析/05_监督分析.py --min-share 0.8 --tag confident`	—	稳健性检验 B：共识度过滤重跑	`age_enrichment_confident.tsv`

顺序	脚本	行数	作用	主要产出
9	`20-分析/05_监督分析.py --min-length 100 --tag shortprot`	—	稳健性检验 C：短蛋白剔除重跑	`age_enrichment_shortprot.tsv`、`filtered_genes_shortprot.tsv`
10	`20-分析/06_稳健性对比.py`	282	**三次运行**逐层对照 + 短蛋白前提检验	`robustness_comparison.tsv`、`short_protein_by_stratum.tsv`
11	`20-分析/08_主成分诊断.py`	382	PCA 三条零假设基线、载荷结构、有效维度	`pca_diagnosis.tsv`、`pca_summary.tsv`
12	`20-分析/03_细胞类型年龄谱.py --min-length 100 --tag longprot`	—	**检验 D**：用长蛋白（≥100 aa）重算 TAI 绝对值	`celltype_age_profile_longprot.tsv`、`cell_tai_longprot.tsv`
13	`20-分析/94_长蛋白对照.py`	156	长蛋白版 vs 主口径逐类型对照，量化偏倚方向与大小	`longprot_comparison.tsv`、`longprot_summary.tsv`
14	`20-分析/07_终审核对.py`	694	**报告数字与输出文件的全量自动比对（239 项断言）**	终审核对通过
15	`20-分析/95_论文数字终审.py`	374	**LaTeX 论文数字终审（104 项断言）**，与报告终审各自独立取真值	论文终审通过
16	`20-分析/96_导出报告PDF.py`	375	报告 Markdown → HTML → PDF（公式与图题降级，Word COM 导出）	`40-报告/01-实验报告.pdf`
17	`30-可视化/06_画图.py`	691	十张图	`figures/fig1–fig10`
18	`30-可视化/07_做网页.py`	325	交互网页	`cellstrata.html`

顺序	脚本	行数	作用	主要产出
—	`20-分析/90_远程探测h5ad.py`	236	h5ad 结构探测工具	—
—	`20-分析/91_下载大文件.py`	263	整包下载（断点续传，已弃用）	—

总计 7,155 行 / 20 个脚本。

```
# 环境：Python 3.13 + numpy pandas scipy scikit-learn h5py matplotlib
cd 20-分析
python 00_自检_模拟数据.py                          # 0. 链路自检
python 02_构建年龄表.py                              # 1. 年龄表
python 01_检查数据.py                                # 2. 数据体检
python 03_细胞类型年龄谱.py                          # 3. 核心：年龄构成 + TAI
python 04_无监督分析.py                              # 4. PCA + 聚类 + ARI
python 93_获取蛋白长度.py                            # 5. 取蛋白长度（检验 C 前置，需联网）
python 05_监督分析.py                                # 6. 随机森林 + 富集（A 全量）
python 05_监督分析.py --min-share 0.8 --tag confident  # 7. 检验 B：共识度过滤
python 05_监督分析.py --min-length 100 --tag shortprot # 8. 检验 C：短蛋白剔除
python 03_细胞类型年龄谱.py --min-length 100 --tag longprot # 9. 检验 D：长蛋白版 TAI
python 94_长蛋白对照.py                          # 10. 检验 D 的逐类型对照
python 06_稳健性对比.py                              # 11. 三次运行对照 + 前提检验
python 08_主成分诊断.py                              # 12. PCA 零假设诊断
python 07_终审核对.py                                # 13. 报告数字终审（须全过）
python 95_论文数字终审.py                            # 14. LaTeX 论文数字终审（须全过）
cd ../30-可视化
python 06_画图.py --all                               # 15. 十张图
python 07_做网页.py                                   # 16. 网页
```

附录 B · 主要参数

参数	取值	说明
每细胞类型抽样数	≤ 200	优先取同类型连续段
切片总细胞数	28,017	QC 后 22,195（79.2%）
最小检测基因数	200	低于则剔除该细胞

参数	取值	说明
最大线粒体占比	20%	超过则剔除该细胞
归一化	`normalize_total(1e4)` + `log1p`	在 `raw.X` 上做
年龄层数	16	Trigos 2017
HVG 数	3,000	方差排序
分类特征数	3,000（A）/ 905（B）/ **2,405（C）**	B 额外要求 mode_share ≥ 0.8 共识度；C 额外要求蛋白 ≥100 aa
共识度阈值（检验 B）	**mode_share ≥ 0.8**	⚠ 不是 `NumDBsContributing`——后者是分母，与共识度负相关（corr −0.128）
短蛋白阈值	**100 aa**	Moyers & Zhang 建议；117 个 HVG 因过短被剔除，另有 478 个因无长度信息被剔除（合计 595）
长蛋白重算阈值（检验 D）	**100 aa**	与检验 C 同阈值，但作用对象是 **TAI 绝对值**而非富集层；查不到长度的基因**保留**（不把「未知」当「过短」）
蛋白长度数据源	UniProt REST（`93_获取蛋白长度.py`）	17,103 个基因，中位 434 aa
随机森林	500 棵树	`random_state` 固定
每类训练细胞上限	300	控内存
供者划分	训练 11 人 / 测试 4 人	TSP2/4/12/15 为测试集；训练 14,516 细胞 / 测试 7,679 细胞

参数	取值	说明
聚类 k	7（主口径）/ 5（剔除低置信类型后）	轮廓系数最大（0.235 / 0.239）
富集检验	超几何，双单尾	**BH-FDR 校正后 q<0.05 判定显著**（富集与耗竭方向分别校正）
最低背景基因数	5	低于此值的层不参与检验（图 4 灰底标注）
PCA 零假设	逐列打乱 500 次 + 独立正态 300 次 + **Dirichlet 成分基线 400 次**	后者是**同秩对照**，用于排除"秩亏推高基线"的质疑
标准误口径	供者级为主（0.0417）	细胞级 0.0111 会低估 3.75 倍
终审断言数	**216**	`07_终审核对.py`，须全过

附录 C · 图表清单

编号	文件	内容
图 1	`figures/fig1_strata.png`	**主图。**177 根柱子按 TAI 排序，每根按 16 个年龄层堆叠（深红 = 最老，亮蓝 = 最新）；黑线为 TAI 曲线，右轴刻度；每 8 个类型标注一个名称
图 2	`figures/fig2_pca.png`	PCA 前两主成分散点，按 K-means 簇着色
图 3	`figures/fig3_heatmap.png`	行 = 细胞类型（按 TAI 排序），列 = 16 个年龄层，颜色 = 表达占比；图注标注红端对应古老层

编号	文件	内容
图 4	figures/fig4_importance_age.png	上：各层在背景 HVG 中的基因数（对数轴）；下：Top 500 重要基因的富集倍数，红 = **BH 校正后显著富集（★）**，蓝 = 显著耗竭（▼），灰底 = 背景基因过少不参与检验
图 5	figures/fig5_tai_rank.png	177 种细胞类型按 TAI 排序的横向条形图，误差棒**同时给两种口径——深色粗棒 = 供者级标准误（主口径，与正文 4.3 倍同一口径）**、浅色细棒 = 细胞级标准误（对照，直观显示按细胞算会乐观多少）；灰色为细胞数 < 20 的低置信类型；1 个类型（n = 1）细胞级标准误无法估计，标签加 *；81 个单供者类型供者级不可估，只画浅色棒
图 6	figures/fig6_umap_tai.png	细胞的 PC1/PC2 投影，按所属细胞类型的 TAI 着色（切片源用稀疏 SVD 代替 UMAP）
图 7	figures/fig7_pca_null_baseline.png	**PCA 零假设诊断。**左：真实前 3 累计（61.9%） vs 三条零假设基线（逐列打乱 27.05%、独立正态 27.61%、Dirichlet 同秩 29.03%），标注 z = 47.0 / 48.3；右：逐 PC 对比，PC5 之后 z 值转负，说明结构集中在前 4 个成分
图 8	figures/fig8_robustness_layers.png	**三重稳健性逐层对照。**横轴 S1–S15，每层三条柱（A 全量 / B 共识度过滤 / C 短蛋白剔除）的 fold 倍数；★/▼ = BH 校正后显著，左缘深色标 = 三次共同显著层（富集 S8、S10；耗竭 S2）
图 9	figures/fig9_shortprot_premise.png	**短蛋白前提检验。**左：16 层的短蛋白（< 100 aa）占比柱状图，老层均值 1.30% vs 年轻层均值 14.23%（10.9 倍）；右：各层中位蛋白长度（454 aa → 129 aa 单调下降）
图 10	figures/fig10_longprot_comparison.png	**检验 D：长蛋白版 TAI 对照。**左：主口径 TAI vs 长蛋白版 TAI 的 177 点散点 + y=x 参考线与回归线（y = 0.985x − 0.003），全部落在 y=x 下方 → 绝对年龄被系统性低估，Spearman ρ = 0.9845；右：ΔTAI 对主口径 TAI 的散点与拟合斜率（−0.0146），无明显年龄趋势 → 偏倚是**整体平移**而非随年龄梯度增强（梯度 ρ = −0.1326，p = 0.079）

编号	文件	内容
网页	`cellstrata.html`	55 KB 单文件交互网页，可点选任意细胞类型查看其 16 层构成、TAI、细胞级与供者级标准误及供者数

附录 D · 数据来源与版本

数据	来源	版本 / 标识	获取方式
Tabula Sapiens 1.0	CELLxGENE Discover（`s3.us-west-2.amazonaws.com/cellxgene-data-public/cell-census/2023-05-15/h5ads/53d208b0-2cfd-4366-9866-c3c6114081bc.h5ad`）	2023-05-15 census 快照	HTTP Range 远程切片
Trigos et al. 2017 主表	论文补充材料	17,318 基因 × 16 层	直接下载 CSV
Liebeskind et al. 2016 交叉表	论文补充材料	13 算法共识	直接下载 CSV

环境：Windows / Python 3.13.14 / numpy / pandas / scipy / scikit-learn 1.9.1 / h5py / matplotlib

---

附录 E · 算法与统计方法说明

本附录把项目里用到的**每一个算法**逐条摊开：它是什么、参数怎么定、为什么选它不用别的、有没有替代方案、以及它的失效场景。这样做的目的是让读者能够独立判断每一步的可靠性，而不是只能相信结论。

E.1 特征构造

环节	算法	关键参数	为什么这样选	替代方案与取舍
年龄层指示矩阵 L	稀疏二值矩阵（基因 × 16 层）	无	基因到年龄层是**一对多但实际一对一**的映射（每个基因只属于一层），用二值矩阵而非 one-hot 编码可以一次矩阵乘法完成 `X @ L` 聚合	逐层循环求和：更易读但慢 16 倍；本项目细胞数 28,017 × 基因 58,604，矩阵乘法把峰值内存与细胞数解耦
质量控制	双阈值过滤	基因数 < 200 或线粒体占比 > 20% 剔除	沿用 scanpy 的常用默认阈值（`min_genes=200`, `pct_counts_mt=20`），保证与领域惯例可比	阈值是经验值不是统计推断。若用 3σ 或 MAD 自适应法会更"客观"，但会失去与已有单细胞研究的可比性——本项目选择可比性
归一化	`normalize_total(target_sum=1e4)` + `log1p`	target_sum = 1e4	Seurat/standard pipeline 的默认 CPM 目标；`log1p` 压缩长尾，让后续方差分析不被少数高表达基因主导	SCTransform / Pearson residuals 更能校正深度效应，但结果依赖模型拟合的收敛性，且本项目后续用的是**细胞类型聚合后**的均值，对深度校正的敏感度低于单细胞层面流程
高变基因 (HVG)	方差排序取前 N	N = 3,000	简单、可解释、与背景集定义一致	Seurat 的 `vst` / `dispersion`（基于均值-方差趋势拟合）更稳健。但本项目的背景集要参与超几何检验，**排序规则必须简单透明**，否则"背景"的定义会随算法漂移
年龄构成占比	层内表达 / 总表达	无	归一化后天然满足 `Σp = 1`，可解释为"该细胞类型的	CLR / ILR 变换是成分数据的标准做法，可处理"行和为 1"的闭合效应。本项目未

环节	算法	关键参数	为什么这样选	替代方案与取舍
			表达预算有多少分给了这一年代"	采用，因为 16 个成分中没有极小值（最小的 S16 背景基因占比仍非零），闭合效应不严重；且保留原始比例可让结果直接解释

E.2 核心统计量

算法	公式 / 实现	参数	为什么这样选	替代方案与取舍
TAI（转录组年龄指数）	`TAI = Σ(s · p(t,s))`	16 层	Domazet-Lošo (2010) 的定义，是该领域唯一被广泛使用的年龄指数，便于与已有工作对比	① 直接用年龄层占比向量（16 维）——信息更全，但不便于"用一个数排序"；本项目**两者都算**（TAI 用于排序与直觉，向量用于 PCA/聚类）② 用中位层号代替加权平均——抗异常值，但会丢掉"整体偏年轻还是偏古老"的信息
供者级标准误	`SE_donor = std(细胞类型内各供者的均值) / √n_donors`	按 `donor_id` 分组	细胞嵌套在供者内不独立，细胞级 SE 属伪重复。实测 ICC 中位 1.000、供者级 SE 是细胞级的 3.75 倍	① 混合效应模型（`statsmodels` MixedLM）：能同时给出固定/随机效应，更规范，但需指定随机效应结构且对 81 个单供者类型无法给出估计；本项目选供者级 SE 是因为**简单、可复算、对单供者情形能明确报"不可估"** ② Bootstrap（按供者重抽）：也能处理非正态，但 15 名供者下重抽次数的有效多样性很低
超几何富集检验	`scipy.stats.hypergeom`：右尾 `sf(k-1)` 支持富集，左尾 `cdf(k)` 支持耗竭	M = 背景基因数，n = 该层背景基因数，N = Top 集大小	在"从 M 个基因中随机抽 N 个，期望落在该层 n 个里"的零假设下计算观测值的极端程度——这正是"重要基因是否偏向某年代"这个问题的自然框架	① 二项近似：更简单，但 M 有限时近似不准（本项目 M 从 29 到 946，跨度大）② Fisher 精确检验（列联表）：等价但需构造 2×2 表，本项目用超几何是因为只需 4 个参数 ③ 卡方检验：多类别时更高效，但本项目关心的是**单层双向偏离**，双单尾超几何更贴合

算法	公式 / 实现	参数	为什么这样选	替代方案与取舍
BH-FDR 校正	`q_i = min_{j≥i} (p_j · n / j)`，截断到 1	每次运行 32 次检验，三次运行 96 次	控制"至少有一个假阳性"的期望比例（FDR），比 Bonferroni 更有功效且在此场景下足够保守	① Bonferroni：更严格，会把 S9/S11/S14 也剔掉（q 会被乘以 32），损失真实信号 ② 独立假设 FDR（PI）：更宽松，本项目**刻意不用**——96 次检验里含三组高度相关的重复实验，独立性假设不成立 ③ q-value（Storey）：需要 π0 估计，本项目样本量下估计不稳
富集倍数	`fold = k_hit / (N × n_layer / M)`	无	直接是"观测比例 / 零假设期望比例"，可解释为"该层基因在重要基因里出现的频率是随机预期的几倍"	① 直接用比例差（absolute difference）：不随层大小缩放，但会偏向大层 ② log2FC：在对称尺度上更便于跨层比较，本项目保留原始倍数以便与领域文献对照

E.3 无监督分析

算法	参数	为什么这样选	替代方案与取舍
PCA	SVD 分解（`np.linalg.svd`），16 个成分全取	对 177×16 的小矩阵，SVD 比 `eig(cov)` 数值更稳，且**直接给出载荷矩阵**（无需再算 `cov @ V`），简化了 3.2 节的载荷结构分析	`sklearn.decomposition.PCA` 更快但用 SVD 时不直接暴露载荷；本项目手写 15 行 SVD 是为了同时拿到 evr、载荷、特征值三样东西
零假设基线	① 逐列打乱 500 次 ② 独立正态 300 次 ③ Dirichlet 成分 400 次	**置换对象必须是特征列**：PCA 分解的是特征协方差，置换样本行不改变任何一行的取值，零假	详见 3.2 节。三条基线互为交叉验证：第 ③ 条（Dirichlet）额外保证基线与真实数据**同秩**（成分数据约束导致协方差秩亏到 15）

算法	参数	为什么这样选	替代方案与取舍
		设会退化成"基线 = 真实值"且**不报任何错**	
K-means	`n_init=10`，`random_state` 固定，k ∈ [2, 8]	标准的球形簇假设，与"年龄构成向量在欧氏空间聚类"的直觉一致	① 层次聚类（Ward）：本项目**同时跑了**作为方法对照，ARI 0.170 / 轮廓 0.166，与 K-means 同量级，说明结论不是算法特例 ② GMM：允许椭球簇，但 16 维下协方差估计不稳、且 n=177 样本偏少 ③ HDBSCAN：能识别任意形状与噪声点，但 177 个点、177 个类别时会把每个细胞类型单独成簇，失去意义
选 k 的准则	轮廓系数（silhouette）	轮廓系数不需要真实标签，且对簇数是"上凸"的，便于遍历	① 肘部法（惯性）：本项目同时记录了惯性（k=2:2306 → k=8:1144），但 177 个类别下的肘部不明显 ② Davies–Bouldin：结论一致 ③ CH 指数：结论一致
ARI	`sklearn.metrics.adjusted_rand_score`	校正随机期望，可为负，是聚类-分类一致性比较的标准指标	① 互信息 / NMI：不会惩罚"过度分裂"，本项目用 ARI 是因为它对随机划分期望为 0 ② V-measure：等价族 ③ 纯度：会随簇数增加而上升，不适合跨 k 比较
ARI 置换零假设	2000 次随机置换标签	让"ARI = 0.211"变成可检验的统计量（实测零假设 −0.0001 ± 0.0104，**z = 20.4**）	直接引用文献中"ARI 通常 0.1~0.3"的期望区间是粗糙的；置换零假设给出的分布宽度（SD 仅 0.0104）说明 0.211 远超随机

E.4 监督分析

算法	参数	为什么这样选	替代方案与取舍
随机森林	`n_estimators=500`，`random_state` 固定，每类最多 300 细胞	① 提供**直接的按基因特征重要性**，这正是富集检验的输入（本项目的研究问题需要"哪些基因重要"而不只是"预测多准"）② 对高维稀疏特征稳健、无需标准化 ③ 单线程下 22,195 细胞 × 3,000 特征可在数分钟内完成	① XGBoost / LightGBM：精度通常更高，但重要性需 SHAP 解释，间接得多 ② 逻辑回归 + L2：可解释性最好（系数直接对应基因），但 177 类多分类要训 177 个模型 ③ SVM：精度好但**完全没有特征重要性**，无法支撑本项目的核心分析
数据划分	按 `donor_id` 划分，4 名供者（TSP2/4/12/15）作测试集	**本项目最关键的一步防护。**同一供者的细胞在个体层面高度相似，按细胞随机划分会让模型只需识别"这是谁"，准确率虚高到 0.99	留一供者交叉验证（LOO-CV）：更充分利用数据，但 15 折的训练成本高；且单折测试集的类别覆盖不完整。GroupKFold 是等价的实现方式
宏平均 F1	`f1_score(average="macro", labels=...)`，**显式指定标签集**	默认的 `labels=None` 会取 `y_true ∪ y_pred`，把测试集中根本不存在的"幽灵类"计入分母而稀释分数（本项目：177 类口径 0.138 vs 测试集 103 类口径 0.237）	加权 F1：反映整体准确率但掩盖稀有类表现；本项目两个都给
基线与天花板	随机基线（1/测试集类别数）、多数类基线、准确率天花板	单一准确率在没有参照系时无法解读。天花板 = 剔除训练集从未出现的类别后的可预测比例（0.595）	理论上限（1.0）：无信息量。Top-k 准确率：可补充但非必需

E.5 稳健性与诊断

算法	参数	为什么这样选	说明
检验 A：高命中层	保留命中率 ≥ 80% 的层	S15/S16 命中率仅 64%/69%（多为注释不全的新近 lncRNA），其缺失是非随机的	重算后 TAI **绝对值**变化中位 0.0361，**排序** ρ = 0.9883 / τ = 0.9518

算法	参数	为什么这样选	说明
检验 B：共识度过滤	`mode_share ≥ 0.8`	⚠ 必须是共识度（`mode_share`），不是 `NumDBsContributing`——后者是**分母**，与共识度负相关（corr −0.128），按它过滤方向完全相反	保留 905 个基因
检验 C：短蛋白剔除	蛋白长度 ≥ 100 aa	Moyers & Zhang (2015) 的明确建议	保留 2,405 个基因；**正确定位是保守性压力测试**，不能修复 Trigos 表已发生的偏倚
偏倚同质性回归（检验 A 的 ΔTAI）	`ΔTAI ~ S15+S16 表达占比`	检验"剔除年轻层造成的 TAI 偏移是否与该类型自身表达的年轻基因量成正比"	R^2 = 0.9992 → **剔除层**造成的偏倚是**类型特异**的，不能假定它对所有类型抵消
长蛋白版 TAI 对照（检验 D 的 ΔTAI）	蛋白 ≥ 100 aa 重算 TAI，逐类型对照	与上一行**不是同一件事**，务必分清：上一行的 ΔTAI 来自「剔除 S15/S16 两层」，本行的 ΔTAI 来自「把短基因换成同层的其余基因」	ΔTAI 均值 **-0.0572**，**177/177 同向**，但年龄梯度 ρ = **-0.1326**（p = 0.079，不显著）→ 短基因偏倚是**系统性整体平移**，不是类型特异；相对排序 ρ = **0.9845**
秩相关对齐	显式 `reindex` 后再算	⚠ `scipy.stats.spearmanr` 对 pandas Series **按位置**取值；两列各自升序时位置秩相关**恒等于 +1**（实测 500/500 次复现）	这是本项目最隐蔽的一个 bug，已修正
参与比 (PR)	`1 / Σ(evr²)`	度量有效维度：evr 完全均匀时取上界 d，信息集中时取下界 1	替代方案：熵（Shannon / von Neumann），但对 evr 分布形态敏感；PR 更稳健
成分数据秩亏诊断	第 16 个 EVR 检查	16 个占比和恒为 1 → 协方差必然秩亏到 15。**这决定了零假设必须同秩**	因此新增 Dirichlet 成分基线

E.6 未采用的方法与原因（如实记录）

方法	为什么没用
Deep learning（深度神经网络 / 图神经网络）	本项目的科学问题不是"能不能预测细胞类型"——那是已有工作早已解决、且远做得好得多的问题。本项目问的是"**年龄构成这一条信息里有什么**"，因此需要**可解释**的特征重要性，随机森林直接给出按基因的重要性，可直接进入超几何检验；深度模型的显著性须经 SHAP 等间接解释，且 22,195 细胞 × 3,000 特征的规模并不构成其优势区间。用深度学习会让结论更不可读，而不是更可信
批次效应校正（Harmony / scVI）	Harmony 的软聚类可能**人为制造**年龄层之间的相似性（批次往往与供者相关，而供者与细胞类型相关），从而虚假抬高 ARI 与富集信号。本项目的划分是按供者划分的，批次效应已在训练/测试间天然隔离
单细胞模型（scVI / scBERT 等）	同上：其价值在于提升分类精度，而本项目的目标恰恰不是精度。且引入一个数千万参数的模型会大幅增加"数字从哪来"的审计难度
CLR / ILR 成分数据变换	16 个成分中无极端小值，闭合效应不严重；保留原始比例可让结果直接解释。若将来加入极稀疏层则应改用
置换检验（对 ARI）以外的显著性来源	ARI 置换零假设已足够；未见显著性的其它来源