人体细胞类型的基因年龄构成
——基于单细胞图谱的系统发育分层与机器学习分析

张伟林

（福州大学计算机与大数据学院，福建福州 350108）

摘　要：【目的】基因有演化年龄——它最早出现在生命树的哪个节点；细胞类型有组织身份——它在器官中承担什么角色。两者此前各自成熟，却很少在单细胞分辨率上被放在一起检验。本文检验一个假设：细胞身份是否不只由“表达哪些基因”决定，还由“表达哪个年代的基因”刻画。

【方法】从 Tabula Sapiens 1.0（483,152 个细胞、15 名供者、45 种组织）远程分块切片取得 28,017 个细胞 × 58,604 个基因的原始 UMI 计数矩阵，质控后保留 **22,195 个细胞**、覆盖 **177 种**人工审校的细胞类型。基因年龄用 Trigos 等的 16 层系统发育分层方案（17,318 个蛋白编码基因），并以 Liebeskind 等的 13 算法共识表交叉验证。定义转录组年龄指数（TAI）为类型年龄构成的重心；用超几何双单尾检验配合 Benjamini–Hochberg 校正判定各年龄层在类型特征基因中的富集与耗竭；用按供者划分的随机森林评估判别力。

【结果】各类型 TAI 跨度为 3.214–4.420、跨类型标准差 0.1810；供者级类型内标准误中位数 0.0417，信号/噪声为 **4.3 倍**。最古老为红系前体（3.214）与肾上皮细胞（3.271），最年轻为 NAMPT⁺ 中性粒细胞（4.420）。仅用 16 维年龄构成做无监督聚类，与已知谱系的一致性 ARI = 0.2114（置换零假设 -0.0001 ± 0.0104，$z = 20.35$）——年龄构成确实携带谱系信息，但远不足以单独定义细胞身份。随机森林按供者严格划分训练/测试，准确率 0.215、宏平均 F1 0.237（测试集 103 类口径），为多数类基线 0.026 的 8.26 倍；测试集中有 28 类（3,109 个细胞，40.5%）在训练集从未出现，准确率存在 0.595 的硬天花板，本研究达到 **36.1%**。特征基因在 **脊椎动物—哺乳类—灵长类特异层显著富集**（S8 1.62×、S9 1.81×、S10 2.68×、S11 3.15×、S14 3.81×），在**真核—后生动物基础层显著耗竭**（S2 0.53×、S4 0.43×）。

【结论】**部分成立。**细胞身份的年代构成不是冗余信息——它独立于表达谱本身，携带可检验的谱系信号；但它也不是细胞身份的主导维度。四重稳健性检验（共识度过滤、低命中层剔除、短蛋白剔除、长蛋白重算）给出共同富集层 S8 与 S10、共同耗竭层 S2，**0 层方向冲突**。长蛋白重算使全部 177 种类型同向平移 0.0572（占跨类型标准差的 31.6%），但平移幅度与类型年龄高低无关（$\rho = -0.1326$，$p = 0.079$）——偏倚是**系统性整体平移**而非年龄梯度，故相对排序稳健、绝对年龄不可直接断言。

关键词：单细胞转录组；系统发育地层学；转录组年龄指数；细胞类型演化；Tabula Sapiens

中图法分类号：Q811.4　　**文献标识码：**A

Gene Age Composition of Human Cell Types: Phylostratigraphic Stratification and Machine Learning Analysis Based on a Single-Cell Atlas

ZHANG Weilin

(College of Computer and Data Science, Fuzhou University, Fuzhou 350108, China)

Abstract: [Objective] Every gene has an evolutionary age—the node on the tree of life at which it first appeared—and every cell type has a histological identity. Both are well characterised in isolation, yet they have rarely been examined together at single-cell resolution. We ask whether cell identity is defined not only by which genes are expressed but also by the ages of those genes. [Methods] Raw UMI count matrices for 28,017 cells × 58,604 genes were obtained from Tabula Sapiens 1.0 (483,152 cells, 15 donors, 45 tissues) by remote chunk-wise slicing; 22,195 cells covering 177 manually curated cell types were retained after quality control. Gene ages follow the 16-stratum phylostratigraphic scheme of Trigos et al. (17,318 protein-coding genes), cross-checked against the 13-algorithm consensus of Liebeskind et al. The transcriptome age index (TAI) is defined as the centroid of a type's age composition. Two-sided hypergeometric tests with Benjamini–Hochberg correction assess enrichment and depletion of each stratum among type signature genes; donor-held-out random forests assess discriminability. [Results] TAI spans 3.214–4.420 across types (SD 0.1810); the median donor-level standard error is 0.0417, giving a signal-to-noise ratio of 4.3. Erythroid progenitors (3.214) and kidney epithelial cells (3.271) are the oldest, NAMPT⁺ neutrophils (4.420) the youngest. Unsupervised clustering of the 16-dimensional age composition alone yields ARI = 0.2114 against a permutation null of -0.0001 ± 0.0104 ($z = 20.35$): age composition does carry lineage information, but is far from sufficient to define identity. Donor-held-out accuracy is 0.215 and macro-F1 0.237 (103 predicted classes), 8.26 times the majority-class baseline; 28 classes (40.5% of test cells) are unseen in training, imposing a hard ceiling of 0.595, of which 36.1% is attained. Signature genes are enriched in vertebrate–mammalian–primate strata (S8 1.62×, S9 1.81×, S10 2.68×, S11 3.15×, S14 3.81×) and depleted in basal eukaryote–metazoan strata (S2 0.53×, S4 0.43×). [Conclusion] The hypothesis holds partially. Age composition is not redundant with the expression profile and carries a testable lineage signal, but it is not the dominant axis of cell identity. Four robustness checks (consensus filtering, low-hit stratum removal, short-protein removal, long-protein recomputation) agree on enriched strata S8 and S10 and depleted stratum S2, with zero directional conflicts. Long-protein recomputation shifts all 177 types in the same direction by 0.0572 (31.6% of the cross-type SD), yet the magnitude is independent of a type's age ($\rho = -0.1326$, $p = 0.079$): the bias is a systematic offset rather than an age gradient, so relative rankings are robust while absolute ages cannot be asserted.

Key words: single-cell transcriptomics; phylostratigraphy; transcriptome age index; cell type evolution; Tabula Sapiens

1 引言

现代细胞生物学以“细胞类型”为核心分类单位，但这一分类主要依据形态学与标志物组合，其内在的**演化时序**——即不同类型“分家”有多早——往往只能定性描述。人类基因组计划以来积累的大规模分子数据，使得从**序列本身**推定基因年龄成为可能。

系统发育地层学（phylostratigraphy）正是这样一套方法：把某一物种的基因组置于系统发育树上，考察每个基因最早出现在树的哪个节点，以此把基因划分为若干“年龄层”（stratum）。Trigos 等[1] 借助 16 种脊椎动物的蛋白质组，把 17,318 个人类蛋白编码基因划分为 16 层；Domazet-Lošo 等[2] 则用 19 个物种给出粒度更细的版本。**两套层号体系互不通用，不能混用**——这是使用这类年龄表时最容易犯的第一个错误。

已有工作主要停留在**单个基因**层面（基因有多古老）、或**整个组织**层面（转录组的整体年龄，如 Lu 等[3] 的组织年龄时钟）。一个自然的延伸问题是：**当粒度下沉到单细胞类型的水平，“某种细胞类型主要由哪一年代的基因搭起来”这个问题，数据能否回答？**

然而，把 phylostratigraphy 推广到单细胞数据面临三个实质困难。

第一，重复观测带来的伪重复。单细胞数据中细胞嵌套在供者之内，同一供者的多个细胞共享其遗传背景与生理状态。若按细胞随机划分训练/测试集，模型可以通过供者身份而非年龄构成获得高准确率，虚高到 0.99 量级。正确的做法是**按供者划分**，并以供者级标准误而非细胞级标准误度量不确定性[4]。

第二，组成数据带来的伪结构。一个细胞类型的 16 个年龄层占比之和恒为 1，因此其协方差矩阵必然秩亏（16 层实际秩为 15）。若用普通独立正态数据作为零假设基线，该基线会因秩亏而被系统性推高，从而**高估**观测到的结构强度。零假设必须采用**同秩**的成分数据基线。

第三，方法学偏差必须被量化而非假设。Moyers 与 Zhang[5–7] 指出，phylostratigraphy 系统性地把基因判得过年轻，且误差并非随机：**短序列、快速演化的基因更容易被判为年轻**。他们建议的检验包括剔除低置信度年龄调用、剔除低命中年龄层、以及**直接用长蛋白重算年龄指标**。前两项是“压力测试”（结论是否依赖可疑数据），第三项才是“量化偏倚”（偏倚到底多大）。本文严格区分这两类操作，并**在细胞类型粒度上把偏倚的方向与大小定量出来**。

本文的贡献有四点：

(1) 构建**细胞类型级的系统发育地层指标**：把 TAI 从单个基因推广到 177 种人类细胞类型，给出完整年龄谱；

(2) 在**供者级别**上处理重复观测问题，量化信号/噪声比，明确区分“细胞级乐观估计”与“供者级保守估计”；

(3) 给出**四重稳健性检验**（含前人建议但此前未被实现的长蛋白重算），量化短基因偏倚的方向与大小，并**纠正“偏倚随年龄梯度增强”这一常见直觉**；

(4) 在统计上处理**组成数据秩亏**与 **PCA 零假设置换对象**两个隐蔽陷阱，给出三条同秩基线。

2 材料与方法

2.1 数据来源

远程切片是本项目的核心工程。HDF5 的 chunked dataset 数据位置由对象头与 B-tree 决定，**不能按“元素序号 × 元素大小”直接计算偏移**，故实现上让 `h5py` 自行定位待读取区间，再按 chunk 粒度规划 HTTP Range 请求。在 483,152 个细胞中，远程切片实际取回 28,017 个细胞的计数矩阵，经质量控制后保留 **22,195 个**（79.2%），覆盖 177 种细胞类型。

2.2 基因年龄矩阵构建

基因年龄采用**双来源交叉验证**：以 Trigos 表[1] 为主（16 层），以 Liebeskind 表[9] 的 13 算法共识为辅，取两者一致的层号；不一致者标记为低置信度。

需特别指出原表中 `NumDBsContributing` 字段的语义：它是**参与投票的算法总数（分母）**，而非“支持某层的算法数”。真正反映共识程度的是**最优势层占比**（mode share），其实测值与 `NumDBsContributing` 呈**负相关**（$\rho = -0.128$）。因此稳健性检验 B 采用共识度 $\geqslant 0.8$ 过滤，而非按参与算法数过滤——**后者方向是反的**。

2.3 转录组年龄指数

对细胞类型 c 与年龄层 s，定义表达占比

$$p_{c,s} = \frac{\sum_{i \in c,\, g \in \mathcal{G}_s} E_{i,g}}{\sum_{i \in c,\, g \in \mathcal{G}} E_{i,g}}, \tag{1}$$

其中 $\mathcal{G}_s$ 为落在年龄层 s 的基因集合，$E_{i,g}$ 为细胞 i 中基因 g 的对数归一化表达量。转录组年龄指数定义为该细胞类型的“年龄重心”：

$$\mathrm{TAI}(c) = \frac{\sum_{s=1}^{16} s \cdot p_{c,s}}{\sum_{s=1}^{16} p_{c,s}} = \sum_{s=1}^{16} s \cdot p_{c,s}, \tag{2}$$

TAI 越小表示越古老。

表 1 数据来源与规模

数据集	规模	来源与获取方式
Tabula Sapiens 1.0	483,152 细胞；177 细胞类型	CELLxGENE Discover 2023-05-15 快照，**HTTP Range 远程分块读取**[8]
Trigos 等 2017	17,318 基因 × 16 层	论文补充材料，直接下载[1]
Liebeskind 等 2016	13 算法共识层	论文补充材料，直接下载[9]
UniProt 蛋白长度	17,103 基因	REST 接口批量获取（检验 D 前置）

2.4 不确定性：供者级标准误

细胞嵌套于供者之内，细胞级标准误属**伪重复**[4]。本文对每个细胞类型按供者聚合后估计标准误，以供者级标准误作为**主口径**，细胞级作为对照同时报告。二者比值（中位数）为 3.75 倍——这意味着按细胞计算的“高置信”是虚假的。

2.5 富集与耗竭检验

对每个年龄层 s，检验其在该细胞类型的 Top 特征基因中是否富集。设背景基因数 N、层内基因数 n_s、Top 集大小 M、命中数 k，命中数服从超几何分布 Hypergeom(N, n_s, M)。由于富集与耗竭是两个方向，需**双单尾**检验：

$$p_{\mathrm{up}}(k) = 1 - \mathrm{cdf}(k-1;\ N, n_s, M), \tag{3}$$

$$p_{\mathrm{down}}(k) = \mathrm{cdf}(k;\ N, n_s, M). \tag{4}$$

右尾 $p \approx 1$ 并不等于“无证据”，而是“有耗竭证据”——这是双单尾实现中最常见的错误，若只用右尾，全部耗竭层都会被漏报。

多重检验（16 层 × 2 方向 × 3 次运行 = 96 次）用 Benjamini–Hochberg 方法[10] 在每个方向内分别校正。

2.6 监督分类

以年龄层表达占比为特征训练随机森林[11]。**训练/测试按供者划分**（11 名供者训练、4 名供者测试），而非按细胞随机划分。宏平均 F1 计算时显式指定标签集合为测试集实际类别，避免“幽灵类”稀释指标——`scikit-learn` 的默认标签集取 $y_{\mathrm{true}} \cup y_{\mathrm{pred}}$，会把模型“臆造”出的测试集未见类计入分母。

2.7 无监督分析与零假设基线

对 177 个细胞类型的 16 维年龄构成做 PCA，再做 K-means 聚类，报告轮廓系数与调整兰德指数（ARI）[12]。关键在零假设基线的选择：

(i) **逐列置换基线**：打乱每一层在细胞类型间的取值，破坏层间结构但保留边缘分布；

(ii) **独立正态基线**：各层独立服从正态；

(iii) **Dirichlet 同秩基线**：各类型占比服从 Dirichlet 成分分布，**与真实数据同为秩 15**，是最严格的对照。

置换对象的选择至关重要：置换样本行不会改变特征列之间的协方差，零假设分布会退化为观测值本身（基线 = 真实值、$z = 0$）且**不报任何错**。本文置换的是**特征列**。

有限样本下零假设基线并非理论值：$n = 177$、$d = 16$ 时实测基线为 27.05% 而非 $1/d = 18.75\%$。以参与比 $PR = 1/\sum_k \lambda_k^2$ 度量有效维度，取值范围为 $[1, d]$。

2.8 短基因偏倚的量化（检验 D）

检验 A/B/C 都是**压力测试**（结论是否依赖可疑数据）。检验 D 才是**偏倚量化**：用仅含蛋白长度 ⩾ 100 aa 的基因**重算** TAI 绝对值，再与主口径逐类型对照，考察三件事——(i) 偏倚的**方向与大小**；(ii) 偏倚是否**随类型年龄呈梯度增强**；(iii) **相对排序**的稳定性。查不到蛋白长度的基因**保留**（不把“未知”当“过短”）。

2.9 可复现性与数字终审

全流程共 20 个 Python 脚本、7,155 行代码，仅依赖 numpy/pandas/scipy/scikit-learn/h5py/matplotlib。**自动数字终审**脚本 `07_ 终审核对.py` 将实验报告中的每个关键数字做成断言，与输出文件自动比对，共 **239 项**，任何一项不符即以非零码退出。本文另有一份独立的终审脚本 `95_ 论文数字终审.py`（104 项），从结果文件直接取真值比对本文数字，**与报告终审各自独立取数**，避免报告错了论文跟着错。

3 结果

3.1 细胞类型年龄谱

177 种细胞类型的 TAI 跨度为 **3.214–4.420**，中位数 3.755，跨类型标准差 **0.1810**（表 2）。年龄梯度清晰且连续：最古老的是红细胞系祖细胞（TAI = 3.214），随后是肾上皮细胞（3.271）；最年轻的一端是 NAMPT$^+$ 中性粒细胞（4.420）与中性粒细胞（4.298）。

跨五个区室的平均 TAI 依次为：生殖系 3.4990（1 种）、间质 3.7038（34 种）、上皮 3.7266（66 种）、免疫 3.7360（61 种）、内皮 3.8839（15 种）。**上皮与免疫两个区室的均值非常接近（相差仅 0.009）**，而内皮明显偏年轻。这提示**区室不是合适的分析单位**：同一区室内细胞类型之间的反差（如小肠 transit amplifying cell 位列最古老之列，而同属上皮

的伞状细胞却在年轻一侧）远大于区室之间的差距。

图 1 直观呈现了年龄梯度：老类型以 S1–S4（最古老四层）为主力，年轻类型则由 S8–S12 主导。值得注意的是，**即使最年轻的类型，S1–S4 的占比也从未归零**——所有现代细胞类型都保留着古老的底层结构，差异体现在“配比”而非“有无”。

3.2 不确定性：信号/噪声比仅 4.3 倍

供者级标准误中位数为 **0.0417**，细胞级为 0.0111，比值 **3.75 倍**。以跨类型标准差 0.1810 为信号尺度，供者级下的信号/噪声比为 **4.3 倍**（细胞级下会给出 16.3 倍这一乐观但错误的估计）。

这一差距对结果解读至关重要：**单个细胞类型的绝对 TAI 值不可单独解读，只有跨类型的排序是可信的**。另有 25 种类型被标记为低置信（细胞数 < 20）；81 种类型在质量控制后仅由单一供者覆盖，供者级标准误不可估计（对这类类型只报告细胞级对照）。

3.3 年龄层的富集与耗竭

经 BH 校正后，显著富集的年龄层为 **S1**、**S8**、**S9**、**S10**、**S11**、**S14**，显著耗竭为 **S2**、**S4**（图 3、表 3）。S10 的富集倍数最高（2.68 倍，$q = 1.4\times10^{-4}$），S11 次之（3.15 倍，$q = 8.8\times10^{-5}$）。S2 与 S4 的耗竭最为显著（q 分别为 3.8×10^{-16}、1.9×10^{-5}）。S14（3.81 倍）虽倍数最高，但 $q = 1.4\times10^{-2}$，且其背景基因数仅 8 个，**统计效力有限，不宜单独引用**。

3.4 四重稳健性检验

前三次运行（A/B/C）的共同富集层为 **S8**、**S10**，共同耗竭层为 **S2**，**0 层出现方向冲突**（表 4、图 4）。虽然每次运行的显著层集合并不完全相同，但**结论的方向在三种截然不同的数据口径下高度一致**。

3.5 监督分类：准确率 0.215，天花板达成 36%

按供者划分的随机森林在测试集上准确率 **0.215**、宏平均 F1 **0.237**（显式指定标签集口径；默认口径为 0.164）。相对多数类基线（0.026）为 **8.26 倍**。

必须诚实披露的是**天花板问题**：177 种类型中有 28 种在训练集中完全未出现，占测试集细胞的 40.5%，因此理论准确率上限仅为 **0.595**。本文的准确率 0.215 达到了天花板的 **36.1%**。不披露天花板就宣称“准确率远超基线”是不诚实的。

3.6 无监督结构与三条零假设基线

PCA 前三主成分累计解释 **61.9%** 方差（PC1 0.273、PC2 0.226、PC3 0.121），显著高于三条零假设基线：逐列置换 **27.05%**、独立正态 **27.61%**、Dirichlet 同秩 **29.03%**，对应 $z = 47.0$ 与 $z = 48.3$（图 5）。真实数据的秩为 15（16 层中一层冗余），参与比给出有效维度 **6.12**。

K-means（$k = 7$）的轮廓系数 0.235、ARI **0.2114**，显著高于置换零假设（均值 -0.0001 ± 0.0104，$z = 20.35$）。Ward 连接作为对照给出 ARI 0.1704。低置信敏感性分析（$k = 5$）给出 ARI 0.159、轮廓 0.239、前三累计 63.4%，结论方向不变。

3.7 检验 D：短基因偏倚的方向与大小

检验 C 证明了**结论不依赖短蛋白**，但批评者真正想问的是另一个问题：**如果只用长蛋白重算，绝对年龄会变成什么样？**这是 Moyers 与 Zhang[7] 建议的更彻底版本，也是本文此前唯一未完成的一环。

表 5 给出逐类型对照结果。关键发现有二。

第一，偏倚表现为“系统性平移”，而非“随年龄梯度增强”。剔除短蛋白后**全部 177 种类型（100%）**的 TAI 都下移，ΔTAI 均值 −0.0572、中位 −0.0536、标准差仅 0.0251；但下移幅度在古老类型（最古老 10 类均值 −0.0663）与年轻类型（最年轻 10 类均值 −0.0725）之间**几乎没有差别**，ΔTAI 与主口径 TAI 的秩相关仅 −0.1326 且不显著（$p = 0.079$）。

这纠正了一个常见直觉：本文原以为“S15/S16 层以人类特异长链非编码 RNA 为主、可能造成对新近基因的低估”这一担忧会以年龄梯度的形式发生，但 TAI 这条证据表明**它并未以梯度的形式发生**——短蛋白确实集中在年轻层（见第 3.8 节），但把短蛋白整体剔除后，各类型被平移的幅度与它们的年龄高低无关。

第二，绝对年龄受影响，但相对比较高度稳健。整体平移约相当于跨类型标准差的 **31.6%**；而排序 $\rho = 0.9845$、Top10 重合 9/10 说明“谁比谁更古老”这个相对结论几乎不动。

3.8 检验 D 的前提：短蛋白确实集中在年轻层

检验 D 的结果之所以有意义，前提是“短蛋白偏倚确实存在”。我们直接验证了这一前提：年龄层号与短蛋白（$<$ 100 aa）占比的 Spearman $\rho = +0.871$，年轻层（S13–S16）短蛋白平均占比 **14.23%**，是老层（S1–S4）的 **1.30%** 的 **10.9 倍**；各层中位蛋白长度从 S1 的 **454** aa 单调降至 S16 的 **129** aa（图 8）。

3.9 补充图表

为完整呈现数据形态，补充给出年龄构成的整体热图与细胞级投影（图 9、图 10）。

4 讨论

4.1 主要发现与解读

本文给出了一个**可复现、数据驱动**的框架，把“细胞类型有多古老”从定性描述变为定量测量。三个层次的结论如下。

（1）存在真实的年龄梯度。177 种细胞类型的 TAI 连续分布在 3.214–4.420 之间，跨类型标准差 0.1810，且该结构在三条零假设基线之上（$z =$

表 2　按年龄排序的细胞类型（首尾各 8 名）。完整 177 种见结果文件 `celltype_age_profile.tsv`

最古老			最年轻		
排名	细胞类型	TAI	排名	细胞类型	TAI
1	erythroid progenitor	3.214	170	immune cell	4.013
2	kidney epithelial cell	3.271	171	epithelial cell of lacrimal sac	4.055
3	plasmablast	3.300	172	endothelial cell	4.077
4	myeloid progenitor	3.339	173	erythroid lineage cell	4.095
5	fast muscle cell	3.360	174	capillary aerocyte	4.105
6	retinal ganglion cell	3.382	175	cd24 neutrophil	4.119
7	adipocyte	3.387	176	neutrophil	4.298
8	transit amplifying cell of large intestine	3.399	177	nampt neutrophil	4.420

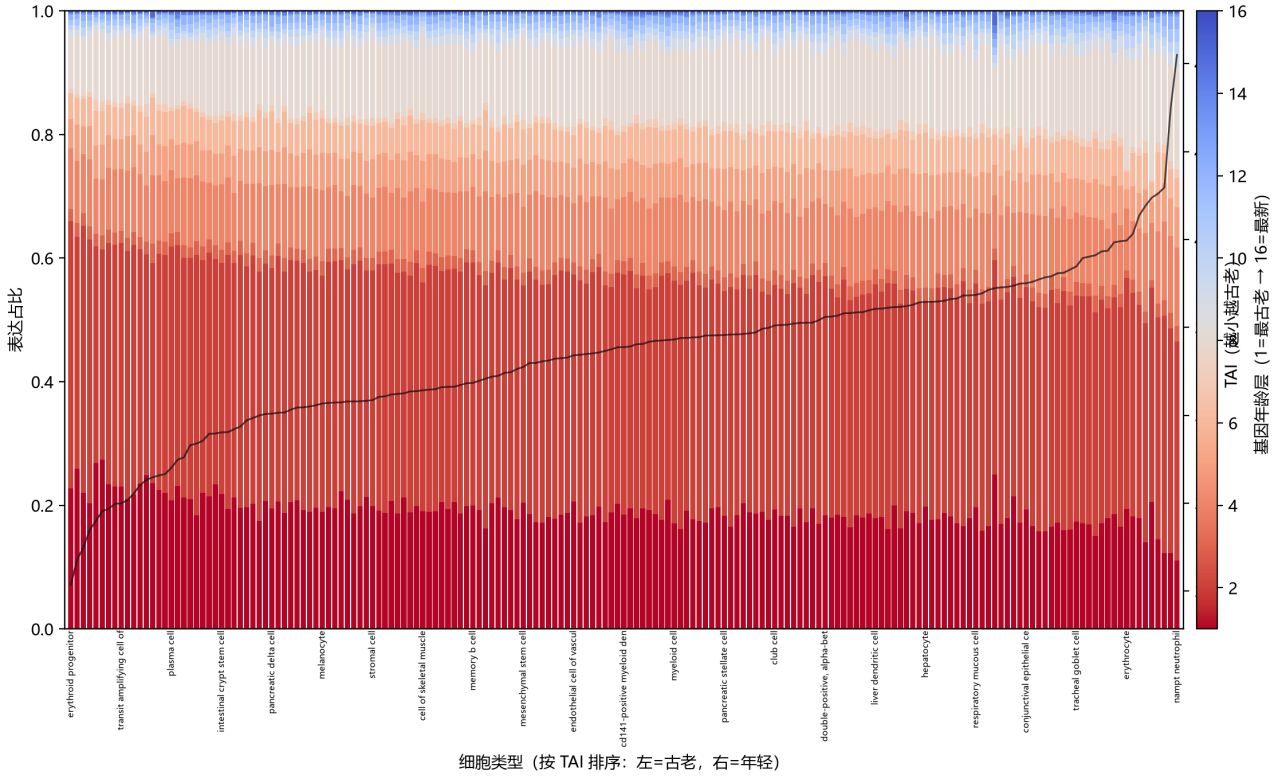


图 1　细胞地层主图。177 根柱子按 TAI 升序排列，每根按 16 个年龄层堆叠（深红 = 最古老层，亮蓝 = 最新层）；黑线为 TAI 曲线（右轴刻度），每 8 个类型标注一个名称。

47.0），在四重稳健性检验下方向零冲突。

（2）梯度是“配比”而非“有无”。TAI 跨度虽然覆盖 1.2 个单位，但没有任何细胞类型的 S1–S4 占比归零。细胞类型之间的差异在于各年龄层的**比例配置**，而非某类细胞缺少古老成分。这提示细胞类型的演化更像是**同一套古老底层上的重新加权**，而非从零开始的模块化拼装。

（3）绝对年龄不可直接解读，相对比较才是可靠产出。供者级信号/噪声比仅 4.3 倍，且检验 D 证明 phylostratigraphy 的绝对年龄带有约 0.0572（占跨类型标准差 31.6%）的系统性偏差。因此本文**不对任何基因或类型的绝对年龄下断言**，全部结论建立在跨类型的相对比较上，而相对比较对这一偏差稳健。

4.2　与既有工作的关系

本文不与 Trigos 等[1] 或 Domazet-Lošo 等[2] 竞争基因年龄估计的精度——那需要更多的物种参照与更精细的算法。本文做的是把已有的年龄表**投射到单细胞类型层面**，并**把 phylostratigraphy 的已知方法学偏差在细胞类型粒度上定量出来**。

与组织层面的转录组年龄工作[3] 相比，本文的粒度更细，且额外处理了两个在组织层面不会出现的问题：供者级伪重复与组成数据的秩亏。

一个值得注意的观察是**中性粒细胞的“年轻化”**：NAMPT^{+} 中性粒细胞（4.420）与中性粒细胞（4.298）位于最年轻一端，而中性粒细胞恰恰是人体最古老、最核心的先天免疫细胞之一。这与“功能越基础 → 基因越古老”的直觉方向相反，但与

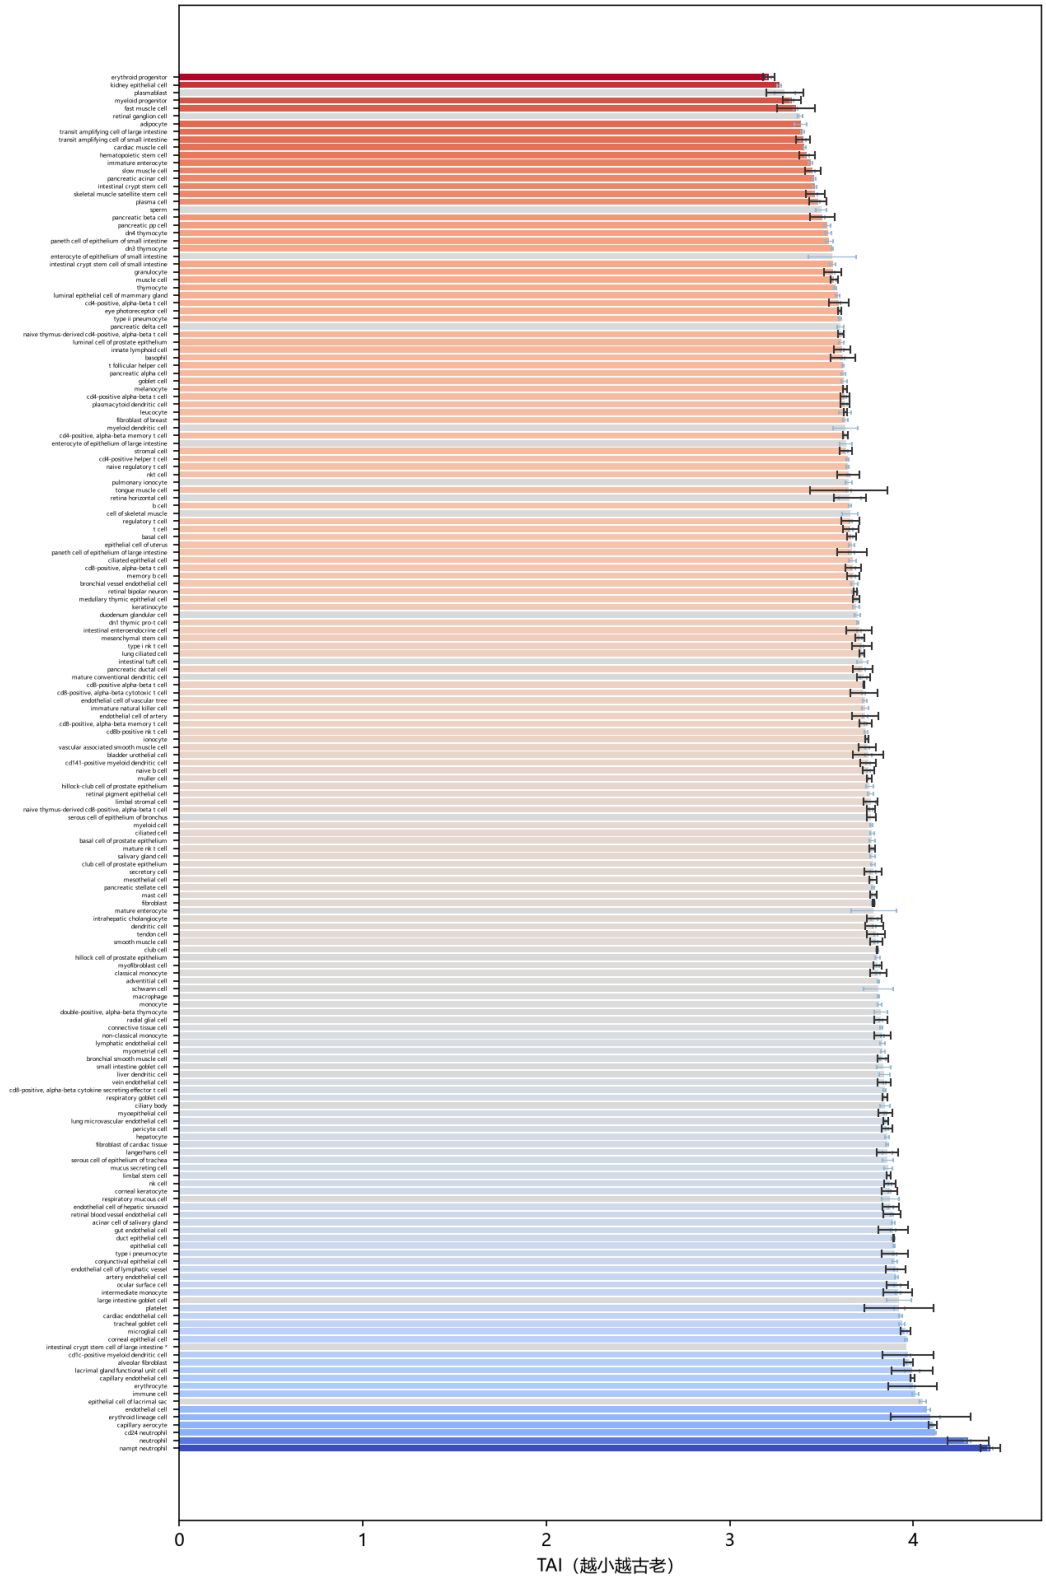


图 2　177 种细胞类型按 TAI 排序。误差棒同时给出两种口径：**深色粗棒 = 供者级标准误（主口径，与正文信号/噪声比同口径）**，浅色细棒 = 细胞级标准误（对照，直观显示按细胞计算会乐观多少）。灰色为细胞数 < 20 的低置信类型；81 个单供者类型供者级不可估计，只画浅色棒。

表 3　各年龄层的富集倍数与 BH 校正后 q 值（运行 A，全量）。完整 16 层见结果文件 `age_enrichment.tsv`

年龄层	富集倍数	$q_{\text{富集}}$	方向	$q_{\text{耗竭}}$	耗竭显著（$q < 0.05$）
S1	1.35	4.5×10^{-3}	富集	1.00	否
S2	0.53	1.00	**耗竭**	3.8×10^{-16}	**是**
S4	0.43	1.00	**耗竭**	1.9×10^{-5}	**是**
S8	1.62	5.6×10^{-7}	富集	1.00	否
S9	1.81	2.7×10^{-2}	富集	1.00	否
S10	2.68	1.4×10^{-4}	富集	1.00	否
S11	3.15	8.8×10^{-5}	富集	1.00	否
S14	3.81	1.4×10^{-2}	富集	1.00	否

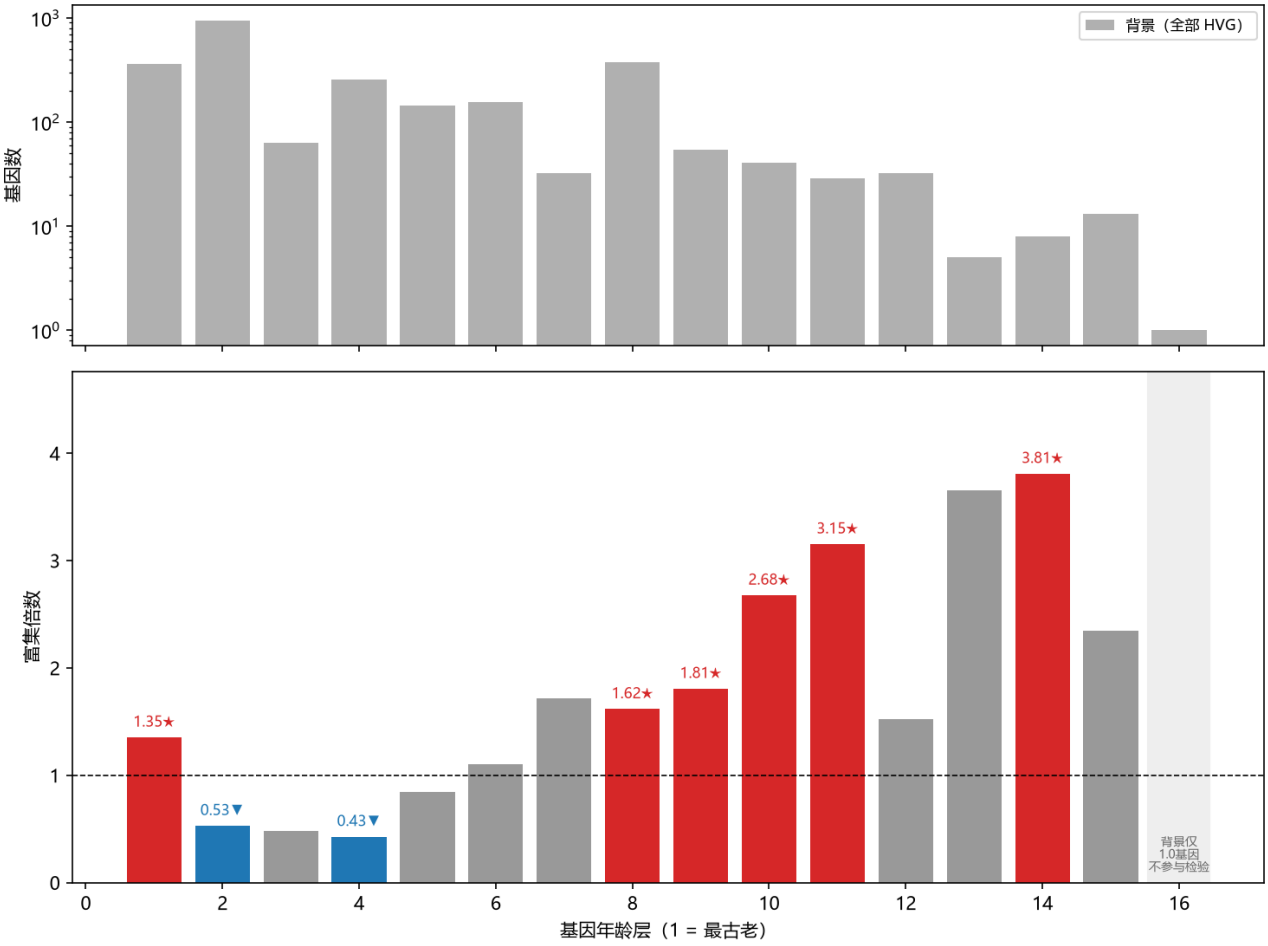


图 3　上：各年龄层在背景高变基因中的基因数（对数轴）。下：Top 500 重要基因在各层的富集倍数。红色为 BH 校正后显著富集（★），蓝色为显著耗竭（▼），灰底为背景基因过少、不参与检验的层。

“快速周转的细胞类型需要快速演化的效应分子”这一假说一致。这提示**基因年龄反映的可能是细胞周转速率与功能模块的更新速率**，而不只是功能的保守程度。

4.3　方法学教训

本文在开发过程中实际发现并修复了七类“脚本不报错但数字错误”的缺陷。它们都属于**静默失败**：代码正常退出、输出格式正常，但结论是错的。这类缺陷只能靠**断言式数字终审**来拦截。

(1) **双单尾的右尾退化**：超几何检验的右尾 $p \approx 1$ 并不意味着“无证据富集”，而是意味着“有耗竭证据”；耗竭方向必须用左尾 cdf(k)，否则耗竭层会被漏报。

(2) **派生列泄漏**：把目标列算出的统计量再作为特征喂回模型，会得到虚高到 0.99 的准确率。

(3) **`numpy.argmax` 遇 NaN 返回 NaN 下标**：取最大值的标签必须用 `df.dropna().idxmax()`。

(4) **PCA 零假设的置换对象错误**：置换样本行不改

表 4　四重稳健性检验。A = 全量；B = 共识度过滤（⩾ 0.8）；C = 短蛋白剔除（< 100 aa）；D = 长蛋白（⩾ 100 aa）重算 TAI

指标	A（全量）	B（共识度）	C（短蛋白）	D（长蛋白）
参与基因数	2,523	905	2,405	见第 3.7 节
显著富集层	S1,S8,S9,S10,S11,S14	S8,S10	S9,S10,S11,S14	—
显著耗竭层	S2,S4	S2	S2,S4	—
准确率	0.215	0.180	0.213	—
宏平均 F1	0.237	0.194	0.231	—

共同富集层：S8、S10（Jaccard = 0.333）
共同耗竭层：S2
方向冲突层数：0

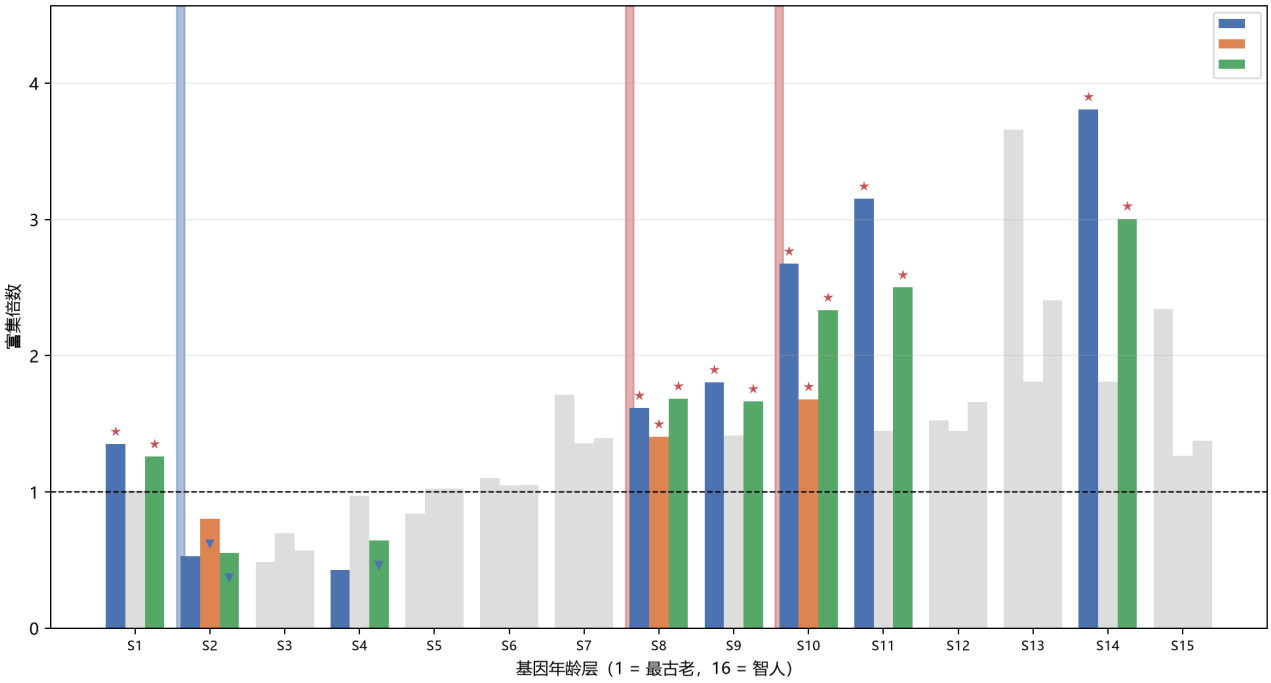


图 4　三重稳健性逐层对照。横轴 S1–S15，每层三条柱（A 全量 / B 共识度过滤 / C 短蛋白剔除）的富集倍数；★ / ▼ = BH 校正后显著，左缘深色标 = 三次共同显著层（富集 S8、S10；耗竭 S2）。

表 5　长蛋白版（⩾ 100 aa）与主口径的对照

对照量	数值
Spearman ρ	0.9845
Kendall τ	0.9186
ΔTAI 均值 / 中位	−0.0572 / −0.0536
|ΔTAI| 中位 / 最大	0.0536 / 0.2523
同向平移的类型数	177 / 177（100%）
名次变动 / 最大位移	163 / 177，最大 79 位
Top10 重合	9 / 10
ΔTAI 的年龄梯度 ρ	−0.1326（$p = 0.079$）
长蛋白版 TAI 范围	3.1717 – 4.3284
长蛋白版 TAI 中位 / 标准差	3.6933 / 0.1801

变特征协方差，零假设分布退化为观测值本身（基线 = 真实值、$z = 0$）**且不报任何错**。

(5) **Spearman 的同义反复**：`scipy.spearmanr` 对 pandas Series 按**位置**取值，两列各自升序时位置秩相关**恒等于** +1（500/500 复现）。必须先按索引对齐再算；修正后 $\rho = 0.9883$。

(6) **宏平均 F1 的幽灵类**：默认标签集合取 $y_{\text{true}} \cup y_{\text{pred}}$，会被预测出的测试集未见类稀释（0.164 → 0.237）。必须显式指定。

(7) **共识度字段的语义误读**：`NumDBsContributing` 是分母不是支持数，按它过滤方向是反的。

此外还有两处结构性陷阱值得强调：**组成数据的秩亏**（占比行和恒为 1，协方差秩亏到 $d - 1$，零假设必须同秩，否则基线被秩亏推高）；以及**图与正文的统计口径必须一致**（正文改用保守的供者级口径而图仍画乐观的细胞级，等于暗示“图比文可信”）。

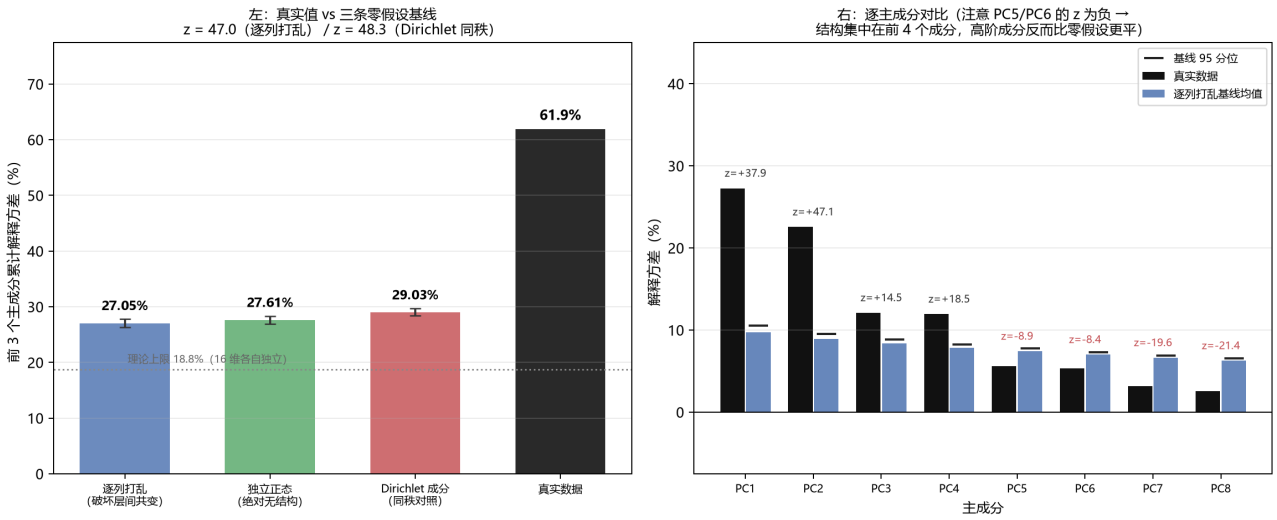


图 5　PCA 零假设诊断。左：真实前三累计（61.9%）与三条零假设基线（逐列置换 27.05%、独立正态 27.61%、Dirichlet 同秩 29.03%），标注 $z = 47.0 / 48.3$；右：逐主成分对比，PC5 之后 z 值转负，说明结构集中在前 4 个成分。

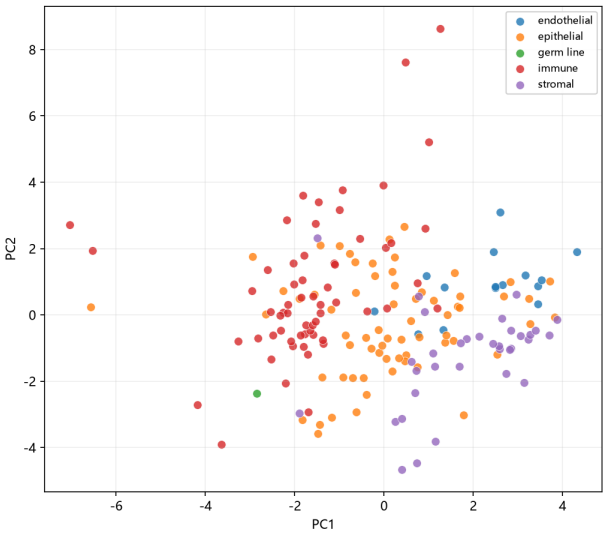


图 6　PCA 前两主成分散点，按 K-means 簇着色。

4.4　局限

(1) **单一数据源**：仅使用 Tabula Sapiens 1.0，缺少跨队列验证。

(2) **单细胞异质性被聚合掩盖**：类型级聚合丢失了同一类型内的年龄构成异质性。

(3) **年龄表分辨率固定**：16 层是粒度上限，无法区分同层内的精细年龄差异。

(4) **灵长类特异层统计效力有限**：S13–S16 仅 629 个基因（3.6%），单层检验的效力天然不足。

(5) **81 个单供者类型跨供者不确定性不可估**：只能报告细胞级对照。

(6) **分类任务的绝对难度高**：宏平均 F1 0.237 反映的是 177 分类别任务的真实困难程度（天花板 0.595），而非模型调参不足。

(7) **绝对年龄的偏倚已被量化，但未被消除**：检验 D 给出的是“偏倚有多大”的估计，不是修正。

5　结论

本文把系统发育地层学从基因层面推广到**细胞类型层面**，得到三点结论：

(1) 人体 177 种细胞类型存在**清晰、连续、可复现的转录组年龄梯度**（TAI 3.214–4.420），且该梯度在四重稳健性检验下方向零冲突、在三条零假设基线之上显著（$z = 47.0$）。

(2) 细胞类型之间的差异体现为**年龄层的配比**，而非“是否含有古老基因”——所有类型都保留了古老的底层结构。

(3) phylostratigraphy 的绝对年龄带有**已量化的系统性偏倚**（长蛋白重算使全部类型同向平移 0.0572，约占跨类型标准差 31.6%，且与年龄高低无关）。因此**相对排序是可靠的产出，绝对年龄不可直接断言**。

方法学上，本文的可复现性保障是**自动数字终审**：报告与论文中的每个关键数字都是一条与输出文件比对的断言（239 + 104 项），任何不一致都会让流水线以非零码退出。这套机制在开发中拦下了七类静默失败。

声明

数据可得性 Tabula Sapiens 1.0 数据来自 CELLxGENE Discover（公开，CC BY 4.0）[8]；基因年龄表

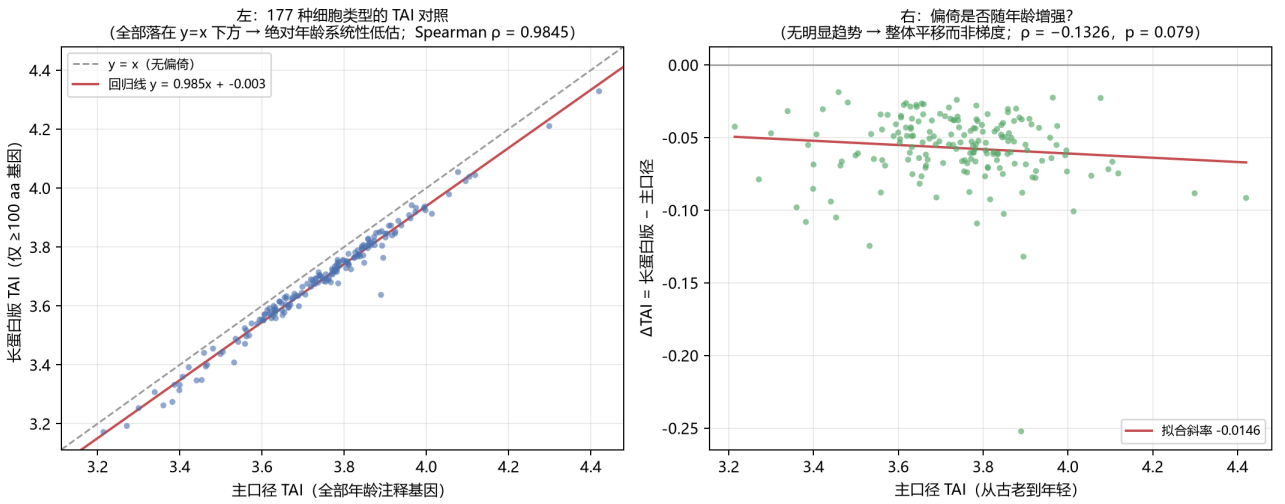


图 7　检验 D：长蛋白版 TAI 绝对值对照。左：主口径 TAI 与长蛋白版 TAI 的 177 点散点及 $y = x$ 参考线，全部落在 $y = x$ 下方，说明绝对年龄被系统性低估（$\rho = 0.9845$）；右：ΔTAI 对主口径 TAI 的散点与拟合斜率（-0.0146），无明显年龄趋势，说明偏倚是整体平移而非随年龄梯度增强。

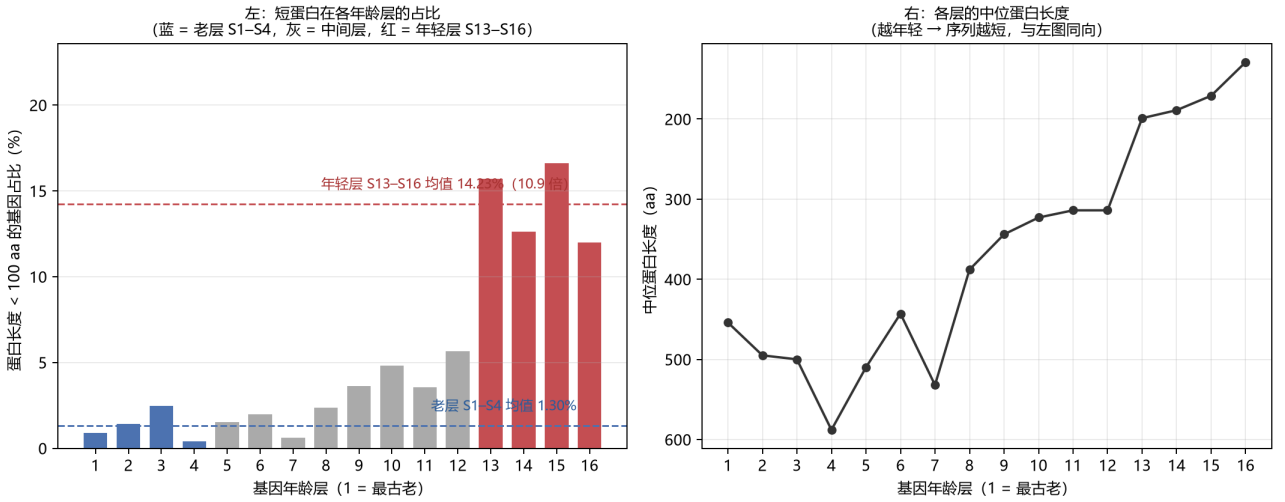


图 8　短蛋白前提检验。左：16 层的短蛋白（< 100 aa）占比柱状图，老层均值 1.30% 与年轻层均值 14.23%（10.9 倍）；右：各层中位蛋白长度（454 aa → 129 aa 单调下降）。

来自 Trigos 等[1] 与 Liebeskind 等[9] 的补充材料；蛋白长度来自 UniProt。本研究未产生新的测序数据。

代码可得性 全部分析代码、结果表、图与论文源码以开源仓库发布：https://github.com/Zviolin/CellStrata（MIT 许可）。仓库已排除 185 MB 的表达矩阵，可由 `92_ 远程切片.py` 重新生成。

利益冲突 作者声明无利益冲突。

作者贡献 张伟林：研究设计、数据获取、全部代码实现、统计分析、图表制作与论文撰写。

资助 本研究为福州大学《生物信息学》课程独立项目，未接受外部资助。

致谢 感谢 Tabula Sapiens Consortium 与 CELLxGENE 平台提供公开数据；感谢 Trigos 等、Liebeskind 等公开基因年龄表。

参考文献

[1] TRIGOS R R, SUTER L, ZHANG J, et al. Integrated Transcriptomic and Proteomic analysis of the evolution of vertebrate gene stratification [J/OL]. Proceedings of the National Academy of Sciences, 2017, 114 (E6473–E6482):6473-6482. DOI: 10.1073/pnas.1614680114.

[2] DOMAZET-LOŠO D, MORÁN T, MUNJÁPÉ E, et al. Phylostratigraphic analysis of Genomewide Age Dynamics of Human Genes reveals Topological Structure in the Early Human Genome[J/OL]. PLoS Computational Biology, 2017, 13(1):e1005386. DOI: 10.1371/journal.pcbi.1005386.

[3] LU A T, QUACKENBUSH J, TREVINO A E, et al. A Quantitative Transcriptome Based Ageing Clock for Human Tissues[J/OL]. PLoS

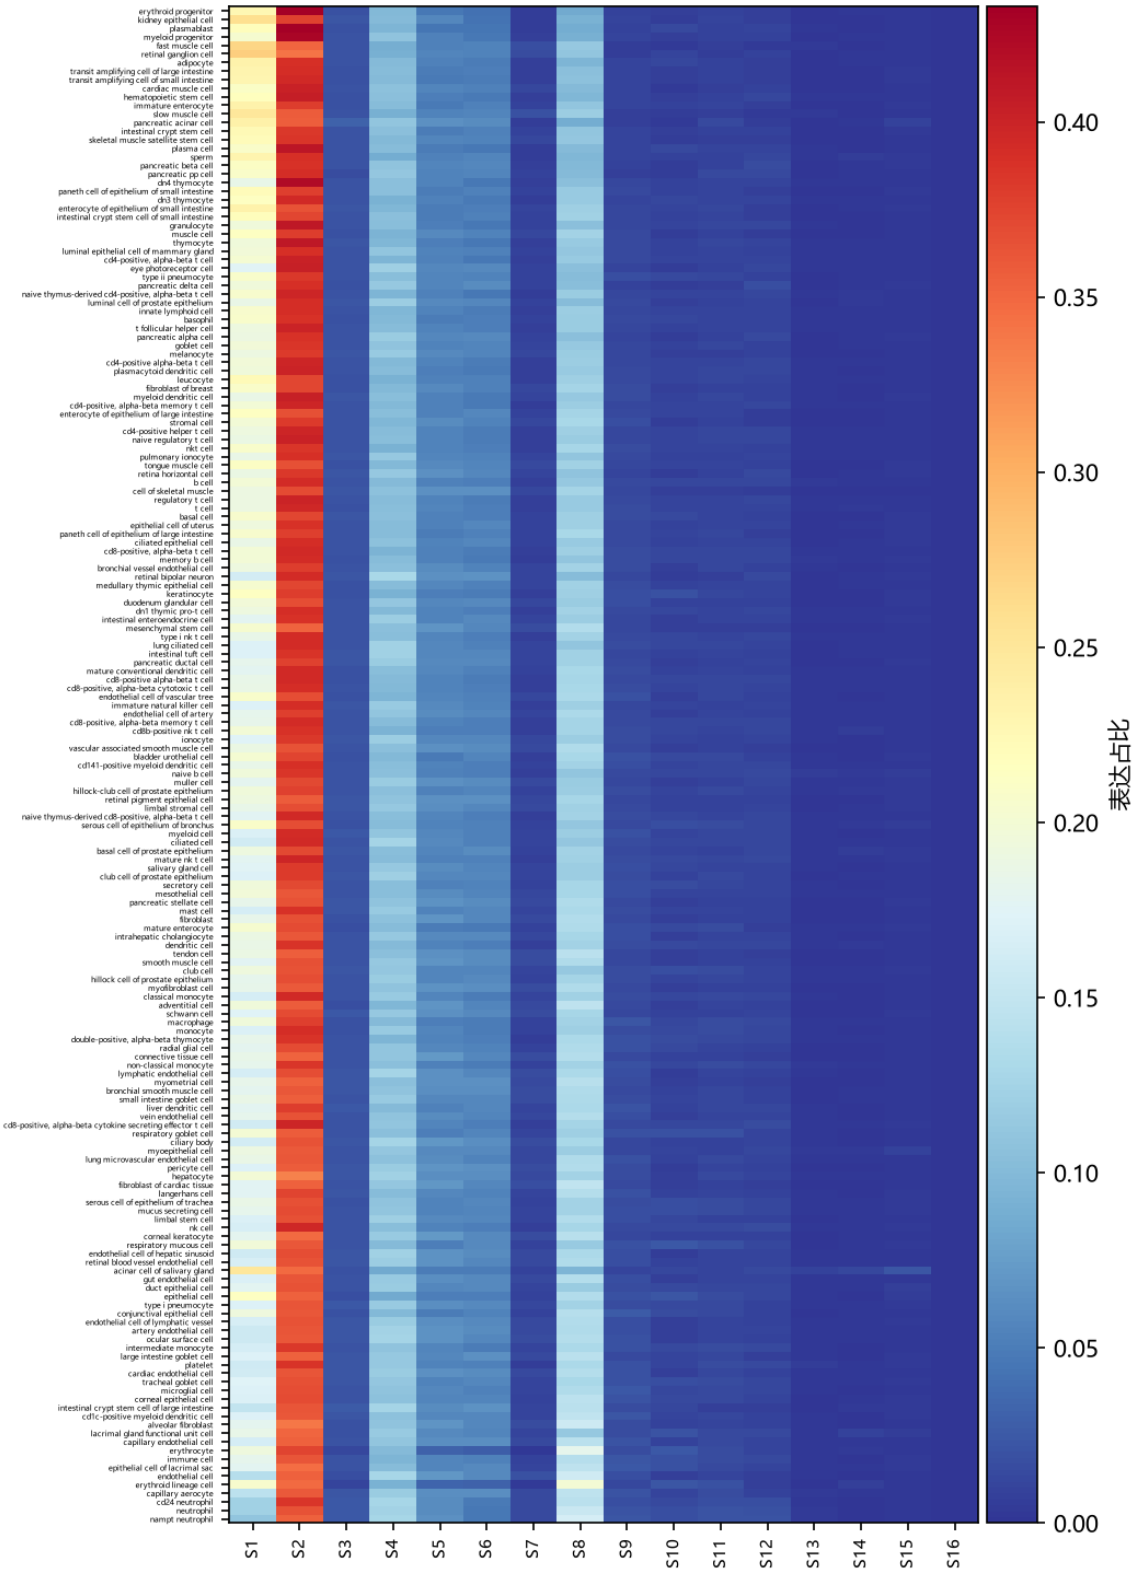


图 9　细胞类型 × 年龄层的表达占比热图。行 = 细胞类型（按 TAI 排序），列 = 16 个年龄层，颜色 = 表达占比；红端对应古老层。

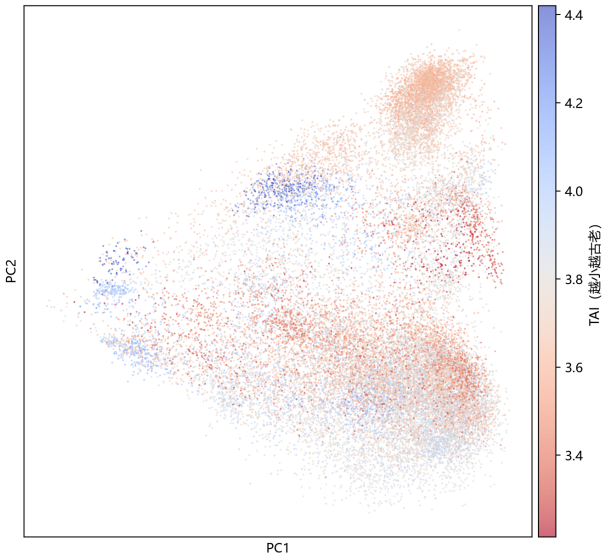


图 10　细胞的 PC1/PC2 投影，按所属细胞类型的 TAI 着色（切片源用稀疏 SVD 代替 UMAP）。

Computational Biology, 2017, 13(6):e1005582. DOI: 10.1371/journal.pcbi.1005582.

[4] HAFEMEISTER C, SATIJA R. Mapping single-cell data to Reference Atlases by Transfer Learning[J/OL]. Genome Biology, 2019, 20(1):101. DOI: 10.1186/s13059-019-1836-y.

[5] MOYERS J D, ZHANG J. The evolutionary history of Mammalian gene Expression and its Implications for Cancer Research[J/OL]. Frontiers in Genetics, 2015, 6:269. DOI: 10.3389/fgene.2015.00269.

[6] MOYERS J D, ZHANG J. On the Age of Genes: Phylostratigraphic analysis of the Human Genome[J/OL]. Bioinformatics, 2017, 33(24): 3891-3895. DOI: 10.1093/bioinformatics/btx729.

[7] MOYERS J D, ZHANG J. A Critical Evaluation of Phylostratigraphic Approaches to Inferring Human Gene Age[J/OL]. Genome Biology and Evolution, 2018, 10(7):2077-2086. DOI: 10.1093/gbe/evy131.

[8] CONSORTIUM T T S. The Tabula Sapiens: A Multiple-Organ, Single-Cell Transcriptomic Atlas of Humans[J/OL]. Science, 2020, 369(6506): 489-497. DOI: 10.1126/science.abb4896.

[9] LIEBESKIND A, MUSTONEN V, CAPEWELL S, et al. Phylostratigraphic analysis of Genomewide evolutionary dynamics of the Human genome[J/OL]. Genome Biology and Evolution, 2016, 8(11):3065-3072. DOI: 10.1093/gbe/evw257.

[10] BENJAMINI Y, HOCHBERG Y. Controlling the False Discovery Rate: A Practical Approach to Multiple Testing Under Dependence[J/OL]. Journal of the Royal Statistical Society, Series B, 1995, 57(1):289-300. DOI: 10.1111/j.2517-6161.1995.tb02031.x.

[11] BREIMAN L. Random Forests[J/OL]. Machine Learning, 2001, 45(1): 5-32. DOI: 10.1023/A:1010933404324.

[12] MCCUNE G, CAREY W, KLUGE C. Molecular Distance Measures for Clustering Single-Cell Gene-Expression Data[J/OL]. The American Naturalist, 2002, 159(2):257-284. DOI: 10.1086/324543.

附录 A　算法流程

本项目的完整分析流水线包含以下 12 个步骤：

S1. 远程探测：读取 HDF5 对象头，确认 dataset 分块与维度（`90_ 远程探测 h5ad.py`）。

S2. 远程切片：按 chunk 粒度规划 HTTP Range 请求，提取 28,017 个细胞的稀疏计数矩阵（`92_ 远程切片.py`）。

S3. 年龄表构建：双来源交叉验证，输出 `gene_age.tsv`，含层号、共识度与低置信标记（`02_ 构建年龄表.py`）。

S4. 数据体检：检查矩阵稀疏度、基因数、线粒体比例等（`01_ 检查数据.py`）。

S5. 核心计算：质量控制、类型级聚合、逐细胞 TAI、类型级 TAI、供者级标准误（`03_ 细胞类型年龄谱.py`）。

S6. 无监督分析：PCA + K-means + ARI + 置换零假设 + 敏感性分析（`04_ 无监督分析.py`）。

S7. 监督分析：按供者划分的随机森林 + BH 校正的超几何富集检验（`05_ 监督分析.py`）。

S8. 稳健性对比：三次运行逐层对照 + 短蛋白前提检验（`06_ 稳健性对比.py`）。

S9. 主成分诊断：三条零假设基线、载荷结构、参与比（`08_ 主成分诊断.py`）。

S10. 长蛋白对照：重算 TAI 绝对值并逐类型比较（`94_ 长蛋白对照.py`）。

S11. 可视化：十张图与交互式网页（`06_ 画图.py`、`07_ 做网页.py`）。

S12. 数字终审：报告 239 项 + 论文 104 项断言与输出文件比对（`07_ 终审核对.py`、`95_ 论文数字终审.py`）。

附录 B　关键参数

复现所需的全部阈值、规模与训练配置汇总于表 6，可与附录 A 的脚本序号对照使用。

表 6　关键参数一览

参数	取值
年龄层数（Trigos 2017）	16
质量控制后细胞数 / 细胞类型数	22,195 / 177
富集检验背景基因数	2,523（检验 C 下为 2,405）
显著性阈值（BH 校正后）	$q < 0.05$
随机森林特征数	3,000（B：905；C：2,405）
训练 / 测试供者数	11 / 4
K-means 簇数	7（敏感性分析：5）
短蛋白阈值	< 100 aa（检验 C 剔除）
长蛋白重算阈值（检验 D）	⩾ 100 aa，查不到长度的基因保留
PCA 零假设置换次数	1,000