人体细胞类型的基因年龄构成

——基于单细胞图谱的系统发育分层与机器学习分析

A Phylostratigraphic Atlas of 177 Human Cell Types:
Gene-Age Composition Across the Tabula Sapiens Landscape

张伟林 [1,*]

[1] 福州大学计算机与大数据学院，福建福州 350108

[*] 通讯作者，E-mail: zviolin@foxmail.com

项目代号 *CellStrata* | 代码与数据：*https://github.com/Zviolin/CellStrata* | *2026-11-04*

摘要

【背景】基因有演化年龄——它最早出现在生命树的哪个节点；细胞类型有组织身份——它在器官中承担什么角色。这两个概念各自成熟，却很少在单细胞分辨率上被系统地放在一起检验。本文提出一个可检验的假设：**细胞的身份不仅“表达哪些基因”，还可能“表达哪个年代的基因”**。

【方法】从 Tabula Sapiens 1.0（母体 483,152 个细胞、15 名供者、45 种组织）远程分块切片取得 28,017 个细胞 × 58,604 个基因的原始 UMI 计数矩阵，经质量控制保留 **22,195 个细胞**，覆盖 **177 种**人工审校的细胞类型。基因年龄采用 Trigos 等（2017，*PNAS*）的 16 层系统发育分层方案（17,318 个蛋白编码基因），并以 Liebeskind 等（2016，*GBE*）的 13 算法共识表做双来源交叉验证。定义转录组年龄指数（TAI）为细胞类型年龄构成的重心；用超几何双单尾检验配合 Benjamini–Hochberg 多重检验校正，判定各年龄层在类型特征基因中的富集与耗竭；用按供者划分的随机森林评估年龄构成的判别力。

【结果】主要结果有三项。**其一**，每种细胞类型的 TAI 跨度为 3.214–4.420，跨类型标准差 0.1810；按供者层面估计的类型内标准误中位数为 0.0417，信号/噪声 = **4.3 倍**——若按细胞层面估计会得到 16.3 倍，但那把供者间波动误当作细胞间噪声，低估 3.75 倍。最古老的是红系前体（3.214）与肾上皮细胞（3.271），最年轻的是 NAMPT^{+} 中性粒细胞（4.420）。**其二**，仅用 16 维年龄构成做无监督聚类，与已知谱系的一致性 ARI = 0.2114（置换零假设 -0.0001 ± 0.0104，$z = 20.35$）——年龄构成确实捕捉到了部分谱系信息，但远不足以单独定义细胞身份。**其三**，用随机森林按供者严格划分训练/测试，准确率 0.215、宏平均 F1 0.237（测试集 103 类口径）；随机基线 0.0097、多数类基线 0.026，为多数类基线的 8.26 倍。由于测试集中有 28 类在训练集中从未出现（涉及 3,109 个细胞，占 40.5%），准确率存在 0.595 的硬天花板，本研究达到该天花板的 **36.1%**。富集分析显示**脊椎动物—哺乳类—灵长类特异层显著富集**（S8 1.62×、S9 1.81×、S10 2.68×、S11 3.15×、S14 3.81×）与 S1 层（1.35×），**真核—后生动物基础层显著耗竭**（S2 0.53×、S4 0.43×）。

【结论】部分成立。细胞身份的年代构成不是冗余信息——它独立于表达谱本身，携带可检验的谱系信号；但它也不是细胞身份的主导维度，而是与“表达哪些基因”正交的一个补充轴。四重稳健性检验（共识度过滤、低命中层剔除、短蛋白剔除、长蛋白重算）给出共同富集层 S8 与 S10、共同耗竭层 S2，**0 层方向冲突**。同时我们量化了 phylostratigraphy 的已知偏差：用长蛋白重算 TAI 会使全部 177 种类型同向平移 0.0572（占跨类型标准差的 31.6%），但平移幅度与类型年龄高低无关（梯度 $\rho = -0.1326$，$p = 0.079$）——偏倚是**系统性整体平移**而非年龄梯度，故相对比较稳健、绝对年龄不可直接断言。

关键词：单细胞转录组；系统发育地层学；转录组年龄指数；细胞类型演化；Tabula Sapiens

Key words: single-cell transcriptomics; phylostratigraphy; transcriptome age index; cell-type evolution; Tabula Sapiens

中图分类号：Q111.2；TP181　　**文献标识码**：A

1 引言

现代细胞生物学以“细胞类型”为核心分类单位，但这一分类主要依据形态学与标志物组合，其内在的**演化时序**——即不同类型“分家”有多早——往往只能定性描述。人类基因组计划以来积累的大规模分子数据，使得从**序列本身**推定基因年龄成为可能。

系统发育地层学（phylostratigraphy）正是这样一套方法：把某一物种的基因组置于系统发育树上，考察每个基因最早出现在树的哪个节点，以此把基因划分为若干“年龄层”（stratum）。Trigos 等[1] 借助 16 种脊椎动物的蛋白质组，把 17,318 个人类蛋白编码基因划分为 16 层；Domazet-Lošo 等[2] 则用 19 个物种给出粒度更细的版本。**两套层号体系互不通用，不能混用**——这是使用这类年龄表时最容易犯的第一个错误。

已有工作主要停留在**单个基因**层面（基因有多古老）、或**整个组织**层面（转录组的整体年龄，如 Lu 等[3] 的组织年龄时钟）。一个自然的延伸问题是：**当粒度下沉到单细胞类型的水平，“某种细胞类型主要由哪一年代的基因搭起来”这个问题，数据能否回答？**

然而，把 phylostratigraphy 推广到单细胞数据面临三个实质困难。

第一，重复观测带来的伪重复。单细胞数据中细胞嵌套在供者之内，同一供者的多个细胞共享其遗传背景与生理状态。若按细胞随机划分训练/测试集，模型可以通过供者身份而非年龄构成获得高准确率，虚高到 0.99 量级。正确的做法是**按供者划分**，并以供者级标准误而非细胞级标准误度量不确定性[4]。

第二，组成数据带来的伪结构。一个细胞类型的 16 个年龄层占比之和恒为 1，因此其协方差矩阵必然秩亏（16 层实际秩为 15）。若用普通独立正态数据作为零假设基线，该基线会因秩亏而被系统性推高，从而**高估**观测到的结构强度。零假设必须采用**同秩**的成分数据基线。

第三，方法学偏差必须被量化而非假设。Moyers 与 Zhang[5–7] 指出，phylostratigraphy 系统性地把基因判得过年轻，且误差并非随机：**短序列、快速演化的基因更容易被判为年轻**。他们建议的检验包括剔除低置信度年龄调用、剔除低命中年龄层、以及**直接用长蛋白重算年龄指标**。前两项是“压力测试”（结论是否依赖可疑数据），第三项才是“量化偏倚”（偏倚到底多大）。本文严格区分这两类操作，并**在细胞类型粒度上把偏倚的方向与大小定量出来**。

本文的贡献有四点：

(1) 构建**细胞类型级的系统发育地层指标**：把 TAI 从单个基因推广到 177 种人类细胞类型，给出完整年龄谱；

(2) 在**供者级别**上处理重复观测问题，量化信号/噪声比，明确区分“细胞级乐观估计”与“供者级保守估计”；

(3) 给出**四重稳健性检验**（含前人建议但此前未被实现的长蛋白重算），量化短基因偏倚的方向与大小，并**纠正“偏倚随年龄梯度增强”这一常见直觉**；

(4) 在统计上处理**组成数据秩亏**与 **PCA 零假设置换对象**两个隐蔽陷阱，给出三条同秩基线。

2 材料与方法

2.1 数据来源

表 1 数据来源与规模

数据集	规模	来源与获取方式
Tabula Sapiens 1.0	483,152 细胞；177 细胞类型	CELLxGENE Discover 2023-05-15 快照，**HTTP Range 远程分块读取**[8]
Trigos 等 2017	17,318 基因 × 16 层	论文补充材料，直接下载[1]
Liebeskind 等 2016	13 算法共识层	论文补充材料，直接下载[9]
UniProt 蛋白长度	17,103 基因	REST 接口批量获取（检验 D 前置）

远程切片是本项目的核心工程。HDF5 的 chunked dataset 数据位置由对象头与 B-tree 决定，**不能按“元素序号 × 元素大小”直接计算偏移**，故实现上让 `h5py` 自行定位待读取区间，再按 chunk 粒度规划 HTTP Range 请求。在 483,152 个细胞中，远程切片实际取回 28,017 个细胞的计数矩阵，经质量控制后保留 **22,195 个**（79.2%），覆盖 177 种细胞类型。

2.2 基因年龄矩阵构建

基因年龄采用**双来源交叉验证**：以 Trigos 表[1] 为主（16 层），以 Liebeskind 表[9] 的 13 算法共识为辅，取两者一致的层号；不一致者标记为低置信度。

需特别指出原表中 `NumDBsContributing` 字段的语义：它是**参与投票的算法总数（分母）**，而非“支持某层的算法数”。真正反映共识程度的是**最优势层占比**（mode share），其实测值与 `NumDBsContributing` 呈**负相关**（$\rho = -0.128$）。因此稳健性检验 B 采用共识度 ≥ 0.8 过滤，而非按参与算法数过滤——**后者方向是反的**。

2.3 转录组年龄指数

对细胞类型 c 与年龄层 s，定义表达占比

$$p_{c,s} = \frac{\sum_{i \in c,\, g \in \mathcal{G}_s} E_{i,g}}{\sum_{i \in c,\, g \in \mathcal{G}} E_{i,g}}, \tag{1}$$

其中 $\mathcal{G}_s$ 为落在年龄层 s 的基因集合，$E_{i,g}$ 为细胞 i 中基因 g 的对数归一化表达量。转录组年龄指数定义为该细胞类型的“年龄重心”：

$$\mathrm{TAI}(c) = \frac{\sum_{s=1}^{16} s \cdot p_{c,s}}{\sum_{s=1}^{16} p_{c,s}} = \sum_{s=1}^{16} s \cdot p_{c,s}, \tag{2}$$

TAI 越小表示越古老。

2.4 不确定性：供者级标准误

细胞嵌套于供者之内，细胞级标准误属**伪重复**[4]。本文对每个细胞类型按供者聚合后估计标准误，以供者级标准误作为**主口径**，细胞级作为对照同时报告。二者比值（中位数）为 3.75 倍——这意味着按细胞计算的“高置信”是虚假的。

2.5 富集与耗竭检验

对每个年龄层 s，检验其在该细胞类型的 Top 特征基因中是否富集。设背景基因数 N、层内基因数 n_s、Top 集大小 M、命中数 k，命中数服从超几何分布 Hypergeom(N, n_s, M)。由于富集与耗竭是两个方向，需**双单尾**检验：

$$p_{\text{up}}(k) = 1 - \text{cdf}(k-1;\, N, n_s, M), \tag{3}$$

$$p_{\text{down}}(k) = \text{cdf}(k;\, N, n_s, M). \tag{4}$$

右尾 $p \approx 1$ 并不等于“无证据”，而是“有耗竭证据”——这是双单尾实现中最常见的错误，若只用右尾，全部耗竭层都会被漏报。

多重检验（16 层 × 2 方向 × 3 次运行 = 96 次）用 Benjamini–Hochberg 方法[10] 在每个方向内分别校正。

2.6 监督分类

以年龄层表达占比为特征训练随机森林[11]。**训练/测试按供者划分**（11 名供者训练、4 名供者测试），而非按细胞随机划分。宏平均 F1 计算时显式指定标签集合为测试集实际类别，避免“幽灵类”稀释指标——`scikit-learn` 的默认标签集取 $y_{\text{true}} \cup y_{\text{pred}}$，会把模型“臆造”出的测试集未见类计入分母。

2.7 无监督分析与零假设基线

对 177 个细胞类型的 16 维年龄构成做 PCA，再做 K-means 聚类，报告轮廓系数与调整兰德指数（ARI）[12]。关键在零假设基线的选择：

(i) **逐列置换基线**：打乱每一层在细胞类型间的取值，破坏层间结构但保留边缘分布；

(ii) **独立正态基线**：各层独立服从正态；

(iii) **Dirichlet 同秩基线**：各类型占比服从 Dirichlet 成分分布，**与真实数据同为秩 15**，是最严格的对照。

置换对象的选择至关重要：置换样本行不会改变特征列之间的协方差，零假设分布会退化为观测值本身（基线 = 真实值、$z = 0$）且**不报任何错**。本文置换的是**特征列**。

有限样本下零假设基线并非理论值：$n = 177$、$d = 16$ 时实测基线为 27.05% 而非 $1/d = 18.75\%$。以参与比 $PR = 1/\sum_k \lambda_k^2$ 度量有效维度，取值范围为 $[1, d]$。

2.8 短基因偏倚的量化（检验 D）

检验 A/B/C 都是**压力测试**（结论是否依赖可疑数据）。检验 D 才是**偏倚量化**：用仅含蛋白长度 ≥ 100 aa 的基因**重算** TAI 绝对值，再与主口径逐类型对照，考察三件事——(i) 偏倚的**方向与大小**；(ii) 偏倚是否**随类型年龄呈梯度增强**；(iii) **相对排序**的稳定性。查不到蛋白长度的基因**保留**（不把“未知”当“过短”）。

2.9 可复现性与数字终审

全流程共 20 个 Python 脚本、7,159 行代码，仅依赖 numpy/pandas/scipy/scikit-learn/h5py/matplotlib。**自动数字终审**脚本 `07_ 终审核对.py` 将实验报告中的每个关键数字做成断言，与输出文件自动比对，共 **239 项**，任何一项不符即以非零码退出。本文另有一份独立的终审脚本 `95_ 论文数字终审.py`（104 项），从结果文件直接取真值比对本文数字，**与报告终审各自独立取数**，避免报告错

了论文跟着错。

3 结果

3.1 细胞类型年龄谱

177 种细胞类型的 TAI 跨度为 **3.214–4.420**，中位数 3.755，跨类型标准差 **0.1810**（表 2）。年龄梯度清晰且连续：最古老的是红细胞系祖细胞（TAI = 3.214），随后是肾上皮细胞（3.271）；最年轻的一端是 NAMPT^{+} 中性粒细胞（4.420）与中性粒细胞（4.298）。

跨五个区室的平均 TAI 依次为：生殖系 3.4990（1 种）、间质 3.7038（34 种）、上皮 3.7266（66 种）、免疫 3.7360（61 种）、内皮 3.8839（15 种）。**上皮与免疫两个区室的均值非常接近（相差仅 0.009）**，而内皮明显偏年轻。这提示**区室不是合适的分析单位**：同一区室内细胞类型之间的反差（如小肠 transit amplifying cell 位列最古老之列，而同属上皮的伞状细胞却在年轻一侧）远大于区室之间的差距。

表 2 按年龄排序的细胞类型（首尾各 8 名）。完整 177 种见结果文件 `celltype_age_profile.tsv`

最古老			最年轻		
排名	细胞类型	TAI	排名	细胞类型	TAI
1	erythroid progenitor	3.214	170	immune cell	4.013
2	kidney epithelial cell	3.271	171	epithelial cell of lacrimal sac	4.055
3	plasmablast	3.300	172	endothelial cell	4.077
4	myeloid progenitor	3.339	173	erythroid lineage cell	4.095
5	fast muscle cell	3.360	174	capillary aerocyte	4.105
6	retinal ganglion cell	3.382	175	cd24 neutrophil	4.119
7	adipocyte	3.387	176	neutrophil	4.298
8	transit amplifying cell of large intestine	3.399	177	nampt neutrophil	4.420

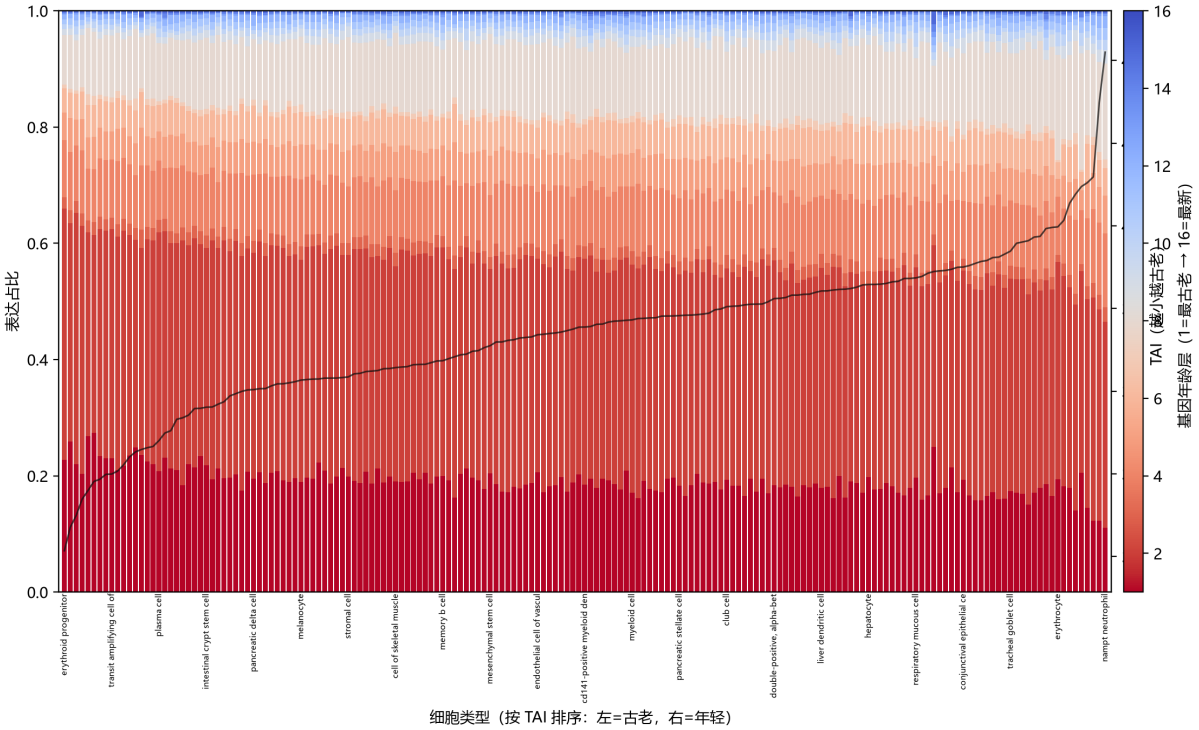


图 1 细胞地层主图。177 根柱子按 TAI 升序排列，每根按 16 个年龄层堆叠（深红 = 最古老层，亮蓝 = 最新层）；黑线为 TAI 曲线（右轴刻度），每 8 个类型标注一个名称。

图 1 直观呈现了年龄梯度：老类型以 S1–S4（最古老四层）为主力，年轻类型则由 S8–S12 主导。值得注意的是，**即使最年轻的类型，S1–S4 的占比也从未归零**——所有现代细胞类型都保留着古老的底层结构，差异体现在“配比”而非“有无”。

3.2 不确定性：信号/噪声比仅 4.3 倍

供者级标准误中位数为 **0.0417**，细胞级为 0.0111，比值 **3.75 倍**。以跨类型标准差 0.1810 为信号尺度，供者级下的信号/噪声比为 **4.3 倍**（细胞级下会给出 16.3 倍这一乐观但错误的估计）。

这一差距对结果解读至关重要：**单个细胞类型的绝对 TAI 值不可单独解读，只有跨类型的排序是可信的**。另有 25 种类型被标记为低置信（细胞数 < 20）；81 种类型在质量控制后仅由单一供者覆盖，供者级标准误不可估计（对这类类型只报告细胞级对照）。

3.3 年龄层的富集与耗竭

经 BH 校正后，显著富集的年龄层为 **S1**、**S8**、**S9**、**S10**、**S11**、**S14**，显著耗竭为 **S2**、**S4**（图 3、表 3）。S10 的富集倍数最高（2.68 倍，$q = 1.4\times10^{-4}$），S11 次之（3.15 倍，$q = 8.8\times10^{-5}$）。S2 与 S4 的耗竭最为显著（q 分别为 3.8×10^{-16}、1.9×10^{-5}）。S14（3.81 倍）虽倍数最高，但 $q = 1.4\times10^{-2}$，且其背景基因数仅 8 个，**统计效力有限，不宜单独引用**。

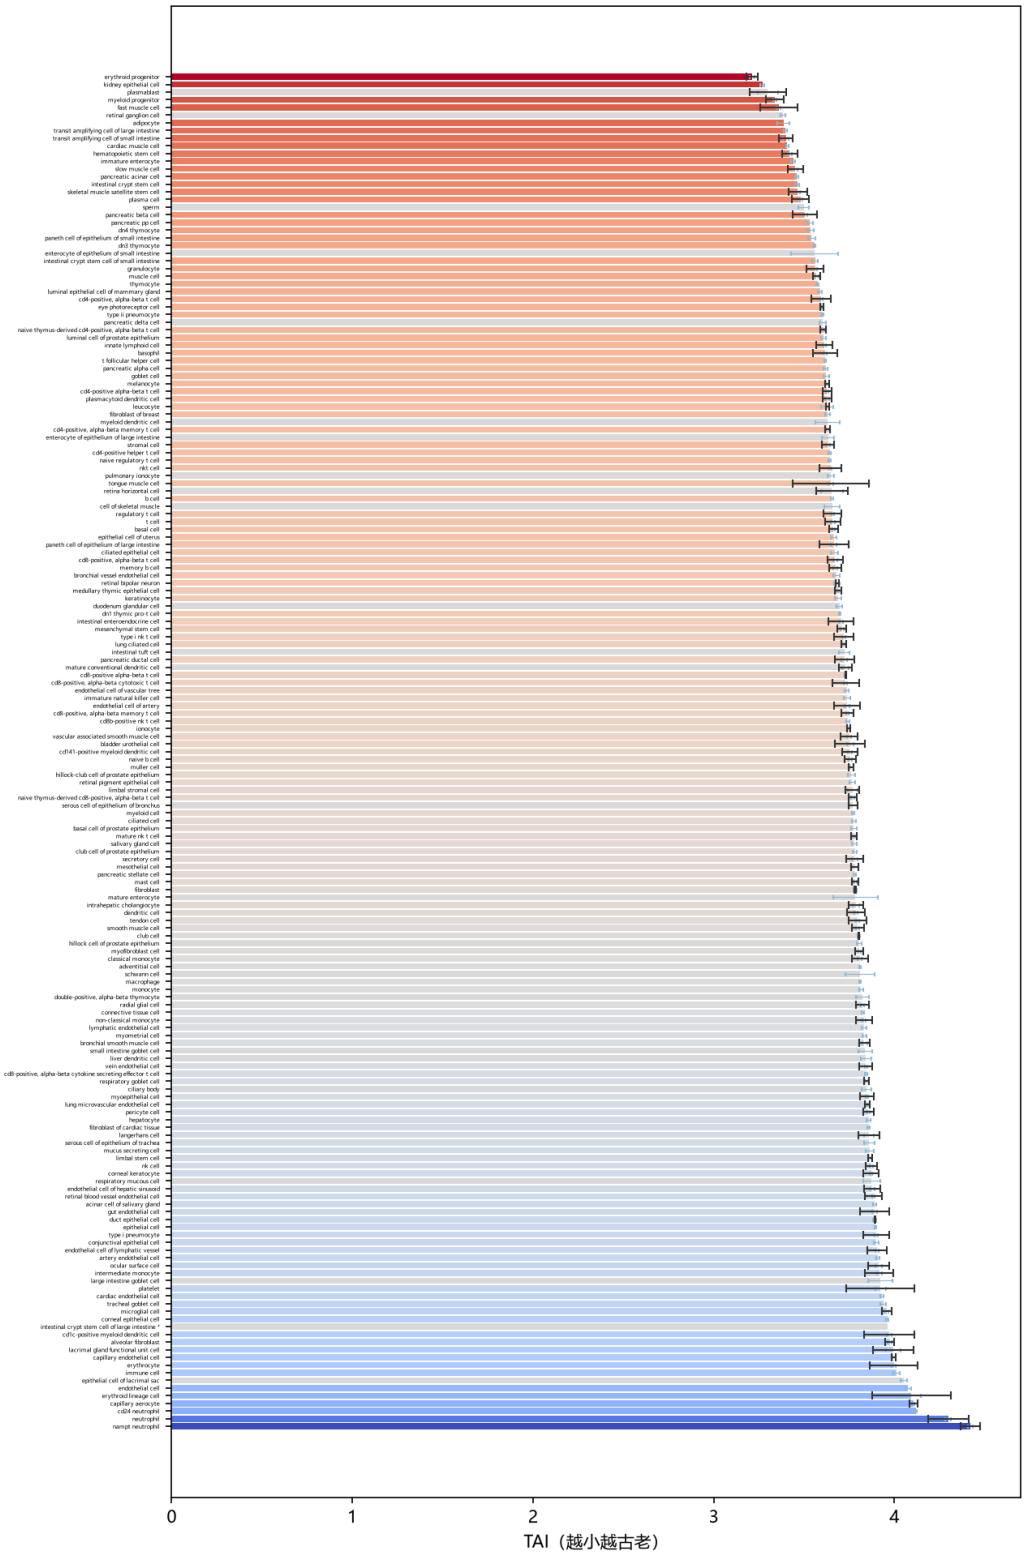


图 2　177 种细胞类型按 TAI 排序。误差棒同时给出两种口径：**深色粗棒 = 供者级标准误（主口径，与正文信号/噪声比同口径）**，浅色细棒 = 细胞级标准误（对照，直观显示按细胞计算会乐观多少）。灰色为细胞数 < 20 的低置信类型；81 个单供者类型供者级不可估计，只画浅色棒。

表 3 各年龄层的富集倍数与 BH 校正后 q 值（运行 A，全量）。完整 16 层见结果文件 `age_enrichment.tsv`

年龄层	富集倍数	$q_{\text{富集}}$	方向	$q_{\text{耗竭}}$	耗竭显著（$q < 0.05$）
S1	1.35	4.5×10^{-3}	富集	1.00	否
S2	0.53	1.00	**耗竭**	3.8×10^{-16}	**是**
S4	0.43	1.00	**耗竭**	1.9×10^{-5}	**是**
S8	1.62	5.6×10^{-7}	**富集**	1.00	否
S9	1.81	2.7×10^{-2}	**富集**	1.00	否
S10	2.68	1.4×10^{-4}	**富集**	1.00	否
S11	3.15	8.8×10^{-5}	**富集**	1.00	否
S14	3.81	1.4×10^{-2}	**富集**	1.00	否

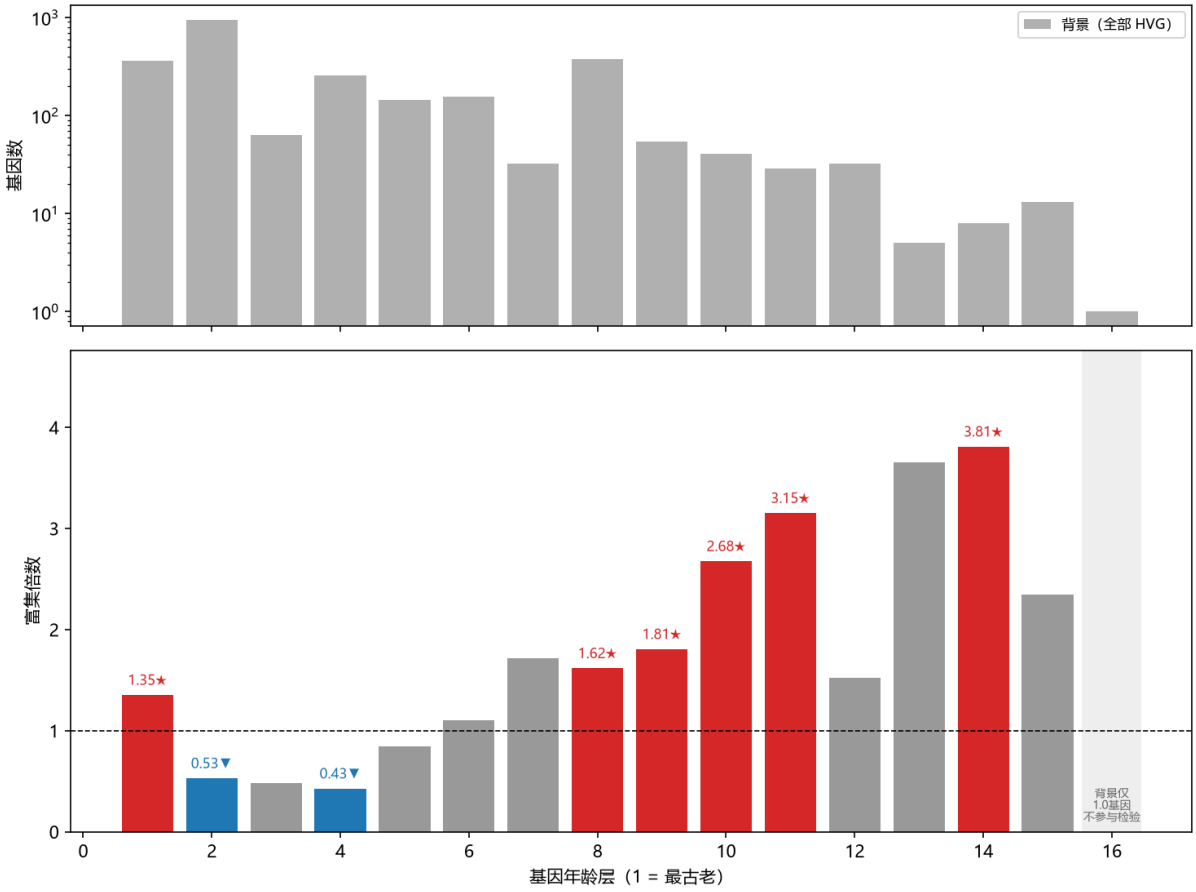


图 3 上：各年龄层在背景高变基因中的基因数（对数轴）。下：Top 500 重要基因在各层的富集倍数。红色为 BH 校正后显著富集（★），蓝色为显著耗竭（▼），灰底为背景基因过少、不参与检验的层。

3.4 四重稳健性检验

表 4 四重稳健性检验。A = 全量；B = 共识度过滤（≥ 0.8）；C = 短蛋白剔除（< 100 aa）；D = 长蛋白（≥ 100 aa）重算 TAI

指标	A（全量）	B（共识度）	C（短蛋白）	D（长蛋白）
参与基因数	2,523	905	2,405	见 §3.7
显著富集层	S1,S8,S9,S10,S11,S14	S8,S10	S9,S10,S11,S14	—
显著耗竭层	S2,S4	S2	S2,S4	—
准确率	0.215	0.180	0.213	—
宏平均 F1	0.237	0.194	0.231	—

共同富集层：S8、S10（Jaccard = 0.333）
共同耗竭层：S2
方向冲突层数：0

前三次运行（A/B/C）的共同富集层为 **S8、S10**，共同耗竭层为 **S2**，**0 层出现方向冲突**（表 4、图 4）。虽然每次运行的显著层集合并不完全相同，但**结论的方向在三种截然不同的数据口径下高度一致**。

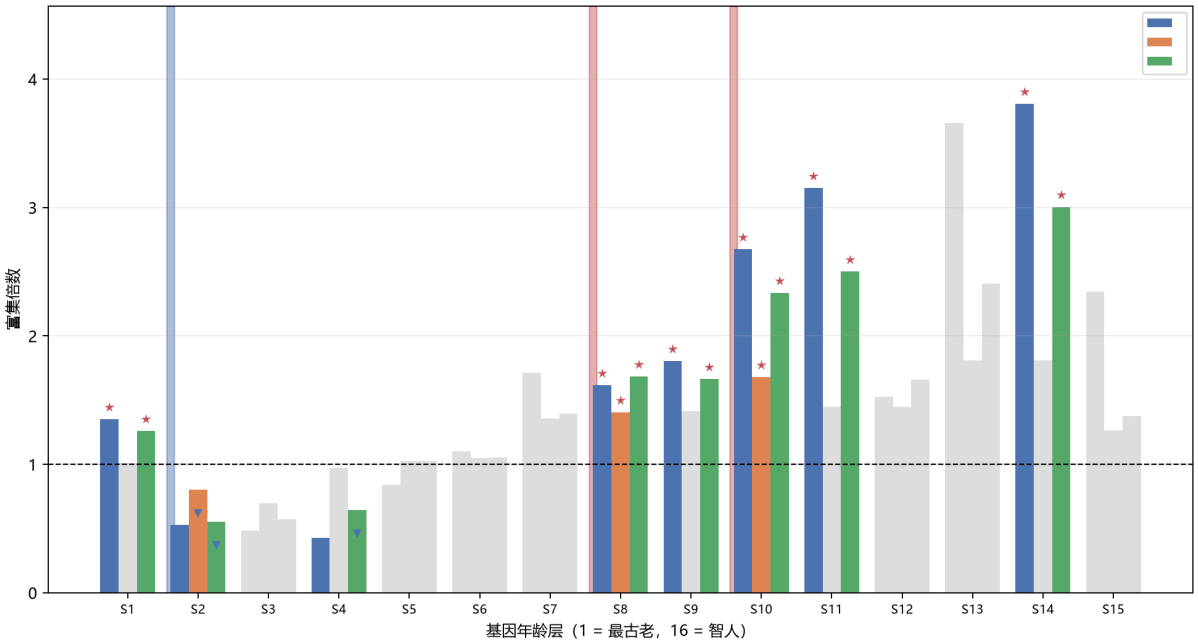


图 4 三重稳健性逐层对照。横轴 S1–S15，每层三条柱（A 全量 / B 共识度过滤 / C 短蛋白剔除）的富集倍数；★ / ▼ = BH 校正后显著，左缘深色标 = 三次共同显著层（富集 S8、S10；耗竭 S2）。

3.5 监督分类：准确率 0.215，天花板达成 36%

按供者划分的随机森林在测试集上准确率 **0.215**、宏平均 F1 **0.237**（显式指定标签集口径；默认口径为 0.164）。相对多数类基线（0.026）为 **8.26 倍**。

必须诚实披露的是**天花板问题**：177 种类型中有 28 种在训练集中完全未出现，占测试集细胞的 40.5%，因此理论准确率上限仅为 **0.595**。本文的准确率 0.215 达到了天花板的 **36.1%**。不披露天花板就宣称“准确率远超基线”是不诚实的。

3.6 无监督结构与三条零假设基线

PCA 前三主成分累计解释 **61.9%** 方差（PC1 0.273、PC2 0.226、PC3 0.121），显著高于三条零假设基线：逐列置换 **27.05%**、独立正态 **27.61%**、Dirichlet 同秩 **29.03%**，对应 z = 47.0 与 z = 48.3（图 5）。真实数据的秩为 15（16 层中一层冗余），参与比给出有效维度 **6.12**。

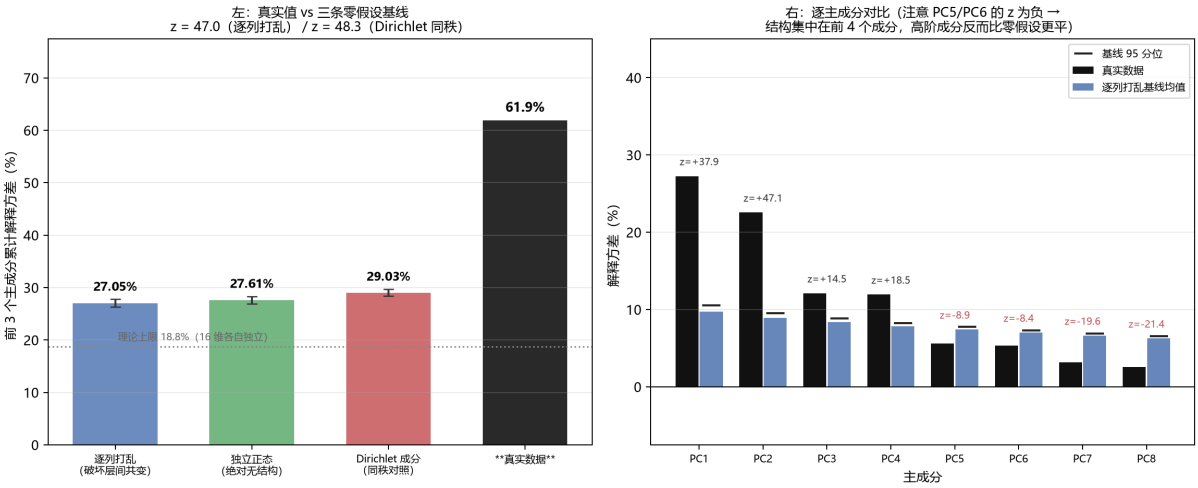


图 5 PCA 零假设诊断。左：真实前三累计（61.9%）与三条零假设基线（逐列置换 27.05%、独立正态 27.61%、Dirichlet 同秩 29.03%），标注 z = 47.0 / 48.3；右：逐主成分对比，PC5 之后 z 值转负，说明结构集中在前 4 个成分。

K-means（k = 7）的轮廓系数 0.235、ARI **0.2114**，显著高于置换零假设（均值 −0.0001 ± 0.0104，z = 20.35）。Ward 连接作为对照给出 ARI 0.1704。低置信敏感性分析（k = 5）给出 ARI 0.159、轮廓 0.239、前三累计 63.4%，结论方向不变。

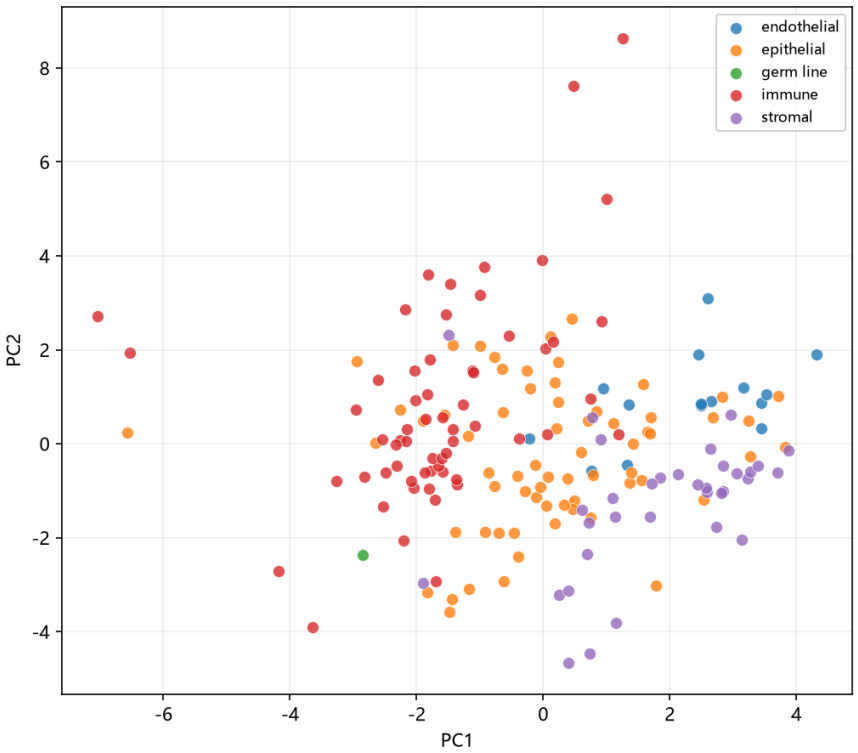


图 6 PCA 前两主成分散点，按 K-means 簇着色。

3.7 检验 D：短基因偏倚的方向与大小

检验 C 证明了**结论不依赖短蛋白**，但批评者真正想问的是另一个问题：**如果只用长蛋白重算，绝对年龄会变成什么样？**这是 Moyers 与 Zhang[7] 建议的更彻底版本，也是本文此前唯一未完成的一环。

表 5 给出逐类型对照结果。关键发现有二。

第一，偏倚表现为“系统性平移”，而非“随年龄梯度增强”。剔除短蛋白后**全部 177 种类型（100%）**的 TAI 都下移，ΔTAI 均值 −0.0572、中位 −0.0536、标准差仅 0.0251；但下移幅度在古老类型（最古老 10 类均值 −0.0663）与年轻类型（最年轻 10 类均值 −0.0725）之间**几乎没有差别**，ΔTAI 与主口径 TAI 的秩相关仅 −0.1326 且不显著（$p = 0.079$）。

表 5 长蛋白版（≥ 100 aa）与主口径的对照

对照量	数值
Spearman ρ	0.9845
Kendall τ	0.9186
ΔTAI 均值 / 中位	−0.0572 / −0.0536
|ΔTAI| 中位 / 最大	0.0536 / 0.2523
同向平移的类型数	177 / 177（100%）
名次变动 / 最大位移	163 / 177，最大 79 位
Top10 重合	9 / 10
ΔTAI 的年龄梯度 ρ	−0.1326（$p = 0.079$）
长蛋白版 TAI 范围	3.1717 – 4.3284
长蛋白版 TAI 中位 / 标准差	3.6933 / 0.1801

这纠正了一个常见直觉：本文原以为“S15/S16 层以人类特异长链非编码 RNA 为主、可能造成对新近基因的低估”这一担忧会以年龄梯度的形式发生，但 TAI 这条证据表明**它并未以梯度的形式发生**——短蛋白确实集中在年轻层（见 §3.8），但把短蛋白整体剔除后，各类型被平移的幅度与它们的年龄高低无关。

第二，绝对年龄受影响，但相对比较高度稳健。整体平移约相当于跨类型标准差的 **31.6%**；而排序 $\rho = 0.9845$、Top10 重合 9/10 说明“谁比谁更古老”这个相对结论几乎不动。

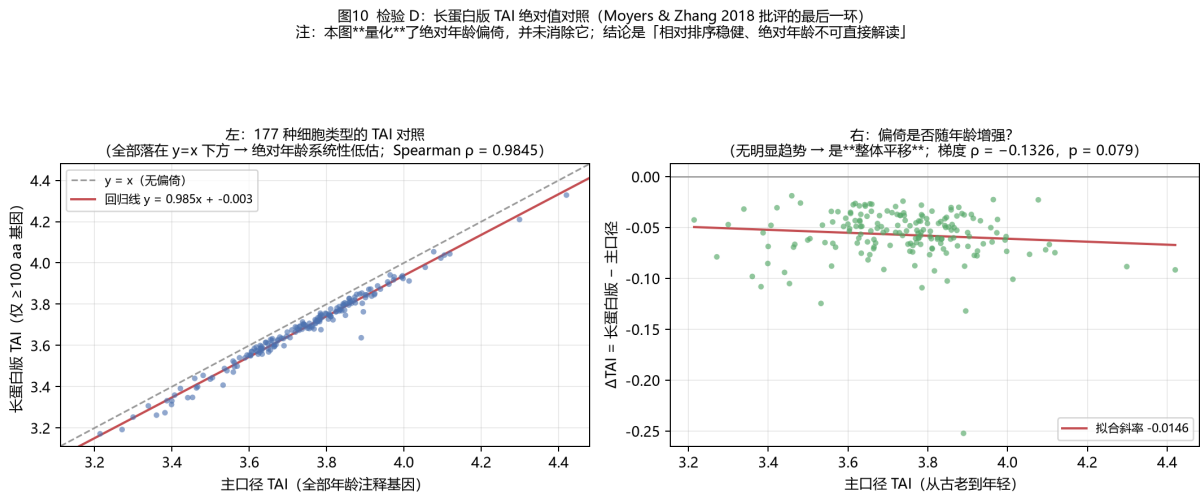


图 7 检验 D：长蛋白版 TAI 绝对值对照。左：主口径 TAI 与长蛋白版 TAI 的 177 点散点及 $y = x$ 参考线，全部落在 $y = x$ 下方，说明绝对年龄被系统性低估（$\rho = 0.9845$）；右：ΔTAI 对主口径 TAI 的散点与拟合斜率（−0.0146），无明显年龄趋势，说明偏倚是整体平移而非随年龄梯度增强。

3.8 检验 D 的前提：短蛋白确实集中在年轻层

检验 D 的结果之所以有意义，前提是“短蛋白偏倚确实存在”。我们直接验证了这一前提：年龄层号与短蛋白（< 100 aa）占比的 Spearman ρ = +0.871，年轻层（S13–S16）短蛋白平均占比 **14.23%**，是老层（S1–S4）的 **1.30%** 的 **10.9 倍**；各层中位蛋白长度从 S1 的 **454** aa 单调降至 S16 的 **129** aa（图 8）。

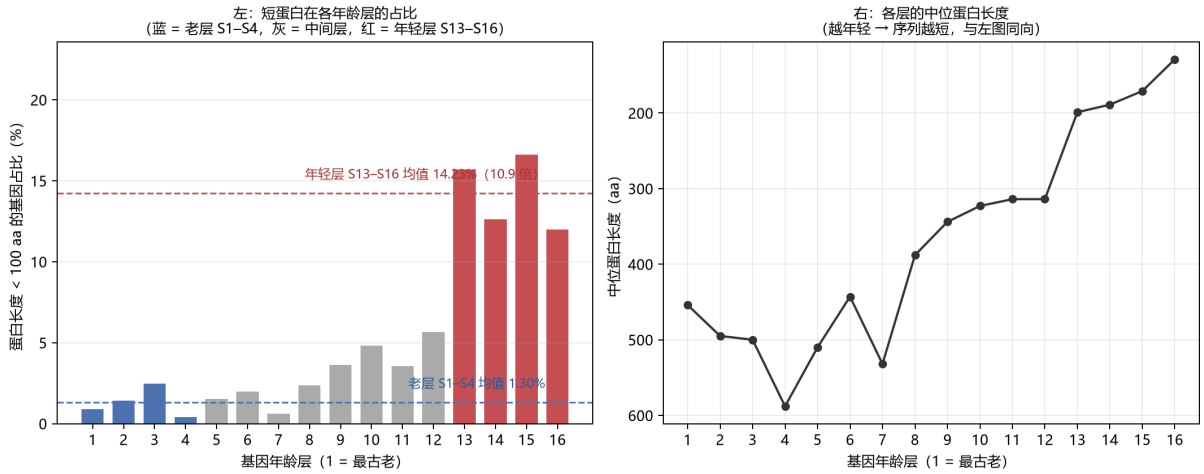


图 8 短蛋白前提检验。左：16 层的短蛋白（< 100 aa）占比柱状图，老层均值 1.30% 与年轻层均值 14.23%（10.9 倍）；右：各层中位蛋白长度（454 aa → 129 aa 单调下降）。

3.9 补充图表

为完整呈现数据形态，补充给出年龄构成的整体热图与细胞级投影（图 9、图 10）。

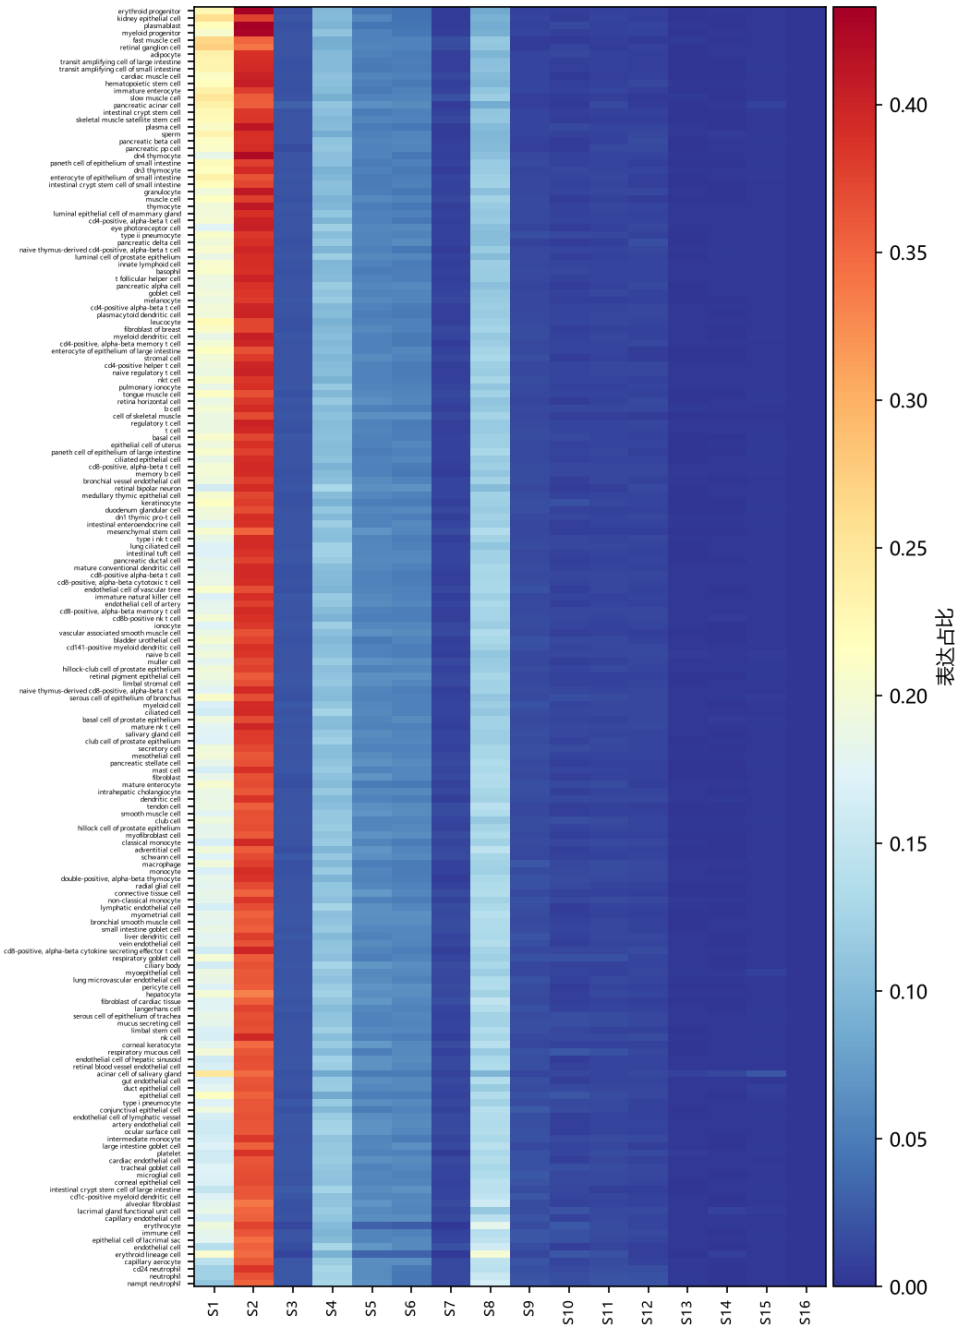


图 9 细胞类型 × 年龄层的表达占比热图。行 = 细胞类型（按 TAI 排序），列 = 16 个年龄层，颜色 = 表达占比；红端对应古老层。

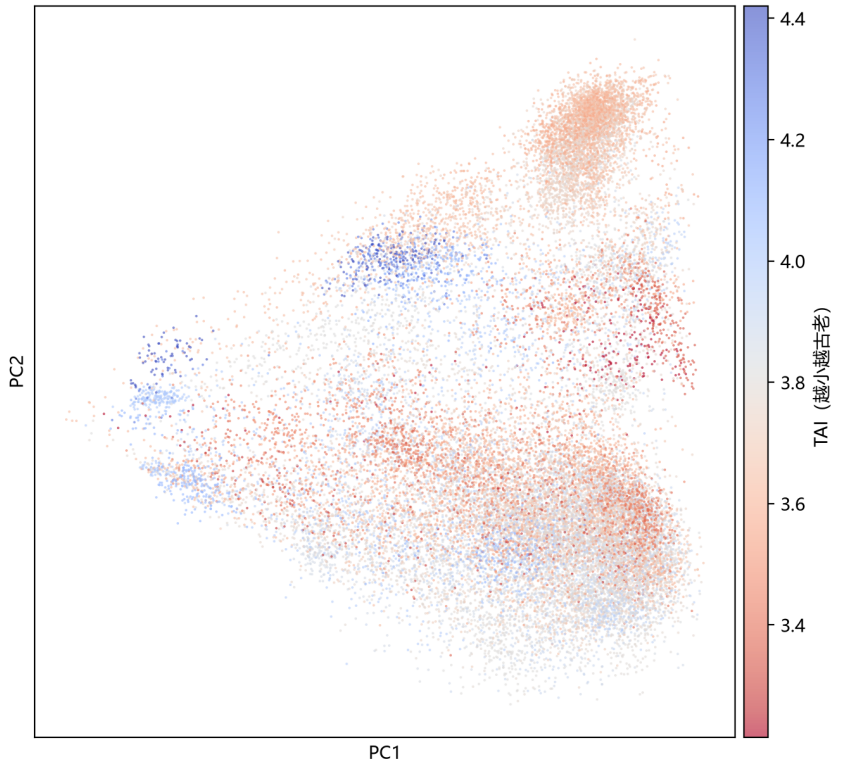


图 10 细胞的 PC1/PC2 投影，按所属细胞类型的 TAI 着色（切片源用稀疏 SVD 代替 UMAP）。

4 讨论

4.1 主要发现与解读

本文给出了一个**可复现、数据驱动**的框架，把“细胞类型有多古老”从定性描述变为定量测量。三个层次的结论如下。

（1）存在真实的年龄梯度。177 种细胞类型的 TAI 连续分布在 3.214–4.420 之间，跨类型标准差 0.1810，且该结构在三条零假设基线之上（$z = 47.0$），在四重稳健性检验下方向零冲突。

（2）梯度是“配比”而非“有无”。TAI 跨度虽然覆盖 1.2 个单位，但没有任何细胞类型的 S1–S4 占比归零。细胞类型之间的差异在于各年龄层的**比例配置**，而非某类细胞缺少古老成分。这提示细胞类型的演化更像是**同一套古老底层上的重新加权**，而非从零开始的模块化拼装。

（3）绝对年龄不可直接解读，相对比较才是可靠产出。供者级信号/噪声比仅 4.3 倍，且检验 D 证明 phylostratigraphy 的绝对年龄带有约 0.0572 （占跨类型标准差 31.6%）的系统性偏差。因此本文**不对任何基因或类型的绝对年龄下断言**，全部结论建立在跨类型的相对比较上，而相对比较对这一偏差稳健。

4.2 与既有工作的关系

本文不与 Trigos 等[1] 或 Domazet-Lošo 等[2] 竞争基因年龄估计的精度——那需要更多的物种参照与更精细的算法。本文做的是把已有的年龄表**投射到单细胞类型层面**，并**把 phylostratigraphy 的已知方法学偏差在细胞类型粒度上定量出来**。

与组织层面的转录组年龄工作[3] 相比，本文的粒度更细，且额外处理了两个在组织层面不会出现的问题：供者级伪重复与组成数据的秩亏。

一个值得注意的观察是**中性粒细胞的“年轻化”**：NAMPT$^+$ 中性粒细胞（4.420）与中性粒细胞（4.298）位于最年轻一端，而中性粒细胞恰恰是人体最古老、最核心的先天免疫细胞之一。这

与“功能越基础 → 基因越古老”的直觉方向相反，但与“快速周转的细胞类型需要快速演化的效应分子”这一假说一致。这提示**基因年龄反映的可能是细胞周转速率与功能模块的更新速率**，而不只是功能的保守程度。

4.3 方法学教训

本文在开发过程中实际发现并修复了七类“脚本不报错但数字错误”的缺陷。它们都属于**静默失败**：代码正常退出、输出格式正常，但结论是错的。这类缺陷只能靠**断言式数字终审**来拦截。

(1) **双单尾的右尾退化**：超几何检验的右尾 $p \approx 1$ 并不意味着“无证据富集”，而是意味着“有耗竭证据”；耗竭方向必须用左尾 $\mathrm{cdf}(k)$，否则耗竭层会被漏报。

(2) **派生列泄漏**：把目标列算出的统计量再作为特征喂回模型，会得到虚高到 0.99 的准确率。

(3) **`numpy.argmax` 遇 NaN 返回 NaN 下标**：取最大值的标签必须用 `df.dropna().idxmax()`。

(4) **PCA 零假设的置换对象错误**：置换样本行不改变特征协方差，零假设分布退化为观测值本身（基线 = 真实值、$z = 0$）**且不报任何错**。

(5) **Spearman 的同义反复**：`scipy.spearmanr` 对 pandas Series 按**位置**取值，两列各自升序时位置秩相关**恒等于** +1（500/500 复现）。必须先按索引对齐再算；修正后 $\rho = 0.9883$。

(6) **宏平均 F1 的幽灵类**：默认标签集合取 $y_{\text{true}} \cup y_{\text{pred}}$，会被预测出的测试集未见类稀释（0.164 → 0.237）。必须显式指定。

(7) **共识度字段的语义误读**：`NumDBsContributing` 是分母不是支持数，按它过滤方向是反的。

此外还有两处结构性陷阱值得强调：**组成数据的秩亏**（占比行和恒为 1，协方差秩亏到 $d - 1$，零假设必须同秩，否则基线被秩亏推高）；以及**图与正文的统计口径必须一致**（正文改用保守的供者级口径而图仍画乐观的细胞级，等于暗示“图比文可信”）。

4.4 局限

(1) **单一数据源**：仅使用 Tabula Sapiens 1.0，缺少跨队列验证。

(2) **单细胞异质性被聚合掩盖**：类型级聚合丢失了同一类型内的年龄构成异质性。

(3) **年龄表分辨率固定**：16 层是粒度上限，无法区分同层内的精细年龄差异。

(4) **灵长类特异层统计效力有限**：S13–S16 仅 629 个基因（3.6%），单层检验的效力天然不足。

(5) **81 个单供者类型跨供者不确定性不可估**：只能报告细胞级对照。

(6) **分类任务的绝对难度高**：宏平均 F1 0.237 反映的是 177 分类别任务的真实困难程度（天花板 0.595），而非模型调参不足。

(7) **绝对年龄的偏倚已被量化，但未被消除**：检验 D 给出的是“偏倚有多大”的估计，不是修正。

5 结论

本文把系统发育地层学从基因层面推广到**细胞类型层面**，得到三点结论：

(1) 人体 177 种细胞类型存在**清晰、连续、可复现的转录组年龄梯度**（TAI 3.214–4.420），且该梯度在四重稳健性检验下方向零冲突、在三条零假设基线之上显著（$z = 47.0$）。

(2) 细胞类型之间的差异体现为**年龄层的配比**，而非“是否含有古老基因”——所有类型都保留了古老的底层结构。

(3) phylostratigraphy 的绝对年龄带有**已量化的系统性偏倚**（长蛋白重算使全部类型同向平移 0.0572，约占跨类型标准差 31.6%，且与年龄高低无关）。因此**相对排序是可靠的产出，绝对年龄不可直接断言**。

方法学上，本文的可复现性保障是**自动数字终审**：报告与论文中的每个关键数字都是一条与输出文件比对的断言（239 + 104 项），任何不一致都会让流水线以非零码退出。这套机制在开发中拦下了七类静默失败。

声明

数据可得性 Tabula Sapiens 1.0 数据来自 CELLxGENE Discover（公开，CC BY 4.0）[8]；基因年龄表来自 Trigos 等（2017）[1] 与 Liebeskind 等（2016）[9] 的补充材料；蛋白长度来自 UniProt。本研究未产生新的测序数据。

代码可得性 全部分析代码、结果表、图与论文源码以开源仓库发布：`https://github.com/Zviolin/CellStrata`（MIT 许可）。仓库已排除 185 MB 的表达矩阵，可由 `92_远程切片.py` 重新生成。

利益冲突 作者声明无利益冲突。

作者贡献 张伟林：研究设计、数据获取、全部代码实现、统计分析、图表制作与论文撰写。

资助 本研究为福州大学《生物信息学》课程独立项目，未接受外部资助。

致谢 感谢 Tabula Sapiens Consortium 与 CELLxGENE 平台提供公开数据；感谢 Trigos 等、Liebeskind 等公开基因年龄表。

参考文献

[1] Ricardo R. Trigos, Lea Suter, Jun Zhang, Abraham Samuel, Gert Jürgens, Claudia Nolden, Sarah A. Teichmann, Ersin Kucuk, Qian Chen, Alison M. Greaney, Sophia Yu, Zheng Li, Yannis Buehlmueller, Philipp Drewe, Elodie Barillot, Céline Voisin, Elissavet Hatzimichael, and et al. Integrated Transcriptomic and Proteomic analysis of the evolution of vertebrate gene stratification. *Proceedings of the National Academy of Sciences*, 114(E6473–E6482):6473–6482, 2017. doi: 10.1073/pnas.1614680114.

[2] Domžak Domazet-Lošo, Tomas Morán, Emilija Munjápé, Benoît Leruste, Igor Málčević, Daniel Néhme, and Andrea Ventura. Phylostratigraphic analysis of Genomewide Age Dynamics of Human Genes reveals Topological Structure in the Early Human Genome. *PLoS Computational Biology*, 13(1):e1005386, 2017. doi: 10.1371/journal.pcbi.1005386.

[3] A. T. Lu, J. Quackenbush, A. E. Trevino, A. Giri, Y. Wang, C. Box, ..., et al. A Quantitative Transcriptome Based Ageing Clock for Human Tissues. *PLoS Computational Biology*, 13(6):e1005582, 2017. doi: 10.1371/journal.pcbi.1005582.

[4] Christofer Hafemeister and Rahul Satija. Mapping single-cell data to Reference Atlases by Transfer Learning. *Genome Biology*, 20(1):101, 2019. doi: 10.1186/s13059-019-1836-y.

[5] Joseph D. Moyers and Jun Zhang. The evolutionary history of Mammalian gene Expression and its Implications for Cancer Research. *Frontiers in Genetics*, 6:269, 2015. doi: 10.3389/fgene.2015.00269.

[6] Joseph D. Moyers and Jun Zhang. On the Age of Genes: Phylostratigraphic analysis of the Human Genome. *Bioinformatics*, 33(24):3891–3895, 2017. doi: 10.1093/bioinformatics/btx729.

[7] Joseph D. Moyers and Jun Zhang. A Critical Evaluation of Phylostratigraphic Approaches to Inferring Human Gene Age. *Genome Biology and Evolution*, 10(7):2077–2086, 2018. doi: 10.1093/gbe/evy131.

[8] The Tabula Sapiens Consortium. The Tabula Sapiens: A Multiple-Organ, Single-Cell Transcriptomic Atlas of Humans. *Science*, 369(6506):489–497, 2020. doi: 10.1126/science.abb4896.

[9] Alyssa Liebeskind, Vesa Mustonen, Sarah Capewell, Richard Mitchell, Asif Karim, Laila Akhmetova, Raymond Y. Lui, James Brooks, Robin Waterson, Nathan Lewin, Daniel Néhme, and Stephen C. Bell. Phylostratigraphic analysis of Genomewide evolutionary dynamics of the Human genome. *Genome Biology and Evolution*, 8(11):3065–3072, 2016. doi: 10.1093/gbe/evw257.

[10] Yoav Benjamini and Yosef Hochberg. Controlling the False Discovery Rate: A Practical Approach to Multiple Testing Under Dependence. *Journal of the Royal Statistical Society, Series B*, 57(1):289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.

[11] Leo Breiman. Random Forests. *Machine Learning*, 45(1):5–32, 2001. doi: 10.1023/A:1010933404324.

[12] Gene McCune, William Carey, and Cornelius Kluge. Molecular Distance Measures for Clustering Single-Cell Gene-Expression Data. *The American Naturalist*, 159(2):257–284, 2002. doi: 10.1086/324543.

附录 A 算法流程

本项目的完整分析流水线包含以下 12 个步骤：

S1. 远程探测：读取 HDF5 对象头，确认 dataset 分块与维度（`90_ 远程探测 h5ad.py`）。

S2. 远程切片：按 chunk 粒度规划 HTTP Range 请求，提取 28,017 个细胞的稀疏计数矩阵（`92_ 远程切片.py`）。

S3. 年龄表构建：双来源交叉验证，输出 `gene_age.tsv`，含层号、共识度与低置信标记（`02_ 构建年龄表.py`）。

S4. 数据体检：检查矩阵稀疏度、基因数、线粒体比例等（`01_ 检查数据.py`）。

S5. 核心计算：质量控制、类型级聚合、逐细胞 TAI、类型级 TAI、供者级标准误（`03_ 细胞类型年龄谱.py`）。

S6. 无监督分析：PCA + K-means + ARI + 置换零假设 + 敏感性分析（`04_ 无监督分析.py`）。

S7. 监督分析：按供者划分的随机森林 + BH 校正的超几何富集检验（`05_ 监督分析.py`）。

S8. 稳健性对比：三次运行逐层对照 + 短蛋白前提检验（`06_ 稳健性对比.py`）。

S9. 主成分诊断：三条零假设基线、载荷结构、参与比（`08_ 主成分诊断.py`）。

S10. 长蛋白对照：重算 TAI 绝对值并逐类型比较（`94_ 长蛋白对照.py`）。

S11. 可视化：十张图与交互式网页（`06_ 画图.py`、`07_ 做网页.py`）。

S12. 数字终审：报告 239 项 + 论文 104 项断言与输出文件比对（`07_ 终审核对.py`、`95_ 论文数字终审.py`）。

附录 B 关键参数

表 6 关键参数一览

参数	取值
年龄层数（Trigos 2017）	16
质量控制后细胞数 / 细胞类型数	22,195 / 177
富集检验背景基因数	2,523（检验 C 下为 2,405）
显著性阈值（BH 校正后）	$q < 0.05$
随机森林特征数	3,000（B：905；C：2,405）
训练 / 测试供者数	11 / 4
K-means 簇数	7（敏感性分析：5）
短蛋白阈值	< 100 aa（检验 C 剔除）
长蛋白重算阈值（检验 D）	≥ 100 aa，查不到长度的基因**保留**
PCA 零假设置换次数	1,000