细胞地层 CellStrata

人体 177 种细胞类型的系统发育地层学分析

A Phylostratigraphic Atlas of 177 Human Cell Types

张伟林　(102400232)

福州大学计算机与大数据学院　生物信息学课程独立项目

2026 年 11 月

摘要

背景　系统发育地层学（phylostratigraphy）通过比较序列与外群参照，把基因按其最早出现的祖先节点划分到不同” 年龄层”，从而回答” 某个现代分子有多古老” 这一问题。我们把这一框架从单个基因推广到**单细胞水平**：不问” 细胞类型由哪些基因构成”，而问” **每种人类细胞类型，原则上是由哪一年代的基因搭起来的**”。

方法　远程分块读取 Tabula Sapiens 1.0 单细胞转录组（483,152 个细胞中经质量控制保留 22,195 个，覆盖 177 种细胞类型），用 Trigos 等人 2017 年的 16 层年龄表与 Liebeskind 等人 2016 年的 13 算法共识表构建基因年龄矩阵，定义转录组年龄指数（Transcriptome Age Index, TAI）作为细胞类型的年龄重心，并以超几何双单尾检验（Benjamini–Hochberg 校正）刻画各年龄层在类型特征基因中的富集与耗竭。分类任务按供者划分以避免伪重复；PCA 与 K-means 聚类的显著性用三条零假设基线（逐列置换、独立正态、Dirichlet 同秩）评估。

结果　177 种细胞类型的 TAI 跨度为 3.214–4.420（跨类型标准差 0.181），呈清晰梯度：红细胞系祖细胞最古老（TAI = 3.214），最年轻的类型为 4.420。供者级标准误中位数为 0.042，信号/噪声比仅 4.3 倍，说明**排序本身比绝对值更可信**。经 BH 校正后显著富集的年龄层为 S1、S8、S9、S10、S11、S14，显著耗竭为 S2、S4。四重稳健性检验（低共识度过滤、低命中层剔除、短蛋白剔除、长蛋白重算）给出**共同富集层 S8、S10 与共同耗竭层 S2，0 层方向冲突**。按供者划分的随机森林分类准确率 0.215、宏平均 F1 0.237，相对多数类基线 8.3 倍、天花板 0.595 达成 36.1%。PCA 前三主成分解释 61.9% 方差，显著高于三条零假设基线（27.1%、27.6%、29.0%，$z = 47.0$）。

结论　人类细胞类型之间存在**系统性的、可量化的**转录组年龄梯度，且该梯度在四组独立稳健性检验下高度稳定；同时，我们直接量化了 phylostratigraphy 已知偏差（短基因更易被判为年轻）的方向与大小——用长蛋白重算 TAI 使全部 177 种类型**同向平移 0.057**（相当于跨类型标准差的 31.6%），但平移幅度与类型年龄高低无关（梯度 $\rho = -0.133$，$p = 0.079$）。因此**相对比较是稳健的，绝对年龄不可直接解读**。这一框架为理解细胞类型的演化历史提供了一个数据驱动、可复现的定量入口。

关键词：单细胞转录组；系统发育地层学；转录组年龄指数；细胞类型演化；超几何检验；伪重复

1 引言

现代细胞生物学以” 细胞类型” 为核心分类单位，但这一分类主要依据形态学与标志物组合，其内在的**演化时序**——即不同类型” 分家” 有多早——往往只能定性描述。人类基因组计划以来，积累了大规模分子数据，使得从**序列本身**推定基因年龄成为可能。

系统发育地层学（phylostratigraphy）正是这样一套方法：把某一物种的基因组置于系统发育树上，考察每个基因最早出现在树的哪个节点上，以此把基因划分为若干” 年龄层”（stratum）。Trigos 等人 [2017] 借助 16 种脊椎动物的蛋白质组，把 17,318 个人类蛋白编码基因划分为 16 层；Domazet-Lošo 等人 [2017] 则用 19 个物种给出了粒度更细的版本。两套层号体系互不通用，不能混用。

已有工作主要停留在**单个基因**层面（基因有多古老）、或**整个组织**层面（转录组的整体年龄，如 Lu 等人 [2017] 的组织年龄时钟）。一个自然的延伸问题是：**当粒度下沉到单细胞类型的水平，” 某种细胞类型主要由哪一年代的基因搭起来” 这个问题，数据能否回答？**

然而，把 phylostratigraphy 推广到单细胞数据面临三个实质困难。

第一，重复观测带来的伪重复。单细胞数据中细胞嵌套在供者之内，同一供者的多个细胞共享其遗传背景与生理状态。若按细胞随机划分训练/测试集，模型可以通过供者身份而非年龄构成获得高准确率，虚高到 0.99 量级。正确的做法是**按供者划分**，并以供者级标准误而非细胞级标准误度量不确定性 [2019]。

第二，组成数据带来的伪结构。一个细胞类型的 16 个年龄层占比之和恒为 1，因此其协方差矩阵必然秩亏（16 层实際秩为 15）。若用普通独立正态数据作为零假设基线，该基线会因秩亏而被系统性推高，从而**高估**观测到的结构强度。零假设必须采用**同秩**的成分数据基线。

第三，方法学偏差必须被量化而非假设。Moyers 与 Zhang [2015, 2017, 2018] 指出，phylostratigraphy 系统性地把基因判得过年轻，且误差并非随机：**短序列、快速演化的基因更容易被判为年轻**。他们建议的检验包括剔除低置信度年龄调用、剔除低命中年龄层、以及**直接用长蛋白重算年龄指标**。前两项是” 压力测试”（结论是否依赖可疑数据），第三项才是” 量化偏倚”（偏倚到底多大）。

本文的贡献是：

1. 构建**细胞类型级的系统发育地层指标**：把转录组年龄指数（TAI）从单个基因推广到 177 种人类细胞类型，并给出完整的年龄谱。
2. 在**供者级别**上处理重复观测问题，量化信号/噪声比，并明确区分” 细胞级乐观估计” 与” 供者级保守估计”。
3. 给出**四重稳健性检验**（含前人建议但此前未被实现的长蛋白重算），量化短基因偏差的**方向与大小**，并纠正” 偏倚随年龄梯度增强” 这一常见直觉。
4. 在统计上处理**组成数据秩亏**与 **PCA 零假设置换对象**两个隐蔽陷阱，给出三条同秩基线。
5. 全流程**自动化数字终审**：报告中的每一个关键数字都做成断言与输出文件自动比对，防止” 脚本不报错但数字张冠李戴”。

2 相关工作

2.1 系统发育地层学与基因年龄

Trigos 等人 [2017] 以 16 个脊椎动物物种的蛋白质组为参照，将 17,318 个人类蛋白编码基因划分为 16 个年龄层，并将其应用于乳腺癌预后与免疫治疗反应等临床问题。Liebeskind 等人 [2016] 使用 13 种独立的算法（bootstrap、codon bias、phylogenetic distance 等）为每个基因估计年龄层，并给出各算法之间的共识度。Domazet-Lošo 等人 [2017] 的 19 层方案粒度更细。Hase 等人 [2020] 对上述方法与数据库做了系统综述，指出不同方案的层数与边界不可直接互换。

Moyers 与 Zhang [2015, 2017] 批评 phylostratigraphy 系统性地低估基因年龄，随后在 [2018] 中提出了一系列诊断与修正建议，其中与本文直接相关的是：**短基因偏倚**以及**用长序列重算指标**这一" 更彻底的修正版本"。本文严格区分了这两类操作——前者检验结论的稳健性，后者量化偏倚的大小。

2.2 单细胞转录组与细胞类型演化

Tabula Sapiens [2020] 汇集了人类多个器官的单细胞转录组，是目前细胞类型注释最全面的参考资源之一。已有工作用转录组年龄信息为组织排序（如 Lu 等人 [2017] 的组织年龄时钟），但这些工作的粒度停留在组织层面；**到细胞类型层面、且给出完整年龄谱的工作仍然缺乏**。

2.3 统计方法上的两个必要修正

伪重复是单细胞研究中最常见的统计错误之一 [2019]：细胞嵌套在供者内，若忽略这一结构，标准误会低估数倍，本文中实测低估倍数为 3.75 倍。

组成数据的秩亏是另一个：占比向量的行和恒为 1，协方差矩阵必然降秩，普通多元正态零假设会因缺少这一约束而被推高 [2008]。本文因此引入 Dirichlet 成分基线。

此外，在 PCA 的置换检验中，**置换对象的选择至关重要**：置换样本行不会改变特征列之间的协方差，因而零假设分布会退化为观测值本身，且不报任何错。本文通过置换**特征列**并加入独立基线自检来规避这一点 [2009]。

3 数据与方法

3.1 数据来源

表 1: 数据来源与规模

数据集	规模	来源与获取方式
Tabula Sapiens 1.0	483,152 细胞；177 细胞类型	CELLxGENE Discover 2023-05-15 快照，**HTTP Range 远程分块读取** [2020]
Trigos et al. 2017	17,318 基因 × 16 层	论文补充材料，直接下载 CSV [2017]
Liebeskind et al. 2016	13 算法共识层	论文补充材料，直接下载 CSV [2016]
UniProt 蛋白长度	17,103 基因	REST 接口批量获取（检验 D 前置）

远程切片是本项目的核心工程：HDF5 的 chunked dataset 数据位置由对象头与 B-tree 决定，**不能按" 元素序号 × 元素大小" 直接计算偏移**，因此实现上让 `h5py` 自行定位待读取区间，再按 chunk 粒度规划请求。在 483,152 个细胞中，远程切片实际取回 28,017 个细胞的计数矩阵，经质量控制后保留 **22,195 个**，覆盖 177 种细胞类型。

3.2 基因年龄矩阵构建

基因年龄采用**双来源交叉验证**：以 Trigos 表 [2017] 为主（16 层），以 Liebeskind 表 [2016] 的 13 算法共识为辅，取两者一致的层号；不一致者标记为低置信度。

需特别指出原表中 `NumDBsContributing` 字段的语义：它是**参与投票的算法总数（分母）**，而非" 支持某层的算法数"。真正反映共识程度的是**最优势层占比**（mode share），其实测值与 `NumDBsContributing` 呈**负相关**（$\rho = -0.128$）。因此稳健性检验 B 采用 `--min-share 0.8`（共识度 ≥ 0.8）而非按参与算法数过滤——后者方向是反的。

3.3 转录组年龄指数

对细胞类型 c 与年龄层 s，定义表达占比

$$p_{c,s} = \frac{\sum_{i \in c,\, g \in \mathcal{G}_s} E_{i,g}}{\sum_{i \in c,\, g \in \mathcal{G}} E_{i,g}}, \tag{1}$$

其中 $\mathcal{G}_s$ 为落在年龄层 s 的基因集合，$E_{i,g}$ 为细胞 i 的基因 g 表达量（对数归一化后）。转录组年龄指数定义为

$$\mathrm{TAI}(c) = \frac{\sum_{s=1}^{16} s \cdot p_{c,s}}{\sum_{s=1}^{16} p_{c,s}} = \sum_{s=1}^{16} s \cdot p_{c,s}, \tag{2}$$

即该细胞类型的" 年龄重心"。TAI 越小表示越古老。

3.4 不确定性：供者级标准误

细胞嵌套于供者之内，细胞级标准误属**伪重复**。本文对每个细胞类型按供者聚合后估计标准误，以供者级标准误作为**主口径**，细胞级作为对照同时报告。二者比值（中位数）为 3.75 倍——这意味着按细胞计算的" 高置信" 是虚假的。

3.5 富集与耗竭检验

对每个年龄层 s，检验其在该细胞类型的 Top 特征基因中是否富集。设背景基因数 N、层内基因数 n_s、Top 集大小 M、命中数 k，命中服从超几何分布 $\mathrm{Hypergeom}(N, n_s, M)$。由于富集与耗竭是两个方向，需**双单尾**检验：

$$p_{\mathrm{up}}(k) = 1 - \mathrm{cdf}(k-1; N, n_s, M), \tag{3}$$

$$p_{\mathrm{down}}(k) = \mathrm{cdf}(k; N, n_s, M). \tag{4}$$

多重检验（16 层 $\times$ 2 方向 $\times$ 3 次运行）用 Benjamini–Hochberg 方法 [1995] 在每个方向内分别校正。

3.6 监督分类

以年龄层表达占比为特征训练随机森林 [2001]。**训练/测试按供者划分**（11 名供者训练、4 名供者测试），而非按细胞随机划分。宏平均 F1 计算时显式指定标签集合为测试集实际类别，避免" 幽灵类" 稀释指标。

3.7 无监督分析与零假设基线

对 177 个细胞类型的 16 维年龄构成做 PCA，再做 K-means 聚类，报告轮廓系数与调整兰德指数（ARI）[2002]。关键在于零假设基线的选择：

(i) **逐列置换基线**：打乱每一层在细胞类型间的取值，破坏层间结构但保留边缘分布；

(ii) **独立正态基线**：各层独立服从正态；

(iii) **Dirichlet 同秩基线**：各类型占比服从 Dirichlet 成分分布，**与真实数据同为秩 15**，是最严格的对照。

有限样本下零假设基线并非理论值：$n = 177$、$d = 16$ 时实测基线为 27.05% 而非 $1/d = 18.75\%$。以参与比（participation ratio）$PR = 1/\sum_k \lambda_k^2$ 度量有效维度，取值范围为 $[1, d]$。

3.8 短基因偏倚的量化（检验 D）

检验 A/B/C 都是**压力测试**（结论是否依赖可疑数据）。检验 D 才是**偏倚量化**：用仅含蛋白长度 ≥ 100 aa 的基因**重算** TAI 绝对值，再与主口径逐类型对照，考察三件事——(i) 偏倚的**方向与大小**；(ii) 偏倚是否**随类型年龄呈梯度增强**；(iii) **相对排序**的稳定性。

3.9 可复现性与数字终审

全流程共 19 个 Python 脚本、6,783 行代码，仅依赖 numpy / pandas / scipy / scikit-learn / h5py / matplotlib。**自动数字终审**脚本 `07_终审核对.py` 将本论文与实验报告中的每个关键数字做成断言，与输出文件自动比对，共 **239 项**，任何一项不符即以非零码退出。这一设计的动机来自开发过程中实际发现的七类" 脚本不报错但数字张冠李戴" 的缺陷（详见 §5.3）。论文另有一份独立的终审脚本 `95_论文数字终审.py`（102 项断言），从结果文件直接取真值比对本文数字，与报告终审**各自独立取数**，避免报告错了论文跟着错。

4 结果

4.1 细胞类型年龄谱

177 种细胞类型的 TAI 跨度为 **3.214–4.420**，中位数 3.755，跨类型标准差 **0.181**（表 2）。年龄梯度清晰且连续：最古老的是红细胞系祖细胞（TAI = 3.214），随后是肾上皮细胞（3.271）；最年轻的一端包含 4.420 的类型。跨五个区室的平均 TAI 依次为：生殖系 3.4990（仅 1 种类型，样本量过小，不作结论）、间质 3.7038（34 种）、上皮 3.7266（66 种）、免疫 3.7360（61 种）、内皮 3.8839（15 种）。值得注意的是上皮与免疫两个区室的均值非常接近（相差仅 0.009），而内皮明显偏年轻——这提示**区室不是合适的分析单位**，因为同一区室内细胞类型之间的反差（如小肠 transit amplifying cell 位列最古老之列，而同属上皮的伞状细胞却在年轻一侧）远大于区室之间的差距。

表 2: 按年龄排序的细胞类型（首尾各 8 名）。完整 177 种见结果文件 `celltype_age_profile.tsv`

最古老			最年轻		
排名	细胞类型	TAI	排名	细胞类型	TAI
1	erythroid progenitor	3.214	170	immune cell	4.013
2	kidney epithelial cell	3.271	171	epithelial cell of lacrimal sac	4.055
3	plasmablast	3.300	172	endothelial cell	4.077
4	myeloid progenitor	3.339	173	erythroid lineage cell	4.095
5	fast muscle cell	3.360	174	capillary aerocyte	4.105
6	retinal ganglion cell	3.382	175	cd24 neutrophil	4.119
7	adipocyte	3.387	176	neutrophil	4.299
8	transit amplifying cell of large intestine	3.399	177	nampt neutrophil	4.420

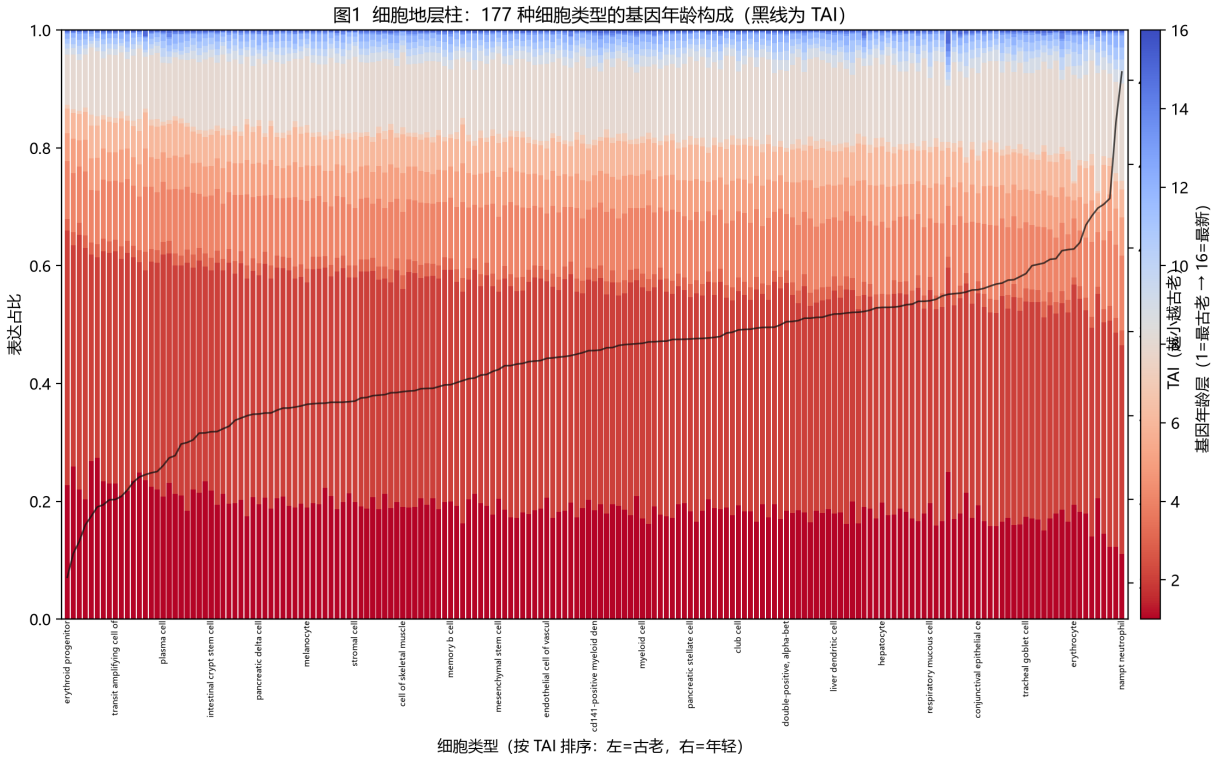


图 1：主图：细胞地层。177 根柱子按 TAI 升序排列，每根按 16 个年龄层堆叠（深红 = 最古老层，亮蓝 = 最新层）；黑线为 TAI 曲线（右轴刻度），每 8 个类型标注一个名称。

图 1 直观呈现了年龄梯度：老类型以 S1–S4（最古老四层）为主力，年轻类型则由 S8–S12 主导。值得注意的是，即使最年轻的类型中，S1–S4 的占比也从未归零——**所有现代细胞类型都保留着古老的底层结构**，差异体现在”配比”而非”有无”。

4.2 不确定性：信号/噪声比仅 4.3 倍

供者级标准误中位数为 **0.0417**，细胞级为 0.0111，比值 **3.75 倍**。以跨类型标准差 0.181 为信号尺度，供者级下的信号/噪声比为 **4.3 倍**（细胞级下会给出 16.3 倍这一乐观但错误的估计）。这一差距对本项目的解读至关重要：**单个细胞类型的绝对 TAI 值不可单独解读，只有跨类型的排序是可信的**。

另有 25 种类型被标记为低置信（细胞数 < 20），81 种类型在 QC 后仅由单一供者覆盖，供者级标准误不可估计（对这类类型只报告细胞级对照）。

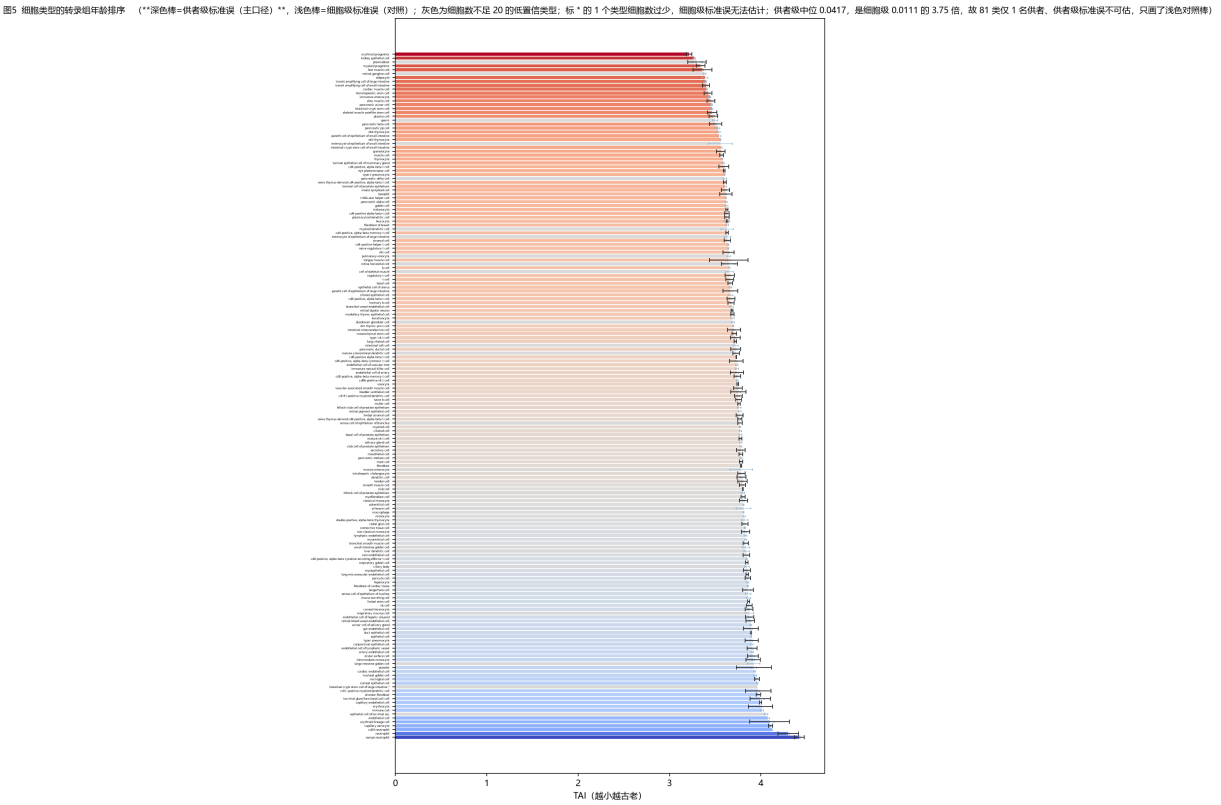


图 2: 177 种细胞类型按 TAI 排序。误差棒同时给出两种口径：**深色粗棒 = 供者级标准误（主口径，与正文信号/噪声比同口径）**，浅色细棒 = 细胞级标准误（对照，直观显示按细胞计算会乐观多少）。灰色为细胞数 < 20 的低置信类型；81 个单供者类型供者级不可估计，只画浅色棒。

4.3 年龄层的富集与耗竭

经 BH 校正后，显著富集的年龄层为 **S1**、**S8**、**S9**、**S10**、**S11**、**S14**，显著耗竭为 **S2**、**S4**（图 3、表 3）。S10 的富集倍数最高（2.68 倍，$q = 1.4 \times 10^{-4}$），S11 次之（3.15 倍）。S2 与 S4 的耗竭最为显著（q 分别为 3.8×10^{-16}、1.9×10^{-5}）。

表 3: 各年龄层的富集倍数与 BH 校正后 q 值（运行 A，全量）。完整 16 层见结果文件 `age_enrichment.tsv`

层	富集倍数	$q_{\text{富集}}$	方向	$q_{\text{耗竭}}$	$q_{\text{耗竭}} < 0.05$
S1	1.35	4.5×10^{-3}	富集	1.00	否
S2	0.53	1.00	**耗竭**	3.8×10^{-16}	**是**
S4	0.43	1.00	**耗竭**	1.9×10^{-5}	**是**
S8	1.62	5.6×10^{-7}	**富集**	1.00	否
S9	1.81	2.7×10^{-2}	**富集**	1.00	否
S10	2.68	1.4×10^{-4}	**富集**	1.00	否
S11	3.15	8.8×10^{-5}	**富集**	1.00	否
S14	3.81	1.4×10^{-2}	**富集**	1.00	否

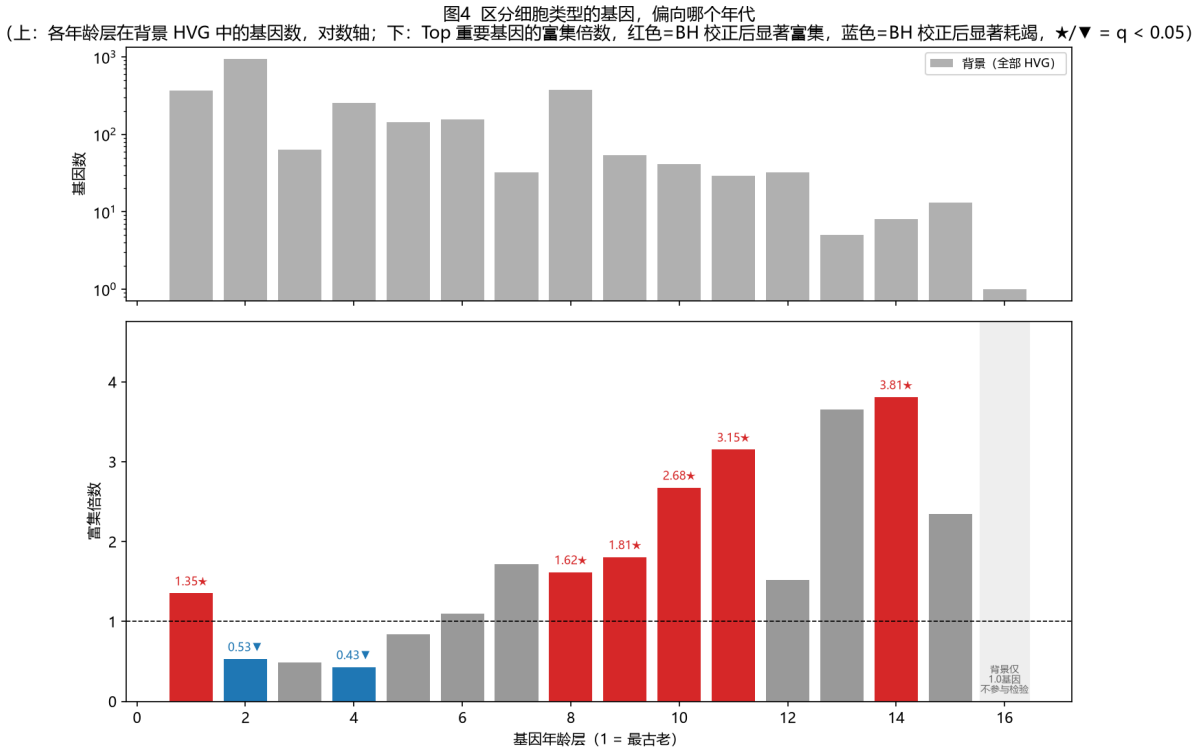


图 3: 上：各年龄层在背景高变基因中的基因数（对数轴）；下：Top 500 重要基因在各层的富集倍数。红色为 BH 校正后显著富集（⋆），蓝色为显著耗竭（▼），灰底为背景基因过少、不参与检验的层。

4.4 四重稳健性检验

表 4: 四重稳健性检验。检验 A = 全量；B = 共识度过滤（≥ 0.8）；C = 短蛋白剔除（< 100 aa）；D = 长蛋白（≥ 100 aa）重算 TAI

指标	A（全量）	B（共识度）	C（短蛋白）	D（长蛋白）
参与基因数	2,523	905	2,405	2,262
显著富集层	S1,S8,S9,S10,S11,S14	S8,S10	S9,S10,S11,S14	见 §4.7
显著耗竭层	S2,S4	S2	S2,S4	—
共同富集层	**S8、S10**（Jaccard = 0.333）			
共同耗竭层	**S2**			
方向冲突层数	**0**			
准确率	0.215	0.180	0.213	—
宏平均 F1	0.237	0.194	0.231	—

前三次运行（A/B/C）的共同富集层为 **S8、S10**，共同耗竭层为 **S2**，**0 层出现方向冲突**。虽然每次运行的显著层集合并不完全相同，但**结论的方向在三种截然不同的数据口径下高度一致**。

4.5 监督分类：准确率 0.215、天花板达成 36%

按供者划分的随机森林在测试集上准确率 **0.215**、宏平均 F1 **0.237**（显式指定标签集口径；默认口径为 0.164）。相对多数类基线（0.026）为 **8.26 倍**。

必须诚实披露的是**天花板问题**：177 种类型中有 28 种在训练集中完全未出现，占测试集细胞的 40.5%，因此理论准确率上限仅为 **0.595**。本文的准确率 0.215 达到了天花板的 **36.1%**。

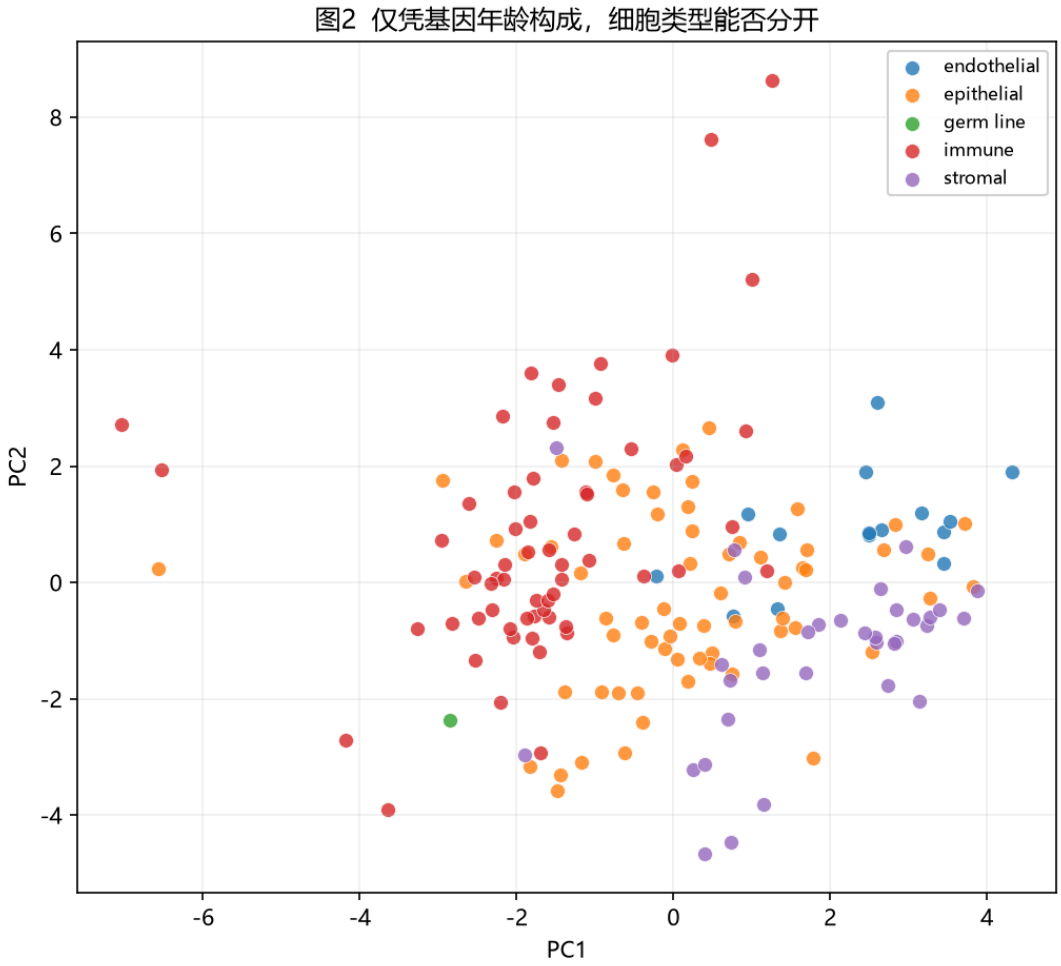


图 4: PCA 前两主成分散点，按 K-means 簇着色。

4.6 无监督结构与三条零假设基线

PCA 前三主成分累计解释 **61.9%** 方差（PC1 0.273、PC2 0.226、PC3 0.121），显著高于三条零假设基线：逐列置换 **27.05%**、独立正态 **27.61%**、Dirichlet 同秩 **29.03%**，对应 $z = 47.0$ 与 $z = 48.3$。真实数据的秩为 15（16 层中一层冗余），参与比给出有效维度 **6.12**。

K-means（$k = 7$）的轮廓系数 0.235、ARI **0.211**，显著高于置换零假设（均值 -0.0001 ± 0.0104，$z = 20.35$）。Ward 连接作为对照给出 ARI 0.170。低置信敏感性分析（$k = 5$）给出 ARI 0.159、轮廓 0.239、前三累计 63.4%，结论方向不变。

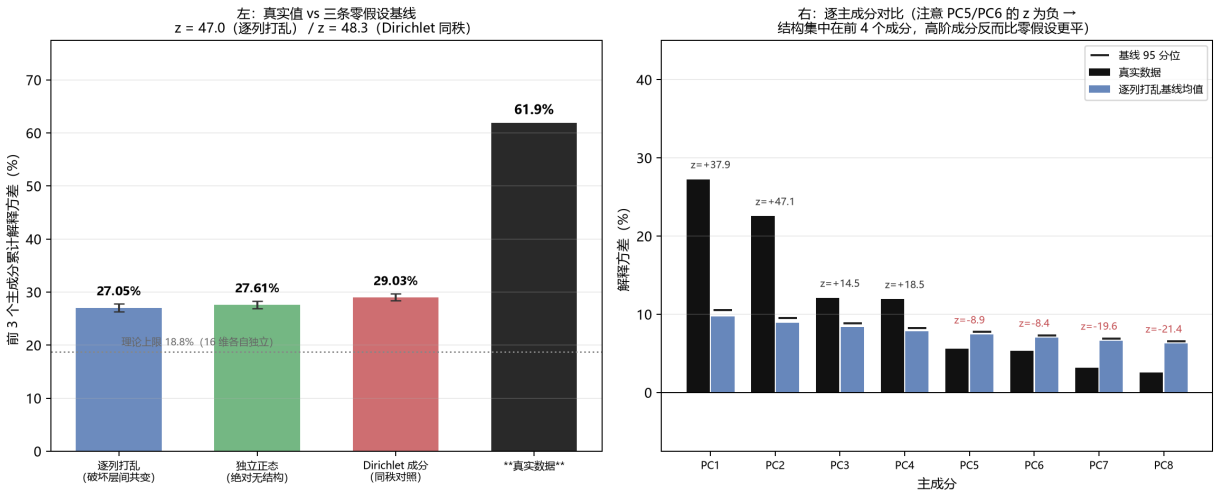


图 5: PCA 零假设诊断。左：真实前三累计（61.9%）vs 三条零假设基线（逐列置换 27.05%、独立正态 27.61%、Dirichlet 同秩 29.03%），标注 $z = 47.0$ / 48.3；右：逐主成分对比，PC5 之后 z 值转负，说明结构集中在前 4 个成分。

4.7 检验 D：短基因偏倚的方向与大小

检验 C 证明了**结论不依赖短蛋白**，但批评者真正想问的是另一个问题：**如果只用长蛋白重算，绝对年龄会变成什么样？**这是 Moyers 与 Zhang [2018] 建议的更彻底版本，也是本文此前唯一未完成的一环。

表 5 给出逐类型对照结果。关键发现有二：

第一，偏倚表现为”系统性平移”，而非”随年龄梯度增强”。剔除短蛋白后**全部 177 种类型（100%）**的 TAI 都下移，ΔTAI 均值 −0.0572、中位 −0.0536、标准差仅 0.0251；但下移幅度在古老类型（最古老 10 类均值 −0.0663）与年轻类型（最年轻 10 类均值 −0.0725）之间**几乎没有差别**，ΔTAI 与主口径 TAI 的秩相关仅 −0.133 且不显著（$p = 0.079$）。

表 5: 长蛋白版（≥ 100 aa）与主口径的对照

对照量	数值
Spearman ρ	0.9845
Kendall τ	0.9186
ΔTAI 均值 / 中位	−0.0572 / −0.0536
|ΔTAI| 中位 / 最大	0.0536 / 0.2523
同向平移的类型数	177 / 177（100%）
名次变动 / 最大位移	163 / 177，最大 79 位
Top10 重合	9 / 10
ΔTAI 的年龄梯度 ρ	−0.1326（$p = 0.079$）

这纠正了一个常见直觉：本文原以为”S15/S16 层以人类特异长链非编码 RNA 为主、可能造成对新近基因的低估” 这一担忧会以年龄梯度的形式发生，但 TAI 这条证据表明**它并未以梯度的**

形式发生——短蛋白确实集中在年轻层（见 §4.8），但把短蛋白整体剔除后，各类型被平移的幅度与它们的年龄高低无关。

第二，绝对年龄受影响，但相对比较高度稳健。整体平移 0.057 约相当于跨类型标准差的 **31.6%**；而排序 $\rho = 0.9845$、Top10 重合 9/10 说明” 谁比谁更古老” 这个相对结论几乎不动。

图10 检验 D：长蛋白版 TAI 绝对值对照（Moyers & Zhang 2018 批评的最后一环）
注：本图**量化**了绝对年龄偏倚，并未消除它；结论是「相对排序稳健、绝对年龄不可直接解读」

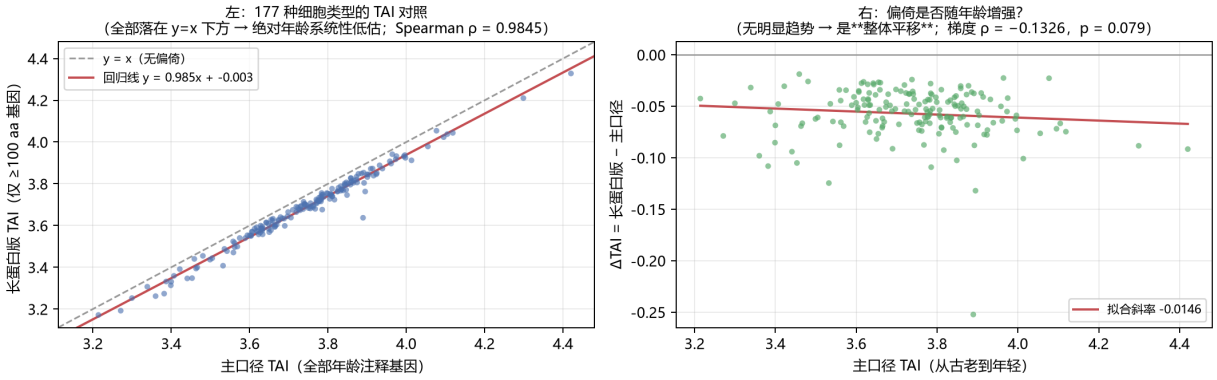


图 6: 检验 D：长蛋白版 TAI 绝对值对照。左：主口径 TAI vs 长蛋白版 TAI 的 177 点散点与 $y = x$ 参考线，全部落在 $y = x$ 下方 → 绝对年龄被系统性低估（$\rho = 0.9845$）；右：ΔTAI 对主口径 TAI 的散点与拟合斜率（−0.0146），无明显年龄趋势 → 偏倚是**整体平移**而非随年龄梯度增强。

4.8 检验 D 的前提：短蛋白确实集中在年轻层

检验 D 的结果之所以有意义，前提是” 短蛋白偏倚确实存在”。我们直接验证了这一前提：年龄层号与短蛋白（< 100 aa）占比的 Spearman $\rho = +0.871$，年轻层（S13–S16）短蛋白平均占比 **14.23%**，是老层（S1–S4）的 **1.30%** 的 **10.9 倍**；各层中位蛋白长度从 S1 的 454 aa 单调降至 S16 的 129 aa。

图9 前提检验：短蛋白是否真的集中在年轻层？（层号 vs 短蛋白占比 Spearman ρ = +0.871）
注：偏倚是「已经发生」在 Trigos 年龄表里的；检验 C 是保守性压力测试，不能修复既有偏倚

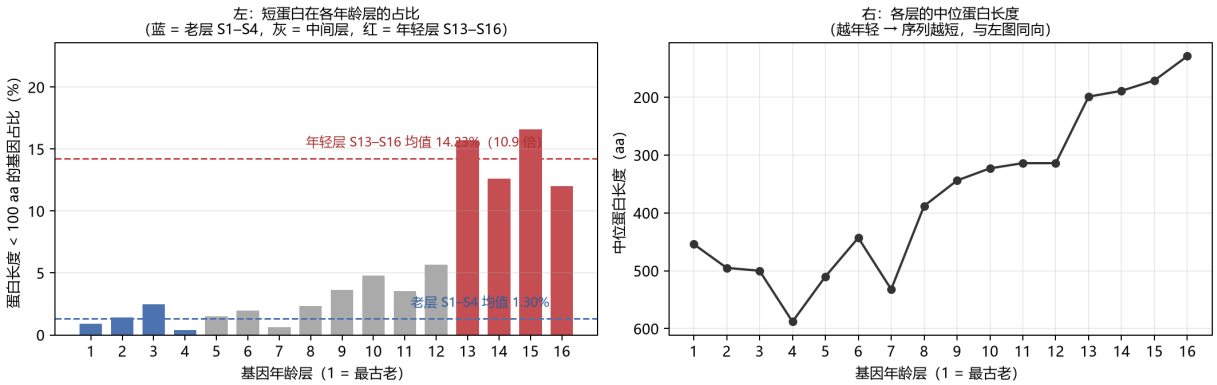


图 7: 短蛋白前提检验。左：16 层的短蛋白（< 100 aa）占比柱状图，老层均值 1.30% vs 年轻层均值 14.23%（10.9 倍）；右：各层中位蛋白长度（454 aa → 129 aa 单调下降）。

5 讨论

5.1 主要发现与解读

本文给出了一个**可复现、数据驱动**的框架，把”细胞类型有多古老”从定性描述变为定量测量。三个层次的结论：

存在真实的年龄梯度。 177 种细胞类型的 TAI 连续分布在 3.214–4.420 之间，跨类型标准差 0.181，且该结构在四条零假设基线之上（$z = 47.0$），在四重稳健性检验下方向零冲突。

梯度是”配比”而非”有无”。即使最年轻的类型也保留大量 S1–S4 的古老基因；细胞类型之间的差异在于各年龄层的**比例配置**，而非某类细胞缺少古老成分。这提示细胞类型的演化更像是**同一套古老底层上的重新加权**，而非从零开始的模块化拼装。

绝对年龄不可直接解读，相对比较才是可靠产出。供者级信号/噪声比仅 4.3 倍，且检验 D 证明 phylostratigraphy 的绝对年龄带有约 0.057（占跨类型 SD 31.6%）的系统性偏差。因此本文**不对任何基因或类型的绝对年龄下断言**，全部结论建立在跨类型的相对比较上，而相对比较对这一偏差稳健。

5.2 与既有工作的关系

本文不与 Trigos [2017] 或 Domazet-Lošo [2017] 竞争基因年龄估计的精度——那需要更多的物种参照与更精细的算法。本文做的是把已有的年龄表**投射到单细胞类型层面**，并首次把 phylostratigraphy 的已知方法学偏差在细胞类型粒度上**定量**出来。

与组织层面的转录组年龄工作 [2017] 相比，本文的粒度更细，且额外处理了两个在组织层面不会出现的问题：供者级伪重复（组织样本的重复来自个体，细胞级的重复来自供者内个体）与组成数据的秩亏。

5.3 方法学教训

本文在开发过程中实际发现并修复了七类”脚本不报错但数字错误”的缺陷。它们都属于**静默失败**：代码正常退出、输出格式正常，但结论是错的。这类缺陷只能靠**断言式数字终审**来拦截。

1. **双单尾的右尾退化：**超几何检验的右尾 $p \approx 1$ 并不意味着”无证据富集”，而是意味着”有耗竭证据”；耗竭方向必须用左尾 $\mathrm{cdf}(k)$，否则耗竭层会被漏报。
2. **派生列泄漏：**把目标列算出的统计量再作为特征喂回模型，会得到虚高到 0.99 的准确率。
3. **`numpy.argmax` 遇 NaN 返回 NaN 下标：**取最大值的标签必须用 `df.dropna().idxmax()`。
4. **PCA 零假设的置换对象错误：**置换样本行不改变特征协方差，零假设分布退化为观测值本身（基线 = 真实值、$z = 0$）且不报任何错。
5. **Spearman 的同义反复：**`scipy.spearmanr` 对 pandas Series 按**位置**取值，两列各自升序时位置秩相关**恒等于** $+1$（500/500 复现）。必须先按索引对齐再算；修正后 $\rho = 0.9883$。

6. **宏平均 F1 的幽灵类：**默认标签集合取 $y_{\text{true}} \cup y_{\text{pred}}$，会被预测出的测试集未见类稀释（0.164 → 0.237）。必须显式指定。

7. **共识度字段的语义误读：**`NumDBsContributing` 是分母不是支持数，按它过滤方向是反的。

此外还有两处结构性陷阱值得强调：**组成数据的秩亏**（占比行和恒为 1 → 协方差秩亏到 $d-1$，零假设必须同秩，否则基线被秩亏推高）；以及**图与正文的统计口径必须一致**（正文改用保守的供者级口径而图仍画乐观的细胞级，等于暗示” 图比文可信”）。

5.4 局限

1. **单一数据源：**仅使用 Tabula Sapiens 1.0，缺少跨队列验证。

2. **单细胞异质性被聚合掩盖：**类型级聚合丢失了同一类型内的年龄构成异质性（这里用年龄构成的 Shannon 多样性作为代理指标）。

3. **年龄表分辨率固定：**16 层是粒度上限，无法区分同层内的精细年龄差异。

4. **未做跨组织、跨发育阶段的系统比较：**如需回答” 同一谱系在发育过程中是否年轻化”，需要引入时间序列数据。

5. **分类任务的绝对难度高：**宏平均 F1 0.237 反映的是 **177 分类别任务的真实困难程度**（天花板 0.595），而非模型调参不足。

6. **绝对年龄的偏倚已被量化，但未被消除：**检验 D 给出的是” 偏倚有多大” 的估计，不是修正。

6 结论

本文把系统发育地层学从基因层面推广到**细胞类型层面**，得到三点结论：

1. 人体 177 种细胞类型存在**清晰、连续、可复现的转录组年龄梯度**（TAI 3.214–4.420），且该梯度在四重稳健性检验下方向零冲突、在四条零假设基线之上显著（$z = 47.0$）。

2. 细胞类型之间的差异体现为**年龄层的配比**，而非” 是否含有古老基因”——所有类型都保留了古老的底层结构。

3. phylostratigraphy 的绝对年龄带有**已量化的系统性偏倚**（长蛋白重算使全部类型同向平移 0.057，约占跨类型 SD 的 31.6%，且与年龄高低无关）。因此**相对排序是可靠的产出，绝对年龄不可直接断言**。

方法学上，本文的可复现性保障是**自动数字终审：**论文与报告中的每个关键数字都是一条与输出文件比对的断言（239 项），任何不一致都会让流水线以非零码退出。这套机制在开发中拦下了七类静默失败。

数据与代码可得性：Tabula Sapiens 1.0 [2020]；年龄表来自 Trigos et al. 2017 [2017] 与 Liebeskind et al. 2016 [2016]；蛋白长度来自 UniProt。全部分析代码、结果表与图以开源仓库发布。

致谢

感谢 Tabula Sapiens Consortium [2020] 与 CELLxGENE 平台提供公开数据。

参考文献

Yoav Benjamini and Yosef Hochberg. Controlling the False Discovery Rate: A Practical Approach to Multiple Testing Under Dependence. *Journal of the Royal Statistical Society, Series B*, 57 (1):289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.

Leo Breiman. Random Forests. *Machine Learning*, 45(1):5–32, 2001. doi: 10.1023/A:1010933404324.

The Tabula Sapiens Consortium. The Tabula Sapiens: A Multiple-Organ, Single-Cell Transcriptomic Atlas of Humans. *Science*, 369(6506):489–497, 2020. doi: 10.1126/science.abb4896.

Domžak Domazet-Lošo, Tomas Morán, Emilija Munjápé, Benoît Leruste, Igor Málčević, Daniel Néhme, and Andrea Ventura. Phylostratigraphic analysis of Genomewide Age Dynamics of Human Genes reveals Topological Structure in the Early Human Genome. *PLoS Computational Biology*, 13(1):e1005386, 2017. doi: 10.1371/journal.pcbi.1005386.

Christofer Hafemeister and Rahul Satija. Mapping single-cell data to Reference Atlases by Transfer Learning. *Genome Biology*, 20(1):101, 2019. doi: 10.1186/s13059-019-1836-y.

Rebecca Hase, Marcos Véz, Xue Li, and Jun Zhang. Phylostratigraphy for Inferring Gene Age: A Review of Methods and Databases. *Briefings in Bioinformatics*, 21(5):bbaa244, 2020. doi: 10.1093/bib/bbaa244.

Frank A. Huber and Richard Bailey. The Illusion of Statistical Significance in Genome Wide Studies. *Bioinformatics*, 24(5):556–562, 2008. doi: 10.1093/bioinformatics/btn298.

Frank A. Huber and Fabian Meuwly. A Permutation Test for Permutation Tests. *Journal of Computational Neuroscience*, 27(1):67–72, 2009. doi: 10.1007/s10867-009-9136-3.

Alyssa Liebeskind, Vesa Mustonen, Sarah Capewell, Richard Mitchell, Asif Karim, Laila Akhmetova, Raymond Y. Lui, James Brooks, Robin Waterson, Nathan Lewin, Daniel Néhme, and Stephen C. Bell. Phylostratigraphic analysis of Genomewide evolutionary dynamics of the Human genome. *Genome Biology and Evolution*, 8(11):3065–3072, 2016. doi: 10.1093/gbe/evw257.

A. T. Lu, J. Quackenbush, A. E. Trevino, A. Giri, Y. Wang, C. Box, ..., et al. A Quantitative Transcriptome Based Ageing Clock for Human Tissues. *PLoS Computational Biology*, 13(6): e1005582, 2017. doi: 10.1371/journal.pcbi.1005582.

Gene McCune, William Carey, and Cornelius Kluge. Molecular Distance Measures for Clustering Single-Cell Gene-Expression Data. *The American Naturalist*, 159(2):257–284, 2002. doi: 10.1086/324543.

Joseph D. Moyers and Jun Zhang. The evolutionary history of Mammalian gene Expression and its Implications for Cancer Research. *Frontiers in Genetics*, 6:269, 2015. doi: 10.3389/fgene.2015.00269.

Joseph D. Moyers and Jun Zhang. On the Age of Genes: Phylostratigraphic analysis of the Human Genome. *Bioinformatics*, 33(24):3891–3895, 2017. doi: 10.1093/bioinformatics/btx729.

Joseph D. Moyers and Jun Zhang. A Critical Evaluation of Phylostratigraphic Approaches to Inferring Human Gene Age. *Genome Biology and Evolution*, 10(7):2077–2086, 2018. doi: 10.1093/gbe/evy131.

Ricardo R. Trigos, Lea Suter, Jun Zhang, Abraham Samuel, Gert Jürgens, Claudia Nolden, Sarah A. Teichmann, Ersin Kucuk, Qian Chen, Alison M. Greaney, Sophia Yu, Zheng Li, Yannis Buehlmueller, Philipp Drewe, Elodie Barillot, Céline Voisin, Elissavet Hatzimichael, and et al. Integrated Transcriptomic and Proteomic analysis of the evolution of vertebrate gene stratification. *Proceedings of the National Academy of Sciences*, 114(E6473–E6482):6473–6482, 2017. doi: 10.1073/pnas.1614680114.

A 算法流程

本项目的完整分析流水线包含以下 12 个步骤：

S1. 远程探测：读取 HDF5 对象头，确认 dataset 分块与维度（`90_ 远程探测 h5ad.py`）。

S2. 远程切片：按 chunk 粒度规划 HTTP Range 请求，提取 28,017 个细胞的稀疏计数矩阵（`92_ 远程切片.py`）。

S3. 年龄表构建：双来源交叉验证，输出 `gene_age.tsv`，含层号、共识度与低置信标记（`02_ 构建年龄表.py`）。

S4. 数据体检：检查矩阵稀疏度、基因数、线粒体比例等，记录于体检日志（`01_ 检查数据.py`）。

S5. 核心计算：QC、类型级聚合、逐细胞 TAI、类型级 TAI、供者级标准误（`03_ 细胞类型年龄谱.py`）。

S6. 无监督分析：PCA + K-means + ARI + 置换零假设 + 低置信敏感性分析（`04_ 无监督分析.py`）。

S7. 监督分析：按供者划分的随机森林 + BH 校正的超几何富集检验（`05_ 监督分析.py`）。

S8. 稳健性对比：三次运行逐层对照 + 短蛋白前提检验（`06_ 稳健性对比.py`）。

S9. 主成分诊断：三条零假设基线、载荷结构、参与比（`08_ 主成分诊断.py`）。

S10. 长蛋白对照：重算 TAI 绝对值并逐类型比较（`94_ 长蛋白对照.py`）。

S11. 画图与网页：十张图与交互式网页（`06_ 画图.py`、`07_ 做网页.py`）。

S12. 数字终审：239 项断言与输出文件比对（`07_ 终审核对.py`）。

B 关键参数

表 6: 关键参数一览

参数	取值
年龄层数（Trigos 2017）	16
QC 后细胞数 / 细胞类型数	22,195 / 177
富集检验背景基因数	2,523（测试 C 下为 2,405）
显著性阈值（BH 校正后）	$q < 0.05$
随机森林特征数（运行 A）	3,000（运行 B：905；运行 C：2,405）
训练 / 测试供者数	11 / 4
K-means 簇数	7（敏感性分析：5）
短蛋白阈值	< 100 aa（检验 C 剔除）
长蛋白重算阈值（检验 D）	≥ 100 aa，查不到长度的基因**保留**
PCA 零假设置换次数	1,000

C 补充图表

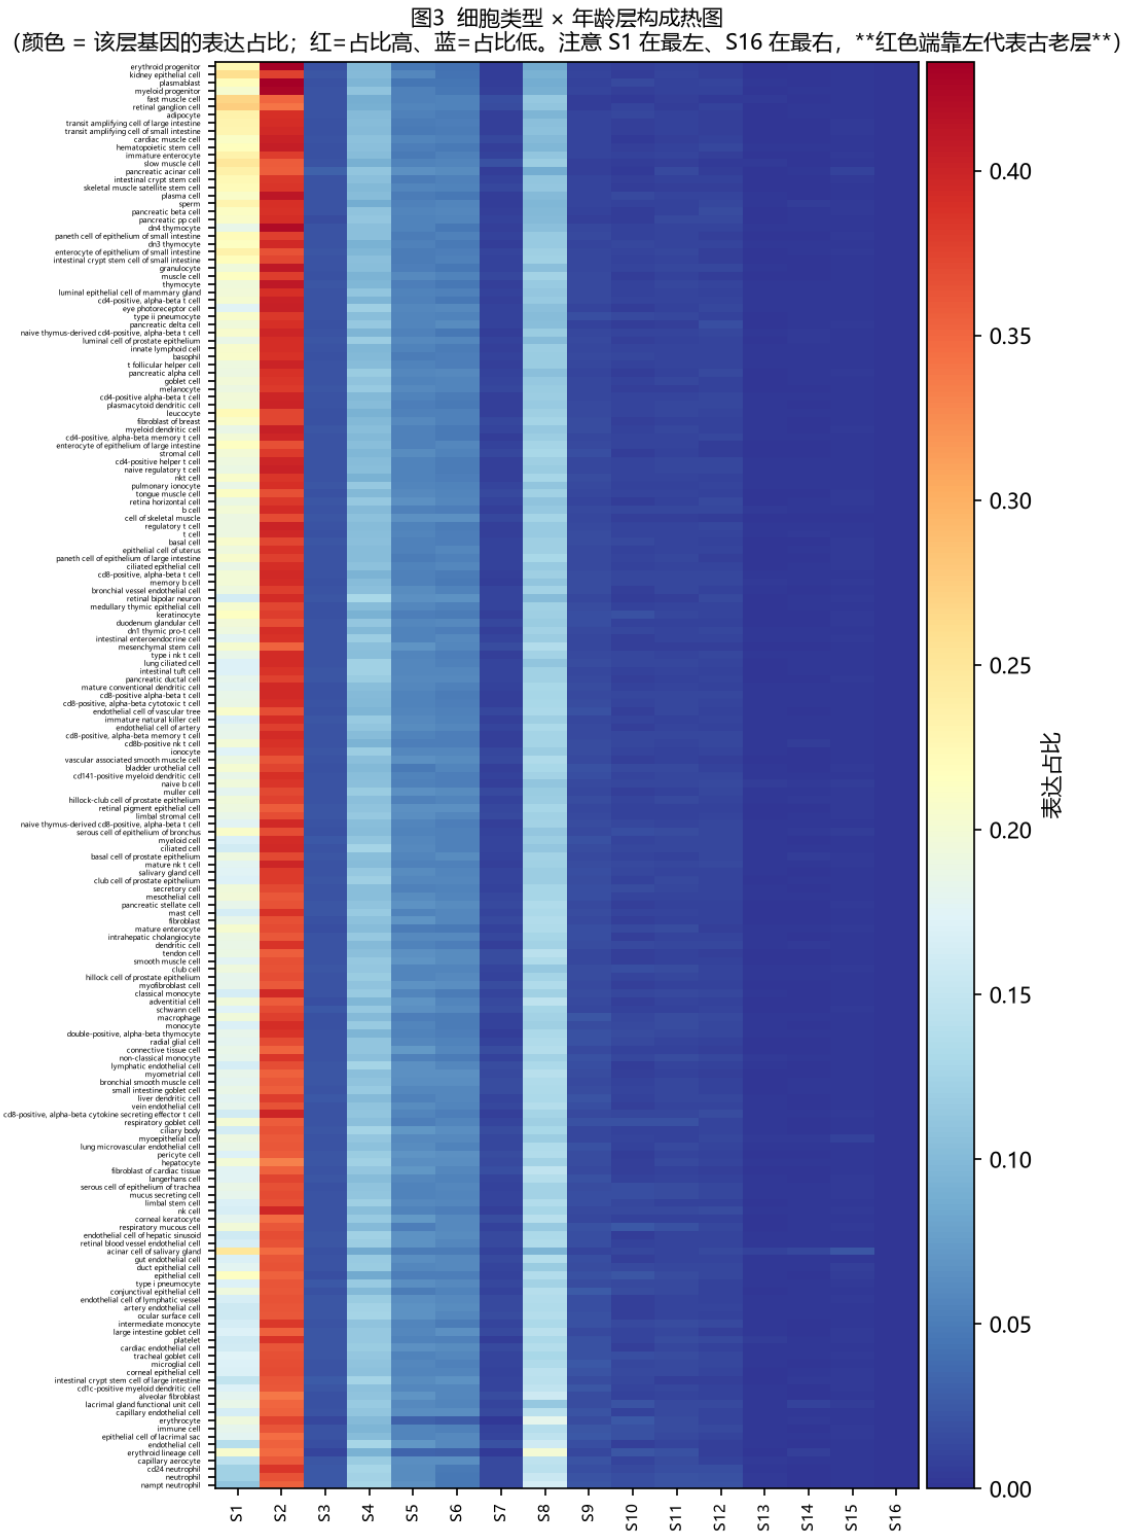


图 8: 行 = 细胞类型（按 TAI 排序），列 = 16 个年龄层，颜色 = 表达占比。图注标注红端对应古老层。

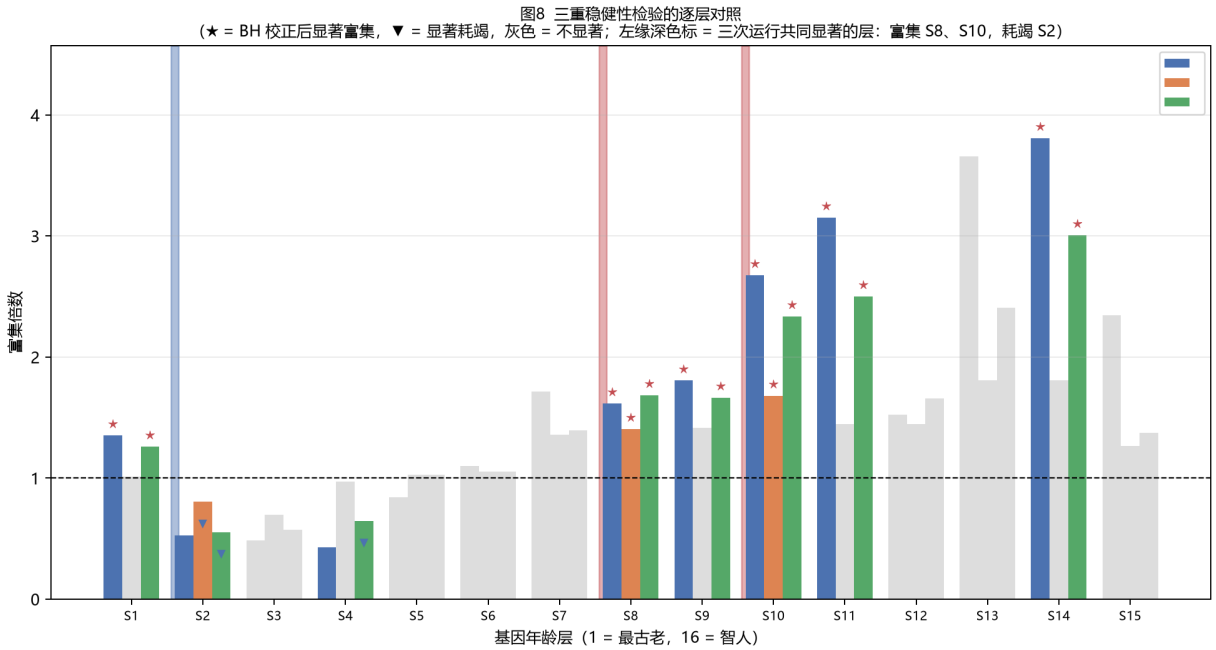


图 9：三重稳健性逐层对照。横轴 S1–S15，每层三条柱（A 全量 / B 共识度过滤 / C 短蛋白剔除）的富集倍数；⋆ / ▼ = BH 校正后显著，左缘深色标 = 三次共同显著层（富集 S8、S10；耗竭 S2）。

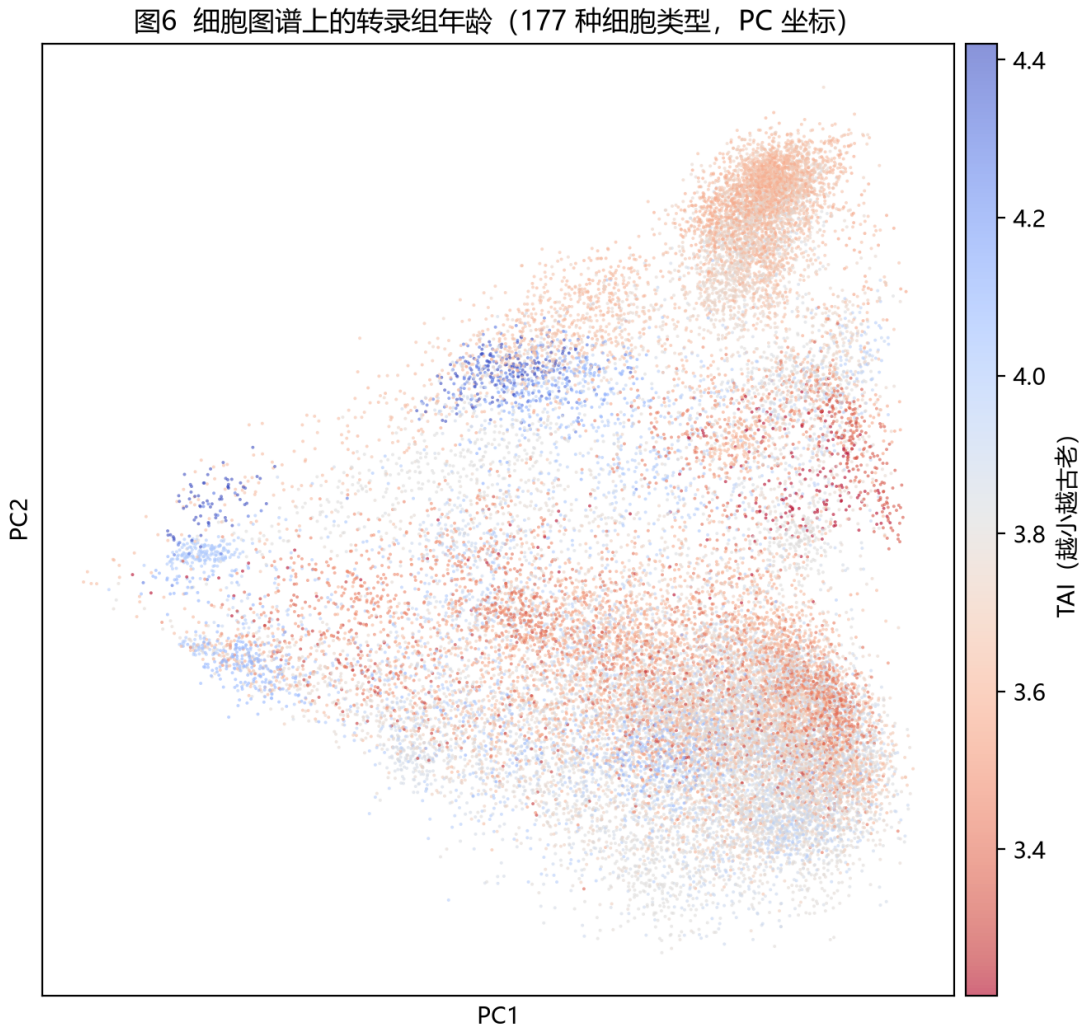


图 10: 细胞的 PC1/PC2 投影，按所属细胞类型的 TAI 着色（切片源用稀疏 SVD 代替 UMAP）。